# 南京大学

## 本 科 毕 业 论 文

院　　系　人工智能学院

专　　业　人工智能

题　　目　**带噪声的多目标演化算法**

**噪声下界理论分析**

年　　级　2020　学　　号　201300001

学生姓名　陈迪轩

指导教师　钱超　职　　称　副教授

提交日期　2024 年 5 月 20 日

# 南京大学本科生毕业论文（设计、作品）中文摘要

**题目**：带噪声的多目标演化算法噪声下界理论分析

**院系**：人工智能学院

**专业**：人工智能

**本科生姓名**：陈迪轩

**指导教师（姓名、职称）**：钱超副教授

**摘要**：

演化算法由于其诸多优良特点，在多目标优化问题上具有广泛的适用性。而现实情境中，不可避免地会遇到带噪的问题，因此带噪声的多目标演化算法的相关研究便应运而生。在多目标演化算法领域，目前已经有许多前沿的相关工作，侧重点不同，其中理论分析很大一部分着重研究算法在特定问题上的时间复杂度。演化算法种类繁杂，近年来关于 SEMO(Simple Evolutionary Multiobjective Optimizer) 这个较为简单、基本的算法的理论分析工作层出不穷，本篇论文也选取了 SEMO 算法，具体分析证明其在处理带噪声的 LOTZ(LeadingOnesTrailingZeroes) 问题上的时间复杂度上界，此处选用了一位噪声 (one-bit noise)。其中进一步重点讨论了再评估 (reevaluation) 这一步骤的存在与否对于 SEMO 算法处理特定带噪问题性能的影响，发现通过引入再评估步骤可以显著提高 SEMO 算法的效率和性能。在定量的理论分析方面，在组里学长的成果之上，先总结了利用 SEMO 算法求解 LOTZ 问题的噪声上界，其中不使用/使用重新评估策略的噪声上界分别为 $O(1/n)$、$O(1/n^4)$。而后利用漂移分析工具，证明了利用 SEMO 算法求解 LOTZ 问题的噪声下界，使用重新评估策略的噪声下界为 $log(n)/(n^3)$。本文为使用 SEMO 算法解决 LOTZ 问题提供了某个情形下的理论拼图，同时也展示了 SEMO 算法在优化问题中的潜力和应用前景。

**关键词：** 演化算法；多目标优化问题；SEMO 算法；重新评估策略；一位噪声；LOTZ 问题；理论分析；噪声上下界证明

# 南京大学本科生毕业论文（设计、作品）英文摘要

THESIS: Analysis of Noise Lower-bound for Multi-Objective Evolutionary Algorithms in Noisy Environments

DEPARTMENT: School of Artificial Intelligence

SPECIALIZATION: Artificial Intelligence

UNDERGRADUATE: Dixuan Chen

MENTOR: Chao Qian, Associate Professor

ABSTRACT:

Evolutionary algorithms(EAs), owing to their numerous advantages, have wide applicability in multi-objective optimization problems. However, in real-world scenarios, encountering noisy environments is inevitable, thus giving rise to the research on noisy multi-objective EAs. In the field of multi-objective EAs, there have been many cutting-edge studies with different focuses, with a significant portion emphasizing theoretical analyses of the algorithms' time complexity on specific problems. Among the diverse range of EAs, there has been a rise of theoretical analysis works on SEMO (Simple Evolutionary Multiobjective Optimizer), which is a relatively simple and fundamental algorithm. This paper also selects the SEMO algorithm, specifically analyzing and proving its upper bound on time complexity in handling the LeadingOnesTrailingZeroes (LOTZ) problem with noise, utilizing one-bit noise. Furthermore, the paper focuses on discussing the impact of the existence of the reevaluation step on the performance of the SEMO algorithm. It is found that introducing the reevaluation step can significantly improve the efficiency and performance of the SEMO algorithm. In terms of quantitative theoretical analysis, based upon the achievements of the senior members in the group, the upper bounds of noise tolerance for solving the LOTZ problem using the SEMO algorithm were initially summarized. Specifically, the upper bounds of noise were determined for scenarios with and without reevaluation strategies, resulting in $O(1/n)$ and $O(1/n^4)$, respectively. Subsequently, by applying drift analysis tools, the lower bound of noise tolerance for solving the LOTZ problem using the SEMO algorithm was established, and the noise lower bound of using the re-evaluation strategy is $log(n)/(n^3)$ in

particular. This paper provides a theoretical piece of the puzzle for using the SEMO algorithm to solve the LOTZ problem in a certain scenario, while also demonstrating the potential and application prospects of the SEMO algorithm in optimization problems.

KEYWORDS: Evolutionary Algorithms; Multi-Objective Optimization Problems; Simple Evolutionary Multiobjective Optimizer (SEMO); reevaluation strategy; one-bit noise; LeadingOnesTrailingZeroes (LOTZ); theoretical analysis; Proof of upper and lower bounds of noise tolerance

# 目　　录


中文摘要 . . . . . I

ABSTRACT . . . . . III

目　　录 . . . . . V

第一章 绪论 . . . . . 1

1.1 研究背景 . . . . . 1

1.1.1 演化算法 . . . . . 1

1.1.2 多目标演化算法 . . . . . 4

1.1.3 带噪声的多目标演化算法 . . . . . 5

1.2 相关工作 . . . . . 6

1.2.1 多目标演化算法理论分析 . . . . . 6

1.2.2 带噪声的多目标演化算法理论分析 . . . . . 7

1.3 论文主要工作 . . . . . 7

第二章 主论 . . . . . 9

2.1 待研究问题描述 . . . . . 9

2.1.1 LOTZ 问题 . . . . . 9

2.1.2 One-bit Noise . . . . . 10

2.1.3 改进前后 SEMO 算法对比 . . . . . 10

2.2 SEMO 求解 LOTZ 问题噪声上界证明 . . . . . 12

2.3 SEMO 求解 LOTZ 问题噪声下界证明 . . . . . 13

第三章 结论 . . . . . 15

3.1 总结 . . . . . 15

3.2 不足与展望 . . . . . 16

**参考文献** . . . . . 17

**致　　谢** . . . . . 19

**附录 A 补充上界证明过程** . . . . . 21

# 第一章　绪论

## 1.1　研究背景

### 1.1.1　演化算法

演化算法 (Evolutionary Algorithms，EAs) 是一类基于生物进化原理的优化算法，通过模拟进化过程中的选择、交叉和变异等操作，寻找问题的最优解或近似最优解。

演化算法在实际应用中被广泛使用。遗传算法 (GA)、演化策略 (ES)、演化规划 (EP)、遗传编程 (GP)、粒子群优化 (PSO)、蚁群优化 (ACO)、差分进化 (DE)、基于概率模型的进化算法 (EDA) 等都属于演化算法的范畴。这些算法都涉及到生成子代、父代选择、初始化评估等操作。

下面我们仔细剖析一下演化算法的基本框架，逐步发掘演化算法的魅力:

1. 个体表示 (Representation): 第一步，要定义问题解空间中所有候选解的表示方式，方便后续处理。EA 中通常使用染色体或向量来表示候选解，而个体的表示形式则取决于待优化问题的特性。

2. 初始化 (Initialization): 第二步，即随机生成一组初始个体作为种群的起始点，它们通常是在解空间中随机采样所得。

3. 适应度评估 (Fitness Evaluation): 第三步，要对种群中已初始化的每个个体根据问题的优化目标进行评估，计算其适应度或目标函数值。这一步用于衡量个体在解空间中的优劣。

4. 选择 (Selection): 第四步，通过某种特定策略从当前种群中选择优质个体，作为下一代的父代。选择策略通常基于第三步得到的适应度，优选适应度较高的个体。

5. 交叉 (Crossover): 第五步，要选取一对或多对父代个体，按照一定的交叉规则组合成新的个体。这一步旨在产生新的解，促进种群多样性。

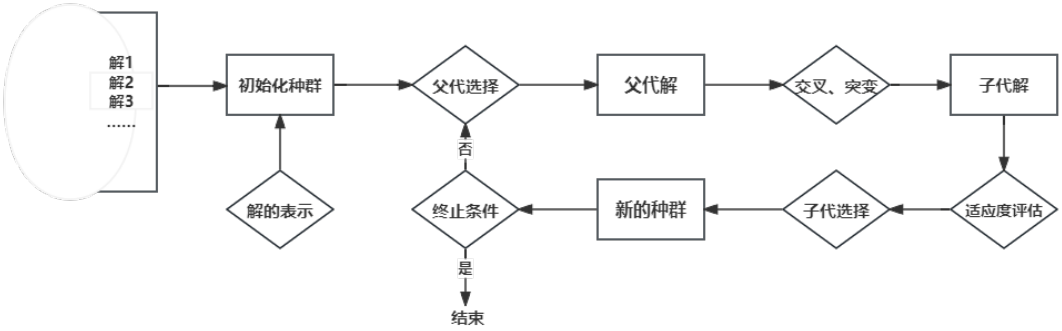


**图 1-1　演化算法流程图**

6. 突变 (Mutation): 第六步，针对上一步新生成的个体，按照一定的变异概率对其进行随机突变。这一步有助于目的是引入新的搜索空间，防止其陷入局部最优解。具体而言，当个体按二进制表示时，突变可分为两种主要且常见的类别。一是一位突变，即 one-bit mutation，随机选取一位改变其值；另一种则是按位突变，即 bit-wise mutation，对每一位独立地计算突变与否，每一位 mutate 之概率皆为 $1/n$。

7. 更新种群 (Population Update): 第七步，根据前三步生成的新个体以及当前种群，选择其中优质的个体，更新形成下一代种群。

8. 终止条件 (Termination Criteria): 第八步，设定终止算法运行的条件，例如达到最大迭代次数、满足特定收敛准则或是解的质量满足要求等等。达成终止条件后，停止搜索并输出最优解。

由以上八个基本步骤可见，演化算法的基本思想便是通过模拟自然界进化过程中的选择、交叉和变异等基本操作，通过循环第四步到第七步，不断优化种群中的个体，逐步寻找或接近解空间中的最优解。值得注意的是，只有突变 (mutation) 步骤会引入新的信息，也只有交叉 (crossover) 步骤能让两个父代信息相互结合。

下面举一个最简化版本的演化算法 (1+1)EA 作为例子，帮助总结出 EA 的基本要点，也为后续介绍 SEMO 算法做一个铺垫。由以下伪代码可见，(1+1)EA 与多数演化算法不同在于，它极端地简化掉了群体 P(population)，且略去了交叉步骤。但 (1+1)EA 也保留了演化算法的一些基本特征，比如在第 3 行，对 $s$ 进行了突变操作。而第 4 行算法伪代码中，为了最大化适应度函数的值 (fitness)，允许将 $s$ 替换为大于等于它的 $s'$；并且在遇到终止条件后，果断停止循环，输出最优

解。

**算法 1** (1+1)EA

```
从 𝒳 中随机均匀选取 s 作为初始个体
for t=1,2,... do
    s′ ← mutation(s)
    if f(s′) ⩾ f(s) then
        s ← s′
    end if
    达到终止条件即停止循环
end for
```

而下面登场的便是本文主要讨论的演化算法 SEMO(Simple Evolutionary Multiobjective Optimizer)，它是一种基于种群的演化算法，可用于解决多目标优化问题。由于演化算法在多目标优化领域逐渐复杂化，对理论分析基线算法 (baseline algorithm) 的简单算法有所忽视。[1][2] 而近年来有人[3]指出了基线算法的潜在需求，其更是间接地促成了 PAES(Pareto Archived Evolution Strategy) 的发明。但 PAES 基于复杂的存档和选择逻辑，因而在理论上很难分析。故有人[4]提出并分析了一种简单的基线算法 SEMO，其可以看作是 (1 + 1)-EA 的多目标泛化，相对易于理论分析。本篇论文也将从 SEMO 出发，分析噪声环境下的算法性能。SEMO 可说是多目标优化中最简单的一种基于群体的演化算法 (population-based EA)。它包含一个大小可变的种群，存贮有所有尚未被其他个体支配的个体。算法刚开始，群体随机利用决策空间中采样得到的单个个体进行初始化；随后每次迭代，从种群中随机均匀选取一个父代个体 (记为 x) 并进行变异操作；变异操作得到的子代 (记为 x’)，进行判定，若它未被其他个体支配并且其目标向量 (objective vector) 尚未为群体涵盖，那么 x’ 可加入种群，随即删除所有为 x’ 所支配的个体。之后通过随机选择位置 $j \in \{1, 2, ..., n\}$ 作为新的决策变量 (decision vector)，并将 $x_j$ 的值改为 1 - $x_j$，且其他决策变量保持不变。下为伪代码:

**算法 2** Simple Evolutionary Multi-objective Optimizer (SEMO)

```
从 𝒳 中随机均匀选取 x 作为初始个体
P ← {x}
while True do
    x ← selection(P)                          ▷ 从 P 中随机选择一个解
    x′ ← mutation(x)
    if ∄z ∈ P s.t. z ⪰ x′ then
        P ← (P \ {z ∈ P | x′ ≻ z}) ∪ {x′}
    end if
end while
```

### 1.1.2 多目标演化算法

现实中的很多工程、科研问题一般牵涉到诸多目标，属于多目标优化问题 (Multi-objective Optimization Problem, MOP)，比如火箭发射中的轨迹优化问题、水资源供应问题、生态系统规划问题，以及深度学习等等。

**定义 1.1.1** *(多目标优化问题)* 同时优化多个目标，且通常这些目标有所冲突。其可以形式化表示为: $\max_{x\in X}\left(f_1(x), f_2(x), \cdots, f_m(x)\right)$

但为什么选择使用演化算法来解决 MOP？随着计算机技术飞速发展，越来越多的研究指出了演化算法这一糅合了达尔文的进化思想的理论，其基于种群、随机化的实质与解决优化问题的许多思路不谋而合，相比传统算法有着鲜明的优势。比如演化算法中的适应度评估 (fitness evaluation) 这一步骤中的 fitness，恰好能与优化问题里的目标暗合；而后续的子代选择 (survivor selection) 则可以遵照适应度高低选择子代留在种群，保证了优化问题解的最优性。进一步看，多目标优化问题 (MOP) 需要同时维护多个优化目标，而 EA 中的种群恰好可以维护一组多样的解，支持在解空间中的搜索，最终达成优化多个目标，并且基本每一种演化算法都有其适用于多目标的拓展版本，适用范围极广。

多目标演化算法 (MOEA,Multi-objective Evolutionary Algorithms) 自上世纪 80 年代以来，得到了蓬勃的发展。MOEA 旨在寻找一个解集，该解集涵盖了问题的所有有效解，即帕累托前沿 (Pareto Front)，会在之后的主论中详细定义。MOEA 与单目标演化算法相比，更注重寻找解集的多样性和均衡性，使得算法更适用于多目标优化问题。故多目标演化算法的两大核心步骤，分别是解的生成 (solution generation)、种群的更新 (population update)，而在利用 MOEA 解决多目标优化问题时，我们通常关注后者，即种群更新多一些，因为直观而言，种群若

一直向“好”的、适应度高的趋势更新，那么优化目标迟早会达成。因而 MOEA 的种群更新具有这样的显著特征即贪心的 (greedy)、有确定性的 (deterministic)。

具体而言,本篇论文将着重讨论 SEMO 算法在 LOTZ(LeadingOnesTrailingZeroes) 这个二目标优化问题上的效用。LOTZ 是一个经典的优化问题，其中“LeadingOnes”表示开头的 1 的数量，“TrailingZeroes”表示结尾的 0 的数量，两个优化目标分别是最大化开头 1 的数量、最大化结尾 0 的数量。在 LOTZ 问题中，通常需要处理一个二进制向量，优化目标是找到一个向量，其中开头 1 的数量尽可能大，且尾部 0 的数量也尽可能大。LOTZ 由于其特性常被用来测试多目标优化算法的性能，特别是对于离散优化问题的处理，会在之后的主论里详细定义。

### 1.1.3 带噪声的多目标演化算法

带噪声的多目标演化算法是近年来的研究热点之一。在噪声环境中，传统的优化算法可能会产生误导性的结果或者陷入局部最优解。

带噪声的 MOEA 旨在提高算法对噪声的适应性和鲁棒性，其面对的主要挑战包括: 如何建模和识别不同类型的噪声、如何调整算法参数以提高鲁棒性、如何设计有效的进化策略以应对噪声干扰等等。噪声有很多种，可大体分为先验噪声和后验噪声，前者是在计算之前已经存在并且可以预见的噪声，而后者则是在计算、优化过程中产生的额外偏差。具体细分的噪声可以是先验一位 (Prior One-bit Noise)、先验逐位 (Prior Bit-wise Noise) 等等。本篇论文将针对于 one-bit noise 噪声环境进行展开讨论。

而在主论的理论分析部分，将要给出 SEMO 算法处理 LOTZ 问题时有关 one-bit 噪声的上、下界证明。在给定算法和问题环境下，噪声的上界意味着只要不超过这个上界，算法可以有效工作；而下界则意味着超过这个阈值范围，算法的运行时间复杂度会飙升至指数级别，能够直观地反映出一个算法在面对特定问题时的抗噪能力。

## 1.2 相关工作

### 1.2.1 多目标演化算法理论分析

多目标演化算法的理论分析有相当一部分集中在时间复杂度的分析[4][5]上，旨在直观地解决具体 EA 解决某个或某类多目标问题的大致能力。这不可避免要涉及三大部分，即用的什么演化算法 (EA)、解决的什么多目标问题 (MOP) 以及使用的什么数学分析工具。

而由于演化算法本身是复杂、随机化的，其各个组成部分，例如突变、重组、选择、种群操作等，都可能很复杂。而且即使是相同的输入条件下，独立运行得到的输出结果也可能不同。故演化算法的理论分析可以说较为复杂，而从头开始进行分析更是难上加难。因此，需要使用较为通用的运行时间分析工具。常用于分析演化算法时间复杂度的工具大致有以下三种。一为适应度水平 (fitness level) 分析，它能很直观地通过观察适应度变化趋势，评估 EA 的性能；二为漂移分析 (drift analysis)，关注特定算法在搜索空间中的漂移情况，即 fitness 随时间的变化是否向好的解“漂移”；最后是切换分析 (switch analysis)，注重分析算法在不同解之间的转换，有利于探索解空间。总的看来，进行演化算法相关理论工作牵涉到了概率论 (Probability Theory)、随机算法 (Randomized Algorithms)、随机过程 (Stochastic Process) 等数学知识的支撑。

具体而言，多目标演化算法的研究背景可以追溯到进化计算和优化领域的经典工作。Goldberg 等早在 1989 年便[6]在其著作中对演化算法及其在多目标优化中的应用进行了深入探讨，这为多目标演化算法的理论后续蓬勃发展奠定了基础。而后 Zitzler[7]等人在 2003 年的研究提出了 Pareto 优化的概念和 NSGA-II 算法，无疑是又一座多目标优化领域的重要里程碑。

带噪声的多目标演化算法理论研究需要考虑到不同噪声模型和优化策略的影响。Deb[8]等人于 2002 年提出了处理约束和噪声的演化算法方法，为带噪声环境下的优化问题提供了颇为实用的解决方案。而后根据 Dang 等人 Laumanns 等人在 2004 年[4]对多目标演化算法在伪布尔函数上的运行时进行了严格的分析。其指出，在 LOTZ、COCZ 以及其 m 个目标的延伸问题 (mLOTZ、mCOCZ) 上，演化算法诸如 SEMO 和它的两种改进版本 (FEMO 以及 GEMO) 同基于 -constraint 方法的 (1+1)-EA 对照的表现。他们使用了两种数学工具，分别为基于

决策空间划分的上界策略、随机图搜索算法，一针见血地得到了结论，即 SEMO 和对照算法效率相当，而其改进版本 FEMO、GEMO 犹有过之。这也为本篇论文进一步理解 SEMO 在应对 LeadingOnesTrailingZeroes 问题时的时间复杂度提供了颇有见地的参考思路。

### 1.2.2 带噪声的多目标演化算法理论分析

如前所言，带噪声的多目标演化算法研究反映了对解决复杂实际问题的需求，理所当然地在近年来获得了更多的关注。早在 1996 年，Bäck[9]便提出了演化策略的概念，并首次探讨了噪声对优化算法的影响，为带噪声环境下的优化算法研究提供了珍贵的启示。之后我校敬爱的 Qian 等老师于 2018 年[10]对在噪声环境中进行优化的采样方法另辟蹊径地进行了研究。这项工作明确了之前始终晦暗的一个问题，即在噪声存在时，算法采样的有效性具体有多强。他们指出，采样 (sampling) 的作用可以指数级别地加快噪声环境下的优化效率，另外采样操作中 k 值的选择亦至关重要。这对于本篇论文后续提高 SEMO 在解决 LOTZ 问题时的稳定性具有深刻意义，拓宽了眼界。

近几年，Dinot 等人 (2023)[11]在其论文中对多目标演化算法在噪声环境中的运行时进行了深度分析。他们的研究显示，当存在后验噪声时，SEMO 在 LOTZ 问题上的性能良好，能够有效地保留有用的搜索点，相比于其他算法，例如 GSEMO 表现更加出色。其中与本篇论文高度相关地揭示了对 SEMO 的改进步骤再评估 (reevaluation) 的作用，这一步通过引入 elim 函数生成了最小帕累托子集 G。

同年，Dang[12]等人的研究则着眼于风头正盛的 NSGA-II 算法在噪声环境多目标优化中的鲁棒性分析，其中对比了 SEMO 与其他算法在应对 LOTZ 问题时的不同表现。他们的研究结果显示，在一定程度的噪声下，SEMO 能够有效地保留 Pareto 前沿的有效搜索点，从而在实际问题中取得更好的性能。

## 1.3 论文主要工作

目前已经有一些国内外文献，分别证明了某个多目标演化算法在某个特定噪声环境下的情形。而本篇论文将选取 SEMO 算法应用在解决 LOTZ(LeadingOnesTrailingZeroes) 问题，其中噪声环境为 one-bit noise，旨在用数学工具理论证明推导出在引入再

评估 (reevaluation) 这一关键步骤的前后，时间复杂度上界的相关具体结论。在这样的过程中，能够直观地体现 reevaluation 步骤对算法性能的影响。

下面的表列出了一些已经被证明的多目标演化算法在噪声环境下的表现，其中噪声强度一列列出了对应算法在应对特定问题时的多项式上界 (polynomial upper bound) 以及超多项式下界 (super-polynomial lower bound) 所对应的某种噪声强度。

| 算法 | 作者及年份 | 应用的问题 | 噪声强度 |
|---|---|---|---|
| (1+1)-EA | Droste (2004)[13] | OneMax | one-bit noise, 多项式时间当 p = $O(\log(n)/n)$ |
| (1+1)-EA | Gießen (2016)[14] | LeadingOnes | one-bit noise, 多项式时间当 p = $O(\log(n)/n^2)$,<br>超多项式时间当 p = $w(log(n)/n)$ |
| $(\mu+1)$-EA | Dang (2015a)[15] | OneMax | bit-wise noise$(1, q)$ , 多项式时间当 p = $O(\log(n)/n^2)$,<br>超多项式时间当 p = $w(\log(n)/n^2)$ |
| (1+1)-EA | Qian(2015a)[16] | OneMax | one-bit noise , 多项式时间当 p = $O(\log(n)/n)$,<br>超多项式时间当 p = $w(\log(n)/n)$ |
| (1+1)-EA | Qian(2015a) | OneMax | bit-wise noise$(p, 1/n)$, 多项式时间当 p = $O(\log(n)/n)$,<br>超多项式时间当 p = $w(\log(n)/n)$ |

**表 1-1**

# 第二章　主论

## 2.1　待研究问题描述

### 2.1.1　LOTZ 问题

LOTZ 问题的全称是“leading ones, trailing zeroes”，字面意思即希望同时最大化位串开头的连续“1”的数量 (LO) 以及最大化结尾的连续“0”的数量 (TZ)。LOTZ 问题可被形式化定义为如下的伪布尔函数:

**定义 2.1.1** *(LOTZ 问题)* $\max_{x\in\{0,1\}^n}\left(\sum_{i=1}^{n}\prod_{j=1}^{i}x_j,\sum_{i=1}^{n}\prod_{j=i}^{n}\left(1-x_j\right)\right)$

为了更好地理解 LOTZ 问题的全貌，在此引入 Pareto 前沿的大致定义。由于本篇论文研究的优化问题是具有多个变量和多个目标函数的二进制决策问题，所有的目标函数都需要最大化。Pareto 最优解的定义如下:

**定义 2.1.2** *(决策空间和目标空间)* 记 $X$ 为决策空间，$F$ 为目标空间。决策空间中的元素称为决策向量 *(decision vectors)*，目标空间中的元素称为目标向量 *(objective vectors)*。

**定义 2.1.3** *(弱支配与支配)* 若有 $\forall i\in\{1,2,\cdots,m\}:f_i(x)\geqslant f_i(y)$，则称 $x$ 弱支配 $y$，记为 $x\succeq y$；若有 $\forall i\in\{1,2,\cdots,m\}:f_i(x)\geqslant f_i(y)$ 且 $\exists i\in\{1,2,\cdots,m\}:f_i(x)>f_i(y)$，则称 $x$ 支配 *(dominate)*$y$，记为 $x\succ y$.

**定义 2.1.4** *(Pareto 最优性)* 如果不存在其他决策向量能在所有目标函数上同时优于它，即它不被任何其他决策向量所支配 *(dominated)*，那么这个决策向量被称为 *Pareto* 最优的 *(Pareto optimal)*。

**定义 2.1.5** *(Pareto 集合和 Pareto 前沿)* 所有 *Pareto* 最优解的决策向量集合称为 *Pareto* 集合 *(Pareto set)*，包含了所有 *Pareto* 最优解对应的目标向量的集合称为 *Pareto* 前沿 *(Pareto front)*。

引入这些概念定义后，我们可以利用 LOTZ 问题的具体示例稍加理解，列出了对应的帕累托集合、帕累托前沿: Pareto 集合:$00\cdots00, 10\cdots00, \cdots, 11\cdots10, 11\cdots11$ Pareto 前沿:$(0,n),(1,n-1),\cdots,(n-1,1),(n,0)$.

### 2.1.2 One-bit Noise

在优化问题中，通常引入噪声来模拟现实中的不确定性、随机性，使得算法能够更好地应对复杂环境中的现实挑战。One-bit noise 是一种简单、常见的噪声模型之一，在理论分析和算法设计中经常用于研究算法对噪声的鲁棒性和稳定性。故在此选择作为噪声环境之背景。具体形式化而言，One-bit Noise 定义如下:

**定义 2.1.6** (*One−bit Noise*) 给定$p \in [0,1]$，在二元解集$x \in \{0,1\}^n$中，不妨令$\tilde{f}(x)$表示噪声条件下的适应度，*f(x)*表示真正的适应度。

$$\tilde{f}(x) = \begin{cases} f(x), & \text{以} 1-p \text{ 的概率}, \\ f\left(x'\right), & \text{以} p \text{ 的概率}, \end{cases}$$

其中 $x'$ 是通过随机均匀翻转 $x$ 的某一位生成的。

### 2.1.3 改进前后 SEMO 算法对比

首先让我们看一下不使用 reevaluation 步骤的 SEMO 算法流程: 在这个版本的 SEMO 中，当一个元素首次进入种群时，会计算其噪声评估值，并将其保存在一个映射函数 $W_t$中，这个函数关联了种群$P_t$中的每个元素与其在加入时计算的噪声值。

值得注意的是，在 SEMO without reevaluation 中，一旦元素被添加到种群中并计算了其噪声值，就不会再重新评估该元素的值。这意味着算法保存了每个元素在加入种群时的噪声评估值，而不会在后续迭代中重新计算。这体现在算法的细节之中。算法中的 Wt 函数用于存储种群 Pt 中元素的噪声评估值，这样每个元素都有一个关联的噪声值，用于判断其在种群中的位置和优劣关系。

算法 3、4 呈现了 SEMO with reevaluation 算法。与算法 2 相比，最明显的自然是重新评估这一引入的操作。SEMO with reevaluation 算法在每次迭代中都会重新评估解决方案。在噪声环境中，reevaluation 可以用来避免长时间使用相同

**算法 3** SEMO without reevaluation

```
从 {0,1}^n 中随机均匀选取 x_init 作为初始化个体
P ← {x_init}
W_0(x_init) ← g̃(x_init)                    ▷ 记录初始的噪声评估值
for t = 0 to ∞ do
    x_t ← selection(P)
    x'_t ← mutation(x_t)
    w ← g̃(x'_t)
    if ∄x ∈ P_t 使得 w ≺ W_t(x) then
        𝒫_{t+1} ← {x'_t}
        𝒲_{t+1}(x'_t) ← w
        for x ∈ P_t do
            if 𝒲_t(x) ⊀ w then
                𝒫_{t+1} ← 𝒫_{t+1} ∪ {x}
                𝒲_{t+1}(x) ← 𝒲_t(x)
            end if
        end for
    else
        𝒫_{t+1} ← 𝒫_t
        𝒲_{t+1} ← 𝒲_t
    end if
end for
```

**算法 4** SEMO with reevaluation

```
从 {0,1}^n 中随机均匀选取 x_init 作为初始化个体
while True do
    x_t ← selection(P)
    x'_t ← mutation(x_t)
    P'_t ← P_t ∪ {x'_t}
    P_{t+1} ← elim(P'_t, g̃)
end while
```

**算法 5** 消除函数 elim，其输入为初始决策向量集合 E 和评估函数 h，输出为最小 Pareto 支配子多重集 G

```
G ← ∅
Temp ← ∅                                   ▷ 初始化临时集合 Temp
while x ∈ E do
    v_x ← h(x)
    if 没有 v ∈ Temp 使得 v_x ≺ v then
        for y ∈ G, v_y ⪯ v_x do
            G ← G\{y}
        end for
        G ← G ∪ {x}
        Temp ← Temp ∪ {v_x}
    end if
end while
return G
```

的适应度 (fitness)。

而由于个体的适应度可能发生变化，我们不仅需要将新的后代整合到现有种群中，还需要适时地主动移除旧的解决方案。因而引出算法 4 中描述的消除函数 (elim function)。该算法使用了名为 elim 的消除函数。给定一个多重集合 E 和一个随机评估函数 h，消除函数 elim(E, h) 将得到 E 的一个最小 Pareto 支配子多重集合 G。这意味着 G 中的每个元素都支配 E 中的至少一个元素，并且 G 是最小的，因为其中任何两个元素的评估值皆不可比较。

一言以蔽之，SEMO with reevaluation 算法的高明之处在于，其可以通过在每次迭代中重新评估解决方案来应对特定噪声环境，并使用消除函数来灵活管理种群中的解决方案，确保种群中保留的解决方案能够更加有效地支配原始集合中的解决方案，从而维持最优性。

## 2.2 SEMO 求解 LOTZ 问题噪声上界证明

根据近期的工作，有对 SEMO 求解 LOTZ 问题在重新评估与不重新评估两个情形下的噪声容忍能力进行分析，有下面两个定理。

**定理 2.2.1** *存在一个常数 $\alpha > 0$ 有如下结论成立。对所有噪声强度 $p \leqslant \frac{\alpha}{n}$, 不使用重新评估策略的 SEMO 算法找到 LOTZ 问题的整个 Pareto 前沿需要使用的期望时间*

$$\mathbb{E}[T_{total}] = O(n^3).$$

**定理 2.2.2** *存在一个常数 $\beta > 0$ 有如下结论成立。对所有噪声强度 $p \leqslant \frac{\beta}{n^4}$, 使用重新评估策略的 SEMO 算法找到 LOTZ 问题的整个 Pareto 前沿需要使用的期望时间*

$$\mathbb{E}[T_{total}] = O(n^3).$$

由这两个定理，我们可以得到利用 SEMO 算法求解 LOTZ 问题噪声上界。

**定理 2.2.3** *不使用重新评估策略的 SEMO 算法求解 LOTZ 问题的噪声上界为 $O(\frac{1}{n})$。*

**定理 2.2.4** *使用重新评估策略的 SEMO 算法求解 LOTZ 问题的噪声上界为 $O(\frac{1}{n^4})$。*

## 2.3 SEMO 求解 LOTZ 问题噪声下界证明

首先引入一个可用来简化下界证明的定理，其由 Oliveto 等人于 2011 年提出[17]。

**定理 2.3.1** *(简化漂移定理)* 令 $X_t, t \geqslant 0$ 为一个实值随机变量，用来描述一个状态空间中的随机过程。假设存在一个区间 $[a,b] \subseteq \mathbb{R}$，有两个常数 $\delta, \varepsilon > 0$，且可能取决于 $\ell := b - a$，一个满足 $1 \leqslant r(\ell) = o(\ell/\log(\ell))$ 的函数 $r(\ell)$ 使得对于所有的 $t \geqslant 0$ 有如下两个条件成立:

*1.* $E\left(X_{t+1} - X_t \mid \mathcal{F}_t \wedge a < X_t < b\right) \geqslant \varepsilon$,

*2.* 对于 $j \in \mathbf{N}_0$ 有 $\text{Prob}\left(\left|X_{t+1} - X_t\right| \geqslant j \mid \mathcal{F}_t \wedge a < X_t\right) \leqslant \frac{r(\ell)}{(1+\delta)^j}$

则有一个常数 $c^* > 0$ 使得对于 $T^* := \min\left\{t \geqslant 0 : X_t \leqslant a \mid \mathcal{F}_t \wedge X_0 \geqslant b\right\}$，有 $\text{Prob}\left(T^* \leqslant 2^{c^*\ell/r(\ell)}\right) = 2^{-\Omega(\ell/r(\ell))}$ 成立。

这个定理又名简化负漂移定理 (Simplified negative drift theorem)，是证明对应指数级别算法运行时间复杂度的噪声下界的有力工具。其中第一个条件指明了当预期漂移为负，即远离预期目标的趋势；而第二个条件则说明了此时有朝目标漂移的概率呈指数级下降的趋势。由此两个条件，定理得出结论，此时的算法运行的时间复杂度为指数级 (超多项式级别)。

**定理 2.3.2** 使用重新评估策略的 *SEMO* 算法求解 *LOTZ* 问题的噪声下界为 $log(n)/(n^3)$ 或 $1/(n^2\sqrt{n})$。

**证明** 下面将利用与上述证明不使用重新评估策略相类似的推导方法，来证明使用重新评估策略的 *SEMO* 算法求解 *LOTZ* 问题的噪声下界。

不妨定义 $L'_t$ 为第 $t$ 轮中带噪种群 $\mathcal{P}_t \cup \left\{x'\right\}$ 中 *Pareto* 解的数量。

接下来，我们先分析当噪声 $p > log(n)/n^3$ 的情况，来逐一验证两个条件。类似于之前的情况:

验证 $L'_t$ 减小的幅度，即 $L'_t - L'_{t+1}$ 大于的数。验证 $|L'_t - L'_{t+1}| \geqslant j$ 的概率。我们可以使用类似的思路来推导这两个条件。在这里利用具体的数学推导给出详细的解释。

首先，我们需要分析第一个条件中 $L'_t$ 减小的幅度。与前面类似地，我们可以通过考虑每一步中选择 *Pareto* 解的概率以及变异操作的影响来推导出这一点。

然后，我们可以根据噪声 $p > \frac{\log(n)}{n^3}$ 的条件，证明 $L'_t$ 减小的幅度满足相应的条件。在每一轮迭代中，使用重新评估策略的 *SEMO* 算法会选择一组个体进行交叉和变异操作，然后通过噪声环境对其进行重新评估。这些操作都会导致 *Pareto* 解的数量发生变化。假设在第 $t$ 轮中，种群 $\mathcal{P}t$ 中有 $L'_t$ 个 *Pareto* 解，经过一轮迭代后，在种群 $\mathcal{P}t+1$ 中有 $L'_{t+1}$ 个 *Pareto* 解。

考虑使用重新评估的情况，此时每个个体的重新评估概率为 $(1-p)$。因此，在进行交叉和变异操作后，每个 *Pareto* 解被错误地评估为非 *Pareto* 解的概率为 $p$。我们可以使用其期望值来估计平均减少的 *Pareto* 解数量，假设种群大小为 $n$，则每个 *Pareto* 解被错误评估为非 *Pareto* 解的期望数量为 $p \cdot L'_t$。

从而可以得出 $L'_t - L'_{t+1} \geqslant p \cdot L'_t$。当噪声 $p$ 大于 $\frac{\log(n)}{n^3}$ 时，$p \cdot L'_t$ 将是一个相对较大的数，因此 $L'_t - L'_{t+1}$ 将大于某个常数 $\epsilon$。第一个条件得证。

下面需要分析第二个条件中 $|L'_t - L'_{t+1}| \geqslant j$ 的概率。我们可以通过分析在给定条件下，重新评估策略对种群数量的影响，以及在变异操作中引入的噪声对 *Pareto* 解数量的影响来进行推导。在每一轮迭代中，考虑每个 *Pareto* 解的重新评估概率以及变异操作的影响。假设在第 $t$ 轮中，我们有 $L'_t$ 个 *Pareto* 解。在进行交叉和变异操作后，可能会有一些 *Pareto* 解被错误评估为非 *Pareto* 解，或者一些非 *Pareto* 解被错误地评估为 *Pareto* 解。通过分析在给定条件下这些操作的影响，我们可以推导出 $|L'_t - L'_{t+1}| \geqslant j$ 的概率。故有对于 $j \in \mathbf{N}_0$ 有 $\mathrm{Prob}\left(\left|L'_{t+1} - L'_t\right| \geqslant j \mid \mathcal{F}_t \wedge a < L'_t\right) \leqslant \frac{r(\ell)}{(1+\delta)^j} = \frac{o(\ell/\log(\ell))}{(1+\delta)^j}$，令 $\lambda = 1+\delta$，则有 $\Pr\left[\left|L'_t - L'_{t+1}\right| \geqslant j \mid L'_t\right] = O_{j\to+\infty}\left(\lambda^j\right)$，第二个条件得证。

故由定理 *2.3.1* 以及上述两个条件，得证使用重新评估策略的 *SEMO* 算法求解 *LOTZ* 问题的噪声下界为 $log(n)/(n^3)$。

# 第三章　结论

## 3.1　总结

在本篇论文中，主要关注了 SEMO 等演化算法在多目标问题 (MOP) 问题上的理论性能与应用。

在绪论中，首先探讨了研究背景，小结了一下多目标演化算法当前领域的相关工作成果，给出了大致的文献综述，为后续论文的理论推导奠定了基础，并探讨了本篇论文将呈现的主要工作。

在主论中，研究了使用 Simple Evolutionary Multiobjective Optimizer (SEMO) 算法解决 LeadingOnesTrailingZeroes (LOTZ) 问题的方法。在此首先介绍了 LOTZ 问题的定义和特点，然后详细描述了 SEMO 算法的基本原理和流程。接着，我们讨论了 SEMO 算法中的 reevaluation 步骤存在与否的影响，以及其在解决特定问题 (尤其是 LOTZ 问题) 中的作用。通过分析有无 reevaluation 步骤的 SEMO 算法在解决 LOTZ 问题时的性能差异，我们初步得出定性的结论:reevaluation 步骤的引入，可以显著提高 SEMO 算法在特定噪声环境中解决 LOTZ 问题的效率和性能。

最后的定量分析部分，首先基于组里学长的成果、结论之上，先利用两个已经证明的定理总结出了利用 SEMO 算法求解 LOTZ 问题的噪声上界，其中不使用/使用重新评估策略的噪声上界分别为 $O(\frac{1}{n})$、$O(\frac{1}{n^4})$。而后，在更为重要的噪声下界方面，利用简化漂移定理这一有力工具，证明了利用 SEMO 算法求解 LOTZ 问题的噪声下界，证明了使用重新评估策略的噪声下界分别为 $log(n)/(n^3)$。

总的来说，本篇论文给出了用 SEMO 算法解决带一位噪声 LOTZ 问题的一小块理论拼图，即证明了噪声的上下界。尤其是下界的证明，较清晰直观地凸显了重新评估 (reevaluation) 步骤之高效。

## 3.2 不足与展望

尽管本文在有关 SEMO 算法解决带噪的 LOTZ 问题上的理论细节上取得了一定的进展，但仍存在许多可以进一步探索和改进的方向。

一是仍存在对算法本身的设计、改进空间，可以通过改进 SEMO 算法的选择、交叉和替换等策略来进一步提高算法的性能，使其更适用于解决其他类型的优化问题。值得注意的是，此前 EMO 问题的相关研究基本关注点在于选择这一步，用前文中提及的贪婪、确定性的思路产生子代，但这种缺乏随机性的方法并不通用，可能会在特定情况下表现不好，因而后续我们需要对交叉、突变这两步给予更多的关注，保有一定的种群多样性。

二是理论分析上的广阔空间。或许我们可以进一步探索 SEMO 算法的理论性质，例如在不同噪声环境下的收敛性和收敛速度，以及在更复杂问题上的时间复杂度分析，未来仍可能探索出更紧致的上、下界等诸多待完善的工作。而这些理论工作反过来又能帮助我们更好地理解演化算法本身、甚至进一步为设计有更好理论保证的 EAs 提供宝贵灵感。

另外，本文单纯涉及到演化算法的理论分析，未能结合实验佐证。理论分析中具体的系数仍需在具体实验中获取、完善，毕竟理论和实验是互补的，适当地结合实验数据，能推导出许多纯理论分析难以抵达的结果。

一言以蔽之，本次毕业论文仅仅触及了 SEMO 算法在解决带有 one-bit noise 的 LOTZ 问题中的一个情形，证明了上下界。但本篇毕业设计缺少实验数据来佐证理论分析，并且多目标演化算法领域仍然存在诸多拼图缺口，静待研究与解决。正如前文所言，演化算法博大精深，噪声环境千变万化，在某个特定条件下，SEMO 算法相关理论分析可以展现某个策略方法（如重新评估策略）潜在的优势，为演化算法研究思路提供新的灵感。我们仍需要进一步的研究和改进，才能使 EAs 更好地满足实际问题的需求。

# 参考文献


[1] COELLO C A C. Evolutionary algorithms for solving multi-objective problems[M]. Springer, 2007.

[2] DEB K. Multi-objective optimization using evolutionary algorithms[M]. John Wiley & Sons, 2001.

[3] KNOWLES J D, CORNE D W. Approximating the nondominated front using the Pareto archived evolution strategy[J]. Evolutionary computation, 2000, 8(2): 149-172.

[4] LAUMANNS M, THIELE L, ZITZLER E. Running time analysis of multiobjective evolutionary algorithms on pseudo-Boolean functions[J]. IEEE Transactions on Evolutionary Computation, 2004, 8(2): 170-182. DOI: 10.1109/TEVC.2004.823470.

[5] BEYER H G, SCHWEFEL H P, WEGENER I. How to analyse evolutionary algorithms[J]. Theoretical Computer Science, 2002, 287(1): 101-130.

[6] GOLDBERG D E, KORB B, DEB K. Messy genetic algorithms: Motivation, analysis, and first results[J]. Complex systems, 1989, 3(5): 493-530.

[7] ZITZLER E, THIELE L, LAUMANNS M, et al. Performance assessment of multiobjective optimizers: An analysis and review[J]. IEEE Transactions on evolutionary computation, 2003, 7(2): 117-132.

[8] DEB K, PRATAP A, AGARWAL S, et al. A fast and elitist multiobjective genetic algorithm: NSGA-II[J]. IEEE transactions on evolutionary computation, 2002, 6(2): 182-197.

[9] BACK T. Evolutionary algorithms in theory and practice: evolution strategies, evolutionary programming, genetic algorithms[M]. Oxford university press, 1996.

[10] QIAN C, YU Y, TANG K, et al. On the Effectiveness of Sampling for Evolutionary Optimization in Noisy Environments[J]. Evolutionary Computation, 2018, 26(2): 237-267. DOI: 10.1162/evco_a_00201.

[11] DINOT M, DOERR B, HENNEBELLE U, et al. Runtime analyses of multi-objective evolutionary algorithms in the presence of noise[J]. ArXiv preprint arXiv:2305.10259, 2023.

[12] DANG D C, OPRIS A, SALEHI B, et al. Analysing the robustness of NSGA-II under noise[C]//Proceedings of the Genetic and Evolutionary Computation Conference. 2023: 642-651.

[13] DROSTE S. Analysis of the (1+ 1) EA for a noisy OneMax[C]//Genetic and Evolutionary Computation Conference. 2004: 1088-1099.

[14] GIEßEN C, KÖTZING T. Robustness of populations in stochastic environments[C]//Proceedings of the 2014 Annual Conference on Genetic and Evolutionary Computation. 2014: 1383-1390.

[15] DANG D C, LEHRE P K. Efficient optimisation of noisy fitness functions with population-based evolutionary algorithms[C]//Proceedings of the 2015 ACM Conference on Foundations of Genetic Algorithms XIII. 2015: 62-68.

[16] QIAN C, YU Y, ZHOU Z H. Subset selection by Pareto optimization[J]. Advances in neural information processing systems, 2015, 28.

[17] OLIVETO P S, WITT C. Simplified drift analysis for proving lower bounds in evolutionary computation[J]. Algorithmica, 2011, 59: 369-386.

# 致　　谢

能够较为顺利地完成本次毕业论文，首先必须感谢我的毕业设计导师钱超老师的无私帮助。钱老师从最初的开题选择就热情地帮助我选择较贴合自己能力的方向，到中期的细致规划，直至最后完成全篇论文，让我如沐春风，受益匪浅。其次十分感谢仇志佳学长的指导、帮助。仇师兄在我的整个毕业论文的撰写过程中，知无不言，言无不尽，对我遇到的一些疑难问题给予了细致的解答。

同时需要感谢大学四年里遇到的每一位良师益友。南京大学的老师们教学认真细致，不仅给予了我知识的养分，更教会了我许多人生至理、丰富了我的阅历。在南大因缘际会，亦是有幸结识了许多优秀的同学，他们不仅学业优异，而且兴趣广泛，在学习、生活中给予了我数不清的帮助、慰藉，在此次本科毕业设计期间，也通过和这些良师益友的交流，明晰了思路，更好地推进了论文进度。

最后更要感谢我的家人，尤其是我的父母。他们如同最温暖的港湾，无时无刻关心、呵护着我。大学四年里，他们细心支持着我的学业，关注着我的每一点成长。

# 附录 A　补充上界证明过程

在附录中，将补充一些上界证明部分未给出的，基于组内学长已有成果的证明过程。此处以不使用重新评估策略的部分证明思路为例录入附录部分，可以辅助对噪声上界证明的理解:

第一步，首先给出 LOTZ 问题描述、问题形式化定义。首先形式化定义 $f(x) = (LO(x), TZ(x))$，令 $V(x) = \tilde{LO}(x)$。将第 t 次迭代中 $V(x)$ 的最大值定义为 $V(x) =: j_t, l_t := j_t + 1 - 1_{A_t}$，其中 $A_t$ 表示事件 $\left(\exists x \in P_t; LO(x) = \tilde{LO}(x) = j_t\right)$。

定义 $S_k = \left(t < T_{\text{low}} \wedge l_t = k\right)$，则有 $E\left[l_t - l_{t+1} \mid S_k\right] = E\left[l_t - l_{t+1} \mid A_t, S_k\right] \Pr\left[A_t \mid S_k\right] + E\left[l_t - l_{t+1} \mid \bar{A}_t, S_k\right] \Pr\left[\bar{A}_t \mid S_k\right]$，当 $A_t$ 成立时，有

$$
\begin{aligned}
&l_t - l_{t+1} = n - j_t + 1 - 1_{A_t} - \left(n - j_{t+1} + 1 - 1_{A_{t+1}}\right) \\
&= j_{t+1} - j_t + 1_{A_{t+1}} - 1 \geqslant -1. \\
&E\left[l_t - l_{t+1} \mid A_t, S_k\right] = \\
&E\left[l_t - l_{t+1} \mid l_t - l_{t+1} > 0, A_t, S_k\right] \Pr\left[l_t - l_{t+1} > 0 \mid A_t, S_k\right] \\
&+E\left[l_t - l_{t+1} \mid l_t - l_{t+1} = 0, A_t, S_k\right] \Pr\left[l_t - l_{t+1} = 0 \mid A_t, S_k\right] \\
&+E\left[l_t - l_{t+1} \mid l_t - l_{t+1} = -1, A_t, S_k\right] \Pr\left[l_t - l_{t+1} = -1 \mid A_t, S_k\right]
\end{aligned}
$$

当 $A_t, S_k$ 成立时，我们有 $k = l_t = j_t$，因而 $\exists x \in \mathcal{P}_t$，使得 $LO(x) = \tilde{LO}(x) = j_t = l_t$，$1/\left|\mathcal{P}_t\right|$ 的概率会将 x 选作亲代。子代 $x_t'$ 有更大的 LO 值的概率为 $1/n$，即选择第一个 0 位翻转的情形。又因为 $x_t'$ 的无噪声评估 (non-noise evaluation) 之概率为 $(1-p)$，故 $V_{t+1}\left(x_t'\right) = j_{t+1}$。此时子代 $x_t'$ 加入了种群，且种群内其他个体不做改动。故有 $j_{t+1} \geqslant j_t + 1$，从而易知，

$$
\begin{aligned}
&l_t - l_{t+1} = j_{t+1} - j_t + 1_{A_{t+1}} - 1 \geqslant 1, \\
&\Pr\left[l_t - l_{t+1} > 0, A_t, S_k\right] \geqslant \tfrac{1-p}{n\left|\mathcal{P}_t\right|}.
\end{aligned}
$$

接下来若 $l_t - l_{t+1} = -1$，仅当 $j_{t+1} = j_t$ 的时候，对于 $x \in \mathcal{P}_{t+1}$，如果 $\tilde{LO}(x) = V_{t+1}(x) = j_{t+1}$，那么有 $LO(x) \neq j_{t+1}$。这里须知，带噪声的解即 LO 的最大值 $j_{t+1}$ 与上一轮的 LO 的最大值 $j_t$ 相等，但真实值不等。即出现了上一轮 $A_t$ 成立但下一轮 $A_{t+1}$ 不成立的情况。下面展开证明，在此分两种情况进行详细

讨论。

第一种情况:$x' \ngeq x$，即前后的适应度 (fitness) 不一样，互不支配，此时根据 SEMO 算法，两个解 $(x, x')$ 都保留；第二种情况:$x' \geqslant x$，即前后的适应度一样，此时根据 SEMO 算法，只保留后面的解 $(x')$。

下面证明最多只有 1 个这样的 x 存在 (使用反证法): 反过来假设，有大于 1 个 x 存在，而由于 $\left|\left\{x : V_t(x) = \tilde{LO}(x) = LO(x) = j_t\right\}\right|$ 最多为 1，此时必然存在支配关系 (dominance)，与已知条件矛盾。故最多只有 1 个这样的 x 存在。

因而选中 x 这个解的概率小于 $1/\left|\mathcal{P}_t\right|$，且其被错误地评估 (wrongly evaluated) 的概率记为 p。对于变异这个步骤，仅有 (k+2) 个位置是可行的 (acceptable)。具体而言，可将其分为三段，全 1，0，中间，1，全 0。易知只有选择不是中间部分的位置做变异操作 (mutation)，随后使用噪声来复原这一位，才能做到真实值和 $j_t$ 不同，同时带噪的值为 $j_t$。如果选择中间部分做变异操作，真实值也为 $j_t$，而噪声恰好复原出 $j_t$ 的概率为 $1/n$，即将此前 mutation 翻转的位置再翻转回来。

而从 $V(x) < j_t$ 的解出发，通过突变操作和噪声环境影响 (mutation+noise) 来实现 $A_{t+1}$ 无法成立，同时 $j_{t+1} = j_t$。下面证明: 因为 SEMO 算法的性质，同一个 V(x) 最多只有一个解在种群里，从而选择小于 $j_t$ 的解概率为 $k/\left|\mathcal{P}_t\right|$，而利用变异操作和噪声环境影响 (mutation+noise) 实现 $j_{t+1} = j_t$ 的概率小于等于 $(n-k-1)/n^2$，具体举例可以是 $j_t = 4$，种群为 110100000,mutation 发生在后 4 个位置，即 $n-k-1$ 个，且噪声在第三位，此时需要进行噪声评估，定量分析概率 p。总概率为 $\Pr\left[l_t - l_{t+1} \mid A_t, S_k\right] \leqslant \frac{(k+2)p}{n^2\left|\mathcal{P}_t\right|} + \frac{k}{\left|\mathcal{P}_t\right|}\frac{n-k-1}{n}\frac{1}{n}p$, 因而 $E\left[l_t - l_{t+1} \mid A_t, S_k\right] \geqslant \frac{1-p}{n\left|\mathcal{P}_t\right|} - \frac{\left(2-k^2+nk\right)p}{n^2\left|\mathcal{P}_t\right|}$.

当 $\bar{A}_t$ 和 $S_k$ 成立时，我们有 $k = l_t = j_t + 1$, 而 $j_t$ 有一个位置上的元素与 $V_t$ 相符合，但与 f 不符合。此时把一个子代正确地评估到至少为 $j_t$ 的值之概率至少为 $\frac{1-p}{n\left|\mathcal{P}_t\right|}$。下面对真实值以 $j_t$ 为界进行分情况讨论：

第一种情况，若真实值大于 $j_t$，那么选取此元素作为亲代的概率为 $1/\left|\mathcal{P}_t\right|$，而经过随机变异的操作后 (mutation) 使其真实值达到大于 $j_t$ 的概率为 $\left(n - j_t\right)/n_t$，即排除了开头 1 之外的结果。而正确评估子代的概率为 $1-p$，那么产生一个值至少为 $j_t$ 的子代且被正确评估的概率是 $\frac{(n-k+1)(1-p)}{n\left|\mathcal{P}_t\right|}$。

第二种情况，若真实值小于 $j_t$，那么选取此元素作为亲代的概率为 $1/\left|\mathcal{P}_t\right|$ 子代有真实值 $j_t$，且需要翻转噪声发生的位置，其概率显然为 $1/n$，又因为正确评估

概率是 $1-p$,故总概率计算得 $\frac{1-p}{n|\mathcal{P}_t|}$. 又因为第一种情况中,$j_t+2 \leqslant n, n-k+1 \geqslant 2$,故综上两种情况,把一个子代正确评估至一个至少为 $j_t$ 的值之概率至少为 $\frac{1-p}{n|\mathcal{P}_t|}$。若此事件发生,则有 $j_{t+1} \geqslant j_t \mathbb{1}_{At+1} = 1$,故有 $l_t - l_{t+1} > 0, \Pr\left[l_t - l_{t+1} > 0 \mid \bar{A}_t, S_k\right] \geqslant \frac{1-p}{n|\mathcal{P}_t|}$ 。$E\left[T_{\text{low}}\right] \leqslant E\left[\arg\min_t l_t = 0\right] = O\left(n/\left(\frac{1}{n(n1)}\right)\right) = O\left(n^3\right)$,即这种情况下我们需要 $O\left(n^3\right)$ 时间来找到极限情况解。证明:

$$
\begin{aligned}
E\left[l_t - l_{t+1} \mid S_k\right] &\geqslant \left(\frac{1-p}{n\left|\mathcal{P}_t\right|} - \frac{\left(2-k^2+nk\right)p}{n^2\left|\mathcal{P}_t\right|}\right)\Pr\left[A_t \mid S_k\right] + \left(\frac{1-p}{n\left|\mathcal{P}_t\right|}\right)\Pr\left[\bar{A}_t \mid S_k\right] \\
&\geqslant \frac{1-p}{n\left|\mathcal{P}_t\right|} - \frac{\left(2-k^2+nk\right)p}{n^2\left|\mathcal{P}_t\right|} \\
&\geqslant \frac{1-p}{n\left|\mathcal{P}_t\right|} - \frac{p}{4\left|\mathcal{P}_t\right|} - \frac{2p}{n^2\left|\mathcal{P}_t\right|}
\end{aligned}
$$

由于我们尚未找到一个帕累托的解,我们有 $\left|\mathcal{P}_t\right| \leqslant n-1$,且 $k+2 \leqslant n$(由于 LO 在到达 n 之前的最大值为 n-2)。换句话说,当 $p \leqslant \alpha/n$,有 $E\left[l_t - l_{t+1} \mid S_k\right] \geqslant \frac{1}{n|\mathcal{P}_t|} \geqslant \frac{1}{n(n1)}$,根据这个对预期过程的期望,应用加性漂移定理 (the additive drift theorem) 可得出 $E\left[T_{\text{low}}\right] \leqslant E\left[\arg\min_t l_t = 0\right] = O\left(n/\left(\frac{1}{n(n-1)}\right)\right) = O\left(n^3\right)$ 。即需要 $O\left(n^3\right)$ 时间来找到两个极限情况解。

下面定义 $X_t := \sum_{i=1}^{n-1} 1_{\exists x \in \mathcal{P}_t, LO(x)=i, \tilde{LO}(x)=i, TZ(x)=T\tilde{T}Z(x)=n-i}$ $+n\sum_{i\in\{0,n\}} 1_{\exists x\in\mathcal{P}_t, LO(x)=i, TZ(x)=n-i}$,变量可以取 $[0..3n-1]$ 中的整数值。$X_t = 3n-1$ 是 $T_{\text{total}} \leqslant t$ 的一个充分条件,故我们可以关注 $T_X = \min\left\{t \in \mathbb{N}, X_t = 3n-1\right\}$,其中 $X_t$ 表示正确评估的元素的数量,其极值点有权重 n,$T_X$ 表示帕累托前沿第一次完全达到且所有元素都被正确评估的时刻。下面证明,存在一个常数 $\alpha > 0$ 使得当 $p \leqslant \alpha/n$ 时,对任意初始分布 $\pi$,任意 $t \in \mathbb{N}$,我们有 $E_\pi\left[X_{t+1} - X_t \mid X_t < 3n-1\right] \geqslant \frac{1}{n^2}$。基于前面证明的引理,我们考虑以下两种情况:$X_t < 2n \mathbb{1} 2n \leqslant X_t < 3n-1$,则有 $\Pr\left[X_{t+1} - X_t = n \mid X_t\right] \leqslant 4p/n^2$。此时一些带噪声的子代解替代了真实的极值点,如 $111...1100 \rightarrow 111..1101(Real), 111..1111(Noise)$ 以及 $111...1100- > 111...1110(Real), 111...1111(Noise)$。故有两个可能的选择 (111..1100, 1100..000),其概率为 $2/\left|\mathcal{P}_t\right| \leqslant 2$,每一种情况都有两个位置可以做突变操作 (mutation),概率为 $2/n$,需要做噪声评估的概率为 $p$,只有一位施加噪声,概率为 $1/n$. 故有 $\Pr\left[X_{t+1} - X_t = -1 \mid X_t\right] \leqslant 6p/n^2$,选择一个无噪声的解,并用一个带噪的解替换

1110000− > 1010000 (Real) 1000000 (Noise)

1110000− > 1100000 (Real) 1000000(Noise)/1110000(Noise)

它，如： 1110000-> 1111000 (Real) 1110000 (Noise)/1111100(Noise)

1110000− > 1110100 (Real) 1111100 (Noise)

故有 $\Pr\left[X_{t+1}-X_t=-k \mid X_t\right]=0, k=\mathbb{N}\backslash\{0,1,n\}$.

**引理 1** *SEMO* 算法处理 *LOTZ* 问题达到帕累托前沿 *(pareto front)* 需要的迭代次数为 $O\left(n^3\right)$。

**证明** 由于至多只有一个解加入了种群，无论是增加还是替换。对于一个适应度的值，至多只有一个解在种群中。除了 *0*，*1*，*n*，别无他解。考虑 $X_t<2n$ 的情形，$\Pr\left[X_{t+1}-X_t=n \mid X_t\right] \geqslant \frac{1}{n+1}\frac{1}{n}(1-p)$，则有选择带噪音的极值点的概率至少为 $1/\left|\mathcal{P}_t\right| \geqslant 1/(n+1)$。又因为恰好翻转噪音位置概率为 $1/n$，正确评估概率为 $(1-p)$，考虑 $2n \leqslant X_t \leqslant 3n-1$ 的情形,$\Pr\left[X_{t+1}-X_t=1 \mid X_t\right]$ $\geqslant \frac{1}{n+1}\frac{1}{n}(1-p)$，寻找一个 $x$，具有最小的 $LO(x)+1 \notin LO\left(\mathcal{P}_t\right)$，选择此解的概率为 $1/\left|\mathcal{P}_t\right|$，翻转噪声位置概率 $1/n$，正确评估概率为 *1-p,* 故有

$$
\begin{aligned}
E_\pi\left[X_{t+1}-X_t \mid X_t<3n-1\right] = & -n \Pr\left[X_{t+1}-X_t=-n \mid X_t<3n-1\right] \\
& -\Pr\left[X_{t+1}-X_t=-1 \mid X_t<3n-1\right] \\
& +n \Pr\left[X_{t+1}-X_t=n \mid X_t<3n-1\right] \\
& +\Pr\left[X_{t+1}-X_t=1 \mid X_t<3n-1\right] \\
\geqslant & -n \cdot \frac{4p}{n^2}-\frac{6p}{n^2}+n\frac{1-p}{n(n+1)} \Pr\left[X_t<2n \mid X_t<3n-1\right] \\
& +\frac{1-p}{n(n+1)} \Pr\left[X_t \geqslant 2n \mid X_t<3n-1\right] \\
\geqslant & -\frac{2(2n+3)p}{n^2}+\frac{1-p}{n(n+1)} \\
\geqslant & -\frac{6p}{n}+\frac{1-p}{2n^2} \\
\geqslant & \frac{1}{4n^2}
\end{aligned}
$$

其中 $p \leqslant \frac{\alpha}{n}, \alpha$ 为某个常数。根据加性漂移分析，达到 *pareto front* 需要的迭代次数为：$O\left((3n-1)/\frac{1}{4n^2}\right)=O\left(n^3\right)$。*Q.E.D.* 由此引理，可得到定理 *2.2.1* 的上界相关结论。