南京大学

本 科 毕 业 设 计

院　　系　人工智能学院

专　　业　人工智能

题　　目　强化学习智能体的轨迹与文本转换方法研究

年　　级　2020　学　　号　201300003

学生姓名　李开元

指导教师　俞扬　职　　称　教授

提交日期　　年　月　日

南京大学本科毕业论文（设计）
诚信承诺书

本人郑重承诺：所呈交的毕业论文（设计）（题目：强化学习智能体的轨迹与文本转换方法研究）是在指导教师的指导下严格按照学校和院系有关规定由本人独立完成的。本毕业论文（设计）中引用他人观点及参考资源的内容均已标注引用，如出现侵犯他人知识产权的行为，由本人承担相应法律责任。本人承诺不存在抄袭、伪造、篡改、代写、买卖毕业论文（设计）等违纪行为。

作者签名：

学号：

日期：

南京大学本科生毕业论文（设计、作品）中文摘要

题目：强化学习智能体的轨迹与文本转换方法研究

院系：人工智能学院

专业：人工智能

本科生姓名：李开元

指导教师（姓名、职称）：俞扬　教授

摘要：

强化学习作为人工智能的关键分支，其核心在于智能体通过与环境的交互学习最优策略。强化学习的轨迹数据，即智能体在特定任务中的行为序列，对于评估和优化智能体策略至关重要。它详细记录了智能体的行为，而且为性能评估和策略改进提供了实证基础。此外，轨迹还能作为训练数据，促进智能体在后续任务中实现更高的奖励累积。然而，获取高质量的强化学习轨迹数据存在挑战，通常需要领域专家的深入参与，以及在复杂仿真环境中进行大量的实验模拟。此外，强化学习轨迹的可解释性也面临挑战，尤其是对于非专业人士而言，理解由状态、动作和奖励构成的三元组数据较为困难。针对上述挑战，本研究提出了一种创新方法，旨在实现强化学习轨迹数据与自然语言文本之间的双向转换。通过微调预训练的大语言模型，本研究构建了一个框架，该框架能够理解强化学习轨迹数据与自然语言文本之间的对应关系，并实现它们之间的有效转换。本方法一方面通过将自然语言目标转换为轨迹数据，能有效地扩充训练集，实现数据的增广，提高智能体策略的学习效率；另一方面，通过将轨迹数据转换为易于理解的自然语言描述，显著提升了数据的可解释性，使得非专业人士也能更好地理解智能体的行为模式。本研究成功地缩小了预训练语言模型与强化学习轨迹之间的差异，为利用语言模型进行强化学习轨迹的生成和解释开辟了新的途径，并展示了其在实际应用中的潜力和效果。

关键词：强化学习；大语言模型；轨迹生成；自然语言指令

南京大学本科生毕业论文（设计、作品）英文摘要

THESIS: Trajectory and Text Transformation Methods for Reinforcement Learning Agents

DEPARTMENT: School of Artificial Intelligence

SPECIALIZATION: Artificial Intelligence

UNDERGRADUATE: Kaiyuan Li

MENTOR: Professor Yang Yu

ABSTRACT:

Reinforcement learning (RL), a pivotal branch of artificial intelligence, hinges on the learning of optimal policies through an agent's interaction with its environment. The trajectory data in RL, which represents the sequence of actions taken by an agent in a specific task, is crucial for evaluating and refining the agent's strategies. It meticulously documents the agent's behavior and provides an empirical foundation for performance assessment and strategic enhancement. Moreover, trajectory data can also serve as training material, facilitating superior reward accumulation in subsequent tasks. However, obtaining high-quality RL trajectory data presents challenges, often necessitating the deep involvement of domain experts and extensive experimental simulations in complex simulation environments. Additionally, the interpretability of RL trajectories faces hurdles, particularly for non-experts due to the difficulty of comprehending the triplet data composed of states, actions, and rewards. To address the aforementioned challenges, this study introduces an innovative method aimed at achieving a bidirectional transformation between RL trajectory data and natural language texts. By fine-tuning a pre-trained large language model, this research constructs a framework capable of understanding the correspondence between RL trajectory data and natural language texts, enabling their effective transformation. On one hand, this method can effectively expand the training set by converting natural language goals into trajectory data, thus achieving data augmentation and improving the learning efficiency of the agent's strategy. On the other hand, by translating trajectory data into understandable natural language descriptions, it significantly enhances data interpretability, allowing

non-experts to better comprehend agent behavior patterns. This study has successfully bridged the gap between pre-trained language models and RL trajectories, paving new avenues for the generation and interpretation of RL trajectories using language models, and demonstrating their potential and effectiveness in practical applications.

KEYWORDS: Reinforcement Learning; Large Language Model; Trajectory Generation; Natural Language Instruction

目　　录

第一章 绪论 1

1.1 研究背景 1

1.2 相关工作 2

1.2.1 强化学习数据增广 2

1.2.2 强化学习可解释性 3

1.3 主要贡献 4

第二章 理论背景 5

2.1 强化学习 5

2.2 大语言模型 6

第三章 轨迹与文本转换方法 7

3.1 问题描述 7

3.2 轨迹与文本统一的训练方法 8

3.3 未见轨迹生成 9

第四章 轨迹与文本转换实验 11

4.1 实验设置 11

4.2 轨迹生成效果 13

4.3 文本生成效果 15

4.4 消融实验 17

第五章 总结与展望 19

5.1 全文总结 19

5.2 未来展望 20

参考文献 23

致　　谢 27

附录 A 使用的提示词 29

A.1 指令微调提示词 29

A.2 文本生成提示词 29

附录 B 未见任务的自然语言目标 31

B.1 未见文本 31

B.2 未见任务（简单） 33

B.3 未见任务（困难） 35

第一章　绪论

1.1　研究背景

人工智能自 20 世纪 50 年代首次被提出以来，经过 60 多年的发展，已经成为一个在多领域引发颠覆性变革的前沿技术。以机器学习、深度学习为核心，人工智能在视觉、语音、通信等领域取得了快速发展，悄然改变着人们的生活及工作方式[1]。随着越来越多的国家意识到人工智能技术的重要性与颠覆性，我国也积极地在 AI 领域深耕布局，培养 AI 领域人才，抢夺技术先机。当前，人工智能已被明确作为未来国家重要的发展战略。2021 年 3 月国家公布的“十四五”发展规划[2]中人工智能的相关表述达到 59 处，突显了以人工智能为代表的新一代信息技术在推动我国经济高质量发展中的重要地位。

强化学习[3]，作为人工智能领域中的一个重要分支，是一种以环境反馈作为输入的、特殊的、适应环境的机器学习方法。它的核心思想是通过与环境的交互和试错，利用评价性的反馈信号来优化决策。这一学习机制不仅与自然界中人类或动物的学习方式相似，而且在人工智能、机器学习和自动控制等领域中得到了广泛的研究和应用。强化学习因其在众多领域中的应用及潜力，被认为是设计智能系统的核心技术之一。

然而，强化学习在实际应用中面临一个主要挑战：它需要通过不断地与环境交互来采集数据，学习策略。这种交互过程往往是成本高昂或难以实现的。例如，在自动驾驶系统的开发中，让系统在真实道路上行驶以收集数据是危险且不可行的。为了克服这一挑战，研究者们提出了离线强化学习[4]的概念，它允许智能体在没有实时环境交互的情况下，通过分析历史离线数据来进行学习。尽管如此，依赖专家或模拟器收集的数据仍然成本较高，强化学习始终面临着可训练数据不太充足的情况。同时，强化学习智能体的轨迹（通常为状态-动作-奖励的三元组）都是以向量或矩阵等形式存在，可解释性较差，这使得即使是领域专家也难以仅根据一条轨迹来理解智能体的行为。

在这样的背景下，自然语言的引入提供了新的视角。目前已有很多将自然语言引入强化学习的工作[5]，但将自然语言与强化学习轨迹结合的工作暂时还未出现。自然语言不仅信息丰富，蕴含了大量的知识，而且获取成本相对较低。它能够根据现有的例子进行泛化，设计出新的示例，从而在不增加数据收集成本的情况下，丰富强化学习的训练数据。此外，自然语言是人类最熟悉的交流方式，如果能够实现强化学习智能体的轨迹和自然语言文本之间的相互转换，不仅可以将大量以自然语言形式存在的外部知识引入到强化学习中，增强策略学习的深度和广度，而且可以借助人类对自然语言的熟悉和理解，显著提高强化学习智能体行为的可解释性，从而促进智能体与人类之间的有效沟通。

1.2 相关工作

1.2.1 强化学习数据增广

数据是机器学习模型训练的核心，尤其在强化学习领域，其重要性更是不容忽视。充足的训练数据对于避免过拟合、扩展参数搜索空间以及引导模型向全局最优解发展具有关键作用。然而，许多实际应用中，获取大量高质量的训练样本既困难又昂贵。强化学习尤其面临数据采集效率低下和泛化能力不足的挑战，通常需要长时间的数据收集和训练才能取得实际成功。为了克服这些难题，从现有训练数据中生成新的合成数据，即数据增广技术[6]，已成为提升训练样本数量和质量的有效手段。

在强化学习中，数据增广技术通常应用于图像状态数据。例如，DrQ[7]和RAD[8]等研究通过特定的图像处理技术来增加状态数据的多样性。然而，这种方法虽然能够增加图像状态的多样性，却不足以直接丰富训练过程中遇到的轨迹，因此对于提高采样效率的帮助十分有限。本研究关注的是强化学习轨迹的增广，旨在通过提高轨迹的多样性来提升模型的泛化能力和采样效率。相关的一个工作是 PlayVirtual[9]。该工作通过训练正向和反向的环境动力学模型，创建了一个轨迹闭环系统。在该系统中，可以通过采样动作并利用动力学模型来生成新的状态，从而产生增广的轨迹，这为强化学习提供了一种新的数据增广途径。

尽管现有的数据增广方法，如像素级别的图像数据增广，能够在一定程度上增加数据的多样性，但它们可能会同时改变与任务相关和无关的特征，这可能会

对模型的性能产生不利影响。为了实现更有意义的数据增广，最理想的方式应该从语义角度出发[10]。本研究提出了一种语义相关的增广方法，核心思想是通过引入自然语言，对强化学习轨迹进行语义上的增广。我们预期，这种方法不仅能够提高数据的质量和多样性，还能够使智能体在处理复杂任务时更加灵活和高效。

1.2.2 强化学习可解释性

强化学习作为一种解决环境交互问题的通用方法，已成为机器学习领域的一个重要分支。然而，它同样面临着机器学习算法普遍存在的可解释性难题。这种可解释性的缺失限制了强化学习在多个领域的应用潜力，因此，强化学习可解释性的研究变得尤为重要，也出现了较多该领域的研究[11]。

在强化学习的可解释性研究中，视觉和语言辅助解释方法尤为突出。这类方法侧重于模型输入输出之间的关联，通过量化输入状态对输出动作的影响，实现关键状态信息的可视化，从而辅助人类理解模型的行为。例如，Wang 等人[12]通过结合特征提取编码、特征选择的注意力机制和自然语言解码器三个部分构建了一个模型，利用生成网络生成自然语言描述，以提供对模型行为的解释。除了视觉和语言辅助解释方法外，策略模仿也是强化学习可解释性研究的重要方向。这种方法通过采用结构简单、可解释性强的模型，从复杂模型的范例中学习，以模仿其输出。VIPER[13]是一个典型的例子，它通过改进模仿学习算法 DAgger，以在线方式不断修正决策树策略，从而从深度神经网络中提取出可解释的策略，性能接近于 DQN 等深度学习方法。也有工作如神经逻辑强化学习[14]摒弃神经网络，牺牲部分性能，使用本身可解释的模型来获得可解释性。

与上述方法不同，本研究着眼于强化学习任务的目标与智能体轨迹之间的关联。因为强化学习不仅关注智能体的行为，还关注智能体所执行的任务，但目前已有的众多方法大多仅致力于对智能体策略的解释，极少数方法涵盖对任务的解释[15]，即着眼于解释智能体当前为何采取某个动作，但对整条轨迹中智能体的整体行为不甚关心。因此，本研究旨在通过将智能体的轨迹转换为自然语言文本，不仅解释智能体的行为，也提供对任务目标的深入理解。

1.3 主要贡献

针对前文提到的强化学习数据量较少，可解释性较差两个问题，本文通过将大语言模型引入自然语言，实现了强化学习轨迹数据与自然语言文本之间的相互转换，以此对强化学习轨迹数据进行增广并且提高其可解释性。图1-1展示了本研究是如何利用大语言模型生成轨迹的。文本的主要贡献如下：

- 实现了强化学习轨迹和自然语言文本之间的相互转换。通过将自然语言目标转化成强化学习轨迹，利用了人类对自然语言的熟悉与理解，在语义层面增广强化学习轨迹数据，增强了轨迹数据的多样性，加速了模型的训练过程，更进一步则可以使智能体通过额外的训练数据学习新的技能。通过将强化学习轨迹转化为自然语言描述，以简单清晰的形式描述了强化学习智能体的行为，便于强化学习的训练者和强化学习智能体的使用者理解智能体。
- 将大语言模型引入强化学习，赋予其对轨迹数据的深层次理解和输出轨迹的能力。在输入输出端实现了语言模型的自然语言文本与强化学习的状态、动作向量的对齐。
- 提供了在 CLEVR-Robot 任务上的实验和结果分析，验证了本研究方法在生成高质量的强化学习轨迹数据和其自然语言描述方面的有效性。

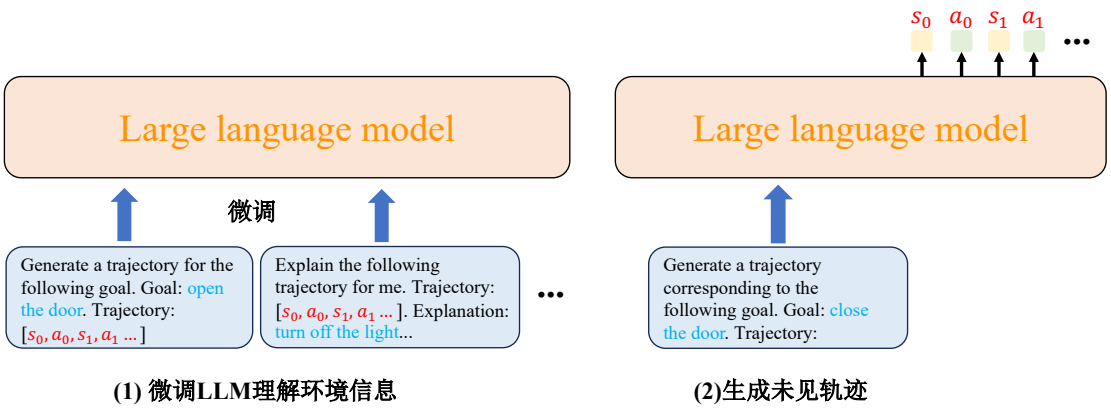

图 1-1　大语言模型生成轨迹的框架

第二章　理论背景

2.1　强化学习

人工智能的终极目标之一是设计出一个智能体，使其能够通过与环境的交互和试错过程，不断自我改进并提升性能，最终学习到最优策略。这种基于交互的学习方式是获取知识的自然途径，也是人类与生俱来的能力。然而，在不同环境中，尤其是在机器人和智能体领域，实现这一目标一直是一个未能被解决的挑战。对于这类学习任务，我们通常采用基于经验自动学习的数学框架——强化学习[3]。

作为一种通过反复试错，并且基于反馈来实现序列化决策的机器学习范式，强化学习可以形式化为对马尔科夫决策过程（Markov Decision Process，MDP）[16]的求解。一个标准的马尔科夫决策过程常以六元组的形式表示：$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \rho_0, \mathcal{R}, \gamma \rangle$。其中 $\mathcal{S}$ 和 $\mathcal{A}$ 分别表示状态空间和动作空间；$P : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \to [0, 1]$ 定义了状态转移概率，$P(\cdot) = p(s'|s, a)$ 表示智能体在状态 s 下执行动作 a 转移到的下一个状态为 s' 的概率，对于任意状态 $a \in \mathcal{A}$ 和状态 $s \in \mathcal{S}$ 有 $\Sigma_{s \in \mathcal{S}} p(s'|s, a) = 1$；$\rho_0$ 表示初始状态分布；$\mathcal{R} : \mathcal{S} \times \mathcal{A} \to \mathcal{R}$ 表示奖赏函数；$\gamma \in [0, 1]$ 表示折扣因子，其值越小代表越关注即时奖赏。在马尔科夫决策过程中，奖励函数 R 和环境转移函数 P 只与当前的状态和动作有关，而与此前的所有状态和动作独立，这个性质被称为马尔科夫性，这也正是 MDP 名称的由来。

强化学习的策略训练在很大程度上依赖于智能体与环境的不断交互。然而，在许多现实任务中，频繁的交互、试错或实时探索或许不可行或代价过高。因此，研究者们开始关注离线强化学习[4]，探索如何利用预先收集的与环境交互的历史轨迹数据来学习策略。离线强化学习问题可以定义为强化学习的数据驱动形式，通过一个静态数据集 $D = \{(s_t^i, a_t^i, s_{t+1}^i, r_t^i)\}$ 来学习策略。这个数据集包含若干条强化学习智能体的轨迹，每条轨迹由多个步骤组成，每个步骤包含了当前状态 s_t，当前动作 a_t，下一状态 s_{t+1} 和获得的奖赏 r。它能够帮助我们理解智能

体与环境之间的交互过程，并优化智能体的行为策略，同时避免在实际环境中进行代价高昂的探索。

2.2 大语言模型

自二十世纪五十年代图灵测试提出以来，人类对如何让机器理解和掌握语言进行了不懈探索。随着自然语言处理技术的演进，从早期的规则系统、统计学习方法，到深度学习模型的兴起，我们见证了语言理解技术的显著进步。当前，预训练的大语言模型（Large Language Models，LLMs）在理解和处理自然语言方面展现了卓越的能力，尤其在下游任务上取得了显著成效，并涌现了 in-context learning 等令人惊喜的文本处理能力[17]。这些模型多采用 Transformer[18]架构，具备数十至数百层的神经元和数十亿至数千亿的参数，使其能够精细捕捉人类语言的微妙之处，深入理解语言的复杂性。

大语言模型的核心任务是语言建模（Language Modeling，LM），即对词序列的生成概率进行建模，以预测给定现有词序列时下一个词出现的概率。这个过程可以形式化的描述为：$l_{t+1} = \mathcal{M}(E_T(l_0), \cdots, E_T(l_t))$，其中 l_t 代表第 t 个词，E_T 是词嵌入层，能够把离散的词转换为连续的 D 维向量。大语言模型通过预测给定前 t 个词时，第 t+1 个词可能为词典中的每个词的概率，来最终自回归地生成完整的文本。

在预训练之后，大语言模型通常还会经过多种微调以提升其性能和对话能力。一种有效的微调方法是指令微调（Instruction Tuning）[19]。在指令微调中，训练数据由一系列按照特定指令格式组织的文本构成。这种方法不仅增强了模型在未见任务上的泛化能力，而且使其能够更准确地根据人类的指令进行响应。

第三章　轨迹与文本转换方法

本章节展示了本研究提出的利用大语言模型将强化学习轨迹与自然语言描述相互转换的具体方法。

3.1　问题描述

轨迹数据　本研究使用的强化学习的离线轨迹数据由一系列状态-动作对组成，表示为 $\{G^k, (s_0^k, a_0^k, s_1^k, a_1^k, \cdots)\}_{k=1}^{K}$。其中 $(s_0^k, a_0^k, s_1^k, a_1^k, \cdots)$ 代表智能体在环境中执行某个具体任务的轨迹，展现了达成自然语言目标 G^k 所需要的状态动作 (s_i^k, a_i^k) 序列。由于本研究采用的轨迹数据集来源于专家，因此数据中不包含奖赏信息 r。本研究的目标是实现强化学习轨迹与自然语言文本之间的相互转换，即给定轨迹 $(s_0^k, a_0^k, s_1^k, a_1^k, \cdots)$ 时，能够生成对应的自然语言描述 G^k；反之，给定自然语言目标 G^k 时，能够生成一条可以完成该目标的轨迹。

大语言模型　本研究使用了大语言模型，通过自回归的方式生成强化学习智能体的轨迹或者其对应的自然语言描述。传统的大语言模型在处理文本时，输入输出均是预先切分好的词。具体而言，在输入时，将词通过词嵌入层转换为连续向量 $e_k = E_T(l_k) \in \mathbb{R}^D$，再通过深度神经网络进行计算；在输出时通过一个线性层预测下一个词的概率分布 $P(l_k|l_{<k})$。为了使大语言模型能够处理强化学习轨迹中以向量形式存在的状态和动作数据，本研究对大语言模型的结构进行了修改，引入了多层感知机（MLPs）替换输入输出层来处理向量形式的数据。这种结构上的调整旨在更好地将状态和动作数据与自然语言文本对齐，以及反过来根据自然语言目标生成相应的轨迹。具体的修改细节和模型架构将在第3.2节中详细阐述。

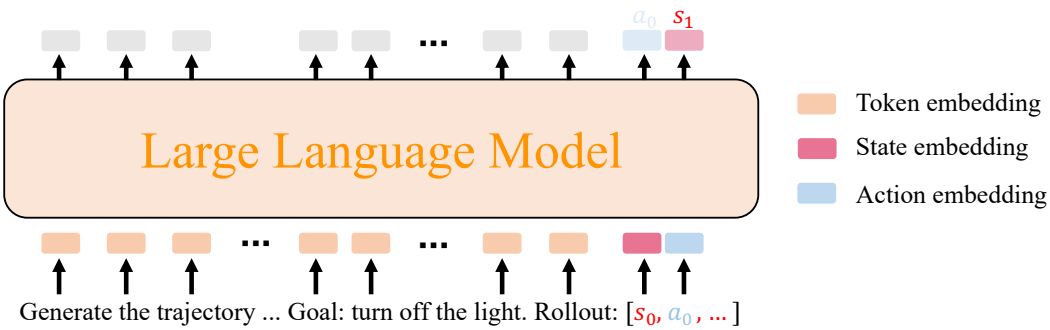

图 3-1　大语言模型框架

3.2　轨迹与文本统一的训练方法

为了实现强化学习轨迹与自然语言文本的相互转换，大语言模型必须深入理解数据的采集环境。这包括对状态信息、动作信息和动力学信息等的理解。本研究旨在训练一个模型，使其能够完成基于强化学习轨迹生成自然语言描述和基于自然语言目标生成强化学习轨迹这两个不同的任务。尽管任务不同，它们在本质上仅是输入输出的反转，统一训练可以增强模型对轨迹的理解，提升训练效果。

为了实现这个目标，本研究为数据集设计了四种不同的范式，以对大语言模型进行微调：

- 动力学预测：预测环境中的动力学变化。给定当前状态 s_i 和动作 a_i，模型需预测下一状态 s_{i+1}。
- 文本生成：给定一条轨迹，模型需生成自然语言描述以解释智能体的行为。
- 轨迹生成：给定一个自然语言目标 G，模型需生成一条能够实现该目标的轨迹。
- 结果预测：预测轨迹执行的结果。给定初始状态 s_0 和目标 G，模型需预测终止状态 s_T。

通过以上四种范式，本研究将轨迹生成和文本生成任务组织成了指令微调的形式。因为经过指令微调的大语言模型具有很强的根据给定的自然语言指令完成任务，输出答案的能力。受此启发，本研究根据四种范式设计了指令提示词，进一步再进行轨迹层面的指令微调，以指导模型理解环境与轨迹，实现轨迹与文本统一的训练，从而完成二者相互转换的任务。使用的提示词展示在附录A.1中。

由于大语言模型在预训练时仅学习了处理文本数据和预测词序列，故无法被直接用于强化学习轨迹和自然语言文本的转换。故如图3-1所示，本研究采用了一个预训练的大语言模型作为基础模型，并对其进行了扩展，以处理状态和动作数据。在输入端，我们引入了可学习的 MLP 作为状态和动作数据的嵌入层：$E_S : \mathcal{S} \to \mathbb{R}^D, E_A : \mathcal{A} \to \mathbb{R}^D$，将输入映射到与词向量相同维度的向量空间，并实现了一定程度上的对齐。在输出端，增加了线性投影层：$H_S : \mathbb{R}^D \to \mathcal{S}, H_A : \mathbb{R}^D \to \mathcal{A}$，将模型的输出映射回状态空间或动作空间。

3.3 未见轨迹生成

在根据环境数据微调后，大语言模型已经能够理解环境中的状态、动作和动力学信息。鉴于大语言模型通过预训练学习了大量关于世界的知识，它应当具备生成全新的未见轨迹的潜力。为此，本研究利用训练过后的模型，通过特定的提示词来生成未见轨迹，例如“Translate the textual instruction to state/action trajectory. Instruction: {instruction}. Trajectory:”。参考先前利用大语言模型生成强化学习策略的一篇工作[20]，本研究从两个维度出发探索其生成未见轨迹的能力。

- 未见文本：这一维度评估了模型在面对不同语言表述但相同语言含义的目标 G 时，是否能够正确输出相应的轨迹。不同的语言表述包括对动作的不同描述或物体名称的重新构造等。
- 未见任务：这一维度评估了模型是否能够完成那些在训练数据集中未出现过的新任务。这些任务要求对训练集中的任务进行重组，例如将机器人的行走任务转变为跑步任务。此维度的任务需要大语言模型对环境中的物品和动力学信息有全面深刻的理解，才能生成可以完成任务的轨迹。

本文在节4.1详细阐述了如何设计上述两个维度，以评估大语言模型生成未见轨迹的能力。

第四章　轨迹与文本转换实验

本章节将详细分析和评估强化学习轨迹与自然语言文本互相转换效果的实验设计及其结果。实验的主要目标分为三个部分：首先，分析基于自然语言目标生成强化学习轨迹的能力（见4.2节）；其次，评估基于强化学习轨迹生成自然语言描述的准确性（见4.3节）；最后，考察指令微调对模型性能的影响（见4.4节）。接下来，本节将首先介绍实验所采用的环境等设置，随后详细阐述实验过程中的关键细节。

4.1　实验设置

实验环境　实验在 CLEVR-Robot 环境[21]中进行。该环境是一个基于 MuJoCo 物理引擎[22]构建的物品操作任务环境。如图4-1所示，它模拟了一个三维空间，其中包含了一个智能体（图中的银色小球）和五个可操纵的小球。图中的任务为："*Can you move the purple ball* ***to the left of*** *the blue ball?*"。环境中的状态空间为 $\mathbb{R}^{10}$，代表了五个小球的位置坐标。动作空间则为 $\mathbb{R}^{40}$，每个动作由独热编码表示，具体指代某个小球向八个基本方向之一的移动。

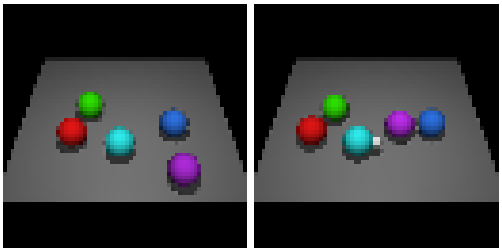

(a) 任务前　　**(b) 任务后**

图 4-1　CLEVR-Robot 环境

数据集　我们预先收集并构建了一个离线数据集，该数据集包含 100,000 对轨迹和相应的自然语言描述。每条数据对应的任务为将一个特定的球体移动至另一个特定球体的指定方向（前、后、左、右）。例如，任务描述可以是"*Move the*

red ball ***to the left of*** *the blue ball*”。数据集中总共包含了 80 种不同的任务类型，这些任务类型由 $5 \times 4 = 20$ 种球体选择和 4 种移动方向组合构成。沿用先前的研究工作[23]，我们为每种任务准备了 54 种不同的自然语言描述。在对大语言模型进行微调的过程中，我们以上述数据集为基础构建了一个包含 400,000 条轨迹的训练集。我们将数据集中的每一对（轨迹，文本）数据根据第3.2节中描述的四种不同的范式，扩展为四条独立的轨迹。这些转换样式包括动力学预测、文本生成、轨迹生成和结果预测。

未见任务 为了评估训练后的大语言模型在生成未见轨迹方面的能力，本研究在第3.3节的基础上进行了扩展，将未见轨迹的生成细分为以下三个维度：

- 未见文本：在此维度上，智能体执行的任务与训练集相同，但接收到的自然语言目标的表述不同。尽管表述方式有所变化，但自然语言目标的语义保持不变，这要求智能体能够准确识别理解目标，并响应语言的变体。
- 未见任务（简单）：智能体面临的任务是将特定颜色的球体沿特定方向移动，例如：“*Move the blue ball* ***forward***”。这些任务虽然在结构上较为简单，但它们在数据集中并未出现，因此需要大语言模型对环境数据，包括状态、动作和动力学信息等有深刻的理解。
- 未见任务（困难）：智能体需要处理的是在数据集中完全未出现过的任务，并且这些任务要求对动作进行复杂的组合，如：“*Gather all balls together*”或“*Move five balls to a straight line*”。这不仅要求智能体理解环境数据，还要求其能够创新性地对训练集中出现的任务动作进行分析、拆分和重组。

想要生成与未见任务相对应的轨迹，需要相应的自然语言目标。本研究使用 ChatGPT[24]为每个任务类别生成了对应的自然语言描述。附录B详细展示了这些自然语言目标的示例。

大语言模型 本研究选取了 Llama-2-7b-chat-hf[25]作为基础模型，并以 24 个样本的批量大小（batch size）进行了 10 个周期（epoch）的训练。随后利用训练得到的多个模型检查点进行了轨迹生成和文本生成的实验。

4.2 轨迹生成效果

本节通过实验评估了大语言模型在未见任务上生成的轨迹的质量。评估采用的是未见任务（简单）这一维度，智能体的任务是根据指定的方向，通过一个动作推动特定的球体。量化轨迹质量的方法是计算生成的轨迹的准确率，即生成的状态/动作是否符合自然语言目标的要求。例如，对于自然语言目标“*Move the red ball to the **left***”，需要判断的是生成的状态/动作是否真的把红球向左推动了。图4-2展示了在训练过程中五个不同模型检查点的轨迹生成的正确率。从结果我们可以看出，虽然动作的生成的正确率保持在大约 30%，但状态的生成的正确率是随着训练的过程不断上升的。结果说明，大语言模型在生成状态方面的能力优于生成动作的能力。这在一定程度上表明，大语言模型更适合作为环境模拟工具，而非策略决策工具。同时结果也可以说明，尽管没有直接进行过训练，大语言模型在未见任务上生成轨迹的能力也较为可观，显示出了相当的潜力。

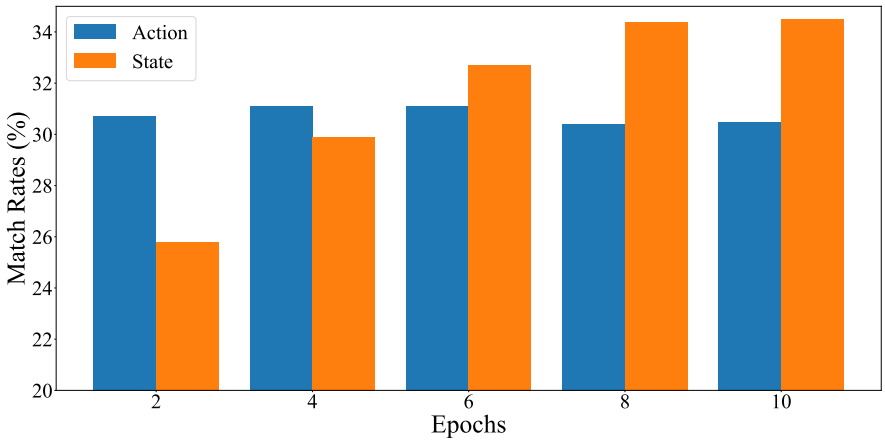

图 4-2　轨迹生成准确率

在正确率之外，本节还随机选取了一些为未见任务生成的轨迹的示例，如图4-3、4-4、4-5。总体来说，大语言模型生成的轨迹在很大程度上符合实际的物理规律。同时，它也能准确地捕捉到未见自然语言目标中的物体（如球体）、方向等关键信息。

- 在未见文本（图4-3（a））维度上，大语言模型正确地理解了自然语言目标中的语义信息，而不是简单地从中提取关键词。同时我们发现，生成的轨迹的质量对初始状态较为敏感。如图4-3（b）所示，尽管自然语言目标相对简单，但由于对初始状态的不熟悉，大语言模型未能正确生成轨迹。

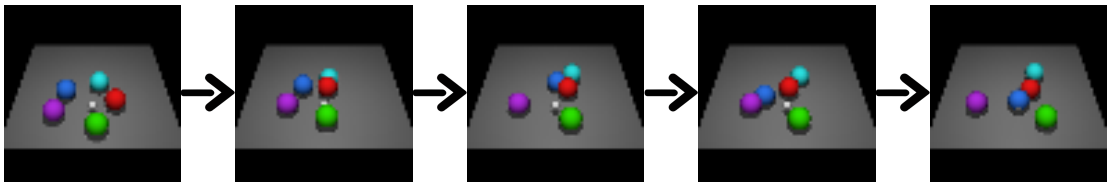

(a) **Success**: *I can't stand the red ball ahead of the blue one. Could you switch the positions of them?*

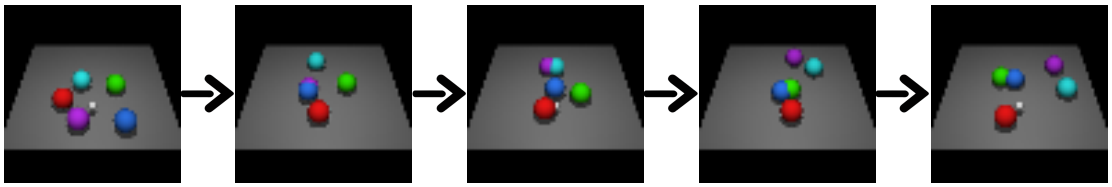

(b) **Failure**: *The sight of the red ball positioned to the right of the blue ball brings me joy.*

图 4-3　未见文本轨迹示例

- 在未见任务（简单）（图4-4（a））维度上，大语言模型能够成功地从自然语言目标中捕捉到相应的信息，尽管自然语言目标和训练时的数据并不相同。然而，从图4-4（b）我们可以发现，虽然大语言模型在选择对应颜色的球上表现不俗，但在准确识别动作轨迹上遇到了一定困难。这也与上文中状态生成准确率高于动作生成准确率的情况相吻合。

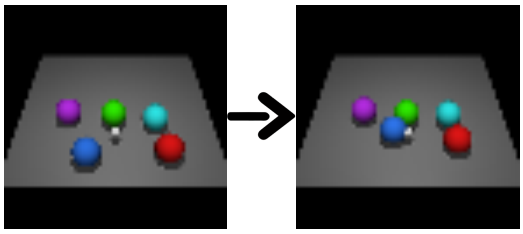

(a) **Success**: *Move the blue ball back, not forward.*

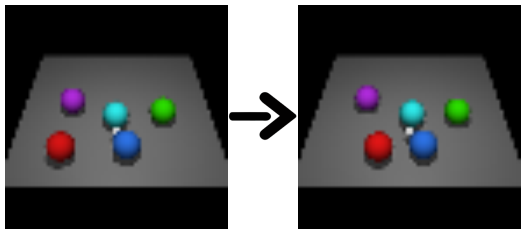

(b) **Success**: *Move the ball that has the color red to the right.*

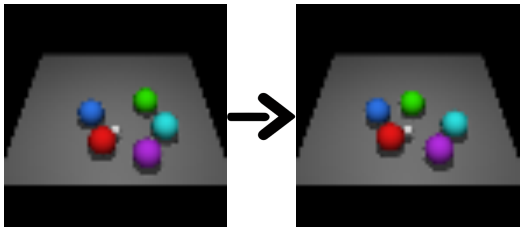

(c) **Failure**: *Would you mind moving the ball, which is colored green, to the right?*

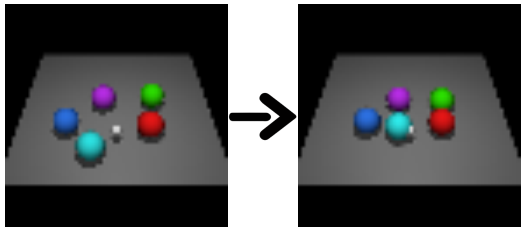

(d) **Failure**: *Kindly shift the cyan sphere ahead.*

图 4-4　未见任务（简单）轨迹示例

- 在未见任务（困难）（图4-5（a））维度上，尽管任务要求更加复杂，需要在一条轨迹中对多个物体进行操作（训练数据中一条轨迹仅包含对一个物体的操作），大语言模型依然能够完成任务。但是在图4-5（b）中，任务的难度进一步增加，当需要考虑多个物体之间的相对位置关系时，大语言模

型表现不佳。但尽管未能精确地按照给定的颜色顺序排列物品，模型还是展现出了将物品排列成一行的明显倾向，显示出了一定的潜力。

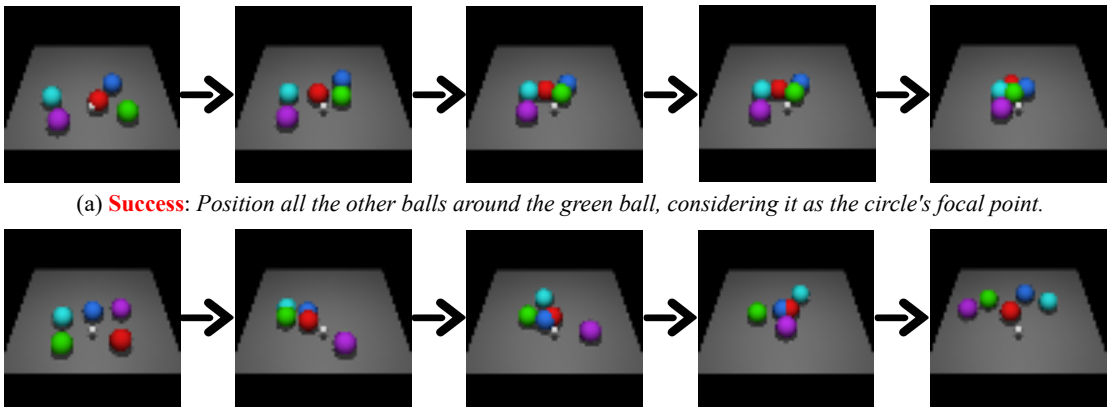

(a) **Success**: *Position all the other balls around the green ball, considering it as the circle's focal point.*

(b) **Failure**: *Position the balls horizontally, organizing them from left to right, following the sequence of red, blue, green, purple, and cyan.*

图 4-5　未见任务（困难）轨迹示例

4.3　文本生成效果

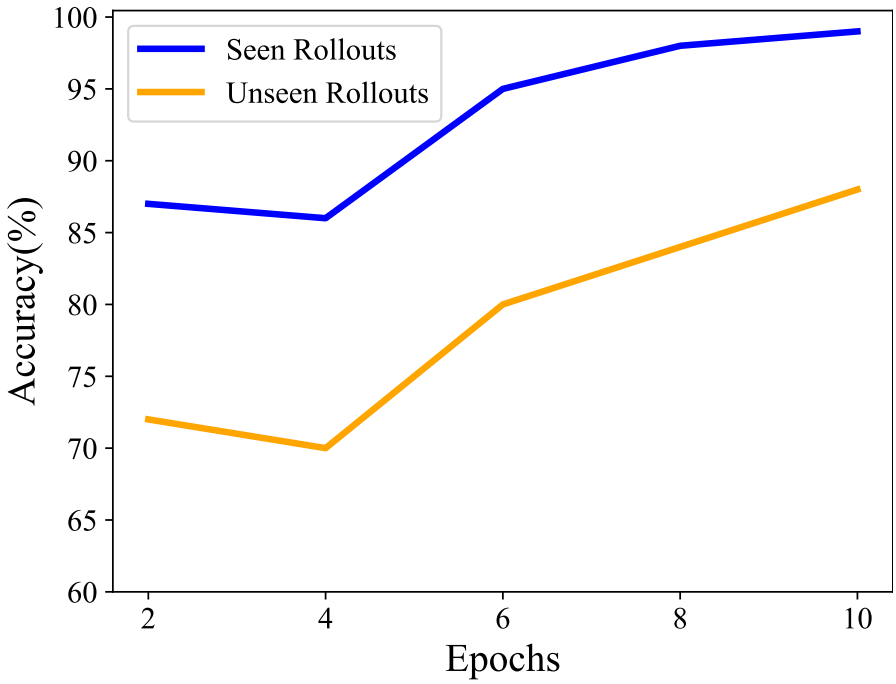

图 4-6　自然语言解释生成准确率

理解环境中的变化是实现强化学习轨迹和自然语言文本相互转换的关键，大语言模型必须准确捕捉这些变化以生成准确的轨迹或文本。本节通过实验评估

了经过微调的大语言模型是否能够充分理解并准确解释智能体在环境中的轨迹。实验中分别尝试了训练时使用的提示词和未见的提示词，具体的提示词展示在附录A.2中。量化的评估标准依然是准确率，模型将判断给定轨迹中球体的移动和方向，只有当两个球的选择及其移动方向全部匹配时，才被视作正确，结果展示在图4-6中。从结果可以看出，即使只经过两个 epoch 的训练，模型就能以非常高的正确率生成自然语言解释，并且正确率随着训练的持续还在不断提高。同时，大语言模型面对未见的提示词时，也能以较高的正确率生成自然语言解释。这说明在微调的过程中，大语言模型不仅学会了理解向量输入中的关键信息，而且依然保持了预训练中理解自然语言，输出自然语言的能力。

与4.2节相同，在准确率评估之外，本节还随机选取了一些轨迹的自然语言解释作为示例。无论是训练中使用的还是未见的提示词，模型均能以统一格式输出结果。部分示例如下：

- 解释正确的例子一
  - 模型解释：*The green ball is being moved **left** the cyan ball*
  - 实际含义：*The green ball is pushed to the **left** of the cyan ball*
- 解释正确的例子二
  - 模型解释：*The cyan ball is being moved the **front** the purple ball*
  - 实际含义：*Push the purple ball in **behind** of the cyan ball*
- 解释错误的例子
  - 模型解释：*The red ball is being moved **behind** the cyan ball*
  - 实际含义：*The blue ball is pushed in **behind** of the cyan ball*

我们可以发现，模型有时会将轨迹中球体的颜色和位置关系进行对称理解，例如解释正确的例子二。这种例子进一步证明了模型做到了对强化学习轨迹及其对应的自然语言描述的深入理解，并非仅仅是对训练数据的简单记忆。同时，即使部分轨迹被解释错误，也仅仅是一个球的颜色出错，更进一步说明了生成的自然语言解释的正确率较高。

4.4 消融实验

本研究进一步开展了消融实验，以评估对大语言模型进行指令微调的实际效果。为了形成有效的对照，本节采用了仅包含 100,000 条轨迹的原始离线数据集，通过监督学习，对大型语言模型进行了自然语言目标生成强化学习轨迹的微调。本研究选取了训练中最后五个 epoch 的模型检查点，并针对三个不同的随机种子进行了实验，将生成的轨迹的状态的准确率取平均，结果展示在图4-7中。图中所示的结果表明，经过指令微调的模型（标记为“w/ IFF”）在轨迹状态生成的准确率上超过了监督学习微调的模型（标记为“w/o IFF”）。特别是在未见任务（困难任务）维度上，指令微调后的模型明显展现出了更高的性能。这表明指令微调有助于大语言模型更有效地理解环境信息，并生成更高质量的轨迹。

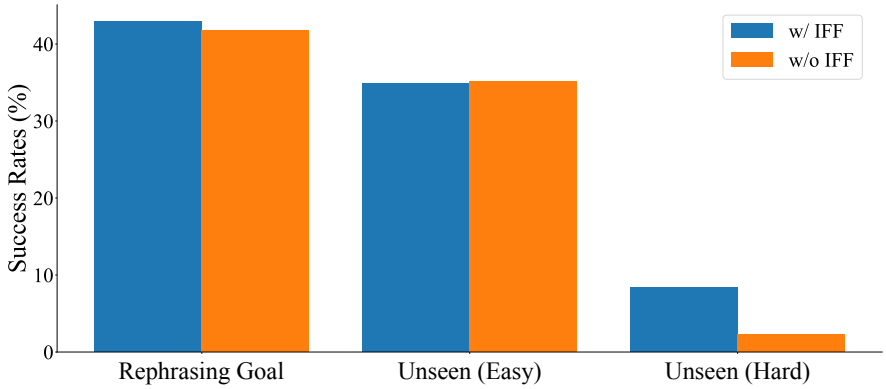

图 4-7　消融实验轨迹生成准确率

第五章　总结与展望

5.1　全文总结

自从 DeepMind 的 AlphaGo 战胜了人类顶尖棋手李世石之后，强化学习引起了学术界和工业界的广泛关注。其基于试错和反馈的学习机制具有显著的适应性和说服力，被认为是最有可能实现强人工智能的一种学习范式。然而，迄今为止，强化学习尚未在各个领域实现广泛的应用。其面临的两个主要问题包括：在真实环境中采样的代价较高或不可行，难以获取足够的数据以进行有效的训练；状态和动作数据以向量形式存在，组合成轨迹后的理解难度进一步增加。

本文针对这两个问题，提出了将自然语言引入强化学习轨迹的方法。借助自然语言的可解释性和其在不同任务和领域中的泛化能力，一方面，可以将大量以自然语言形式存在的知识和信息引入强化学习的训练过程中，从而增广强化学习的训练数据；另一方面，借助人类对自然语言的熟悉和理解，提高强化学习智能体行为的可解释性。

本文在前两章论述了人工智能发展的必然趋势、强化学习的广阔前景和目前强化学习进一步发展所面临的其中两个问题。在第三章中，本文提出可以引入自然语言，利用大语言模型的极强的表示能力，实现强化学习轨迹与自然语言文本之间的相互转化。在第四章，本文通过一系列实验，验证了大语言模型能够较好的实现强化学习轨迹与自然语言文本之间的相互转化，为解决强化学习数据量较少，可解释性较差提供了可行的思路。

本研究提出了一种新颖的方法，通过指令微调技术对大语言模型进行微调，将大语言模型与环境信息相结合，从而获得生成未见轨迹的能力。同时，本文还通过实验，检验了引入预训练的大语言模型，利用其内部知识生成或解释强化学习轨迹的可能性和有效性，验证了经过微调的大语言模型能够生成具有较高准确性和可靠性的未见轨迹。

5.2 未来展望

虽然本文提出了一种新颖的方法，通过预训练的大语言模型实现强化学习轨迹与自然语言文本的相互转换，一定程度上解决了强化学习数据稀缺和轨迹数据可解释性差的问题，但研究仍存在一些局限性和不足之处：

- 首先，实验设计存在局限性，主要体现在实验的广度和深度上。例如，本文的训练仅限于大语言模型对向量形式的状态数据的处理，而忽略了强化学习中常见的图像状态数据。未来的工作可以考虑对图像形式的状态数据组成的轨迹开展实验，在本文的方法框架上额外增加一个图片编码器来将图像转化为隐空间的向量。另外，本文仅在 CLEVR-Robot 这一个环境上进行了实验。如果能够在多样化的强化学习环境中进行实验能进一步增强本研究的说服力。
- 然后存在的不足是大语言模型需要同时学习输出状态和动作。要求单一模型同时学习状态和动作的表示，可能导致模型负担较重，学习效率下降。根据传统的强化学习框架，模型常被分为状态转移模型和策略模型。本文的方法相当于将这两种角色合并于单一模型之中。正如前文实验部分4.2所展示的，大语言模型输出状态的能力相对与输出动作的能力要更强，也许将输出状态与输出动作两个任务分配给两个独立的模型能够更好的输出高质量的轨迹。
- 此外，本研究的另一个局限在于其主要集中在语言模型的应用上。鉴于许多强化学习任务中的状态数据以图像形式存在，引入多模态的大模型，可能会进一步提升方法的性能。
- 最后的局限性在于本研究提出的方法还有进一步拓展的空间。未来的研究可以探索，在利用自然语言文本生成未见轨迹的基础上，应用离线强化学习方法进行训练，以验证这种方法是否确实能够实现数据增广，并提高智能体的学习效果，甚至让智能体学会训练数据中原本不存在的技能。

当前强化学习的发展与实现其最终目标——达到或超越人类水平的自主学习和决策能力——之间仍存在显著差距。这些差距既体现在学习能力上，又在解释能力上有所表现。人类能够通过自然语言高效地获取和传递知识，自主学习新技能，并能够用自然语言对复杂行为进行精确和有洞察力的解释。相比之下，强

化学习的大面积应用迟迟无法实现，或许正是因为这两方面的能力发展尚不足够。因此，如果我们能够在这两个方向努力发展，相互协作，则强化学习可以站在人类、其它智能体的肩膀上，从而加速向强人工智能的迈进。

参考文献

[1] RUSSELL S, NORVIG P. Artificial Intelligence: A Modern Approach (4th Edition)[M]. Pearson, 2020.

[2] 中华人民共和国国民经济和社会发展第十四个五年规划和 2035 年远景目标纲要[R]. 人民日报, 2021.

[3] SUTTON R S, BARTO A G. Reinforcement Learning: An Introduction[M]. MIT Press, 1998.

[4] LEVINE S, KUMAR A, TUCKER G, et al. Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems[J]. CoRR, 2020, abs/2005.01643. arXiv: 2005.01643.

[5] LUKETINA J, NARDELLI N, FARQUHAR G, et al. A Survey of Reinforcement Learning Informed by Natural Language[C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI). Macao, China: International Joint Conferences on Artificial Intelligence Organization, 2019: 6309-6317.

[6] 马岽㝵, 唐娉, 赵理君, 等. 深度学习图像数据增广方法研究综述[J]. 中国图象图形学报, 2021, 26(03): 487-502.

[7] YARATS D, KOSTRIKOV I, FERGUS R. Image Augmentation Is All You Need: Regularizing Deep Reinforcement Learning from Pixels[C]//Proceedings of the 9th International Conference on Learning Representations (ICLR). Virtual: OpenReview.net, 2021.

[8] LASKIN M, LEE K, STOOKE A, et al. Reinforcement Learning with Augmented Data[C]//Advances in Neural Information Processing Systems (NeurIPS). Virtual: Curran Associates, Inc., 2020: 19884-19895.

[9] YU T, LAN C, ZENG W, et al. PlayVirtual: Augmenting Cycle-Consistent Virtual Trajectories for Reinforcement Learning[C]//Advances in Neural Information Processing Systems (NeurIPS). Virtual: Curran Associates, Inc., 2021: 5276-5289.

[10] MA G, WANG Z, YUAN Z, et al. A Comprehensive Survey of Data Augmentation in Visual Reinforcement Learning[J]. CoRR, 2022, abs/2210.04561. arXiv: 2210.04561.

[11] PUIUTTA E, VEITH E M S P. Explainable Reinforcement Learning: A Survey[C]//Lecture Notes in Computer Science: Proceedings of the 4th International Cross-Domain Conference for Machine Learning and Knowledge Extraction (CD-MAKE): vol. 12279. Dublin, Ireland: Springer International Publishing, 2020: 77-95.

[12] WANG X, YUAN S, ZHANG H, et al. Verbal Explanations for Deep Reinforcement Learning Neural Networks with Attention on Extracted Features[C]//Proceedings of the 28th IEEE International Conference on Robot and Human Interactive Communication (RO-MAN). New Delhi, India: IEEE, 2019: 1-7.

[13] BASTANI O, PU Y, SOLAR-LEZAMA A. Verifiable Reinforcement Learning via Policy Extraction[C]//Advances in Neural Information Processing Systems (NeurIPS). Montréal, Canada: Curran Associates, Inc., 2018: 2499-2509.

[14] JIANG Z, LUO S. Neural Logic Reinforcement Learning[C]//Proceedings of Machine Learning Research: Proceedings of the 36th International Conference on Machine Learning (ICML): vol. 97. Long Beach, CA: PMLR, 2019: 3110-3119.

[15] 刘潇, 刘书洋, 庄韫恺, 等. 强化学习可解释性基础问题探索和方法综述[J]. 软件学报, 2023, 34(05): 2300-2316.

[16] PUTERMAN M L. Markov Decision Processes: Discrete Stochastic Dynamic Programming[M]. Wiley, 1994.

[17] WEI J, TAY Y, BOMMASANI R, et al. Emergent Abilities of Large Language Models[J]. Transactions on Machine Learning Research, 2022.

[18] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is All you Need[C]//Advances in Neural Information Processing Systems (NeurIPS). Long Beach, CA: Curran Associates, Inc., 2017: 5998-6008.

[19] WEI J, BOSMA M, ZHAO V, et al. Finetuned Language Models are Zero-Shot Learners[C]//Proceedings of the 10th International Conference on Learning Representations (ICLR). Virtual: OpenReview.net, 2022.

[20] SZOT A, SCHWARZER M, AGRAWAL H, et al. Large Language Models as Generalizable Policies for Embodied Tasks[C]//Proceedings of the 12th International Conference on Learning Representations (ICLR). Vienna, Austria: OpenReview.net, 2024.

[21] JIANG Y, GU S (, MURPHY K P, et al. Language as an Abstraction for Hierarchical Deep Reinforcement Learning[C]//Advances in Neural Information Processing Systems (NeurIPS). Vancouver Canada: Curran Associates, Inc., 2019: 9414-9426.

[22] TODOROV E, EREZ T, TASSA Y. MuJoCo: A physics engine for model-based control[C]//Proceedings of the 25th IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Algarve, Portugal: IEEE, 2012: 5026-5033.

[23] PANG J C, YANG X Y, YANG S H, et al. Natural Language Instruction-following with Task-related Language Development and Translation[C]//Advances in Neural Information Processing Systems (NeurIPS). New Orleans, LA: Curran Associates, Inc., 2023: 9248-9278.

[24] TEAM O. ChatGPT[Z]. https://chat.openai.com. 2023.

[25] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: Open Foundation and Fine-Tuned Chat Models[J]. CoRR, 2023, abs/2307.09288. arXiv: 2307.09288.

致　　谢

四年的本科时光转瞬即逝。回顾自己的大学生活，有愉快也有悲伤，有成功也有失败，有许多人陪我走过了这段跌跌撞撞又充满快乐的时光。

在这段时间里，我最要感谢的是我的指导老师俞扬教授。自从大三提前进入俞老师的课题组开始科研，俞老师就一直带领着我在机器学习领域里不断的探索和学习。俞老师积极联系了博士生与硕士生对我进行指导，让我深度参与项目，受益匪浅。在治学之外，俞老师谦逊而风趣的为人处世态度也让我深深折服。跟随俞老师的这段时间，我不仅从俞老师身上学习到了对于学术的严谨认真，更被俞老师的学者风范所深深影响，能够不盲从大流，低调谦逊，在自己所认同的方向上深耕细作，数量质量两手抓，令人敬佩。

其次，我要感谢俞老师门下各位师兄们，在我遇到困难时不吝赐教，慷概指导。博士生师兄庞竞成自我进组以来对我的帮助最大，积极指导我科研的方向，在遇到不论是方法上的问题还是实验上的问题时都会悉心指导。同时还要感谢与我一同开展本研究的硕士生师兄杨思航，和我一起完成本项目，并且在一些问题上将自己的经验无私传授给我。

最后感谢南京大学 Linux 用户组维护的NJU Thesis项目，为广大南京大学同学提供了本科生毕业论文、研究生学位论文、博士后出站报告的 LaTeX 文档，极大地便利了我们的论文写作。

附录 A　使用的提示词

A.1　指令微调提示词

- 动力学预测：*You are an expert in identifying dynamics change in the environment. Current state is [s_t], after executing action [a_t], we get next state: [ANSWER].*
- 文本生成：*Translate the state/action trajectory to textual instruction.\nTrajectory: [TRAJECTORY]\nInstruction: [ANSWER].*
- 轨迹生成：*Translate the textual instruction to state/action trajectory.\nInstruction: [INSTRUCTION].\nTrajectory: [ANSWER]*
- 结果预测：*Initial state is [s_0], after completing the instruction [INSTRUCTION], we get terminal state [ANSWER].*

[ANSWER] 处为大语言模型需要生成的内容

A.2　文本生成提示词

- 训练时使用的提示词：*Translate the state/action trajectory to textual instruction.\nTrajectory: [TRAJECTORY]\nInstruction: [ANSWER].*
- 未见的提示词：*Suppose you are playing a gaming of five balls with different colors. Please explain the following trajectory briefly.\nTrajectory: [TRAJECTORY]\Answer:[ANSWER]*

[ANSWER] 处为大语言模型需要生成的内容

附录 B　未见任务的自然语言目标

B.1　未见文本

我们为此维度准备了 40 种不同的自然语言来描述目标。如果我们的任务涉及的物体是“*red ball*”和“*blue ball*”，那对应的自然语言目标为：

- I can’t stand the red ball ahead of the blue one. Could you switch the positions of them?
- The sight of the red ball ahead of the blue one bothers me. Can we reverse their order?
- I really dislike how the red ball is positioned in front of the blue ball. Could you exchange their places?
- It annoys me to see the red ball in front of the blue ball. Can we swap them around?
- Seeing the red ball ahead of the blue ball fills me with frustration. Let’s switch them.
- The placement of the red ball in front of the blue ball is something I detest. Can you flip them?
- I can’t bear to see the red ball positioned in front of the blue ball. Would you mind interchanging them?
- It irks me to have the red ball come in front of the blue ball. Could we trade their positions?
- The red ball being in front of the blue ball is something I can’t tolerate. Let’s switch them up.
- It really bothers me that the red ball precedes the blue ball. Can we swap their positions, please?
- Move the red ball gently to the left of the blue ball.

- Slowly nudge the red ball to the left side of the blue ball.
- Push the red ball towards the left of the blue ball at a leisurely pace.
- Slide the red ball to the left of the blue ball with a gentle touch.
- Gradually maneuver the red ball to the left side of the blue ball.
- Hasten the movement of the red ball to the left of the blue ball promptly.
- Expeditiously maneuver the red ball to the left side of the blue ball.
- Swiftly propel the red ball to the left, positioning it adjacent to the blue ball.
- Urgently shift the red ball to the left of the blue ball with rapidity.
- Accelerate the motion of the red ball towards the left of the blue ball expeditiously.
- Push the red sphere ahead of the blue sphere.
- Drive the red orb in front of the blue orb.
- Launch the red ball forward, preceding the blue one.
- Catapult the red sphere ahead of the blue sphere.
- Thrust the red sphere in front of the blue sphere.
- Propel the red-colored orb forward, leading the blue-colored orb.
- Send the red ball ahead of the blue ball.
- Fling the red sphere in front of the blue sphere.
- Hurl the red ball forward, preceding the blue ball.
- Cast the red sphere ahead of the blue sphere.
- The sight of the red ball positioned to the right of the blue ball brings me joy.
- It pleases me to observe the red ball situated on the right side of the blue ball.
- Seeing the red ball to the right of the blue ball fills me with happiness.
- I feel delighted witnessing the red ball located to the right of the blue ball.
- It brings me satisfaction to see the red ball positioned to the right of the blue ball.
- I am happy to notice the red ball situated on the right-hand side of the blue ball.
- Observing the red ball to the right of the blue ball brings me contentment.
- I am pleased by the arrangement of the red ball to the right of the blue ball.
- The red ball being on the right side of the blue ball gives me a sense of satisfaction.
- I find joy in the sight of the red ball being positioned to the right of the blue ball.

B.2 未见任务（简单）

我们为此维度准备了 80 种不同的自然语言来描述目标。如果我们的任务涉及的物体是“*red ball*”，那对应的自然语言目标为：

- Move the ball backward, it’s red.
- Push the red ball in reverse.
- Back up the red ball, please.
- Shift the red ball backwards.
- Can you move the red ball backwards?
- Retract the red ball, moving it backwards.
- Put the red ball in backward motion.
- Move the red ball back, not forward.
- Send the red ball backward, if you can.
- Maneuver the red ball to the rear.
- Drive the red ball backward, please.
- Pull the red ball back.
- Make the red ball move backwards.
- Shift the red ball rearward.
- Go backwards with the red ball.
- Execute a backward movement with the red ball.
- Make the red ball’s position backward.
- Pull the red ball towards the back.
- Slide the red ball backwards.
- Propel the red ball backward, if possible.
- Kindly relocate the red sphere towards the left.
- Would you mind shifting the red orb to the left?
- I request that you move the red spherical object to the left.
- Could you please transfer the red ball towards the left?
- It would be appreciated if you could shift the red ball to the left.
- Please adjust the position of the red ball to the left.

- Kindly reposition the red ball to the left.
- I'd like you to move the red ball to the left, please.
- Please ensure the red ball is moved to the left.
- Could you relocate the red ball to the left?
- Please shift the red ball leftwards.
- Please slide the red ball over to the left.
- I need you to move the red ball leftward, please.
- Please nudge the red ball towards the left.
- Please push the red ball to the left.
- Would you kindly push the red ball towards the left?
- Kindly shift the red ball in the leftward direction.
- Could you move the red ball to the left side?
- It's required that you move the red ball towards the left.
- Please execute a leftward movement of the red ball.
- Kindly shift the red sphere ahead.
- Would you mind advancing the red orb?
- Can you push the red ball onward?
- Please nudge the red-colored sphere ahead.
- Kindly relocate the red-colored orb forward.
- Would you be so kind as to move the red-colored ball forward?
- Can you shift the red-colored sphere ahead?
- Please push the red-hued orb onward.
- Kindly advance the red-colored ball forward.
- Would you mind nudging the red sphere ahead?
- Can you move the red-colored ball forward?
- Please shift the red-toned orb onward.
- Kindly relocate the red-hued sphere forward.
- Would you be so kind as to push the red-colored ball forward?
- Can you nudge the red-colored sphere ahead?
- Please move the red-colored orb forward.

- Kindly advance the red-hued ball forward.
- Would you mind shifting the red sphere ahead?
- Can you push the red-colored orb onward?
- Please nudge the red-hued ball forward.
- Kindly relocate the red sphere to the starboard side.
- Move the red orb towards the right.
- Could you shift the red ball to the right?
- I request that you move the red ball to the right.
- Please shift the red ball to the right.
- Move the ball, which is red, to the right.
- Would you mind moving the ball, which is colored red, to the right?
- Kindly relocate the spherical object of red hue towards the right.
- Can you shift the ball, which happens to be red, to the right?
- I'd appreciate it if you could move the red ball to the right.
- Please adjust the position of the red ball to the right.
- Could you possibly move the red ball to the right?
- It would be great if you could move the red ball to the right.
- Kindly transfer the red-colored ball to the right.
- Move the ball that has the color red to the right.
- Would you kindly relocate the ball, specifically the red one, to the right?
- Please make the red ball move to the right.
- Can you shift the ball that's red to the right?
- Move the ball with the red hue to the right, please.
- Could you adjust the position of the ball, specifically the one that's red, to the right?

B.3 未见任务（困难）

我们设计了四种任务来测试微调后的大语言模型在完全未见的困难任务上的性能：两种简单任务的组合、三种简单任务的组合、物品布置和物品收集。

- 用于进行简单任务组合的自然语言模板。如果我们的任务是“*red ball behind blue ball*”，那对应的自然语言目标为：

    1. Push the red ball behind the blue ball.
    2. Move the red ball behind the blue ball.
    3. Keep the red ball behind the blue ball.
    4. Help me push the red ball behind the blue ball.
    5. Help me move the red ball behind the blue ball.
    6. Help me keep the red ball behind the blue ball.

- 两种简单任务的组合：Push the red ball behind the blue ball and move the green ball behind the purple ball.
- 三种简单任务的组合：Push the red ball behind the blue ball and move the green ball to the left of the purple ball and keep the cyan ball in front of the red ball.
- 物品布置

    1. Place the balls horizontally, lining them up from left to right, in the order of red, blue, green, purple, and cyan.
    2. Set up the balls in a row from left to right, with red, blue, green, purple, and cyan in sequence.
    3. Arrange the balls in a line, moving from left to right, with red, blue, green, purple, and cyan.
    4. Position the balls horizontally, organizing them from left to right, following the sequence of red, blue, green, purple, and cyan.
    5. Line up the balls horizontally, sequencing them left to right as follows: red, blue, green, purple, and cyan.
    6. Order the balls in a row from left to right, with the sequence being red, blue, green, purple, and cyan.
    7. Arrange the balls in a horizontal line, starting from the left and proceeding to the right, with red, blue, green, purple, and cyan in order.
    8. Place the balls in a row horizontally, from left to right, in the sequence: red, blue, green, purple, and cyan.

9. Set up the balls horizontally, arranging them in the order of red, blue, green, purple, and cyan from left to right.
10. Line up the balls horizontally, sequencing them from left to right: red, blue, green, purple, and cyan.
11. Position the balls in a horizontal row, ordering them left to right as follows: red, blue, green, purple, and cyan.
12. Organize the balls horizontally, moving from left to right, with the sequence being red, blue, green, purple, and cyan.
13. Place the balls in a line horizontally, arranging them from left to right, in the following order: red, blue, green, purple, and cyan.
14. Set up the balls in a row horizontally, starting from the left and proceeding to the right, with red, blue, green, purple, and cyan in sequence.
15. Arrange the balls in a horizontal line, sequencing them left to right as follows: red, blue, green, purple, and cyan.
16. Order the balls in a horizontal row from left to right, with the sequence being red, blue, green, purple, and cyan.
17. Position the balls horizontally, organizing them in the order of red, blue, green, purple, and cyan from left to right.
18. Line up the balls horizontally, arranging them from left to right: red, blue, green, purple, and cyan.
19. Place the balls in a horizontal row, ordering them left to right as follows: red, blue, green, purple, and cyan.
20. Set up the balls in a row horizontally, moving from left to right, with the sequence being red, blue, green, purple, and cyan.

- 物品收集

1. Position all the other balls around the green ball, considering it as the circle's focal point.
2. Use the green ball as the nucleus of the circle, arranging the rest around it.
3. Let the green ball be the anchor of the circle, and arrange the others accord-

ingly.

4. Make the green ball the center of attention in the circle and rearrange the others accordingly.
5. Arrange all other balls around the green one, treating it as the hub of the circle.
6. Centralize the circle around the green ball, repositioning the others accordingly.
7. Focus the circle around the green ball, adjusting the positions of the others.
8. Orient the other balls around the green one, treating it as the central axis of the circle.
9. Use the green ball as the reference point for the circle's arrangement, positioning the others around it.
10. Position all the other balls around the green ball to create the circle.
11. Arrange the other balls around the green ball, making it the center of the circle.
12. Let the green ball dictate the layout of the circle, with the other balls positioned around it.
13. Create the circle with the green ball as the center, arranging the others accordingly.
14. Use the green ball as the pivot for the circle, arranging the other balls around it.
15. Organize the circle around the green ball, adjusting the positions of the other balls.
16. Centralize the arrangement of the circle around the green ball, repositioning the others.
17. Treat the green ball as the central node of the circle and arrange the other balls accordingly.
18. Position all the other balls around the green ball, with it as the focal point of the circle.
19. Arrange the circle with the green ball at the center and the others positioned

around it.

20. Base the arrangement of the circle on the green ball, repositioning the others accordingly.