南京大学

本 科 毕 业 论 文

院　　系　人工智能学院

专　　业　人工智能

题　　目　反绎学习加速方法研究

年　　级　2021　学　　号 211300005

学生姓名　李琪杰

指导教师　姜远　职　　称　教授

提交日期　2025 年 6 月 5 日

南京大学本科毕业论文（设计）
诚信承诺书

本人郑重承诺：所呈交的毕业论文（设计）（题目：反绎学习加速方法研究）是在指导教师的指导下严格按照学校和院系有关规定由本人独立完成的。本毕业论文（设计）中引用他人观点及参考资源的内容均已标注引用，如出现侵犯他人知识产权的行为，由本人承担相应法律责任。本人承诺不存在抄袭、伪造、篡改、代写、买卖毕业论文（设计）等违纪行为。

作者签名：李瑾杰

学号：211300005

日期：2025年5月22日

南京大学本科生毕业论文（设计、作品）中文摘要

题目：反绎学习加速方法研究

院系：人工智能学院

专业：人工智能

本科生姓名：李琪杰

指导教师（姓名、职称）：姜远　教授

摘要：

融合机器学习与逻辑推理是人工智能领域的一个圣杯问题，多年来研究者们一直致力于开发能将二者联合统一的高效算法，并取得了相当丰富的研究成果。其中，反绎学习 (Abductive Learning, ABL) 作为一个新型的机器学习与逻辑推理协同优化框架，在多个领域的任务上都取得了优异的性能。然而，目前反绎学习仍面临着推理效率低下，模型难以收敛的问题。反绎学习通过反绎推理为弱监督样本提供符合逻辑规则的监督信号。然而通常存在多个满足规则的推理结果，机器学习模型在训练过程中难以判断哪一个反绎结果才是正确的监督信号，从而可能受到错误监督的干扰，导致模型性能下降。

为应对上述问题，本文提出多阶段反绎学习 (Multi-Stage Abductive Learning, MSABL) 框架，仿照人类循序渐进地学习新知识的特性，利用知识库规则的内在结构，将原数据集拆分为多个由易到难的切片，并让模型依次在这些切片上学习。MSABL 在缩小反绎空间的同时，能够更加精准地选择正确的反绎推理结果。考虑到更换切片的过程中存在的数据分布变化，本文还在此基础上引入拒绝反绎机制，提出多阶段拒绝反绎学习 (Multi-Stage with Rejection Abductive Learning, MSRABL) 框架，以进一步提升反绎精度，并保持训练过程的稳定性。本文实验部分将所提出的框架用于 Addition 与 Max 任务，取得了超越已有框架的性能。其中 MSRABL 在 Max 任务上能够大幅超越其它反绎学习框架，展示了本文所提出方法的有效性。

关键词：机器学习；深度学习；反绎学习；逻辑推理

南京大学本科生毕业论文（设计、作品）英文摘要

THESIS: Research on the Acceleration Methods for Abductive Learning

DEPARTMENT: School of Artificial Intelligence

SPECIALIZATION: Artificial Intelligence

UNDERGRADUATE: Qi-Jie Li

MENTOR: Professor Yuan Jiang

ABSTRACT:

Integrating machine learning and logical reasoning is a holy grail problem in artificial intelligence. Researchers have been working for years to develop efficient algorithms which can jointly unify them, and have achieved considerable results. Among them, Abductive Learning (ABL), as a novel co-optimization framework for machine learning and logical reasoning, has achieved dramatic performance on tasks in several domains. However, ABL still faces the problems of inefficient reasoning and difficult model convergence at present. ABL provides supervised signals that satisfy logical rules for weakly supervised samples through abduction. But there usually exist many abduction results that satisfy the rules, and it is difficult for a machine learning model to determine which is the correct supervision during the training process. Thus the model may be interfered with by incorrect supervision and lead to degradation of its performance.

To deal with the problems mentioned above, this paper proposes the Multi-Stage Abductive Learning (MSABL) framework, which is modeled on the human characteristic of learning new knowledge step by step. MSABL takes advantage of the intrinsic structure of the rules in the knowledge base to split the original dataset into multiple slices ranging from easy to difficult, and allows the model to learn on these slices sequentially. MSABL is able to more accurately select the correct abduction result while reducing the abduction space. Considering the variation of data distribution in the slice substitution process, this paper also introduces the rejection mechanism on this basis, and proposes the Multi-Stage Rejection Abductive Learning (MSRABL) framework to further improve the abductive accuracy and maintain the stability of the training process.

In the experimental part of this paper, proposed frameworks are applied to Addition and Max tasks, and the performance beyond the existing frameworks is achieved. Among them, MSRABL is able to significantly outperform other ABL frameworks on the Max task, demonstrating the effectiveness of the method proposed in this paper.

KEYWORDS: Machine Learning; Deep Learning; Abductive Learning; Logic Reasoning

目　　录

目　　录 IV

第一章 绪论 1

1.1 引言 1

1.2 研究现状 3

1.3 待研究问题 4

1.4 本文工作 5

第二章 相关工作及背景介绍 7

2.1 反绎推理 7

2.2 反绎学习 8

2.3 神经符号学习 11

2.4 本章小结 12

第三章 多阶段反绎学习 13

3.1 MSABL 框架 13

3.2 MSRABL 框架 17

3.3 本章小结 20

第四章 实验 21

4.1 Addition 任务 21

4.2 Max 任务 22

4.3 结果分析 23

4.3.1 Addition 任务 23

4.3.2 Max 任务 23

4.3.3 案例研究 25

4.4 本章小结 28

第五章 总结与展望 29

参考文献 31

致 谢 35

第一章　绪论

1.1　引言

人工智能（Artificial Intelligence，AI）旨在研究如何让机器具备类似人类的智能，如感知、学习、推理、规划、决策等能力。机器学习（Machine Learning，ML）作为人工智能领域的主要分支，通过数据与算法的训练，使得计算机主动从海量数据中学习潜在分布与规律，并帮助人类完成识别、理解、预测和决策等任务。机器学习模型能够独立执行一些先前需要人类智慧介入的任务，在图像视频处理、自然语言理解、语音识别和自动驾驶等领域都有广泛应用。

现阶段机器学习算法主要依赖于深度神经网络（Deep Neural Network，DNN）模型，其核心思想是模拟人脑中神经元之间传递电信号的方式，来建模人类对外界环境的“感知”过程。通过大规模数据驱动的训练过程，深度神经网络能够自动学习图像、语音、文本等多模态信息的特征表示，实现对复杂环境的识别与理解。与之形成对比的是，在人工智能发展的早期阶段，研究者大多关注专家系统等基于符号推理的方法。这一类方法通过人工构建的知识库和精确的符号规则，结合逻辑推理算法，来建模人类认知“推理”的过程。当时专家系统在某些封闭、规则明确的领域中曾取得显著成果。然而，随着现实问题的复杂性增加，基于逻辑推理的系统暴露出诸多局限性。知识获取与特征工程高度依赖人工处理，规则系统难以扩展，应对模糊、噪声信息的鲁棒性不足，专家系统的推理效率也受到算法复杂度的限制。与此同时，在互联网和大数据时代，数据获取非常容易，加之硬件算力的飞跃发展，使得能够自动学习的深度神经网络迅速崛起。在此背景下，以专家系统为代表的“符号主义”流派逐渐失去了主导地位，而以深度神经网络为代表的“连结主义”学派则逐渐成为人工智能领域的主流方向，在计算机视觉、自然语言处理等领域中取得突破性成果，成为当前人工智能发展的中流砥柱。

近年来，研究者面临机器学习模型在注重逻辑推理的任务上表现不佳的问

题，重新将研究重心转向符号推理领域，希望以逻辑推理所具有的严谨可信的优点来弥补现有机器学习模型的不足。一个重要的发展趋势是将机器学习与逻辑推理两个模块进行整合，从而让模型像人类一样同时具备强大的感知能力与严谨的推理能力，以实现更可信、更智能的决策[1]。

当前广泛应用的深度神经网络等机器学习模型虽然在图像识别、语言处理等感知任务中表现卓越，然由于机器学习模型遵从概率近似正确（Probably Approximately Correct，PAC）学习理论，对于未见或分布外样本，无法保证其预测结果的绝对正确[2-3]。如今应用广泛的深度神经网络是典型的黑盒模型，其可解释性十分欠缺；且模型的体量十分庞大，大模型动辄就含有上亿的参数量，使得探究其预测与决策的原理变得异常困难。然而诸多现实任务对预测精度和正确率都有极高的要求，需要使用高度可解释可信赖的机器学习模型，而目前的机器学习技术尚不能应对如此挑战。

与此同时，逻辑推理因其正确性与严谨性而被用于定理证明与关系归纳推理，能够弥补机器学习模型在先验知识与可信度上的欠缺。然而与机器学习不同的是，逻辑推理本身并不具备高效的从原始数据中主动学习并自动转换为逻辑事实的能力，难以应对开放世界中复杂的感知任务。面对现实世界的庞大数据量，若仅利用逻辑推理系统从中挖掘并归纳出一般性的规则，代价及其高昂。因此，融合机器学习的强大感知能力与逻辑推理的严谨可信的特性，成为构建下一代人工智能系统的关键方向。

然而这一融合存在两大难点：一是逻辑推理的可满足性问题本质上是组合优化问题，常被编码为布尔可满足性（SAT）或整数线性规划等形式，属于 NP-hard 问题，求解复杂度高[4]；二是逻辑推理基于离散符号归结，而机器学习或是深度学习往往依赖于梯度下降等连续优化方法，离散和连续二者难以在同一个框架中协同运作。

下一代人工智能的发展需要数据与知识的“双驱动”：机器学习模型不仅需要大规模数据的支持，更需要深层次的领域知识保障，唯有实现数据与知识的“双驱动”协同，才能真正推动人工智能迈向更高的智能水平。构建一个统一的框架，使得机器学习与逻辑推理这两种不同且互补的模块得以协同运作，从而实现感知与推理的深度融合与相互促进，是推动人工智能走向可信赖、高效能和通用化的必由之路。只有具备这种综合性的智能体系，人工智能系统在面对错综复

杂的现实世界任务时，才能展现出更强的泛化能力、更高的决策效率以及更高的可信度。因此，这种数据与知识的“双驱动”的发展路径，具有重大的实践意义，尤其在智慧医疗、自动驾驶、金融风控、军事装备等关键应用领域中，将带来突破性的进展。

1.2 研究现状

为了充分结合神经网络对海量数据建模的“感知”能力和符号规则系统的“推理”能力，数十年以来，研究者们一直致力于探寻整合二者的方法[5-6]。近期的研究工作中也不乏一些经典的算法或框架。有一些研究者尝试将规则转换为对模型参数的约束。其中一种方法是将逻辑规则约束嵌入训练模型的损失函数，希望模型输出的概率与规则达到最大程度的匹配[7]。另有一些与之相似的方法将这种思想应用于各种不同类型的逻辑约束中[8-9]。另一些研究者尝试使用包含神经网络与推理模块的混合系统。其中一些方法将神经网络与概率逻辑推理结合，并使用可微的概率推理过程计算梯度对神经网络做反向传播[10-12]；而另一些方法则使用了模态逻辑，将常规的二值逻辑连续化以处理不确定性[13]。还有一些方法将逻辑推理松弛为优化问题，并将优化参数作为神经网络层的参数，以实现端到端的模型推理[14-15]。

然而，上述框架有的侧重于模型的学习过程，而有的则注重推理模块的设计，并没有做到学习与推理二者兼顾，也即没有将机器学习与符号推理的潜力完全发挥出来。反绎学习（Abductive Learning，ABL）[16-17]框架则能够在学习与推理间取得平衡。在反绎学习的训练过程中，首先由机器学习模型处理无标记数据，输出对应的预测标签，称为伪标记。然后，逻辑推理模块基于先验知识（通常为一阶逻辑表达式集合），通过反绎推理修正伪标记，并尽可能使得修正后的伪标记的推理结果与事实一致。之后用修正后的伪标记重新训练模型，并将训练后的模型用于下一次迭代过程。通过多次迭代循环，可以使得模型的预测符合通过先验知识推理得到的逻辑事实。

在反绎学习框架提出后，不少研究者在其基础上进行了跟进工作，在多种方向与各个领域都有改进与应用。一些研究者通过理论分析反绎学习的可行性与有效性[18-19]；一些研究者提出加快反绎学习反绎与收敛速度的方法[20-23]；还

有一些研究旨在从数据中挖掘新的规则，或修改错误规则，以增强逻辑推理模块[24-25]。此外，反绎学习也被应用于多个现实任务中[26-29]，展示了反绎学习优秀的性能。反绎学习在机器学习与逻辑推理的结合方面进行了可行的探索，并在多个现实场景应用中取得了优于其它算法的性能，验证了反绎学习的优越性。

1.3 待研究问题

反绎学习框架将机器学习与逻辑推理结合的特性，使其在现实场景任务中能够可靠地运行，并取得优秀的模型性能，有着很高的应用价值。然而，反绎学习在效率方面仍面临诸多亟待解决的问题与挑战。因此，本文将主要研究加速反绎学习模型收敛并提高模型泛化性能的方法。

在反绎学习框架的反绎推理过程中，逻辑推理模块需要基于模型预测输出的伪标记和预定义的符号规则通过反绎推理修正伪标记，并尽可能使得修正后的伪标记的推理结果与事实结果一致。在后续对模型重新训练时，即将修正后的伪标记视为真实标记。反绎标记与样本真实标记是否一致将直接影响训练后模型的性能。在反绎学习中，我们希望通过反绎推理修正后的伪标记尽量与真实标签一致。然而，反绎结果的候选集通常包含多个反绎结果，当知识规则较为复杂时，针对一组伪标记甚至有成千上万种可能的反绎标记，而其中仅有一种符合事实，这使得从中选择正确的反绎结果非常困难。如果从中选择出错误的反绎结果，则会在之后的训练过程中误导模型，从而导致模型收敛速度变慢[19]，最坏情况下模型参数会落入局部最优，之后便难以再跳脱出来。更糟糕的是，当模型的泛化性能下降时，下一轮模型输出的伪标记的质量也会随之下降，接着导致反绎过程更加耗时，甚至反绎结果也会逐渐偏离事实，陷入了恶性循环。由此可见，如何设计学习流程能够缩小反绎结果候选集的大小，以及如何设计从候选集中选择符合事实的反绎结果的策略，对反绎学习学得的模型性能的好坏，起到关键作用。

以往的方法中，有的依赖于样本特征的相似性度量，当相似的样本被反绎为同一类时可以获得更高的分数，最后选择得分最高的反绎结果用于训练模型[21]。然而，以图像分类任务为例，在训练的初期阶段，模型对图像的特征提取能力很弱。对于噪声较大，特征较为复杂的图像，得到的特征图（向量）在特征空间内

近似随机分布，这意味着特征相似与类别相同两者关系不大，根据样本相似度来反绎的结果也很有可能失真。还有的方法借鉴 WMC（Weighted Model Counting）的思想，根据模型预测的概率，为反绎结果分配权重[22]。这需要事先就列举出所有的反绎结果，可以应用在知识规则比较简单的场景。这些方法在巨大的反绎空间与候选集的情况下，计算开销非常大。如何在反绎空间与反绎结果候选集都较大时，仍能保持高效率地进行反绎推理，是加速反绎学习过程的一个重要挑战。

1.4 本文工作

针对1.3节所述的问题与挑战，本文提出一种创新性的加速反绎学习过程的框架和方法，并进行了实验验证。本文的主要工作如下：

为缓解反绎空间较大而带来的反绎结果选择困难的问题，本文提出多阶段反绎学习（Multi-Stage Abductive Learning，MSABL）框架。与已有方法不同，MSABL 框架能够缩减反绎结果候选集的大小。以往的方法将知识库视为一个黑箱，并不关注其内在结构与所含规则间的依赖关系。如果能够分析并利用知识库自身的结构与性质，来降低反绎推理的复杂度并缩减反绎结果候选集，可以进一步优化反绎结果的选择过程，从而加速模型的收敛。事实上，许多知识库都存在分阶段的特征，所以知识库中的规则往往可以按复杂程度分为若干阶段。MSABL 框架的核心思想即是将原始任务分解为由易到难的多个子阶段，让模型先去学习那些容易从数据和知识库中分辨出来的类别，之后逐渐加入难度更大，更难区分的类别，循序渐进式地学习。最后再使用全部的数据做反绎学习，使得模型在保持容易类别上的优秀分类性能的同时，提升模型在困难类别上的性能。基于 MSABL 的进一步改进，同时借鉴拒绝推理[20]的思想，本文还提出了 MSRABL（Multi-Stage with Rejection Abductive Learning，MSRABL）框架，对于高度不确定的反绎结果，拒绝给出反绎标记，避免错误监督对模型训练的干扰，提升训练过程的稳定性。实验结果表明，所提出的 MSABL 与 MSRABL 框架在多个任务上均优于现有的反绎学习加速方法，具有更高的反绎正确率与更好的泛化性能。为进一步验证方法在复杂反绎场景下的有效性，本文设计了一项新型反绎学习任务：Max 任务。该任务与 DeepProbLog 中提出的 MNIST Addition 相似，但是将加法规则替换为最大值规则。Max 任务相比于 Addition 任务，其带来

的监督信号更弱，反绎空间也更大，难度更高。

本文余下的内容将以如下结构进行组织：在第二章，本文将详细介绍有关反绎推理和反绎学习框架的背景知识，以及与反绎学习相关的研究工作进展；在第三章，本文将介绍 MSABL 框架以及 MSRABL 框架的流程和实现细节；在第四章，本文将展示提出的框架在多种数据集上的实验结果并加以分析；在第五章，本文将对本篇工作进行总结和展望。

第二章　相关工作及背景介绍

本章将详细介绍与本文工作相关的已有研究成果。在2.1节中，本文将介绍反绎学习的底层机制——反绎推理的概念。在2.2节中，本文将详细介绍反绎学习的流程以及在该领域已有的研究成果。在2.3节中，本文将介绍其它经典的神经符号学习框架。

2.1　反绎推理

反绎推理（Abductive Reasoning）是一种基本的逻辑推理形式，根据给定的一套逻辑规则，通过观测到的事实反向推测导致该事实的原因。在反绎推理时，需要首先给出导致事实的原因的假设，并不断的对假设进行调整，使得调整后的假设能够基于规则合理解释观测事实，即“由果溯因”的过程。

举例来说，现有以下命题逻辑规则：

$$\text{昨晚下雨} \vee \text{洒水器开启} \rightarrow \text{草地湿} \tag{2-1}$$

$$\text{草地湿} \rightarrow \text{鞋子湿} \tag{2-2}$$

$$\text{昨晚下雨} \wedge \text{洒水器开启} \rightarrow \text{false} \tag{2-3}$$

其中式2-1和式2-2解释了草地湿与鞋子湿的原因，式2-3表明昨晚下雨与洒水器开启不会同时为真。若我们观察到经过草地后鞋子湿了，就可以通过式2-2得知草地湿了。如果继续追溯导致草地变湿的原因，可以由式2-1知道其原因是昨晚下雨或洒水器开启，两者都有可能。如果我们还观测到天气预报说昨晚确实有下雨，则由式2-3得知昨晚下雨时导致草地变湿的唯一原因；反之若昨晚并未下雨，则洒水器开启就是导致草地湿的唯一原因。

反绎推理过程可以利用规则对模型的输出加以约束，使得模型给出的预测尽可能与逻辑事实相符，从而提升模型预测的正确性，并对于模型在复杂知识场

景下的推理能力的提升具有重要意义。

2.2 反绎学习

反绎学习是一种将机器学习模型与逻辑推理结合的迭代式算法，以模型输出的伪标记为媒介，通过最小化伪标记与知识库间的不一致性，在学习与推理之间架起相互促进的桥梁。反绎学习框架融合了两个模型，分别为感知模型和推理模型。在反绎学习的训练过程中，首先由机器学习模型作为感知模型在带噪声或无标记数据上做预测，并输出对应的预测标记。由于机器学习模型的 PAC 性质，其部分预测标记很有可能与事实不符，故称此时模型的预测结果为伪标记。然后，由知识库作为推理模型，基于领域先验知识，通过反绎推理调整伪标记中可能出错的地方，并尽量使得修正后的伪标记的推理结果与事实一致。可以认为与模型给出的伪标记相比，修正后的伪标记更符合事实，因此将修正后的伪标记视作为监督信息，与原数据一起使用损失计算，梯度回传等监督学习方法重新训练模型，并将训练后的模型用于下一次迭代过程。图2-1展示了反绎学习的流程。

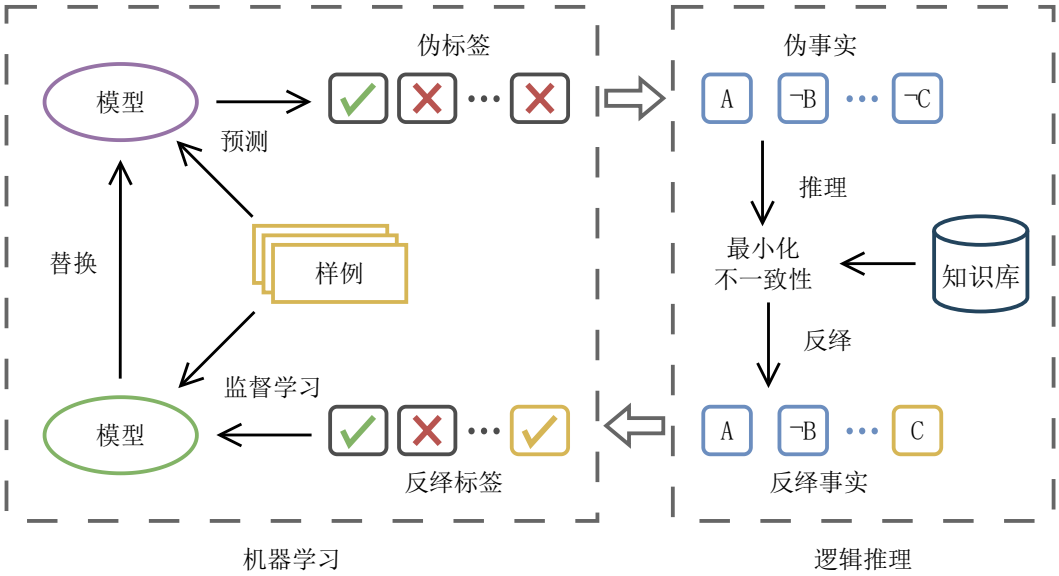

图 2-1　反绎学习框架流程图

在反绎学习使用的数据集中，往往没有样本对应的标记等强监督信息，而只有一些基于样本标记和领域先验知识做推理后得到的推理结果。每一笔数据由一组样本和一个推理结果构成。具体来说，现有样本空间 $\mathcal{X}$，标记空间 $\mathcal{Z}$，推理结果空间 $\mathcal{Y}$，以及给定的知识库 $\mathcal{KB}$，其中知识库 $\mathcal{KB}$ 可以基于一组标记进行推

理得到一个推理结果。对于一组给定样本序列 $\boldsymbol{x} = (x_1, \cdots, x_m) \in \mathcal{X}^m$，其对应的真实标记序列为 $\boldsymbol{z} = (z_1, \cdots, z_m) \in \mathcal{Z}^m$，这里 m 表示样本序列的长度。基于真实标记和知识库，可以得到推理结果 $y \in \mathcal{Y}$，满足 $\boldsymbol{z} \cup \mathcal{KB} \vDash y$。那么数据集就可以表示为 $\mathcal{D} = \{(\boldsymbol{x}, y) \mid \boldsymbol{z} \cup \mathcal{KB} \vDash y\}$。感知模型 f 负责将一组样本 $\boldsymbol{x}$ 映射至一组标记 $\boldsymbol{z}$，可表示为 $f : \mathcal{X}^m \mapsto \mathcal{Z}^m$。反绎学习的目标即基于这样的弱监督数据集和给定的知识库 $\mathcal{KB}$，学习一个能准确预测标记 z 的感知模型 f，且 z 能够经由 $\mathcal{KB}$ 推理得到符合事实的结果 y。

在反绎学习的训练过程中，模型 f 首先处理输入 $\boldsymbol{x}$ 得到输出伪标记序列 $\tilde{\boldsymbol{z}} = \{\tilde{z}_1, \cdots, \tilde{z}_m\}$，这里我们使用波浪号表示伪标记中存在错误。然后使用知识库 $\mathcal{KB}$ 基于伪标记 $\tilde{\boldsymbol{z}}$ 推理得到结果 $\tilde{y}$。如果 $\tilde{y}$ 与数据集中给出的真实结果 y 不一致，则可以通过 $\mathcal{KB}$ 的反绎推理得到反绎结果候选集 $\mathbb{S} = \{\boldsymbol{z} \mid \boldsymbol{z} \in \mathcal{Z}^m, \boldsymbol{z} \cup \mathcal{KB} \vDash y\}$。接着我们通过最小化不一致性从候选集中选出反绎标记 $\bar{\boldsymbol{z}} \in \mathbb{S}$，尽量使得 $\bar{\boldsymbol{z}}$ 与样本 $\boldsymbol{x}$ 一致。由于反绎推理模块通常没有直接处理样本 $\boldsymbol{x}$ 的能力，所以我们退而求其次采用一种启发式的策略，最小化反绎标记 $\bar{\boldsymbol{z}}$ 与伪标记 $\tilde{\boldsymbol{z}}$ 的不一致性。这里我们一般使用汉明距离或模型置信度来度量两者的一致性。有了样本标记对 $(\boldsymbol{x}, \bar{\boldsymbol{z}})$，我们就能以监督学习的方式，用样本标记对来训练模型 f，而训练后的模型 f' 又可以投入到下一轮训练中，由此不断迭代重复。

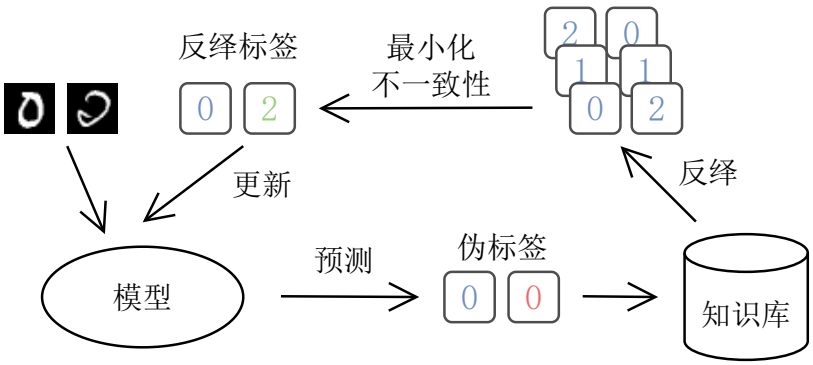

图 2-2　反绎学习训练过程示例

下面以 MNIST Addition 任务为例展示反绎学习的流程。如图2-2所示，模型输入为两张 MNIST 手写数字图像，其真实标记分别为“0, 2”，对应的逻辑推理结果为两个真实标记的和，即为 2。模型给出伪标记“0, 0”，在第二个样本上预测错误。知识库根据推理结果 2，通过反绎推理得到可能的真实标记为“0, 2”，“1, 1”和“2, 0”，这三组候选标记都与推理结果一致。经过最小化不一致

性，选择“0, 2”作为反绎标记，去更新模型参数。

以上介绍的是在知识库全知全能的假设下，反绎学习的训练流程。在广义的反绎学习框架中，我们认为负责逻辑推理的知识库模块也需要调整。现实中人类对一些领域的认知仍非常浅薄，甚至存在诸多谬误。若使用存在问题的知识库做反绎推理，则反绎结果候选集可能并不包含真实标记，所以无论如何选择都无法使模型学习到正确的事实。当反绎推理的严谨性变得不可靠时，反绎推理甚至可能恶化原有的预训练模型的表现。所以需要在训练流程中添加针对知识库更新的步骤，通过观测数据对知识库进行优化，如冲突消解，冗余剪枝，错误修正，知识新增等。不过遗憾的是，仍然存在一些场景，可供训练的数据量不足以支撑知识库的精化。若数据再含有噪声，则对训练泛化性能强的模型构成巨大挑战，仍需进一步研究。

在反绎学习框架提出后，有大量的工作在此基础上展开，其中不乏在各个领域的应用以及框架运行效率与鲁棒性的研究。

在应用方面，反绎学习框架在许多现实任务中都能充当优秀的解决方案。研究者首先将反绎学习框架应用于无标记的手写公式识别问题[30]，在训练神经网络识别数字的同时，从数据中学习公式遵循的运算规则，为后续研究奠定基础。在此基础上，SS-ABL[26]在反绎学习中加入半监督学习，用于法律判决文书的处理与刑期预测，初步将反绎学习应用于现实问题，并取得超越同期先进的半监督学习算法的性能。再此之后反绎学习在乒乓球运动员行为轨迹预测[27]、历史文献识别[28]、牙周炎分类与检测[29]等任务中都有应用，并达到先进的性能。

在现实场景中，人类在某些领域的认知不足，领域先验知识也可能存在不完善的情况。考虑到知识库有待修缮这一点，ABLnc[24]能够在现实场景下识别在训练阶段未接触到的新类别，发明新谓词来更新知识库规则与知识图谱，并设计算法自动消除可能的规则冲突。Safe-ABL[25]假设知识库中存在错误的知识，为知识库中的规则分配置信度权重，使用概率图模型建模推理过程，并通过极大似然估计方法利用数据分布调整规则权重，来从中选择正确的规则。该算法在民事案件争议焦点归纳问题上取得了超越 SS-ABL 的性能。

在反绎空间十分庞大的情况下，以往通过暴力搜索或零阶优化来产生反绎结果的方法变得不可行。ABL-Refl[23]在反绎学习框架中新增反思（Reflection）模块，能够预测模型输出伪标记可能出错的位置，指导反绎推理在指定位置的伪

标记上进行。反思模块大幅缩小了反绎搜索空间，提升了反绎推理的效率，并应用于解数独游戏，以及最大团等经典图论问题。

由于反绎推理的结果通常不唯一，如果从中选择出错误的伪标记，则会在之后的训练过程中误导模型，从而导致模型收敛速度变慢。为提高反绎学习的效率，ABLSim[21]引入特征相似性度量，基于相似的样本大概率属于同一类别的假设，利用集束搜索（beam search）选择得分最高的伪标记，以加速模型的收敛过程，并提升了模型在法律判决文书任务中的表现。A^3BL[22]则采用期望最大化（Expectation Maximization, EM）算法，将伪标记视为隐变量，在反绎学习的循环迭代中最大化似然函数，使得反绎过程更加稳定。

2.3 神经符号学习

一些研究者提出在逻辑推理中引入概率，以实现从离散到连续优化的过渡。Semantic Loss[7]是一种新的损失函数，利用概率计算定量刻画模型输出与逻辑约束之间的相符程度，很大程度地提升了模型在推理问题上的表现。DeepProbLog[10]和 NeurASP[11]是两个相似的框架。它们先利用神经网络处理样本，其输出作为逻辑前件成立的概率，进而计算得出推理结果成立的概率，通过梯度回传调整网络参数可以使得推理结果尽量接近事实。两者区别在于前者使用 ASP（Answer Set Programming）[31]作为推理器，而后者使用 ProbLog[32]，所以在推理开销上有所差距。DeepStochLog[12]在 DeepProbLog 的基础上改进，使用随机逻辑系统在一定程度上提升了计算效率。然而，这些方法将逻辑规则转化为概率计算，事实上是弱化了约束的强度，从而削弱了推理模块对模型性能的提升作用。此外，随着逻辑系统规模的增大且规则关系繁杂时，计算概率和梯度的开销将以指数式增加，这限制了此类方法的应用范围。LTN（Logic Tensor Networks）[13]则使用模态逻辑处理数据中的不确定性，将逻辑符号嵌入到连续的张量表示中，使得逻辑推理可以在神经网络的计算图上表示。这种方法既保留了逻辑推理的可解释性，又能够通过神经网络进行高效的学习和泛化。

另一些研究者提出使用优化问题近似逻辑推理，并使用神经网络求解该优化问题的方法。OptNet（Optimization Networks）[14]是一种结合了神经网络和优化问题的框架，使得优化问题能够作为神经网络的一部分进行端到端学习。SAT-

Net[15]基于 OptNet 的思想，将逻辑推理问题规约为命题逻辑中的 MaxSAT 问题，并用神经网络建模，从而省去了逻辑推理模块。SATNet 用于解数独等逻辑推理问题，效果显著优于同期先进的模型。但是 SATNet 的建模过程实际上将 SAT 问题松弛为一个半正定规划问题，并使用神经网络求该问题的近似解，削弱了逻辑推理的严密性；此外对于较复杂的逻辑推理问题，其规约到 SAT 问题后参数数量呈指数式增长，导致 SATNet 的扩展性不高。

但是，在知识库复杂，符号空间庞大的场景下，现有的框架都面临训练效率低下，模型收敛速度缓慢的问题。此外，在领域知识尚未完善的场景下，如何鉴别并利用有效的知识，修缮错误的知识，补充新的知识，也是亟待进一步研究的问题。

2.4 本章小结

本章围绕反绎学习框架，详细介绍了反绎学习相关的背景知识以及已有的相关工作。本章首先通过一个具体例子介绍了反绎推理的概念，并由此引出反绎学习框架。接着本章以形式化语言描述了反绎学习框架的训练流程，并以 MNIST Addition 为例加以解释。然后本章介绍了在反绎学习范式下进一步的方法研究与应用成果，并以反绎学习为出发点，介绍了一些相关的神经符号学习的近期研究工作，分析了这些方法的闪光点与不足之处，为后续的研究奠定基础。

第三章　多阶段反绎学习

本章节将主要介绍一种可加速反绎学习过程并提升模型准确率的算法及框架。具体而言，在第3.1节中，本文将介绍提出的反绎学习加速方法 MSABL 的整体算法框架；在第3.2节中，本文将介绍 MSABL 的改进版本 MSRABL。

3.1　MSABL 框架

本文的研究基于知识库包含完备的规则的假设，所以真实的标记组合必然存在于反绎结果候选集中，需要设计策略提升。我们不考虑数据对知识库的精化过程，而主要关注反绎推理模块对模型性能的提升作用。

反绎结果候选集通常包含多个反绎结果，但其中只有一种与事实相符。如果选择了错误的反绎结果，则会在后续训练过程中影响模型收敛速度，甚至导致模型陷入局部最优。如何设计策略以获得与事实匹配度较高的反绎结果，这一点至关重要。以往的工作更多关注于优化选择策略，如 ABL_r[20]在不确定如何选择时直接拒绝反绎；ABLSim[21]利用样本相似度量为每个候选反绎标记打分；A^3BL[22]则使用模糊反绎机制，以不同的概率同时考虑所有的候选标记，在探索与利用间取得平衡。然而当反绎结果候选集庞大的情况下，优化选择策略所带来预测性能上的提升无法弥补训练过程指数级增长的开销，所以这些方法在知识库规模层面存在一定的限制。

与上述方法不同，本文的研究则主要关注如何缩减反绎结果候选集的大小。本文注意到，已有的加速方法并不关注知识库本身的规则依赖关系与内在结构，而是仅将其视为一个黑箱函数，输入已有的逻辑事实，输出需要的反绎结果候选集。显而易见的是，分析并利用知识库自身的结构与性质，来降低反绎推理的复杂度并缩减反绎结果候选集，可以进一步优化反绎学习的训练过程，并加速模型的收敛。事实上，许多知识库都表现出固有的多阶段和分层结构的特性。以法律领域为例[26]，一些法律法规相对简单且具有普适性，而另一些则涉及更复杂的

Algorithm 1 数据切片算法

输入： 数据集 $\mathcal{D}$，知识库 $\mathcal{KB}$，标记空间 $\mathcal{Z}$，推理结果空间 $\mathcal{Y}$
输出： 数据切片 slice_i

$i \leftarrow 1$，$A \leftarrow \mathcal{Z}$
for each $y \in \mathcal{Y}$ **do**
  根据式3-1计算 Ψ_y
end for
while $A \neq \varnothing$ **do**
  for each $c \in A$ **do**
    根据式3-2与式3-3分别计算 $\text{DI}(c)$ 与 $\text{CRR}(c)$
  end for
  $C \leftarrow \{c \mid c \in A, c = \text{argmin}_c \text{DI}(c)\}$
  $Y \leftarrow \{\text{CRR}(c) \mid c \in C\}$
  $\text{slice}_i \leftarrow \text{slice}_{i-1} \cup \{(\boldsymbol{x}, y) \mid y \in Y\}$
  $A \leftarrow A \setminus C$
  for each $y \in \mathcal{Y}$ **do**
    $\Psi_y \leftarrow \Psi_y \setminus C$
  end for
  $i \leftarrow i + 1$
end while
return slice_i

条件或例外情况。这些规则可以按复杂程度的递增分为若干阶段。

受这种常见结构的启发，我们提出**多阶段反绎学习（Multi-Stage Abductive Learning，MSABL）**。首先在训练之前，MSABL 框架需要先分析知识库标记之间的依赖关系以及领域先验知识规则的内在结构。接着 MSABL 框架计算在知识库中每种标记类别的区分难易程度，我们称之为**难度指数（Difficulty Index，DI）**。之后根据标记的难度指数对整个训练数据集做切片，并按照一定顺序在这些切片子集上进行反绎学习。简单来说，就是让模型先去学习那些容易从数据和知识库中分辨出来的类别，之后逐渐加入难度更大，更难区分的类别，以一种循序渐进的模式去学习。最后再使用全部的数据做反绎学习，使得模型在保持容易类别上的优秀分类性能的同时，提升模型在困难类别上的性能。

首先我们需要给出类别的难度指数的定义。对于给定的知识库 $\mathcal{KB}$ 以及推理结果 y，可以得到反绎结果候选集 $\mathbb{S} = \{\boldsymbol{z} \mid \boldsymbol{z} \in \mathcal{Z}^m, \boldsymbol{z} \cup \mathcal{KB} \vDash y\}$，这里假设所有 $\boldsymbol{x}$ 与 $\boldsymbol{z}$ 的序列长度皆为 m。定义**反绎标记集合**

$$\Psi(y, \mathcal{KB}) = \{z_i \mid i \in [m], z_i \in \boldsymbol{z}, \boldsymbol{z} \cup \mathcal{KB} \vDash y\} \tag{3-1}$$

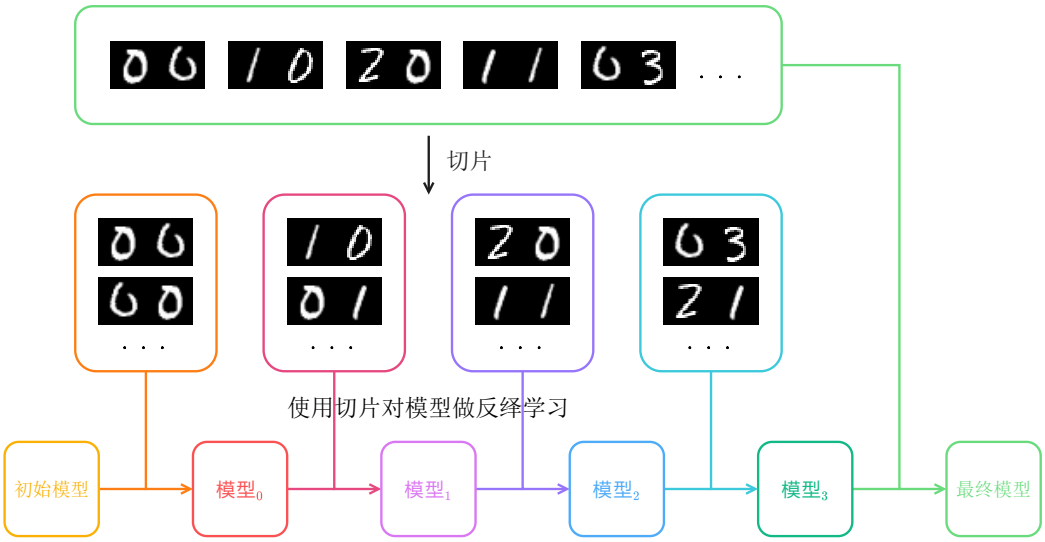

图 3-1　MSABL 框架流程图

后面将 $\Psi(y, \mathcal{KB})$ 简写为 Ψ_y。由此可定义类别 c 的难度指数为

$$\mathrm{DI}(c, \mathcal{KB}) = \min_{c \in \Psi_y} |\Psi_y| \tag{3-2}$$

基于难度指数我们还可以定义类别 c 的**特征推理结果（Characteristic Reasoning Result，CRR）**

$$\mathrm{CRR}(c, \mathcal{KB}) = \mathrm{argmin}_{y,\, c \in \Psi_y} |\Psi_y| \tag{3-3}$$

同样以 MNIST Addition 为例，$\mathcal{KB}$ 为加法规则且 $m = 2$，由反绎标记集合的定义可知 $\Psi_y = \{0, \cdots, y\}$，所以由式3-2得到对任意类别 $c \in \{0, \cdots, 9\}$，有 $\mathrm{DI}(c) = c + 1$，由式3-3得到 $\mathrm{CRR}(c) = c$。

根据 DI 的计算方法，我们可以对训练数据集做切片。首先需要在每次切片之前，找出所有当前 DI 最小的类别，这样的类别可能有多个。这意味着我们希望从剩余的类别中挑选出最容易区分的，不确定性最低的类别。这里的不确定性指的是知识库为当前样本给出的监督信号的强弱，与反绎结果候选集的大小相关。

找出 DI 最小的类别后，需要确定这些类别各自的 CRR，并从数据集中选择所有推理结果与 CRR 一致的数据，与上一轮的训练数据切片合并，作为本轮的训练数据切片。切片完成后，需要在所有的反绎标记集合中去掉本轮 DI 最小的类别。在更新反绎标记集合后，重新计算 DI 与 CRR，以用于确定下一个切片。

例如，在 MNIST Addition 任务中，第 i 个切片 $\text{slice}_i = \{(\boldsymbol{x}, y) \mid y < i\}$，即包含所有两数之和小于 i 的数据。通过给出两数之和的范围，间接地限制了样本的类别范围，因此反绎结果候选集得到缩减，也更容易选择正确的反绎标记。数据集切片的具体流程如算法1所示。

得到一系列数据切片后，就可以按顺序在这些切片上做一般意义上的反绎学习。切片排位越前，则其包含的类别越容易被区分。由数据切片算法的设计可知，基于切片中数据的真实推理结果做反绎推理，得到的反绎结果的类别，必定是当前切片对应的简单类别的子集。所以在学习容易类别的时候，反绎推理过程就可以直接将困难类别排除在外，即大幅缩小了反绎空间。

只要模型在第 i 个数据切片上得到充分训练，即在当前切片对应的类别上取得较好的泛化性能或达到终止条件，我们就过渡到第 $i+1$ 个切片上继续训练模型。泛化性能可量化为模型在验证集上的表现，而终止条件可以是达到最大迭代次数。切换数据切片与反绎学习交替进行，这一过程一直重复到最后一个切片训练完毕，意味着模型已经具备区分所有类别的能力。在所有切片都训练完成后，最后再使用全部的数据做反绎学习，以进一步稳定并提升模型的性能，直至模型收敛或达到最大迭代次数。图3-1展示了 MSABL 框架的流程。

以 MNIST Addition 为例，原数据集 $\mathcal{D}$ 包含任意 0 至 9 类的两位数加减，若直接在 $\mathcal{D}$ 上做反绎学习，则起步阶段在反绎结果候选集中选择出错误的反绎标记的概率较大，模型很容易被误导。在 MSABL 框架中，我们先使用算法1将 $\mathcal{D}$ 切片为 $\text{slice}_i = \{(\boldsymbol{x}, y) \mid y < i\}$，然后从 slice_1 上开始做反绎学习，更新初始模型。当在 slice_1 上反绎学习收敛后，模型能够识别 0 类样本。此时可以切换到 slice_2 继续训练，收敛后模型就能够识别 0 和 1 类样本，再切换至 slice_3，以此类推。所有切片训练完毕后，再使用原数据集 $\mathcal{D}$ 训练，以进一步增强模型性能。MSABL 的整体流程如算法2所示。

通过 MSABL 框架，模型实行一种类似于人类学习新知识时由浅入深，由易到难的过程。MSABL 可以系统地解构原本庞大繁杂的知识库，划分为多个由简单逐渐到困难的知识库子集，从而创建不同的学习阶段，逐步扩大反绎空间。在早期阶段，我们会在缩小的知识库，即简单版本的知识库子集上，进行反绎学习过程，从而缓解一开始就使用知识库包含的全部规则所带来反绎空间与反绎结果候选集大小的指数级增长。这种循序渐进的训练策略不仅能确保初始阶段的

Algorithm 2 MSABL 算法

输入： 数据集 $\mathcal{D}$，知识库 $\mathcal{KB}$
输出： 模型 f

```
基于 D, KB 基于算法1做数据切片，得到 slice_1, ⋯, slice_K
初始化模型 f
for each i ∈ [K] do
    在 slice_i 上做反绎学习，更新 f
end for
在 D 上做反绎学习，更新 f
return f
```

推理简单易行，还能让模型逐渐适应更具挑战性的约束条件。模型在简单基础的任务上达到高性能，对后续学习高级困难任务也有一定的帮助。在最后阶段，我们整合了完整的知识库，使模型能够纳入所有相关知识，同时保持通过先前多阶段学习得到的模型性能。这种方法反映了逻辑层面成熟的多阶段技术，在早期阶段的探索广度和最终阶段的整个知识库保真度之间取得了平衡，从而为加速反绎学习提供了一条可扩展的系统化途径。

3.2 MSRABL 框架

在 MSABL 训练过程中，切换数据切片的环节会引入难度指数更高的类别，并与先前难度指数低的类别共同参与反绎推理过程并更新模型。在刚切换数据切片时，可以认为模型在低难度的类别上泛化性能较好，但在新引进的高难度类别上性能较差。因此，模型对高难度类别的识别能力很弱，并倾向于将高难度类别错误分类为低难度类别。换句话说，模型给出的伪标记大多仍然属于低难度类别，在知识库约束能力较弱的情形下，高难度类别上的反绎正确率不高。虽然 MSABL 在一定程度上缩小了反绎结果的搜索范围，但若使用一般的反绎推理方法对伪标记做修正，则仍然存在选择反绎结果错误率高的问题。

为解决该问题，我们提出多阶段拒绝反绎学习框架（Multi-Stage with Rejection ABL，MSRABL）。该框架基于如下假设：在每个数据切片上训练完毕后，模型在该切片所包含的类别上具有高召回率（Recall）。例如在 MNIST Addition 任务中，第一个切片包含所有两数之和为 0 的数据，即所有的样本其真实标记都为 0。那么模型在第一个切片上训练完成后，需要对于任意的真实标记为 0 的样本，以很大概率预测其为 0。这要求用于反绎学习的数据集的样本分布均匀，性质良

好。下面的分析默认上述假设成立。

当切换至下一个数据切片，就引入了更高难度的类别，此时切片中包含上一轮的低难度类别与新引进的高难度类别。当模型预测一个样本不属于低难度类别，则根据假设可知，此样本的真实标记大概率也不属于低难度类别。那么此样本的标记就可以被反绎推理修改为本轮引进的高难度类别。反之，若模型预测样本属于低难度类别，这时我们就不能确定该样本的真实标记，因为我们没有对模型的精确率（precision）做任何假设。因此如果该样本的反绎标记不能唯一确定，即存在多个反绎标记，那么我们拒绝为这样的样本提供反绎结果，在下一次更新模型参数时也不会使用这样的样本。以 MNIST Max（见第四章第4.2节）为例，图3-2展示了 MSABL 与 MSRABL 在相同的情景下反绎推理过程的对比。现有两张类别为 1 的手写数字图像作为输入，模型在两张图片上分别给出预测

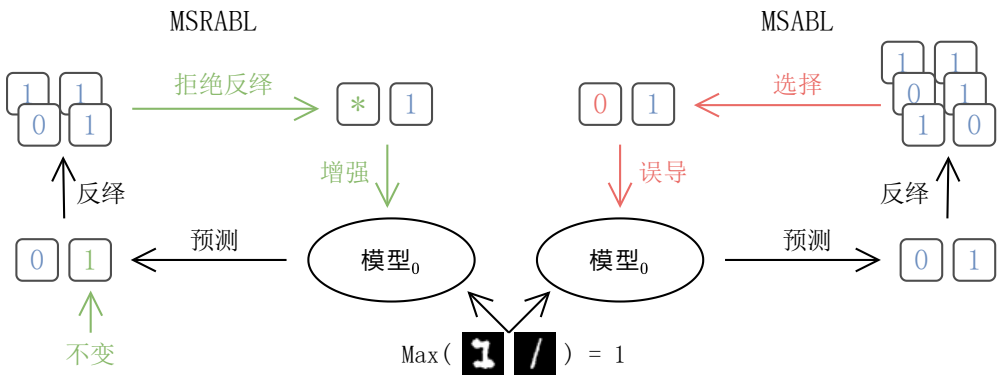

图 3-2　MSABL 与 MSRABL 训练过程对比

0 和 1。在未改进的 MSABL 框架中，反绎推理正常进行，根据真实的推理结果 1，推理得到反绎结果候选集 $\{[0,1],[1,0],[1,1]\}$。然后根据最小化不一致性原则，MSABL 会选择 $[0,1]$ 作为反绎标记，并用于更新模型。然而我们知道，对第一张图像的反绎结果是错误的，用错误的标记更新模型，会导致模型的性能不升反降。而 MSRABL 利用拒绝反绎机制，可以缓解上述存在的问题。在第 1 个数据切片上训练完毕后，模型在类别 0 上具有高召回率。当切换至第 2 个切片后，则新引入了类别 1。对于模型给出的预测 0 和 1，我们有把握认为在第二张图像上预测的 1 大概率是正确的，但不能确定第一张图像上预测的 0 是否正确。所以反绎模块保留 1 的预测不变，并尝试对 0 进行反绎推理修正，得到反绎结果 $\{[0,1],[1,1]\}$。遗憾的是，对于第一张图像的反绎推理结果仍然有多个，不能唯

Algorithm 3 MSRABL 拒绝反绎算法

输入： 伪标记 $\tilde{\boldsymbol{z}}$，知识库 $\mathcal{KB}$，低难度类别集合 $\boldsymbol{E}$，新引进的高难度类别集合 $\boldsymbol{H}$
输出： 反绎标记 $\bar{\boldsymbol{z}}$

for each $\tilde{z}_i \in \tilde{\boldsymbol{z}}$ **do**
  if $\tilde{z}_i \notin \boldsymbol{E}$ **then**
    $\mathbb{I}_i \leftarrow \langle \texttt{HARD} \rangle$
  else
    $\mathbb{I}_i \leftarrow \langle \texttt{UNK} \rangle$
  end if
end for
使用 $\mathcal{KB}$ 对 $\tilde{\boldsymbol{z}}$ 做反绎，得到反绎结果候选集 $\mathbb{S}$。其中 $\mathbb{I}_i = \langle \texttt{HARD} \rangle$ 的位置在 $\boldsymbol{H}$ 中反绎；反之 $\mathbb{I}_i = \langle \texttt{UNK} \rangle$ 的位置在 $\boldsymbol{E} \cup \boldsymbol{H}$ 中反绎。
for each $i \in [m]$ **do**
  $\Phi_i \leftarrow \{z_i \mid \boldsymbol{z} \in s\}$
  if $|\Phi_i| = 1$ **then**
    $\bar{z}_i \leftarrow \Phi_i[0]$
  else
    $\bar{z}_i \leftarrow \langle \texttt{REJ} \rangle$
  end if
end for
return $\bar{\boldsymbol{z}}$

一确定，所以 MSRABL 拒绝对 0 进行反绎，在更新模型时也仅计算模型在第二张图像上的分类损失，而不考虑第一张。将确定的反绎标记用于训练，至少能够大幅降低误导模型的可能，维持了模型的性能。MSRABL 中拒绝反绎的具体流程如算法3所示。

拒绝反绎的技巧对多阶段反绎学习有如下促进作用。多阶段反绎学习框架由于特殊的算法机制，决定了其在训练过程中势必需要频繁地更换数据切片，这就带来数据分布的频繁变化，而机器学习模型对于数据分布的变化非常敏感。这就导致在数据切片更换后的初期，模型处于一种很不稳定的“混沌”阶段，故其预测的伪标记大多不可靠[18]。以往的工作希望通过样本相似度量，最大化概率似然等方法在不可靠的伪标记上做优化；相比之下，MSRABL 采取了更为保守而直接的策略：当反绎结果存在较高不确定性时，MSRABL 选择跳过这些高风险的样本，只利用逻辑上较为确定、支持度更强的伪标签进行训练。这一设计虽然看似简单，但显著降低了错误反绎对模型训练的干扰，提升了整体的训练稳定性和推理正确率。第四章的实验结果进一步验证了这一点：在 Max 任务中，MSRABL 的反绎正确率显著高于对比方法，最终模型的性能也更优。这一结果说明，稳定可靠的反绎监督信号远比数量更多但不可靠反绎结果更为重要。相比

复杂但容易引入噪声的伪标签选择策略，MSRABL 所采用的保守机制在保证逻辑一致性的同时，提高了模型在复杂知识环境下的实际表现。

3.3 本章小结

本章针对反绎推理的不确定性而引发的模型收敛缓慢的问题,提出了 MSABL 框架，意在提升选择正确反绎结果的概率。MSABL 利用领域先验知识规则的内在结构，将数据集打散并组成多个数据切片。之后，MSABL 让模型以由易到难，循序渐进的方式，以一定的顺序在这些切片上学习。在 MSABL 的基础上，本章还提出 MSRABL，通过引入拒绝反绎机制，将反绎推理的不确定性尽量降到最低，在数据分布变化时仍能保持训练过程的稳定性。

第四章　实验

本章将详细展示多种反绎学习框架在多种任务与数据集上的实验结果，以展示本文所提出的多阶段反绎学习框架对模型性能的提升。在4.1节，本文将介绍 Addition 任务的设定与数据集；在4.2节，本文将介绍 Max 任务的设定与数据集；在4.3节，本文将对实验结果进行详细分析，并讨论多阶段反绎学习对模型性能提升的原理。所有实验使用不同随机种子重复运行 5 次，并计算指标的均值与标准差。实验使用的服务器配备 Intel Xeon Platinum 8358 CPU 与 Nvidia A100 80GB PCIe GPU。具体实验数据集与程序代码可见 github[1]。

4.1　Addition 任务

MNIST Addition 任务在 DeepProbLog[10]中首次提出。在训练集的每一笔数据中，两张 MNIST[33]手写数字图像作为样本序列，是模型输入；它们所代表的数字之和是推理结果，作为样本的弱监督信号。例如 SUM(,) = 1 就是一笔数据。数据集由于 MNIST 数据集过于简单，为增加任务难度，我们在 MNIST 之外还使用 Fashion-MNIST 数据集[34]和 CIFAR-10 数据集[35]构建了 Fashion Addition 和 CIFAR-10 Addition 任务。由于这两个数据集也包含 10 类图像，类别由 0 到 9，可以直接移植到 Addition 任务中。我们使用 ABL，ABLSim 以及 A^3BL 作为基准方法与 MSABL 做比较。其中 ABL 和 MSABL 使用置信度（confidence）指标从候选集中选择反绎结果，ABLSim 使用神经网络的最后一层隐藏层状态（last hidden state）作为样本特征表示。我们在 MNIST 和 Fashion 数据集上使用 LeNet[36]作为感知模型，在 CIFAR-10 数据集上使用 ResNet18[37]作为感知模型。所有的模型随机初始化且没有预训练。表4-1展示了多种反绎学习框架在三种 Addition 数据集上的测试集准确率与模型收敛时间。收敛时间计算方法为从训练开始至首次达到与最终准确率误差在 3% 以内的时间。

1　数据集与代码地址：https://github.com/wnqn1597/msabl

表 4-1　Addition 任务

	Method	MNIST	Fashion	CIFAR-10
准确率 (%)	ABL	95.08±0.38	83.70±0.26	69.87±0.66
	ABLSim	**95.62±0.16**	83.66±0.32	71.48±0.39
	A^3BL	93.66±0.58	82.86±0.54	71.41±0.35
	MSABL (ours)	95.45±0.95	**84.25±0.35**	**72.60±0.47**
时间 (s)	ABL	15±2	32±4	449±53
	ABLSim	20±1	67±5	785±84
	A^3BL	12±2	24±4	371±33
	MSABL (ours)	18±1	36±2	508±41

4.2　Max 任务

为了更直观地展示多阶段反绎学习框架与其它反绎学习框架相比所具有的独特优越性，我们设计了一类新的反绎学习基准测试（benchmark）：最大值（Max）任务。以 MNIST Max 为例，在训练集的每一笔数据中，m 张 n 类别 MNIST 手写数字图像作为样本序列；而它们所代表的数字之中的最大值是推理结果，例如 MAX(, , , , ,) = 5 就是一笔数据。n 类别 MNIST 表示随机选取 10 个类别中的 n 个类别。若 m 或 n 的值越大，则 Max 任务的反绎空间越大，则用来反绎学习也就越困难。为方便表示，我们用 Max(m, n) 表示序列长度为 m，共有 n 类别样本的 Max 任务。在实验中，我们使用 MNIST Max(5,4)，Fashion Max(5,4)，CIFAR-10 Max(5,4) 以及 CIFAR-10 Max(16,10) 四种任务设定，并使用 ABL，ABLSim 以及 A^3BL 作为基准方法与 MSABL 和 MSRABL 做比较。算法与模型细节设定与 Addition 任务一致。由于 Max 任务的难度较大，我们使用少量有标记样本对模型做预训练。表4-2记录了每个任务设定下预训练样本个数以及我们用来预训练的样本占原图像数据集训练样本的比例。表4-3展示了多种反绎学习框架在 Max(5,4) 数据集上的测试集准确率与模型收敛时间，而表4-4展示了 Max(16,10) 数据集上的测试集准确率，其中 N/A 表示在该框架的训练下模型无法在 2 小时内收敛。

表 4-2　预训练样本数量及其占原数据集训练样本的比例

	MNIST Max(5,4)	Fashion Max(5,4)	CIFAR-10 Max(5,4)	CIFAR-10 Max(16,10)
预训练	16	40	100	500
原数据集	24754	24000	20000	50000
占比	0.06%	0.17%	0.50%	1.00%

表 4-3　Max(5,4) 任务

	Method	MNIST	Fashion	CIFAR-10
准确率 (%)	ABL	92.46±1.06	57.28±4.52	60.14±1.46
	ABLSim	87.92±4.93	49.61±3.63	56.06±2.14
	A^3BL	95.35±1.86	69.32±1.41	70.86±1.83
	MSABL (ours)	94.21±1.33	64.14±2.82	59.21±1.64
	MSRABL (ours)	**96.86±0.39**	**69.75±0.17**	**80.34±2.25**
时间 (s)	ABL	8±1	38±7	328±174
	ABLSim	7±3	56±9	336±141
	A^3BL	8±2	24±10	584±259
	MSABL (ours)	17±1	43±4	615±113
	MSRABL (ours)	12±1	30±3	381±36

表 4-4　CIFAR-10 Max(16,10) 任务

	ABL	ABLSim	A^3BL	MSABL (ours)	MSRABL (ours)
准确率 (%)	26.30±3.22	N/A	N/A	13.78±0.59	**75.83±0.27**

4.3　结果分析

4.3.1　Addition 任务

根据表4-1可知，本文提出的 MSABL 框架在大部分 Addition 任务上，训练得到的模型测试准确率高于其它反绎学习框架。ABLSim 由于存在额外的抽取样本特征，计算样本相似度，集束搜索等步骤，增加了一定的计算量，所以运行速度与其它框架相比较慢，但其利用样本相似性做反绎推理使得反绎准确率较高，故模型测试准确率优于 ABL 和 A^3BL。A^3BL 虽然收敛速度很快，但由于其模糊反绎的机制，用于训练的反绎标记是概率分布而不是准确的标签，使得模型在某些分类困难的样本上表现不佳。总体来看，由于 Addition 知识库较为简单，且加法规则对样本提供的监督信息较强，用反绎学习做训练模型很容易收敛，多种框架的模型表现相近，不太能够直观体现多阶段反绎学习框架的优越性。

4.3.2　Max 任务

Max 任务与 Addition 任务相比难度更大，因为最大值规则对样本的监督信号更弱。根据表4-3可知，大部分反绎学习框架，包括未改进前的 MSABL，在 Max 任务上表现不佳，这一点在 CIFAR-10 Max(5,4) 任务上尤其明显。CIFAR-10 作为现实图像数据集，样本特征复杂，噪声较大，加上监督信号很弱的 Max 知识规

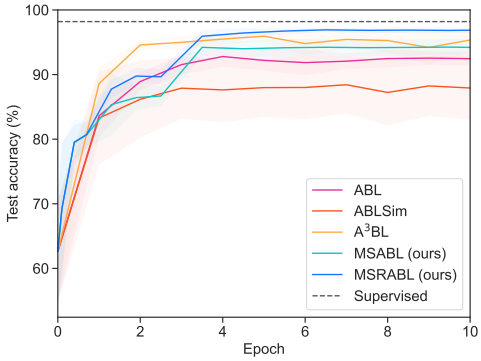

(a) MNIST Max 测试集准确率

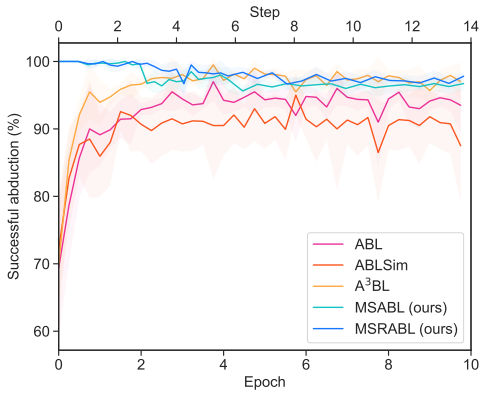

(b) MNIST Max 反绎准确率

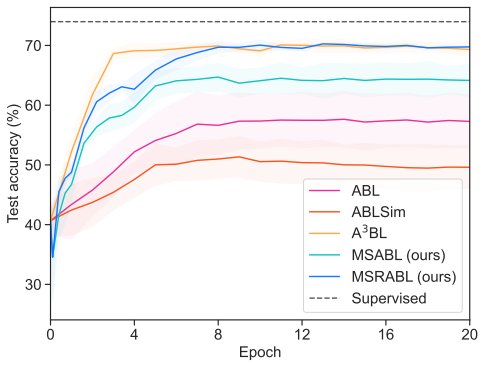

(c) Fashion Max 测试集准确率

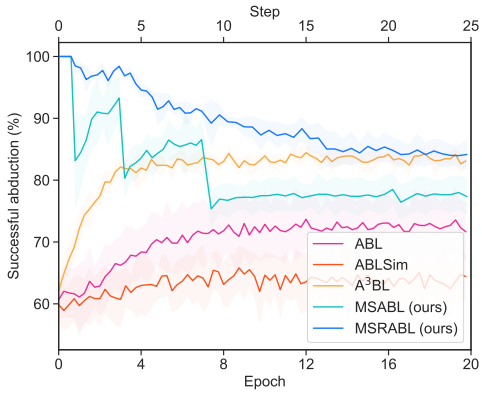

(d) Fashion Max 反绎准确率

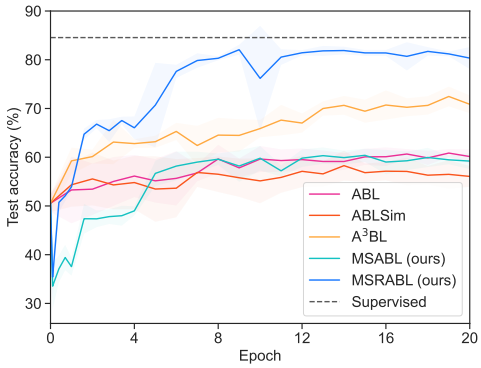

(e) CIFAR-10 Max 测试集准确率

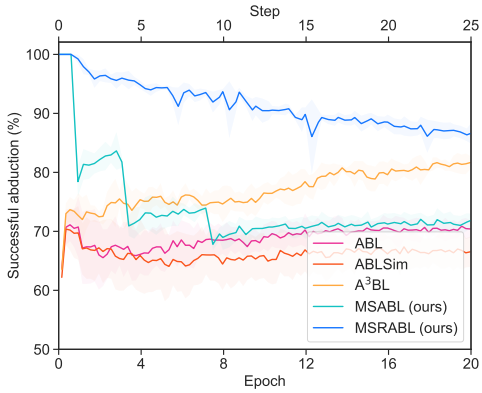

(f) CIFAR-10 Max 反绎准确率

图 4-1　Max(5, 4) 任务学习曲线

则，为学习泛化性能好的模型带来不小的挑战。图4-1中的学习曲线详细地展示了各种框架在三个 Max(5,4) 任务上的学习过程与指标的变化。ABL 与 ABLSim 方法的准确率较低，并且在测试与反绎准确率上有较大的标准差浮动，代表着其学习过程不稳定。A^3BL 相对其它方法表现较好，在 MNIST 与 Fashion 数据集上可以做到接近监督学习的水平，但在 CIFAR-10 数据集上也无法做到高精度的反绎。由于多阶段反绎学习的训练数据是根据类别难易程度划分的切片，是由易到难的学习过程，所以 MSABL 与 MSRABL 的反绎准确率曲线与其它框架不同，是先高后低的曲线。MSABL 在 Fashion 与 CIFAR-10 上的反绎准确率有三次下坠形态，这对应着三次数据切片的更换。与 MSRABL 不同，MSABL 并没有对切片更换带来的数据分布变化做相应的措施，故反绎准确率有明显回落的现象，测试准确率也不及 MSRABL。而 MSRABL 在三个任务上都能做到最高的反绎精度与测试准确率，并且模型的泛化性能都接近于监督学习，有力地验证了其框架设计的优越性。注意到拒绝反绎的机制使得在数据切片更换时，MSRABL 能够在反绎准确率上实现平滑的过渡，并没有像 MSABL 一样出现性能的快速下降，表明拒绝反绎机制可以有效地应对数据分布的变化。

为进一步探索 MSRABL 的能力，我们设计了一个极具挑战性的任务：CIFAR-10 Max(16,10)。表4-4展示了多个反绎学习框架在该任务上的表现。在该任务的数据集中，每一笔数据由 16 张 10 分类 CIFAR 图像与这些图像类别的最大值组成，反绎结果候选集最大可达 10^{16} 的数量级。A^3BL 需要事先计算所有的反绎结果，以使用模型输出的概率计算反绎概率；而 ABLSim 需要在所有反绎标记上做集束搜索。面对巨大的反绎结果数量，这两种方法由于时间复杂度的限制，无法在规定时间内收敛。ABL 和 MSABL 在经过训练后，其模型测试准确率甚至不如预训练模型的准确率，产生了负优化的现象。其中 MSABL 的模型能力退化现象最为严重，与之相对应的是其在反绎准确率上的逐步下降，仅在 10 步后反绎准确率就降至 50% 以下。与两者相反的是，MSRABL 仍然能够始终保持 90% 以上的反绎准确率，并在测试准确率上接近监督学习的效果。

4.3.3 案例研究

由于 Max 知识库的最大值规则具有其自身的特性，它对不同类别的约束强度有很大的差别。数据集中存在推理结果为 0 的数据，其样本序列中仅有 0 类

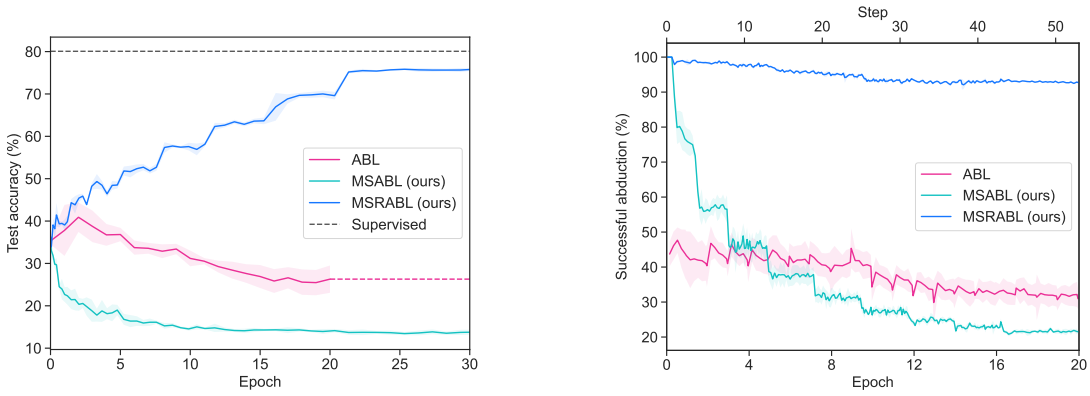

(a) 测试集准确率 **(b) 反绎准确率**

图 4-2 CIFAR-10 Max(16, 10) 任务学习曲线

样本，而知识库对其反绎推理也只有 0 类这一种结果，此监督信号已与监督学习相当。而对其它类别而言，知识库没有能力给出与 0 类强度相近的监督信号，故模型在这些类别上的泛化能力长时间处于“混沌”状态。而通过错误的反绎结果选择反而加速了模型将各类样本都误分为 0 类的进程，由此陷入恶性循环。在 MSABL 中，不使用拒绝反绎机制，而仅依靠反绎推理的结果与最小化一致性原则，那么选出的反绎标记虽然能够与知识规则相符，但仍然与真实标记不一致。而 MSRABL 中的拒绝反绎机制能够一定程度上检测到这种不一致性，并消除了由不确定性可能带来的错误反绎标记对模型的误导。

在 CIFAR-10 Max(16,10) 任务的训练过程中，我们对 MSABL 与 MSRABL 的模型在 10 个类别上的各自的测试准确率进行全程跟踪，并绘制图4-3。在 MSABL 框架下，模型倾向于将所有样本预测为 0 类，因而在 0 类上的预测准确率很高；然而模型在其它类别上泛化性能与预训练模型相比都有不同程度的退化。在 MSRABL 框架下，随着数据切片的切换，新的困难类别被依次引入，模型在这些类别上的泛化性能依次被提升，这一点由图4-3a中明显的按类别“阶梯式”上升的测试准确率可得，“多阶段”学习的底层机制在此图中也得到了最具象化的诠释。由于 CIFAR-10 的数据噪声较大，模型在学习新类别的同时，会导致在已学习类别上的性能产生一定程度的下降。如何在带噪数据场景下，优化在数据切片更换时对数据分布变化的应对措施，有待进一步的研究。

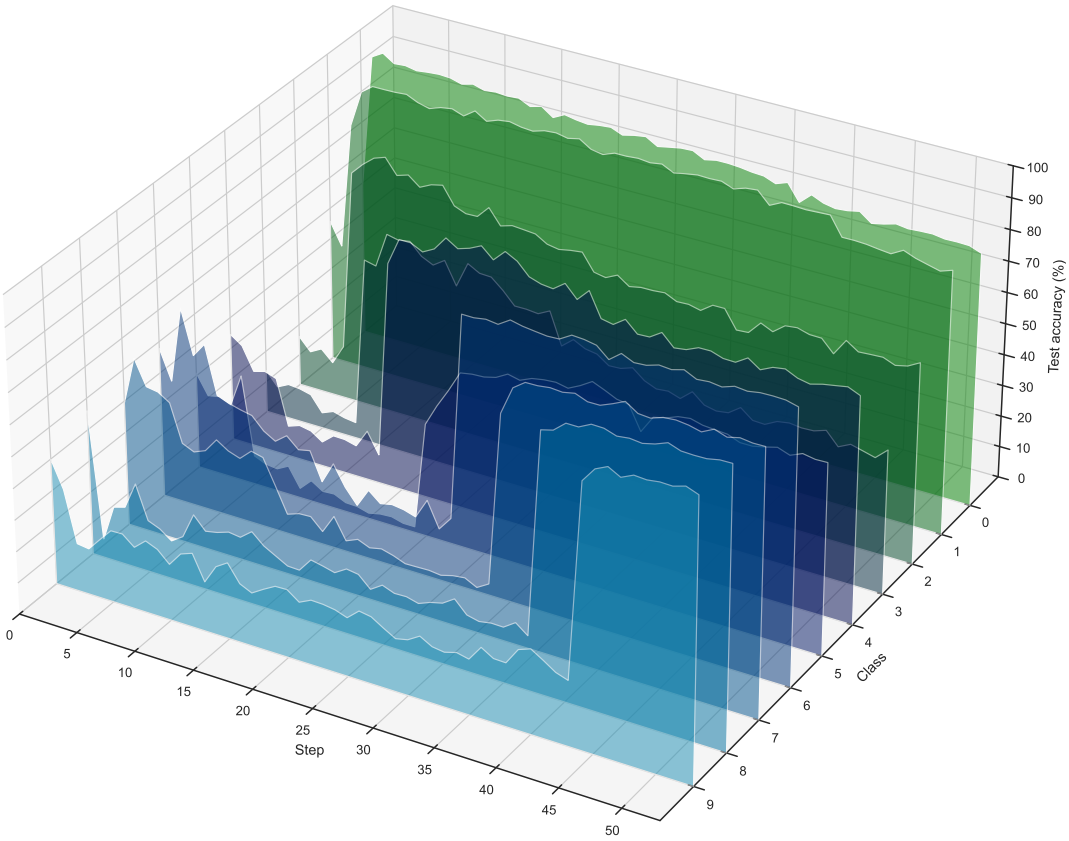

(a) MSRABL 各类别测试集准确率

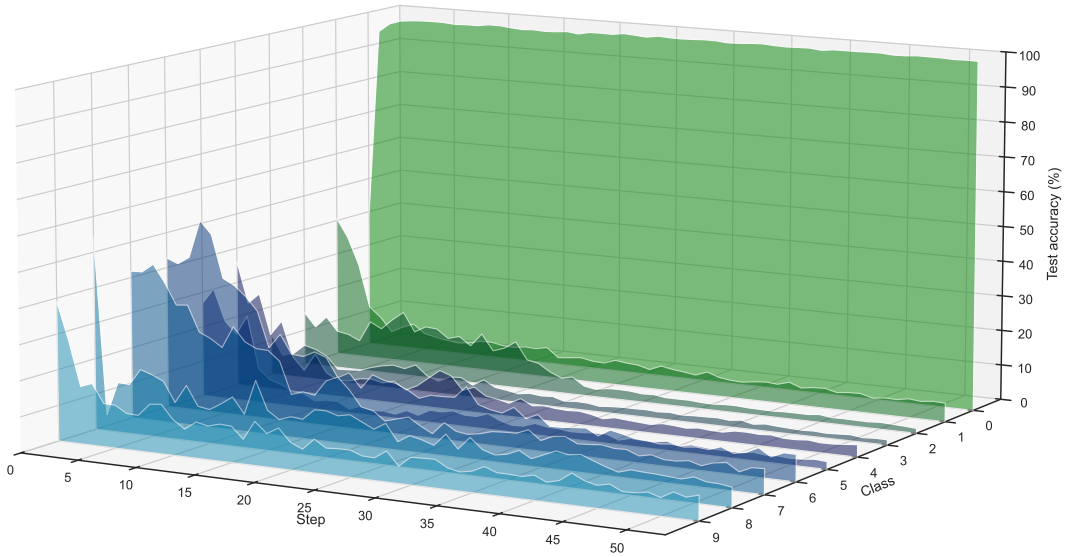

(b) MSABL 各类别测试集准确率

图 4-3　CIFAR-10 Max(16, 10) 任务各类别测试集准确率

4.4 本章小结

为充分展示多阶段反绎学习框架的优越性，本章参照反绎学习经典任务 Addition，设计了一个全新的反绎学习任务——Max 任务。本章给出了多种反绎学习框架在我们给定的 Addition 任务与 Max 任务上的性能指标。多项实验结果充分验证了 MSABL 以及 MSRABL 方法在我们给出的任务上性能优于以往的反绎学习框架。值得注意的是，MSRABL 在 Max 任务上的性能大幅度优于其余方法。本章还通过立体图例具体分析了 MSRABL 在该任务上性能优秀的原因，并分析了其它方法的不足之处，为将来提升反绎学习的效率提供了全新的思路。

第五章　总结与展望

本文主要研究了加速反绎学习模型收敛的方法。本文为提高正确反绎的概率，以缩小反绎结果候选集为问题切入点，提出了 MSABL 框架，并在此基础上优化得到 MSRABL 框架。参考人类学习新知识通常倾向于由浅入深和由易到难的特点，我们希望在反绎学习过程中，模型能够以一种循序渐进的模式在知识库的指导下进行学习。MSABL 通过建立类别难度指数的概念，为原本相互对等的类别引入了顺序，并利用这种顺序指导模型的学习流程。在知识库的约束下，通过设计切片算法让模型首先学习监督信号较强的类别，使得模型能够较快地在某些容易的类别上提高性能，为后续区分高难度类别打下坚实基础；在学习弱监督信号的类别时，便可以利用模型在低难度类别上已经具有较好的泛化性能的性质，缩小反绎空间与反绎结果候选集大小，在推理效率和模型收敛速度上都能实现加速效果。考虑到 MSABL 训练过程中不可避免地数据分布变化，我们利用拒绝反绎机制，提出 MSRABL 框架，以一种类似于新类别识别的方法，加速新类别的学习，以实现在不同分布间的平滑过渡。多组实验结果强有力地验证了多阶段学习框架的优越性：在训练时长相当的情况下，多阶段反绎学习能够在 Addition 与 Max 任务上保持较高的反绎准确率，并取得更佳的模型泛化性能。在反绎空间更大，知识库更复杂的任务上，多阶段反绎学习对模型性能提升效果更加明显，且都能达到与监督学习接近的性能。同时本文还通过绘制立体图展示训练过程中各个类别泛化性能的变化，揭示了多阶段学习循序渐进的本质。多阶段反绎学习框架为反绎学习加速方法提供了一种全新的解决方案。

当然，本文提出的多阶段反绎学习框架也存在待改进的问题。多阶段反绎学习要求知识库满足特定的性质，即不同类别的监督信号强度不同，存在一些类别，将它们从所有类别中辨别出来比较容易。对于类别“纠缠”在一起的知识库，目前多阶段学习还难以处理。

本文的研究还仅局限于知识库完备的假设，并且知识库仅含有很少数量的规则。广义上而言，反绎学习框架下仍有许多亟待解决的问题值得研究：

1. 知识库包含的知识有空缺或包含错误的知识。知识库存在问题会极大地影响反绎推理的准确率，使得模型长时间无法收敛。而在现实任务场景中，我们在很多领域的知识储备仍存在空白。目前在该方向的初步研究尚不能处理大规模复杂的知识库，有待进一步研究。
2. 数据噪声大。在现实数据的收集过程中，不可避免地会引入噪声，这对以往希望通过数据分布挖掘逻辑规则的方法提出了挑战。如何从噪声数据中辨识出有用的信息，并过滤掉错误的，无用的信息，以高效率地精化知识库，也是一个非常具有现实意义的研究课题。
3. 与在线学习的结合。某些场景下数据以流式的形式生成，我们没有足够的资源成本来存储这些海量的数据。这使得以往反绎学习方法中多次迭代重复训练模型的方法变得不再可行。如何高效地利用这些一次性的流式数据，是反绎学习能否应用于流式数据场景的关键。
4. 如何利用反绎学习框架提升模型的可解释性。反绎学习是一个将机器学习与逻辑推理联合统一，协同运作的框架。之所以引入逻辑推理模块，是因为我们希望通过推理使得模型的输出尽量如逻辑知识那样可靠，同时还能利用机器学习模型预测的高效性。反绎学习作为学习与推理之间的桥梁，有望为机器学习模型的可解释性提供可能性。

参考文献

[1] Bengio Y. The consciousness prior[J]. ArXiv preprint arXiv:1709.08568, 2017.

[2] 周志华. 机器学习[M]. 清华大学出版社, 2016.

[3] Valiant L G. A theory of the learnable[J]. Communications of the ACM, 1984, 27(11): 1134-1142.

[4] Li C M, Manya F. MaxSAT, hard and soft constraints[G]//Handbook of satisfiability. IOS Press, 2021: 903-927.

[5] Towell G G, Shavlik J W. Knowledge-based artificial neural networks[J]. Artificial Intelligence, 1994, 70(1-2): 119-165.

[6] Garcez A S d, Gabbay D M, Broda K B. Neural-Symbolic Learning System: Foundations and Applications[M]. Springer-Verlag, 2002.

[7] Xu J, Zhang Z, Friedman T, et al. A semantic loss function for deep learning with symbolic knowledge[C]//Proceedings of the 35th International Conference on Machine Learning (ICML' 18). 2018: 5502-5511.

[8] Fischer M, Balunovic M, Drachsler-Cohen D, et al. DL2: Training and Querying Neural Networks with Logic[C]//Proceedings of the 36th International Conference on Machine Learning (ICML' 19): vol. 97. PMLR, 2019: 1931-1941.

[9] Yang Z, Lee J, Park C. Injecting Logical Constraints into Neural Networks via Straight-Through Estimators[C]//Proceedings of the 39th International Conference on Machine Learning (ICML' 22): vol. 162. PMLR, 2022: 25096-25122.

[10] Manhaeve R, Dumancic S, Kimmig A, et al. Deepproblog: Neural probabilistic logic programming[J]. Proceedings of the 32nd Conference on neural information processing systems (NeurIPS' 18), 2018, 31: 3753-3763.

[11] Yang Z, Ishay A, Lee J. Neurasp: Embracing neural networks into answer set programming[J]. ArXiv preprint arXiv:2307.07700, 2023.

[12] Winters T, Marra G, Manhaeve R, et al. Deepstochlog: Neural stochastic logic programming[C]//Proceedings of the 36th AAAI Conference on Artificial Intelligence (AAAI' 22): vol. 36: 9. 2022: 10090-10100.

[13] Badreddine S, Garcez A d, Serafini L, et al. Logic tensor networks[J]. Artificial Intelligence, 2022, 303: 103649.

[14] Amos B, Kolter J Z. OptNet: Differentiable Optimization as a Layer in Neural Networks[C]//Proceedings of the 34th International Conference on Machine Learning (ICML' 17): vol. 70. PMLR, 2017: 136-145.

[15] Wang P W, Donti P, Wilder B, et al. Satnet: Bridging deep learning and logical reasoning using a differentiable satisfiability solver[C]//Proceedings of the 36th International Conference on Machine Learning (ICML' 19). 2019: 6545-6554.

[16] Zhou Z H. Abductive learning: towards bridging machine learning and logical reasoning[J]. Science China. Information Sciences, 2019, 62(7): 76101.

[17] Zhou Z H, Huang Y X. Abductive Learning[G]//Neuro-Symbolic Artificial Intelligence: The State of the Art. IOS Press, 2022: 353-369.

[18] Tao L, Huang Y X, Dai W Z, et al. Deciphering raw data in neuro-symbolic learning with provable guarantees[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence (AAAI' 24): vol. 38: 14. 2024: 15310-15318.

[19] Yang X W, Wei W D, Shao J J, et al. Analysis for Abductive Learning and Neural-Symbolic Reasoning Shortcuts[C]//Proceedings of the 41st International Conference on Machine Learning (ICML' 24): vol. 235. 2024: 56524-56541.

[20] 黄宇轩, 姜远. 带拒绝推理的反绎学习方法[J]. 计算机研究与发展, 2024, 61(7): 1791-1798.

[21] Huang Y X, Dai W Z, Cai L W, et al. Fast Abductive Learning by Similarity-based Consistency Optimization[C]//Proceedings of the 35th Conference on Neural Information Processing Systems (NeurIPS' 21): vol. 34. Curran Associates, Inc., 2021: 26574-26584.

[22] He H Y, Sun H, Xie Z, et al. Ambiguity-Aware Abductive Learning[C]//Proceedings of the 41st International Conference on Machine Learning (ICML' 24): vol. 235. PMLR, 2024: 18019-18042.

[23] Hu W C, Dai W Z, Jiang Y, et al. Efficient Rectification of Neuro-Symbolic Reasoning Inconsistencies by Abductive Reflection[C]//Proceedings of the 39th AAAI Conference on Artificial Intelligence (AAAI' 25): vol. 39: 16. 2025: 17333-17341.

[24] Huang Y X, Dai W Z, Jiang Y, et al. Enabling knowledge refinement upon new concepts in abductive learning[C]//Proceedings of the 37th AAAI Conference on Artificial Intelligence (AAAI' 23): vol. 37: 7. 2023: 7928-7935.

[25] Yang X W, Shao J J, Tu W W, et al. Safe abductive learning in the presence of inaccurate rules[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence (AAAI' 24): vol. 38: 15. 2024: 16361-16369.

[26] Huang Y X, Dai W Z, Yang J, et al. Semi-Supervised Abductive Learning and Its Application to Theft Judicial Sentencing[C]//Proceedings of 20th IEEE International Conference on Data Mining (ICDM' 20). 2020: 1070-1075.

[27] Wang J, Deng D, Xie X, et al. Tac-Valuer: Knowledge-based Stroke Evaluation in Table Tennis[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD' 21). 2021: 3688-3696.

[28] Gao E H, Huang Y X, Hu W C, et al. Knowledge-Enhanced Historical Document Segmentation and Recognition[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence (AAAI' 24): vol. 38: 8. 2024: 8409-8416.

[29] Wu Z Y, Guo W, Zhou W, et al. Abductive multi-instance multi-label learning for periodontal disease classification with prior domain knowledge[J]. Medical Image Analysis, 2025, 101: 103452.

[30] Dai W Z, Xu Q, Yu Y, et al. Bridging Machine Learning and Logical Reasoning by Abductive Learning[C]//Proceedings of the 33rd Conference on Neural Information Processing Systems (NeurIPS' 19): vol. 32. Curran Associates, Inc., 2019: 2815-2826.

[31] Dimopoulos Y, Nebel B, Koehler J. Encoding planning problems in nonmonotonic logic programs[C]//Proceedings of the 4th European Conference on Planning (ECP' 97). 1997: 169-181.

[32] De Raedt L, Kimmig A, Toivonen H. ProbLog: A probabilistic Prolog and its application in link discovery[C]//Proceedings of the 20th International Joint Conference on Artificial Intelligence (IJCAI' 07). 2007: 2462-2467.

[33] Deng L. The mnist database of handwritten digit images for machine learning research [best of the web][J]. IEEE Signal Processing Magazine, 2012, 29(6): 141-142.

[34] Xiao H, Rasul K, Vollgraf R. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms[J]. ArXiv preprint ArXiv:1708.07747, 2017.

[35] Krizhevsky A, Hinton G, et al. Learning multiple layers of features from tiny images[R]. Toronto, ON, Canada, 2009.

[36] LeCun Y, Bengio Y, et al. Convolutional networks for images, speech, and time series[J]. The Handbook of Brain Theory and Neural Networks, 1995, 3361(10): 255-258.

[37] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR' 16). 2016: 770-778.

致　　谢

岁月不居，时节如流，四年的本科生涯转瞬即逝，即将画上圆满的句号。本科毕业论文的完成，离不开大家的帮助与支持。在此，我谨向所有给予我关心、帮助和支持的人表示最诚挚的感谢。

首先，我要衷心感谢周志华老师和姜远老师，在论文写作期间，两位老师从论文选题到内容结构，再到论文的反复修改，都给予了我细致耐心的指导。老师一丝不苟的治学态度和在机器学习领域的渊博知识与深入见解，让我受益匪浅。

其次，我要感谢胡文超师兄对我的帮助。师兄不仅为本文中所使用的方法提供了部分思路，还对本文的实验代码实现细节提供了帮助。我们常在一起交流科研进展与论文写作方向。师兄丰富的科研经验为我提供了宝贵的帮助。

感谢我的同学和朋友们，尤其是一起讨论问题、互相鼓励的你们，在论文撰写的过程中给予了我很多帮助和鼓励，让这段经历更加充实与难忘。

最后，特别感谢我的家人，是你们一直以来关心与支持让我能够安心学习、顺利完成学业。