南京大学

本 科 毕 业 论 文

院　　系　人工智能学院

专　　业　人工智能

题　　目　一种基于表征学习的高效持续强化学习方法

年　　级　2021　学　　号　211300032

学生姓名　何翊豪

指导教师　章宗长　职　　称　副教授

提交日期　2025 年 6 月 6 日

南京大学本科毕业论文（设计）
诚信承诺书

本人郑重承诺：所呈交的毕业论文（设计）（题目：一种基于表征学习的高效持续强化学习方法）是在指导教师的指导下严格按照学校和院系有关规定由本人独立完成的。本毕业论文（设计）中引用他人观点及参考资源的内容均已标注引用，如出现侵犯他人知识产权的行为，由本人承担相应法律责任。本人承诺不存在抄袭、伪造、篡改、代写、买卖毕业论文（设计）等违纪行为。

作者签名：何翊豪

学号：211300032

日期：2025年6月6日

南京大学本科生毕业论文（设计、作品）中文摘要

题目：一种基于表征学习的高效持续强化学习方法

院系：人工智能学院

专业：人工智能

本科生姓名：何翊豪

指导教师（姓名、职称）：章宗长　副教授

摘要：

强化学习模型在持续适应动态环境上面临挑战，尤其是当奖赏函数频繁变化时，现有方法往往难以在知识保留与新任务学习中保持平衡。本文针对环境敏感上下文策略学习（ESCP）框架在奖赏函数动态变化任务中的局限性，提出一种基于表征学习的高效持续强化学习算法——基于奖赏的序列上下文解释算法（RoSeLIA）。该算法通过设计奖励函数感知的上下文编码器，结合历史截断交互序列提取潜在任务特征，并引入移动平均值机制降低训练方差。此外，针对循环神经网络梯度不稳定性问题，RoSeLIA 采用上下文编码器特定学习率策略以抑制参数更新对长期序列建模的干扰。实验表明，RoSeLIA 在奖赏函数突变的场景中能够快速适应环境变化，较传统元强化学习方法在策略调整速度和任务完成率上均有显著提升，在部分任务上相较 ESCP 算法有高达 7% 的性能提升。本研究为动态环境下的实时决策系统（如智能交通调度、工业过程控制等）提供了新的技术思路，并拓展了持续强化学习在复杂多任务场景中的应用边界。

关键词：持续强化学习；表征学习；上下文编码；环境适应

南京大学本科生毕业论文（设计、作品）英文摘要

THESIS: Representation Learning-Based Efficient Reinforcement Learning

DEPARTMENT: School of Artificial Intelligence

SPECIALIZATION: Artificial Intelligence

UNDERGRADUATE: He Yihao

MENTOR: Associate Professor Zhang Zongzhang

ABSTRACT:

The continuous adaptation capability of reinforcement learning in dynamic environments faces significant challenges, especially when reward functions change frequently, as existing methods often struggle to balance knowledge retention and new task learning. Targeting the limitations of the Environment-Sensitive Contextual Policy learning (ESCP) framework in dynamic reward function tasks, this paper proposes an efficient continual reinforcement learning algorithm based on representation learning – **R**eward-**o**n **Se**quentia**L** context **I**nterpretation **A**lgorithm (RoSeLIA). RoSeLIA is deployed a reward-function-aware context encoder to extract latent environment features from truncated historical interaction sequences, while introducing a moving average mechanism to reduce training variance. Additionally, to address the gradient instability of recurrent neural networks, RoSeLIA employs a context-encoder-specific learning rate strategy to mitigate interference from parameter updates on long-term sequence modeling. Experiments demonstrate that RoSeLIA rapidly adapts to environmental changes under reward function mutation scenarios, significantly outperforming traditional meta-reinforcement learning methods in terms of policy adjustment speed and task completion rate, achieving a performance improvement of 7% in some tasks. This study provides new technical insights for real-time decision-making systems in dynamic environments, such as intelligent traffic scheduling and industrial process control, while expanding the application boundaries of continual reinforcement learning in complex multi-task scenarios.

KEYWORDS: Continual Reinforcement Learning; Representation Learning; Context Encoding; Environment Adaptation

目　　录

目　　录 III

第一章 绪论 1

1.1 研究背景及意义 1

1.2 本文组织结构 2

第二章 相关工作 4

2.1 相关理论和概念 4

2.1.1 马尔可夫决策过程 4

2.1.2 部分可观测的马尔可夫决策过程 6

2.1.3 离线和在线强化学习 7

2.2 国内外研究现状 8

2.2.1 元强化学习 8

2.2.2 基于记忆的强化学习 9

2.2.3 基于上下文的元强化学习 10

2.2.4 持续强化学习的代表算法 11

第三章 本文方法 12

3.1 模型结构概述 12

3.2 上下文编码器 CE 的优化目标 13

3.3 历史序列截断 16

3.4 移动平均值 16

3.5 特定学习率 17

3.6 总训练过程 19

第四章 实验 21

4.1 网格世界 21
4.1.1 环境概况 21
4.1.2 实验结果 22
4.2 MuJoCo 任务环境 24
4.2.1 环境概况 24
4.2.2 实验结果 25
4.3 实验结果总结 26
第五章 结语 27
参考文献 28
致 谢 33

第一章　绪论

1.1　研究背景及意义

强化学习（Reinforcement Learning, RL）是机器学习领域的一个重要的分支，在人工智能（Artificial Intelligence, AI）发展的最早期阶段便被闵斯基（Marvin L. Minsky）等人提出，其核心在于通过试错机制实现智能体与动态环境的交互式学习[1]。在经典的强化学习框架中，智能体（Agent）通常通过马尔可夫决策过程（Markov Decision Process, MDP）（见2.1.1小节）对环境动态进行建模[2]。在建模过程中，智能体以长期累积奖励为最大化目标，通过与环境（environment）进行交互从而获得奖励（reward）信号，进而逐步优化其策略（policy）。然而，传统的强化学习方法通常假设任务环境静态不变且任务目标单一，这与现实应用场景中复杂多变的动态环境存在显著差异。例如，在自动驾驶系统中，道路交通规则、行人行为模式以及车辆动力学参数等因素可能随时间动态变化；在金融交易场景中，市场状态与用户偏好同样呈现非平稳的波动特性。这样的动态变化环境对智能体的持续适应能力提出了更高要求。

为了解决上文所述的动态多任务环境下的长期适应性问题，持续强化学习（Continual RL, CRL）[3]应运而生。作为强化学习的一种扩展范式，持续强化学习的核心挑战可归纳为以下三方面：首先，神经网络（Neural Network, NN）固有的灾难性遗忘（catastrophic forgetting）现象导致智能体在新任务学习过程中伴随着旧任务上性能的急剧退化[4-5]；其次，持续强化学习模型可能产生跨任务知识迁移即如何利用历史经验加速新任务学习的效率问题[6]；最后，模型在动态环境中的泛化能力不足，难以应对未见任务或环境突变。研究表明，现有的持续强化学习方法在边界明确且变化缓慢的任务场景中表现尚可，但在奖赏函数（reward function）频繁变化的复杂任务中仍存在显著的性能瓶颈。

基于表征学习（representation learning）的持续强化学习方法为解决上文所述的三方面核心问题提供了创新路径。基于表征学习的持续强化学习方法部署

了编码器（encoder）用于提取任务无关的高层特征表示，在保留历史任务分布信息的同时，增强了对动态环境的适应性[7-8]。同时，编码器也能有效地处理基于动态环境的任务，从而解决了知识迁移问题[9]，因而保证了模型对新任务的学习能力。例如，环境敏感上下文策略学习（Environment Sensitive Contextual Policy learning, ESCP）[10]采用在线元学习（online meta-learning）框架，通过最小化上下文编码方差、最大化关系矩阵行列式以及历史截断循环神经网络的三阶段优化，实现了对突变的环境动力学（environment dynamics）的高效表征。实验结果表明，ESCP 在环境参数突变的模拟场景（如机械臂负载突变、迷宫地形重构）中的适应速度和适应效果相较于传统的元强化学习（Meta RL）[11]方法有了显著提升。然而，ESCP 的设计局限在于其仅关注了环境动力学的表征学习，而未考虑到奖赏函数动态变化的任务场景，导致其可能难以在持续强化学习基准测试（如 MetaWorld[12]等）场景中直接应用。

本文拟针对 ESCP 框架的局限性展开研究，并提出一种面向奖赏函数动态变化的改进型持续强化学习算法，笔者将其命名为“基于奖赏的序列上下文解释算法”（**R**eward-**o**n **Se**quentia**L** context **I**nterpretation **A**lgorithm, RoSeLIA）。具体而言，RoSeLIA 在若干任务环境的实验中表现出了优于 ESCP 的性能，例如在网格世界（见第四章）中，RoSeLIA 相较于 ESCP，在评价返回值上有着约 7% 的提升。本研究不仅拓展了持续强化学习的应用边界，也为动态环境下的实时决策系统，如智能交通调度、工业过程控制等，提供了新的技术思路。

1.2 本文组织结构

本文的组织结构说明如下：

- 第一章为绪论，指出了传统强化学习和近年来部分模型在奖赏可变环境下适应能力的不足，从而引出基于奖赏的序列上下文解释算法相应的研究意义。
- 第二章介绍了强化学习的相关理论、概念背景和国内外相关研究成果，这是 RoSeLIA 模型提出的理论和实践基础。
- 第三章为模型与优化，主要介绍基于奖赏的序列上下文解释算法的框架组成，并说明其中部分环节的优化过程，同时给出相应的数学证明。

- 第四章为基于奖赏的序列上下文解释算法在仿真环境下的实验及结论，我们在该章进行了多种任务环境的对比实验，并根据实验结果提出了实验结论和一些相关猜想。
- 第五章为结语，总结了本文的主要成果，分析了本文研究结果的局限和不足，并对进一步的研究进行了展望。

第二章　相关工作

2.1　相关理论和概念

2.1.1　马尔可夫决策过程

如前文所述，在强化学习中，我们通常将智能体同环境的交互过程建模为一个马尔可夫决策过程或其衍生形态。图2-1给出了强化学习的基本模式，接下来我们讨论如何用马尔可夫决策过程描述这个模式。

在一个马尔可夫决策过程中，我们定义一个初始状态分布 ρ_0、一个状态空间（state space）$\mathcal{S}$ 和一个动作空间（action space）$\mathcal{A}$。当处于状态 $s \in \mathcal{S}$ 时，我们定义智能体选择执行动作 $a \in \mathcal{A}$ 的概率为 $\pi(a \mid s)$，并且定义智能体在状态 s 下执行动作 a 后变换至状态 $s' \in \mathcal{S}$ 的概率为 $P(s' \mid s, a)$，我们称这个概率为转移概率（transition probability），以及获得的奖赏（reward）值为 $R(s, a, s')$。概率 π 又称为策略（policy），而一个策略的好坏由累积奖赏（cumulative reward）决定，这使得强化学习的智能体能够摆脱贪心算法的局限性，从而做出长期最优的决策。常见的累积奖赏包括 T 步累积奖赏 $G(\pi) = \mathbb{E}_\pi\left[\frac{1}{T}\sum_{t=1}^{T} r_t\right]$ 和 γ 折扣累积奖赏 $G(\pi) = \mathbb{E}_\pi\left[\sum_{t=0}^{+\infty} \gamma^t r_{t+1}\right]$[2]，其中 $r_t = R(s_t, a_t)$ 表示智能体在时刻 t 获得的奖赏值，γ 称为折扣因子。于是，我们可以将一个马尔可夫决策过程相应地记作 $\langle \mathcal{S}, \mathcal{A}, P, R, \rho_0, T\rangle$ 或 $\langle \mathcal{S}, \mathcal{A}, P, R, \rho_0, \gamma\rangle$。

为了对马尔可夫决策过程问题进行求解，我们引入状态值函数（state value function）$V^\pi(s)$ 和状态-动作值函数（state-action value function）$Q^\pi(s, a)$。前者表示当前处于状态 $s \in \mathcal{S}$ 的智能体使用策略 π 后得到的累积奖赏，后者表示当前处于状态 s 的智能体执行动作 $a \in \mathcal{A}$ 再使用策略 π 后得到的累积奖赏。由累积

图 2-1　强化学习模式示意图。图片修改引用自周志华《机器学习》[2]。

奖赏的定义，我们有

$$
\begin{aligned}
V_T^{\pi}(s) &= \mathbb{E}_{\pi}\left[\frac{1}{T}\sum_{t=1}^{T} r_t \,\middle|\, s_0 = s\right]; \\
V_{\gamma}^{\pi}(s) &= \mathbb{E}_{\pi}\left[\sum_{t=0}^{+\infty} \gamma^t r_{t+1} \,\middle|\, s_0 = s\right]
\end{aligned}
\tag{2-1}
$$

以及

$$
\begin{aligned}
Q_T^{\pi}(s,a) &= \mathbb{E}_{\pi}\left[\frac{1}{T}\sum_{t=1}^{T} r_t \,\middle|\, s_0 = s, a_0 = a\right]; \\
Q_{\gamma}^{\pi}(s,a) &= \mathbb{E}_{\pi}\left[\sum_{t=0}^{+\infty} \gamma^t r_{t+1} \,\middle|\, s_0 = s, a_0 = a\right].
\end{aligned}
\tag{2-2}
$$

一般通过贝尔曼最优方程（Bellman Optimality Equation）[13]来最优化动作选择概率，即策略。我们首先生成上述两种值函数的递归求解式。由于马尔可夫决策过程具有马尔可夫性质，即系统在下一时刻的状态仅取决于当前时刻的状态，于是我们有

$$
\begin{aligned}
V_T^{\pi}(s) &= \mathbb{E}_{\pi}\left[\frac{1}{T}\sum_{t=1}^{T} r_t \,\middle|\, s_0 = s\right] \\
&= \mathbb{E}_{\pi}\left[\frac{1}{T} r_1 + \frac{T-1}{T}\cdot\frac{1}{T-1}\sum_{t=2}^{T} r_t \,\middle|\, s_0 = s\right] \\
&= \sum_{a\in\mathcal{A}} \pi(a \mid s) \sum_{s'\in\mathcal{S}} P(s' \mid s,a)\left(\frac{1}{T}R(s,a,s') + \frac{T-1}{T}\mathbb{E}_{\pi}\left[\frac{1}{T-1}\sum_{t=1}^{T-1} r_t \,\middle|\, s_0 = s'\right]\right) \\
&= \sum_{a\in\mathcal{A}} \pi(a \mid s) \sum_{s'\in\mathcal{S}} P(s' \mid s,a)\left(\frac{1}{T}R(s,a,s') + \frac{T-1}{T}V_{T-1}^{\pi}(s')\right).
\end{aligned}
\tag{2-3}
$$

相似地，我们有

$$V_\gamma^\pi = \sum_{a\in\mathcal{A}} \pi(a \mid s) \sum_{s'\in\mathcal{S}} P(s' \mid s,a)\left(R(s,a,s') + \gamma V_\gamma^\pi(s')\right). \tag{2-4}$$

于是，我们容易得到状态-动作值函数的递归式

$$\begin{aligned} Q_T^\pi(s,a) &= \sum_{s'\in\mathcal{S}} P(s' \mid s,a)\left(\frac{1}{T}R(s,a,s') + \frac{T-1}{T}V_{T-1}^\pi(s')\right); \\ Q_\gamma^\pi(s,a) &= \sum_{s'\in\mathcal{S}} P(s' \mid s,a)\left(R(s,a,s') + \gamma V_\gamma^\pi(s')\right). \end{aligned} \tag{2-5}$$

显然，由于策略本身作为优化的目标，为了得到最优的状态值函数 V，我们有

$$V^\star = \max_{a\in\mathcal{A}} Q^{\pi^\star}(s,a). \tag{2-6}$$

相对地，我们将最优状态值函数代入状态-动作值函数的递归式，得到

$$\begin{aligned} Q_T^\star(s,a) &= \sum_{s'\in\mathcal{S}} P(s' \mid s,a)\left(\frac{1}{T}R(s,a,s') + \frac{T-1}{T}\max_{a\in\mathcal{A}} Q_{T-1}^\star(s',a')\right); \\ Q_\gamma^\pi(s,a) &= \sum_{s'\in\mathcal{S}} P(s' \mid s,a)\left(R(s,a,s') + \gamma \max_{a\in\mathcal{A}} Q_\gamma^\star(s',a')\right), \end{aligned} \tag{2-7}$$

至此，我们利用贝尔曼最优方程得到了非最优化策略的更新优化方式。

2.1.2 部分可观测的马尔可夫决策过程

在式 (2-3) 中，动作-状态全概率展开的前提条件是转移概率 $\boldsymbol{P}$ 和奖赏函数 $\boldsymbol{R}$ 可知。但在大多数现实任务环境中，由于我们无法对所有的环境变量或因素进行测量，所以无法准确得到状态 s，也就无法通过状态来决策动作。我们引入部分可观测的马尔可夫决策过程（Partially Observable MDP, POMDP）[14-15]，将其作为智能体与环境交互过程的建模目标。

在部分可观测的马尔可夫决策过程中，我们引入一个观测空间（observation space）$\mathcal{Z}$，即所有观测值的集合。智能体在同环境进行交互的过程中通过观测值对环境状态进行推理和建模。对于某个观测值 $z \in \mathcal{Z}$，我们定义观测概率

（observation probability）$O(z \mid s', a)$ 为智能体在执行动作 $a \in \mathcal{A}$ 后转移至状态 $s' \in \mathcal{S}$ 的条件下得到观测值 z 的概率。观测概率有时也被定义为 $O(z \mid s')$。

由于我们无法像一般的马尔可夫决策过程一样求解状态值函数和动作-状态值函数，我们引入信念状态（belief state）。首先，我们定义一个历史变量 h_t，表示系统在时刻 t 之前的观测值、行动等信息记录。然后，我们可以定义信念状态为智能体在初始信念 b_0 和当前历史 h_t 的条件下，处于状态 s 的概率，即 $b_t(s) = p(s \mid b_0, h_t)$。信念状态的更新方程为

$$b_{t+1}(s') = \frac{O(z_{t+1} \mid s', a_t) \sum_{s \in \mathcal{S}} P(s' \mid s, a_t) b_t(s)}{\sum_{s \in \mathcal{S}} b_t(s) \sum_{s'' \in \mathcal{S}} O(z_{t+1} \mid s'', a_t) P(s'' \mid s, a_t)}, \tag{2-8}$$

即下一时刻的信念 b_{t+1} 等于转移至下一状态 s' 的概率、在下一状态观测到 z_{t+1} 的概率和当前信念 b_t 的乘积。

在部分可观测的马尔可夫决策过程中，以 γ 折扣累积奖赏为例，我们可以相应地定义状态值函数和状态-动作值函数，最终写出相应的贝尔曼最优方程如下：

$$V^\star(b) = \max_{a \in \mathcal{A}} \left(R_b(b, a) + \gamma \sum_{z \in \mathcal{Z}} p(z \mid b, a) V^\star(b') \right), \tag{2-9}$$

$$Q^\star(b, a) = R_b(b, a) + \gamma \sum_{z \in \mathcal{Z}} p(z \mid b, a) V^\star(b'), \tag{2-10}$$

其中 $p(z \mid b, a)$ 表示智能体在信念 b 和执行动作 a 的条件下观测到 z 的概率，这个值的计算可以参考式 (2-8) 的分母部分。

2.1.3 离线和在线强化学习

如 1.1 节所述，标准的强化学习方法通过反复试错来习得如何执行任务，并在探索（exploration）与利用（exploitation）之间的平衡中试图取得更好的表现。离线强化学习（offline RL），又称批强化学习（Batch RL, BRL），研究如何最大限度地利用静态的离线数据集来训练强化学习的智能体。它要求智能体从一个固定的数据集中进行学习，而不能在环境中进行探索。图 2-2 (c) 展示了离线强化学习的模型结构，其中经验池 $\mathcal{D}$ 中的离线数据由未知的行为策略（behavior policy）生成，而离线强化学习正是希望利用经验池 $\mathcal{D}$ 中的这些未知来源的数据对当前策略进行训练，并期望学到的策略在部署到交互环境中时能够有较好的表现。

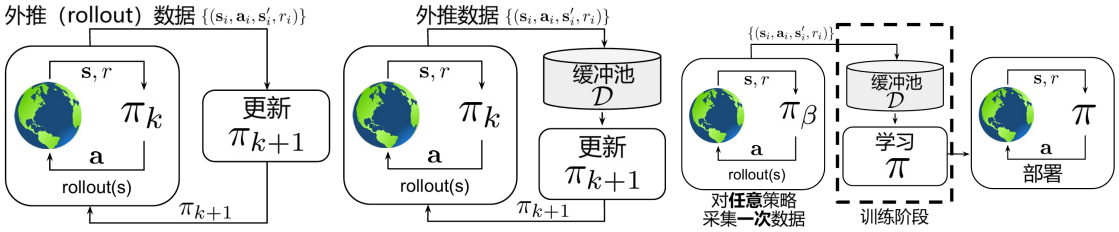

(a) 在线强化学习　　(b) 异策略强化学习　　(c) 离线强化学习

图 2-2　在线强化学习 (a)、异策略强化学习 (b) 和离线强化学习 (c) 的示意图，图片引用自 [Levine, Kumar, Tucker et al., 2020][16]。

在线强化学习（online RL）是一种更为常见的强化学习模式，它要求智能体在训练过程中同环境进行交互。图 2-2 (a) 展示了在线强化学习的模型结构。在线强化学习又可以分为异策略（off-policy）和同策略（on-policy）两种训练模式，其中所谓的“策略”指的是行为策略和目标策略（target policy）。行为策略应用于学习数据获取阶段，具有一定的随机性，有一定的概率选出潜在的最优动作，而目标策略利用行为策略收集到的样本并使用若干策略提升方法提升自身性能，最终得到最优策略。在异策略模式中，智能体将学习数据获取作为一个独立的任务，智能体的学习数据来自一个单独的用于探索的策略。典型的异策略算法包括 Q 学习（Q-learning）[17]、深度 Q 网络（Deep Q Network, DQN）[18]、双延迟深度确定性策略梯度（Twin Delayed Deep Deterministic policy gradient, TD3）[19]和软动作评价（Soft Actor-Critic, SAC）[20-21]等。相对地，在同策略模式中，行为策略和目标策略是相同的，即将学习数据的获取过程和智能体的训练过程当作同一个任务，此时智能体只能使用当前正在优化的策略生成的数据进行训练。典型的同策略算法包括近端策略优化（Proximal Policy Optimization, PPO）[22]等。

2.2　国内外研究现状

2.2.1　元强化学习

元强化学习[11]通过“学会学习”（Learning to Learn）[23-24]机制，使智能体能够快速适应未知任务。元强化学习的核心思想是通过元训练阶段获取跨任务共享的先验知识，然后在元测试阶段通过少量样本实现快速的微调。元强化学习的一种早期代表算法 RL^2[11]采用了双层循环架构，其中外层通过慢速强化学习（slow RL）学习任务分布的通用策略，内层利用门控循环单元（Gated Recurrent

Unit, GRU）[25]实现快速的策略调整。然而，RL^2 的外层循环算法已被证明是一个直接的性能瓶颈，并且 RL^2 在处理任务时需要使用完整的情节（episode），它对先验知识的利用效率也不甚理想，无法解决长期依赖问题。

模型不可知的元学习（Model-Agnostic Meta-Learning, MAML）[26]算法也是一种重要的元强化学习方法。它使用一套预先训练完毕的环境参数，用尽可能少的梯度更新步数使得模型能够迅速迁移至新的环境中。具有结构噪声的模型不可知探索（Model Agnostic Exploration with Structured Noise, MAESN）[27]算法是模型不可知元学习的一种衍生算法，它在策略网络中注入结构化噪声，通过潜在探索空间的结构随机性（structured stochasticity）来生成多样性的探索动作。实验证明了具有结构噪声的模型不可知探索在 Wheeled Locomotion 任务中的探索效率相较于一般的模型不可知元学习提升了大约 30%。近年来，概率嵌入元强化学习（Probabilistic Embedding for Actor-critic meta-RL, PEARL）[28]通过变分推断构建任务后验分布，结合异策略训练机制，显著降低了元训练阶段的样本复杂度。

2.2.2 基于记忆的强化学习

基于记忆的强化学习（memory-based RL）是元强化学习的另一分野。它通过显式地存储历史经验从而缓解神经网络的灾难性遗忘问题。记忆增强神经网络（Memory-Augmented Neural Network, MANN）[29]受神经图灵机（Neural Turing Machine, NTM）[30]的启发，使用了一种类似于记忆缓冲池的结构。它采用可微分的读写头机制，实现经验的选择性存储与检索；无模型情节控制（Model-Free Episodic Control, MFEC）[31]结合了认知科学领域的知识，模仿了人类大脑中海马体的情节记忆（episodic memory）[32]机能，构建了由状态-动作二元组构成的快速检索库，但其离散存储特性限制了它在高维连续状态空间的应用。Young 等人提出的蓄水池抽样过程（reservoir sampling procedure）[33]维护一个由固定数目的过去状态组成的外部记忆，并通过动态优先级调整实现记忆库的高效更新，在 Atari 游戏任务中取得优于传统经验回放（experience replay）的性能。

值得关注的是，混合记忆架构（hybrid memory architecture）逐渐成为了一个新的研究热点。例如，神经情景控制（Neural Episodic Control, NEC）[34-35]将记忆增强神经网络与无模型情节控制两种方法结合，通过可学习的键值对记忆实现

快速策略检索。此外，动态记忆网络（Dynamic Memory Networks, DMN）[36-37]通过注意力机制实现记忆内容的动态加权融合，在部分可观测的马尔可夫决策过程中展现出了更强的环境建模能力。

2.2.3 基于上下文的元强化学习

基于上下文的元强化学习（context-based meta RL）应用于部分可观测的马尔可夫决策任务中，在智能体感知环境受限的情况下帮助智能体对环境进行建模。在动态环境建模领域，上下文编码器（Context Encoder, CE）通过提取潜在任务变量（latent context variables）以增强策略的适应性。环境探测交互策略（Environment Probing Interaction, EPI）[38]通过主动探索行为（如随机扰动、定向采样等）构建环境动态的隐式表示，但其缺陷在于探索阶段的额外时间成本较高；上下文感知动力学模型（Context-aware Dynamics Model, CaDM）[39]引入了一种新的损失函数，有助于上下文潜在向量有效预测前向和后向动态。对比之下，在线系统识别（Online System Identification, OSI）[40]采用监督学习方法，利用历史状态-动作序列预测环境参数，但其线性假设难以捕捉复杂非线性动态。上述三种方法都将上下文编码器 CE 引入模型[10]，帮助智能体感知环境并做出更优的策略。

前文提到的 ESCP 模型[10]通过三阶段优化实现突变环境的高效适应：1）上下文编码方差最小化（variance minimization），以确保任务表征的稳定性使得模型能够快速且准确地提供环境上下文的编码；2）关系矩阵行列式最大化（relational matrix determinant maximization），以避免模型学到平凡解使编码空间塌缩；3）历史截断循环神经网络（history-truncated RNN），以过滤无关历史信息。实验结果表明，ESCP 在 MuJoCo[41]连续控制任务的突变场景（如机械臂质量参数突变等）中，策略调整效果远超在线系统识别模型，后者甚至无法追踪环境突变[10]。然而，ESCP 未考虑奖赏函数动态变化的场景，其上下文编码器仅捕获环境动力学特征，导致在奖赏稀疏或奖励函数频繁调整的任务中性能受限。

2.2.4 持续强化学习的代表算法

策略优化算法的进步为持续强化学习提供了基础支撑。信赖域策略优化（Trust Region Policy Optimization, TRPO）[42]算法类似于自然策略梯度方法，它忽略状态分布的变化，而是利用重要性采样对动作分布进行处理，并且通过 KL 散度约束保证策略更新的稳定性，但是该模型的二阶导数计算复杂度较高，影响了该算法在实际应用中的效果；近端策略优化（PPO）[22]在信赖域策略优化的基础上将计算难度较大的 KL 散度通过截断的重要性采样比（clipped importance ratio）进行替代，用一种更加简化的方式实现了信赖域策略优化，并较其更为通用，且具有更佳的样本复杂性，实用性更强，在并行化训练中展现出显著优势；深度确定性策略梯度（Deep Deterministic Policy Gradient, DDPG）算法[43]解决了深度 Q 网络（DQN）[18]难以解决的连续控制型问题，首次将动作评价（Actor-Critic）框架扩展至连续动作空间，但其对超参数较为敏感且容易出现过估计（overestimation）问题；双延迟深度确定性策略梯度（TD3）[19]算法通过双重 Q 网络（twin Q-networks）和延迟策略更新（delayed policy update）机制有效缓解了上述缺陷。

最大熵强化学习（maximum entropy RL）框架[20]通过引入熵正则化项来实现探索与利用二者的平衡。软动作评价（SAC）[20-21]作为其代表算法，采用了随机策略（stochastic policy）和自动调整的温度系数（temperature coefficient），在复杂控制任务中表现出卓越的鲁棒性。研究表明，软动作评价的熵最大化机制可等效转化为对策略多样性的显式约束，使其在动态环境中能持续生成多样性动作以避免局部最优。ESCP 正是一种基于软动作评价算法的模型。

具有上下文编码器特定学习率的递归非策略强化学习（**R**ecurrent off-policy RL with context-**E**ncoder-**S**pecific **L**earning rate, RESeL）[44]对上下文编码器使用相较于其他多层感知机（Multi-Layer Perceptron, MLP）层来说更低的学习率来解决由循环神经网络的梯度不稳定性造成的上下文编码器训练稳定性问题，同时保证其他多层感知机层的训练效率。由于非策略强化学习的简单性、灵活性和潜在的高样本效率，RESeL 使用它来直接训练递归模型。RoSeLIA 基于 ESCP 和 RESeL 框架进行扩展，通过奖励函数感知的上下文编码机制，在保证达到上述两个模型的性能的基础上，进一步提升模型对奖赏变化的适应能力。

第三章　本文方法

本章主要介绍 RoSeLIA 的模型结构和 RoSeLIA 在理论与实践中的各类优化方法，最后我们给出 RoSeLIA 的总体训练过程。

3.1　模型结构概述

RoSeLIA 由两个主要部分组成：1）上下文编码器（CE），以历史交互信息为输入，生成关于潜在环境上下文的编码；2）上下文策略（Contextual Policy, CP），以采样出来的环境上下文和当前状态为输入，生成适应性策略。这种组合结构与上文中提到的若干种基于环境上下文的强化学习算法[10,38-40]类似。在每一个时间步 t，上下文编码器 CE 接收来自历史缓冲池（history buffer）的由状态、动作、奖励三元组 $\langle s, a, r\rangle$ 组成的交互信息序列，并且接收当前状态 s_t，然后预测出一个关于当前任务环境的潜在上下文分布。特别地，为了在学到上下文特征的基础上实现对突变环境的适应，我们需要防止过于久远的历史交互信息对当前编码和决策的干扰。为此，RoSeLIA 学习了 ESCP[10]的做法，将历史信息序列截断后再用作上下文编码器 CE 的输入。3.3 节对历史序列截断进行了更详细的说明。具体地，我们定义一个历史截断长度 H，并在输入过程中仅取用由最近 H 次交互组成的序列 $\{s_{t-H}, a_{t-H}, r_{t-H}, \cdots, s_{t-1}, a_{t-1}, r_{t-1}\}$。之后，一个潜在上下文 c_t 从

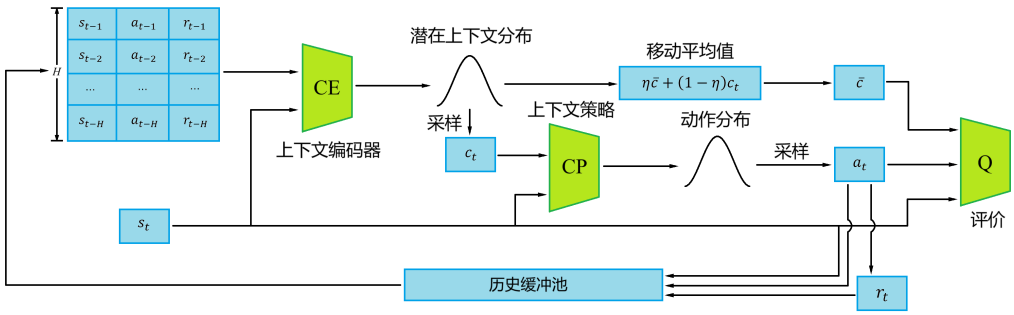

图 3-1　以状态-动作值函数 Q 为评价函数的 RoSeLIA 模型结构示意图。

由上下文编码器 CE 预测的上下文分布中采样出来，并与当前状态 s_t 连接，送入上下文策略 CP 网络的输入端。最后，上下文策略 CP 根据连接后的向量 (s_t, c_t) 生成一个动作分布并采样一个动作 a_t。智能体执行动作 a_t 与环境交互并产生相应的奖赏 r_t，这个奖赏同当前状态 s_t 和当前动作 a_t 一起送入历史缓冲池，其信息可供下一次交互使用。

评价模块的输入包含上下文信息、当前动作 a_t 和当前状态 s_t。由于平均上下文具有更小的方差并且更稳定，故我们选择使用（移动更新过的）平均潜在上下文作为动作值函数的输入。我们维护一组移动加权平均潜在上下文向量的集合 $\{\bar{c}^0, \bar{c}^1, \cdots, \bar{c}^{M-1}\}$，其中每个移动平均上下文向量的上标表示其所处的环境编号。当我们需要在第 i 个环境中预测某个状态-动作对（state-action pair）的评价值时，我们只需从集合中提取对应环境的平均上下文，同状态-动作对一起送入评价网络。我们在 3.4 节对移动加权平均潜在上下文的使用做了详细的说明。图 3-1 给出了以状态-动作值函数 Q 为评价函数时的模型结构示意图。

从而，上下文策略 CP 和相应的动作评价函数（以状态-动作值函数为例）可以分别被表示为

$$\pi(a \mid s, c; \theta), \quad Q(s, a, \bar{c}; \varphi), \tag{3-1}$$

其中 θ 和 φ 分别表示上下文策略 CP 和状态-动作值函数 Q 的参数。在本文中，上下文策略 CP 的训练遵循软动作评价（SAC）[20-21]的模式。当然，RoSeLIA 对上下文策略 CP 的训练也可以使用其他模式，例如信赖域策略优化（TRPO）[42]、近端策略优化（PPO）[22]等。

3.2 上下文编码器 CE 的优化目标

由于上下文策略 CP 的决策以上下文编码器 CE 所习得的上下文编码为基础，在后者完成对上下文的编码后，一个最优的上下文策略 CP 便可相应地生成一个最优的策略。换言之，只要上下文编码器 CE 能迅速识别并跟踪变化的环境或变化的奖赏函数，上下文策略 CP 便能通过上下文编码器 CE 生成的新的潜在上下文分布采样做出最优的新的决策。因此，我们只需考虑对上下文编码器 CE 进行优化。我们希望上下文编码器 CE 能尽可能快地对变化的环境或奖赏函数进行相

应的正确的调整。

我们记潜在上下文空间（latent context space）为 $\mathcal{C}$，并令第 i $(i = 0, 1, \cdots, M-1)$ 个环境中的真实潜在上下文向量为 $u^i \in \mathcal{C}$。我们希望上下文编码器 CE 能够尽可能快地预测 u^i，并且希望在每个时间步 t，上下文编码器 CE 的预测结果 c_t^i 都能尽可能接近真实潜在值 u^i。我们再记上下文编码器 CE 在第 i 个环境下预测的潜在上下文分布为 $\mathcal{D}^i$，于是，上下文编码器 CE 在第 i 个环境中的损失函数或优化目标可以写作

$$\ell_{\mathrm{CE}}^i = \mathbb{E}_{c_t^i \sim \mathcal{D}^i}\left[\left\|c_t^i - u^i\right\|_2^2\right], \tag{3-2}$$

这里我们使用了 L2 距离作为度量。为方便起见，在下文中，我们将 $\mathbb{E}_{c_t^i \sim \mathcal{D}^i}[\cdot]$ 简记为 $\mathbb{E}[\cdot]$。

我们对式 (3-2) 进行偏置-方差分解（bias-variance decomposition），得到

$$\begin{aligned}
\ell_{\mathrm{CE}}^i &= \mathbb{E}\left[\left\|c_t^i - u^i\right\|_2^2\right] \\
&= \sum_k \mathbb{E}\left[\left(\left(c_t^i\right)_k - \left(u^i\right)_k\right)^2\right] \\
&= \sum_k \left(\mathbb{E}^2\left[\left(c_t^i\right)_k - \left(u^i\right)_k\right] + \mathrm{Var}\left(\left(c_t^i\right)_k - \left(u^i\right)_k\right)\right) \\
&= \sum_k \left(\left(\mathbb{E}\left[\left(c_t^i\right)_k\right] - \left(u^i\right)_k\right)^2 + \mathrm{Var}\left(\left(c_t^i\right)_k\right)\right) \\
&= \left\|\mathbb{E}\left[c_t^i\right] - u^i\right\|_2^2 + \sum_k \mathbb{E}\left[\left(\left(c_t^i\right)_k - \mathbb{E}\left[\left(c_t^i\right)_k\right]\right)^2\right] \\
&= \left\|\mathbb{E}\left[c_t^i\right] - u^i\right\|_2^2 + \mathbb{E}\left[\sum_k \left(\left(c_t^i\right)_k - \mathbb{E}\left[\left(c_t^i\right)_k\right]\right)^2\right] \\
&= \left\|\mathbb{E}\left[c_t^i\right] - u^i\right\|_2^2 + \mathbb{E}\left[\left\|c_t^i - \mathbb{E}\left[c_t^i\right]\right\|_2^2\right].
\end{aligned} \tag{3-3}$$

这样，上下文编码器 CE 的优化目标就被分为两个部分：1）偏置（bias），用于表征上下文编码器 CE 预测值的平均值 $\mathbb{E}\left[c_t^i\right]$ 与真实潜在上下文 u^i 之间的距离，目标是在训练过程中让前者趋近后者；2）方差（variance），用于表征上下文编码器 CE 预测值 c_t^i 与所有预测值的平均值 $\mathbb{E}\left[c_t^i\right]$ 之间的距离，它将上下文编码器 CE 预测值的平均值 $\mathbb{E}\left[c_t^i\right]$ 视作潜在上下文，目标是使上下文编码器 CE 的

预测结果快速而平稳地趋近平均值。

接下来我们尝试为上下文编码器 CE，或者更准确地，为所有环境构建一组合适的上下文向量 $u^i \in \mathcal{C},\ i = 0, 1, \cdots, M-1$，其中每个上下文向量都各自唯一代表其对应环境。我们希望 u^i 是（线性）可分的，并且能够使训练中的方差最小化过程不至于产生平凡解，因此我们需要让集合 $\mathcal{U} = \left\{u^i \mid i = 0, 1, \cdots, M-1\right\}$ 中各个向量的差异程度尽可能大。为此，我们引入一种计算一个向量集合中各向量的差异程度的方法——行列式点过程（Determinant Point Process, DPP）[10,45]。我们记两个向量 $\boldsymbol{p}$、$\boldsymbol{q}$ 的相关性为

$$\operatorname{cor}(\boldsymbol{p}, \boldsymbol{q}) = \exp\left(-\rho \left\|\boldsymbol{p} - \boldsymbol{q}\right\|_2^2\right), \tag{3-4}$$

其中 ρ 是用来控制度量比例的超参数。我们再令向量集合 $\mathcal{U}$ 的关系矩阵为 $\boldsymbol{R}_{\mathcal{U}}$，其中每个元素定义如下：

$$\boldsymbol{R}_{\mathcal{U}}(i, j) = \operatorname{cor}\left(u^i, u^j\right), \quad i, j \in \{0, 1, \cdots, M-1\}. \tag{3-5}$$

最后，我们记向量集合 $\mathcal{U}$ 的差异程度为 $\operatorname{div}(\mathcal{U}) = \det\left(\boldsymbol{R}_{\mathcal{U}}\right)$，其中 $\det(\cdot)$ 表示矩阵的特征值。

根据上述定义，我们有

命题 3.1 $\operatorname{div}(\mathcal{U})$ 的下界为 0，上界为 1。

以下给出一个定性的、数学上不严谨的证明。

证明 我们考虑两种最极端的情况：*1*）集合 $\mathcal{U}$ 中的所有向量均相同，此情形是相关性度量 $\operatorname{cor}(\cdot)$ 最大的情形；*2*）集合 $\mathcal{U}$ 中的所有向量两两不相关，此情形是相关性度量 $\operatorname{cor}(\cdot)$ 最小的情形。根据式 *(3-4)* 中对相关性度量的定义，我们知道，$\forall \boldsymbol{p} \forall \boldsymbol{q}.\ \operatorname{cor}(\boldsymbol{p}, \boldsymbol{q}) \in [0, 1]$。因此，对于情形 *1*，我们有 $\forall i \forall j.\ \operatorname{cor}\left(u^i, u^j\right) = 1$，从而有 $\forall i \forall j. \boldsymbol{R}_{\mathcal{U}}(i, j) = 1$，于是 $\operatorname{div}(\mathcal{U}) = \det\left(\boldsymbol{R}_{\mathcal{U}}\right) = 0$，这表示集合 $\mathcal{U}$ 中的向量的差异程度最小。对于情形 *2*，我们有 $\forall i \forall j.\ \left(i \neq j \rightarrow \operatorname{cor}\left(u^i, u^j\right) = 0\right)$，从而 $\boldsymbol{R}_{\mathcal{U}}$ 等价于单位矩阵 $\boldsymbol{I}$，于是 $\operatorname{div}(\mathcal{U}) = \det(\boldsymbol{I}) = 1$，这表示集合 $\mathcal{U}$ 中的向量的差异程度最大。综上所述，我们知道 0 和 1 分别是 $\operatorname{div}(\mathcal{U})$ 的下界和上界。 □

那么，我们可以通过最大化向量集合 $\mathcal{U}$ 的对数差异来得到 $\mathcal{U}$ 的最优解，即

$$\mathcal{U}^{\star} = \arg\max_{\mathcal{U}} \log \operatorname{div}(\mathcal{U}) = \arg\max_{\mathcal{U}} \log \det\left(\boldsymbol{R}_{\mathcal{U}}\right). \tag{3-6}$$

根据式 (3-3)，我们知道，u^i 是 $\mathbb{E}\left[c_t^i\right]$ 的目标逼近对象，因此我们不妨将式 (3-6) 中得出的最优解中的优化对象替换成由 $\mathbb{E}\left[c_t^i\right]$ 构成的向量集合。我们记 $\mathcal{E} = \left\{\mathbb{E}\left[c_t^i\right] \mid i = 0, 1, \cdots, M-1\right\}$，于是我们得到了关于 $\mathcal{E}$ 的最大化优化目标 $\mathcal{E}^{\star} = \arg\max_{\mathcal{E}} \log \det\left(\boldsymbol{R}_{\mathcal{E}}\right)$。因此，对模型总体而言，上下文编码器 CE 的优化目标可以写作

$$\ell_{\mathrm{CE}} = \lambda \sum_{i=0}^{M-1} \mathbb{E}\left[\left\|c_t^i - \mathbb{E}\left[c_t^i\right]\right\|_2^2\right] - \log \det\left(\boldsymbol{R}_{\mathcal{E}}\right), \tag{3-7}$$

其中 λ 是控制方差损失权重的正则化参数。

3.3 历史序列截断

历史序列截断（history sequence truncation）首次在 ESCP[10]中被提出，主要作用是在随时可能突变的环境中防止上下文编码器 CE 从过于久远的观测值和其他历史交互信息中学到突变之前的环境的特征，对编码新环境这个过程产生负面影响。在 RoSeLIA 中，我们学习这种做法，上下文编码器 CE 仅使用最近 $\boldsymbol{H}$ 次交互用于预测潜在上下文：

$$c_t^i \sim f(x_{t-H:t}, s_t; \psi), \tag{3-8}$$

其中 $x_{t-H:t} = \{s_{t-H}, a_{t-H}, r_{t-H}, \cdots, s_{t-1}, a_{t-1}, r_{t-1}\}$。上下文编码器 CE 在预测潜在上下文时，首先将初始隐藏层状态设置为零，随后截断后的历史交互序列被输入进上下文编码器 CE，后者最终的输出即被用作当前预测的潜在上下文。

3.4 移动平均值

在实践中，式 (3-7) 中的期望值通常是由一个批次（batch）的数据计算而得的。然而，数据批次的大小会直接影响期望值 $\mathbb{E}\left[c_t^i\right]$ 的方差。换言之，较小的数

据批次会导致较大的期望值方差，从而导致训练不稳定。为了解决这个问题，我们维护一组移动加权平均潜在上下文向量集合 $\left\{\bar{c}^i \mid i=0,1,\cdots,M-1\right\}$，其中每个元素表示在第 i 个环境下，过去所有潜在上下文向量的加权平均。一般地，对一个潜在上下文数据批次 $\mathcal{B}_c$，我们可以写出移动加权平均潜在上下文的更新公式

$$\bar{c}^i \leftarrow \eta \bar{c}^i + (1-\eta)\mathbb{E}_{c_t^i \sim \mathcal{B}_c}\left[c_t^i\right], \tag{3-9}$$

其中 $\eta \in [0,1)$ 是控制权重的超参数。在梯度计算过程中，我们将赋值式右边的 $\bar{c}^i$ 视为常数，即程序在梯度计算过程中将 $\bar{c}^i$ 的梯度视为 0。综合上文，我们可以得到上下文编码器 CE 的损失函数在实验过程中的计算式

$$\hat{\ell}_{\mathrm{CE}} = \lambda \sum_{i=0}^{M-1} \mathbb{E}_{c_t^i \sim \mathcal{B}_c}\left[\left\|c_t^i - \bar{c}^i\right\|_2^2\right] - \log\det\left(\boldsymbol{R}_{\mathcal{E}}\right). \tag{3-10}$$

同样地，这里的 $\bar{c}^i$ 在梯度计算过程中被视为常数。

3.5 特定学习率

如前文所述，上下文编码器 CE 以循环神经网络（RNN）的形式实现。一般地，我们记在时间步 t，上下文编码器 CE 预测出的潜在上下文 c_t 和下一时刻的隐藏状态 h_{t+1} 为

$$c_t, h_{t+1} = f^{\psi}(x_t; h_t),$$

其中 ψ 表示循环神经网络的参数，$x_t = \{s_{t-H}, a_{t-H}, r_{t-H}, \cdots, s_{t-1}, a_{t-1}, r_{t-1}, s_t\}$ 表示由 $\langle s, a, r\rangle$ 三元组和当前状态 s_t 构成的以 H 为历史截断长度的历史截断交互序列，h_t 表示当前时间步下循环神经网络的隐藏状态。为方便起见，我们记 $c_t = f_c^{\psi}(x_t; h_t)$ 以及 $h_{t+1} = f_h^{\psi}(x_t; h_t)$。给定一组长度为 $T+1$ 的输入序列 $\{x_0, x_1, \cdots, x_T\}$ 和一个初始化隐藏状态 h_0，我们记由 f^{ψ} 产生的输出序列为 $\{y_0, y_1, \cdots, y_T\}$。我们假设 ψ' 是以 ψ 为参数的循环神经网络经过一次梯度更新后得到的新网络的参数，那么由 $f^{\psi'}$ 产生的输出序列可写作 $\{y'_0, y'_1, \cdots, y'_T\}$。[Luo,

Tu, Huang, et al., 2024][44]给出了一个关于两次输出之间差异上界的命题：

命题 3.2 假设 f 与 f' 均满足利普希茨连续性（*Lipschitz continuity*），即，对于任意的 $\hat{\psi} \in \{\psi, \psi'\}$、$x \in \mathcal{X}$ 和 $h, h' \in \mathcal{H}$，存在常数 $K_h \in [0,1)$ 及 $K_y \in \mathbb{R}$，满足

$$\left\| f_h^{\hat{\psi}}(x;h) - f_h^{\hat{\psi}}(x;h') \right\| \leqslant K_h \left\| h - h' \right\|, \quad \left\| f_y^{\hat{\psi}}(x;h) - f_y^{\hat{\psi}}(x;h') \right\| \leqslant K_h \left\| h - h' \right\|,$$

并且对于任意的 $x \in \mathcal{X}$ 和 $h \in \mathcal{H}$，存在常数 $\epsilon \in \mathbb{R}$，使得以 ψ 和 ψ' 为参数的循环神经网络产生的输出满足

$$\left\| f_h^{\psi}(x;h) - f_h^{\psi'}(x;h) \right\| \leqslant \epsilon, \quad \left\| f_y^{\psi}(x;h) - f_y^{\psi'}(x;h) \right\| \leqslant \epsilon,$$

以及使得循环神经网络在时间步 t 产生的输出满足

$$\left\| y_t - y_t' \right\| \leqslant K_y \frac{1 - \left(K_h\right)^t}{1 - K_h} \epsilon + \epsilon, \quad \forall t > 0. \tag{3-11}$$

[Luo, Tu, Huang, et al., 2024][44]亦给出了详细证明。值得注意的是，命题 3.2 关注 $K_h \in [0,1)$ 的情形，它能被大多数的循环神经网络模型满足。例如，门控循环单元（GRU）[46]和长短期记忆网络（Long-Short Term Memory, LSTM)[47]通过使用 sigmoid 激活函数（activation function）、Mamba[48]通过限制隐藏状态转移矩阵的值来满足上述条件。

在式 (3-11) 中，ϵ 表示在模型参数（在梯度更新过程中）被修改后，以及模型输入和隐藏状态均不变的情况下，模型输出的最大变化。然而，由式 (3-11)，我们可以观察到模型输出的最终变化由于隐藏状态的变化而被放大了，其中放大的倍数为 $K_y \frac{1 - \left(K_h\right)^t}{1 - K_h}$，我们称这个倍数为扩增因子。扩增因子在 $t = 0$ 时处于最小值 0，并且随着 t 增大而逐渐增大，最终收敛于 $\mu = \frac{K_y}{1 - K_h}$。另外，我们还可以得到如下命题：

命题 3.3 网络输出变化的平均值 $\frac{1}{t+1} \sum_{i=0}^{t} \left\| y_i - y_i' \right\|$ 随 t 的增大而收敛于 $(\mu + 1)\epsilon$。

证明 由式 *(3-11)*，我们有

$$
\begin{aligned}
\left\|y_t - y_t'\right\| &\leqslant K_y \frac{1-\left(K_h\right)^t}{1-K_h}\epsilon + \epsilon \\
&= \frac{K_y}{1-K_h}\epsilon + \epsilon - K_y \frac{\left(K_h\right)^t}{1-K_h}\epsilon \\
&= (\mu+1)\epsilon - K_y \frac{\left(K_h\right)^t}{1-K_h}\epsilon.
\end{aligned}
$$

又由等比数列求和公式知

$$
\sum_{i=0}^{t}\left(K_h\right)^i = \frac{1-\left(K_h\right)^{t+1}}{1-K_h},
$$

于是我们有

$$
\begin{aligned}
\frac{1}{t+1}\sum_{i=0}^{t}\left\|y_i - y_i'\right\| &\leqslant (\mu+1)\epsilon - \frac{K_y}{1-K_h}\cdot\frac{1-\left(K_h\right)^{t+1}}{(t+1)\left(1-K_h\right)}\epsilon \\
&= (\mu+1)\epsilon - \mu\epsilon\frac{1-\left(K_h\right)^{t+1}}{(t+1)\left(1-K_h\right)}.
\end{aligned}
$$

当 t 足够大时，上式右边收敛于 $(\mu+1)\epsilon$。 □

由命题 3.3 知，平均输出仍由一个以 μ 定义的倍数被放大。这表明了一个事实，相较于非序列输入，即序列长度为 1 的情况，具有较长输入序列的循环神经网络在梯度下降过程中产生的输出的平均变化被放大了。为平衡这种放大效果，我们需要对循环神经网络使用一个较小的学习率，同时我们也需要保证其他网络模型的训练效率。因此，我们为以循环神经网络为结构的上下文编码器 CE 部署一个较小的特定学习率 $\mathrm{LR}_{\mathrm{CE}}$，而为其他神经网络模型部署正常的学习率 $\mathrm{LR}_{\mathrm{normal}}$。

3.6 总训练过程

我们使用门控循环单元（GRU）[25]来实现上下文编码器 CE，并使用全连接神经网络来实现上下文策略 CP。我们定义潜在上下文分布是一个方差固定的高斯分布，其输出定义为该高斯分布的均值（mean）。在初始阶段采样轨迹之

前，我们从环境集合中等概率地随机选择一个环境，智能体在这个环境中进行交互，每个时间步的状态转换（包括奖赏函数信息）都被记录于回放缓冲池（replay buffer）$\mathcal{R}$ 中。在参数优化阶段，我们通过利用回放缓冲池 $\mathcal{R}$ 中记录的历史交互信息，使用 SAC 算法[20]来计算上下文策略 CP 的损失函数。另外，我们将采样后的潜在上下文 c_t 连接至上下文策略 CP 的输入，以及将移动平均计算处理后的平均上下文 $\bar{c}$ 连接至动作值函数。上下文策略 CP 和动作值函数的所有训练过程基本遵循 ESCP[10] 的做法。最后，我们使用 Adam[49] 对上下文编码器 CE 的参数进行优化。RoSeLIA 的总训练过程如算法 1 所示。

算法 1: RoSeLIA 的训练过程

输入: 训练环境集合 $\{e^0, e^1, \cdots, e^{M-1}\}$, 上下文编码器 CE$(c_{t+1} \mid x_t, s_t; \psi)$,
上下文策略 $\pi(a \mid s_t, c_t; \theta)$, Q 函数 $Q(s_t, a_t, \bar{c}; \varphi)$, 历史截断长度 H,
移动平均上下文 $\{\bar{c}^0, \bar{c}^1, \cdots, \bar{c}^{M-1}\}$, 回放缓冲池 $\mathcal{R}$.

```
for step = 0, 1, ··· do
    从训练环境集合 {e^0, e^1, ···, e^{M-1}} 中随机均匀采样一个环境 e^i ;
    t ← 0 ;
    while 训练未结束 do
        从上下文编码器 CE 中得到潜在上下文分布并采样上下文 c_t^i ;
        从上下文策略 CP 中得到动作分布并采样动作 a_t ;
        将动作 a_t 作用于环境 e^i 得到状态 s_{t+1} 和奖赏 r_t ;
        将 {s_t, a_t, s_{t+1}, r_t, i} 添加至 R ;
        if 需要更新参数 then
            从 R 中采样一个转移批次 B ;
            通过上下文编码器 CE 得到 B 的上下文 c ;
            根据式 (3-9) 更新移动平均值 ;
            利用 SAC 算法更新 θ 和 φ ;
            根据式 (3-10) 得到上下文编码器 CE 的损失 ℓ̂_CE ;
            利用 Adam 优化器更新 ψ;
        end
        t ← t + 1 ;
    end
end
```

第四章　实验

在本章中，我们在网格世界（Grid-World）和三个 MuJoCo[41]任务环境中将 RoSeLIA 与其基础模型 ESCP 进行了对比实验。我们将实验结果分成两节讨论，其中 4.1 节展示 RoSeLIA 在网格世界任务环境下相对于 ESCP 的性能提升，4.2 节展示 RoSeLIA 在 MuJoCo 任务环境下相对于 ESCP 的性能提升。

4.1　网格世界

4.1.1　环境概况

上文提到的“网格世界”是一个人为设计的环境，它是一个默认大小为 11×11 的棋盘。我们定义网格世界的奖赏中心方格的奖赏为 20，而其他方格的奖赏则按照它与奖赏中心的 L1 距离（即曼哈顿距离）递减。初始时，这个奖赏中心就是整个网格世界的几何中心，如图 4-1 所示。在本任务中，我们将状态空间（state space）定义为所有网格上的位置 $\{(x, y) \mid x, y \in \{0, 1, \cdots, 10\}\}$，将动作空间（action space）定义为 $\{(\Delta x, \Delta y) \mid \Delta x, \Delta y \in \{-3, -2, \cdots, 3\}\}$，其中 Δx 和 Δy 分别表示智能体在水平方向和垂直方向的坐标位移。另外，环境本身会对智能体施加一个智能体无法观测的影响（作为环境上下文的一部分），我们将其比作一阵风将智能体沿某个固定的方向吹走。我们将这个上下文（或者，风）定义为 $\{(x', y') \mid x, y \in \{-2, -1, \cdots, 2\}\}$。除此之外，在每次交互过程后，环境都有 0.001 的概率将奖赏中心移动至一个随机的方格，导致整个网格空间的奖赏值改变。假设当前时刻智能体处于状态 (x, y)，那么经过一次与环境的交互，智能体在下一个时刻将处于状态 $\text{Ranged}[(x + \Delta x + x', y + \Delta y + y')]$，其中 $\text{Ranged}[\cdot]$ 约束了智能体的位移使之不会掉出网格世界的边界。于是，在本任务中，智能体需要在识别大风的影响的基础上面对随机变化的奖赏中心，作出最佳的决策。

与此同时，我们还设置了一种新的网格世界。为了表述方便，我们将上文提到的网格世界称作“世界 A”，将新设置的网格世界称作“世界 B”。世界 B 将

10	11	12	13	14	15	14	13	12	11	10
11	12	13	14	15	16	15	14	13	12	11
12	13	14	15	16	17	16	15	14	13	12
13	14	15	16	17	18	17	16	15	14	13
14	15	16	17	18	19	18	17	16	15	14
15	16	17	18	19	20	19	18	17	16	15
14	15	16	17	18	19	18	17	16	15	14
13	14	15	16	17	18	17	16	15	14	13
12	13	14	15	16	17	16	15	14	13	12
11	12	13	14	15	16	15	14	13	12	11
10	11	12	13	14	15	14	13	12	11	10

图 4-1　网格世界示意图，在每个方格内标注了其奖励值。

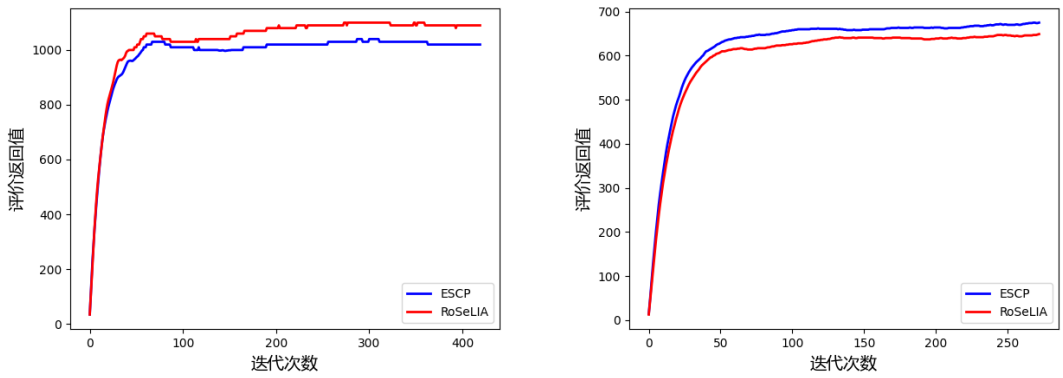

(a) 奖赏中心随机变化的网格世界　　**(b) 奖赏中心固定的网格世界**

图 4-2　RoSeLIA 和 ESCP 在网格世界中的学习曲线对比。

奖赏中心固定在网格世界的几何中心，其奖赏值设置为 10（当奖赏中心固定在几何中心时，只需将其奖赏值设置为 10 即可保证所有网格的奖赏值均为非负），其余网格的奖赏计算方式和世界 A 相同，也是按照它与奖赏中心的曼哈顿距离递减。设计世界 B 的目的是比较 RoSeLIA 在奖赏固定环境中相对于 ESCP 的性能变化。

4.1.2　实验结果

图 4-2 展示了 RoSeLIA 和 ESCP 在网格世界中的学习曲线对比。由于模型很快就能够达到收敛状态，我们在奖赏中心固定的实验中进行了较奖赏中心变化实验更少轮数的迭代。

从图中不难发现，在奖赏中心随机变化的环境（世界 A）中，两个模型的学习曲线都出现了上升、略微下降和平缓上升的态势。我们称两个模型在训练初期学习曲线快速上升直至峰值的时间段为“上升阶段”，模型在这一阶段学习到以环境特征为中心的上下文编码。在大约第 70 次迭代时，环境奖赏中心可能发生变化，导致二者均出现不同程度的奖赏损失，学习曲线出现小幅度的下降，我们称这一阶段为“扰动阶段”。在第 150 次迭代之后，二者的学习曲线不再出现明显下降而平缓上升，我们称这一阶段为“稳定阶段”。可以看到，在世界 A 中，RoSeLIA 从上升阶段就取得了优于 ESCP 的学习效果。我们发现，从训练开始到大约第 20 次迭代期间，两个模型的学习曲线几乎重合，而在第 20 次迭代之后，RoSeLIA 的学习曲线开始保持在 ESCP 之上。我们猜想，环境可能在大约第 20 次迭代就出现了奖赏中心的移动，而 RoSeLIA 具有将奖赏因素建模进环境上下文中的能力，这才导致 RoSeLIA 从训练初期就取得了优于 ESCP 的效果。同样地，RoSeLIA 也比 ESCP 更快地从扰动阶段进入稳定阶段，并且前者在稳定阶段的学习曲线斜率也要略大于后者。仅从实验获取的数据中，RoSeLIA 就较 ESCP 取得了约 7% 的性能提升。并且，我们大胆地猜测这一差距会在后续更多的迭代轮数中被扩大。

在奖赏中心固定的环境（世界 B）中，由于奖赏中心固定，模型在训练过程中没有经历扰动阶段。然而，RoSeLIA 的训练效果却要略逊于 ESCP。在上升阶段结束时，RoSeLIA 的学习曲线已经展示了这个性能差距，并且在稳定阶段，这个差距也几乎保持不变，RoSeLIA 的学习曲线也没有即将反超的趋势。我们猜测，由于在奖赏中心固定的网格世界中，上下文编码器 CE 接收了（在本实验中）冗余的信息，即并不会在训练过程中改变的奖赏作为输入，导致了其一定程度的过拟合，从而产生了较差的训练效果。

为了更有效地对比 RoSeLIA 与 ESCP 在网格世界任务环境下的性能，我们尝试使用不同随机种子更改初始环境配置，进行了多次平行实验。图 4-3 展示了 RoSeLIA 与 ESCP 在平行实验中的运行结果学习曲线。从这四次平行实验的学习曲线中，我们不难看出 ESCP 在迭代过程中出现了较为明显的扰动阶段，即学习曲线的下降。相反地，RoSeLIA 却在上升阶段之后几乎直接进入了稳定阶段，这一现象可能表明了 RoSeLIA 在稳定性上优于 ESCP。另外，我们还可以发现，即使在几个场景中，RoSeLIA 在上升阶段的学习曲线要低于 ESCP，但是随着迭代

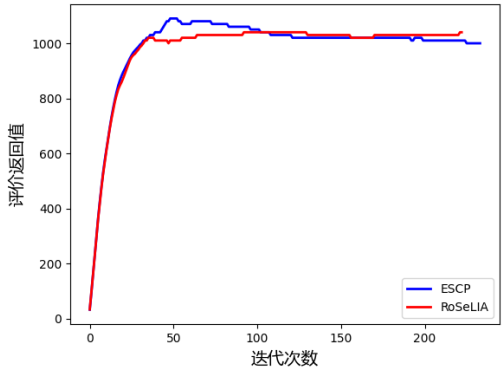

(a) 随机种子为 10 时的实验结果

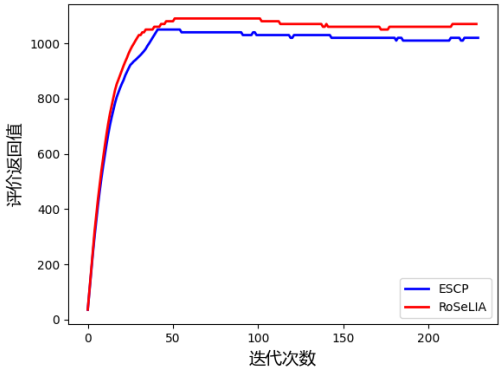

(b) 随机种子为 15 时的实验结果

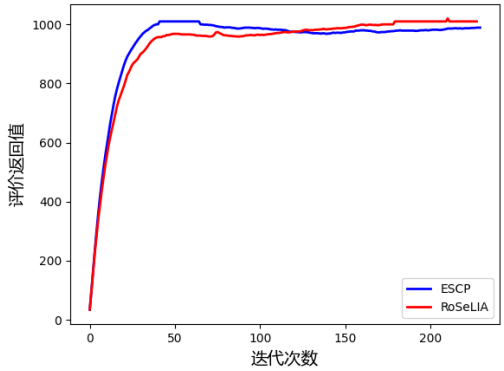

(c) 随机种子为 20 时的实验结果

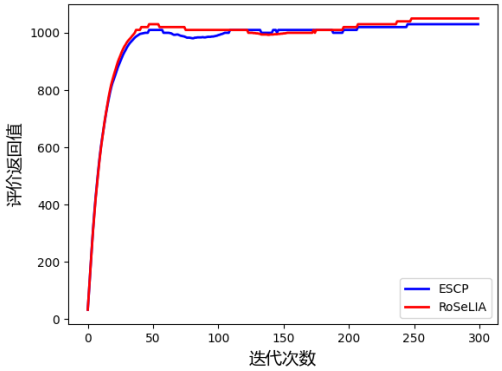

(d) 随机种子为 25 时的实验结果

图 4-3　通过更改随机种子（seed）在网格世界上进行平行实验的结果。

次数的增加，不仅 ESCP 的学习曲线出现下降，相对地，RoSeLIA 的学习曲线在缓慢上升，最终后者的学习曲线还是会超越前者。从长期的角度来看，RoSeLIA 的性能可能优于 ESCP，这种差距可能是 RoSeLIA 不具备适应奖赏函数变化环境的能力导致的。

4.2　MuJoCo 任务环境

我们亦尝试了在比网格世界更复杂的任务环境——MuJoCo[41]任务环境中对 RoSeLIA 和 ESCP 两个模型做了对比实验。

4.2.1　环境概况

在实验中，我们让环境中的重力（gravity）随机变化，这个变化被视为突变上下文的一部分。由于 MuJoCo 任务环境目标的确定性，随机改变奖赏值缺乏意义，因此我们只是出于好奇和比较的心态选择了三个任务（Half-Cheetah、Hopper

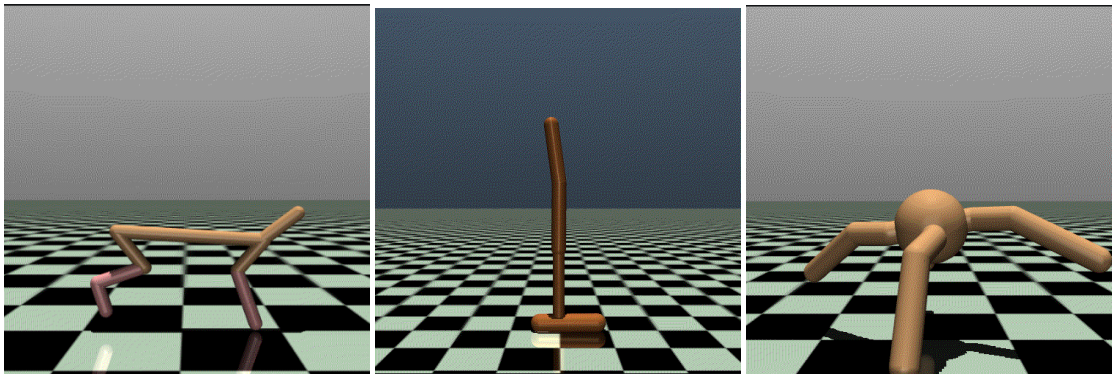

(a) Half-Cheetah 任务环境　　(b) Hopper 任务环境　　(c) Ant 任务环境

图 4-4　实验中使用的 MuJoCo 任务环境，图片截自 Gym MuJoCo 官网[1]。

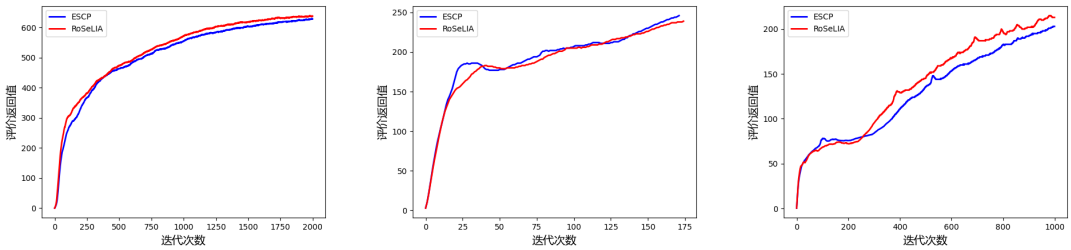

(a) Half-Cheetah 任务环境　　(b) Hopper 任务环境　　(c) Ant 任务环境

图 4-5　RoSeLIA 和 ESCP 在 MuJoCo 任务环境中的学习曲线对比。

和 Ant）来对比两个模型的性能。

图 4-4 展示了本实验所用 MuJoCo 任务环境的三维建模示意。其中，Half-Cheetah[50]任务环境中的智能体是一只“半猎豹”，由八个关节（其中两个关节固定）连接八条骨骼（其中两条骨骼作为“爪子”）组成；Hopper[51]任务环境的智能体是一条机械腿，由三个关节（分别为大腿转子、小腿转子和脚部转子）连接而成；Ant[52]任务环境的智能体是一只四足昆虫，由一个身体通过关节连接四条腿（其中每条腿由一个关节连接的两条骨骼组成）构成。这三个任务的最终目标都是通过在关节处施加扭矩，在不产生过大动作的前提下尽可能快地向前移动。

4.2.2　实验结果

图 4-5 展示了 RoSeLIA 和 ESCP 在上述三个任务环境中的学习曲线对比。由实验结果可以看出，RoSeLIA 在比网格世界复杂得多的 MuJoCo 任务环境中展现出了与 ESCP 相近甚至更好的性能。

在 Half-Cheetah 任务中，RoSeLIA 从训练一开始就表现出了比 ESCP 更佳的

1　https://www.gymlibrary.dev/environments/mujoco/。

学习效果，在大约 500 次迭代后，二者的学习曲线近乎平行上升，最终 RoSeLIA 呈现出与 ESCP 相比的微弱优势。在 Hopper 任务中，虽然 ESCP 在训练初期拥有比 RoSeLIA 更快的收敛速度，但前者的学习曲线在达到峰值后出现了较为明显的下降，而后者则没有明显的下降，这可能说明奖赏感知的上下文编码器会提升决策的稳定性。随着迭代次数的增加，二者的学习曲线基本重合，最终 ESCP 略优势于 RoSeLIA。在 Ant 任务中，RoSeLIA 训练初期的学习曲线低于 ESCP，但 RoSeLIA 在大约第 250 次迭代中实现了学习曲线的反超，并在之后的迭代中保持了领先。这个任务是三个任务中复杂度最高的，不难发现，两个模型的学习曲线都出现了不同程度的波动，但是 ESCP 在训练前期的波动较大而后期较小，RoSeLIA 正好相反。如果我们可以将两个模型结合运用，或许能够较大程度地提升智能体总体的稳定性。

4.3 实验结果总结

通过在网格世界和 MuJoCo 任务环境下对 RoSeLIA 和 ESCP 进行的对比实验，我们可以给出如下结论与设想：

- RoSeLIA 在训练初期的收敛能力与 ESCP 不相上下；
- RoSeLIA 的训练稳定性可能要强于 ESCP；
- RoSeLIA 的长期模型性能可能要优于 ESCP，尽管性能提升的程度可能十分有限。

第五章　结语

在本论文中，我们针对动态环境下奖赏函数频繁变化的任务场景，提出了一种基于表征学习的高效持续强化学习算法——RoSeLIA，一种具有特殊上下文编码器的基于 ESCP 算法的模型。我们为 RoSeLIA 设计了包含奖赏信息的历史缓冲池，并为其配置了能够识别奖赏变化的上下文编码器。该算法结合历史截断交互序列提取潜在任务特征，并引入移动平均值机制降低训练方差。此外，针对循环神经网络的梯度不稳定性问题，RoSeLIA 采用上下文编码器特定学习率策略，有效抑制了参数更新对长期序列建模的干扰。最后，我们在不同任务环境中对比了 RoSeLIA 相对于 ESCP 的性能提升。实验结果表明, RoSeLIA 在部分任务环境中能够取得优于 ESCP 的学习效果。

然而，本研究仍存在一定局限性。首先，实验环境局限于模拟场景，未涉及真实物理系统或高维复杂任务；其次，在奖赏函数固定的任务中，RoSeLIA 因上下文编码器对奖赏信息的过拟合而表现略逊于 ESCP，需进一步优化模型泛化能力；最后，硬件条件限制了实验规模和迭代次数，可能影响结论的全面性。未来的研究工作可从以下方向展开：1）将算法扩展至多模态动态环境（如自动驾驶、机器人多任务操作等），验证其实际应用潜力；2）探索自适应上下文编码机制，平衡稳定环境与突变环境的性能表现；3）结合元学习与注意力机制，提升模型对长期历史信息的利用效率；4）引入分布式训练框架，突破硬件限制以验证算法的大规模可扩展性。随着持续强化学习理论与工程实践的深度融合，动态环境下的智能体自适应能力有望迈向新的台阶。

参考文献

[1] SUTTON R S, BARTO A G, et al. Reinforcement learning: An introduction[M]. MIT press Cambridge, 1998.

[2] 周志华. 机器学习[M]. 清华大学出版社, 2016.

[3] PARISI G I, KEMKER R, PART J L, et al. Continual lifelong learning with neural networks: A review[J]. Neural Networks, 2019, 113: 54-71.

[4] MCCLOSKEY M, COHEN N J. Catastrophic interference in connectionist networks: The sequential learning problem[G]//Psychology of Learning and Motivation: vol. 24. Elsevier, 1989: 109-165.

[5] GOODFELLOW I J, MIRZA M, XIAO D, et al. An Empirical Investigation of Catastrophic Forgetting in Gradient-Based Neural Networks[J]. Computer Science, 2013, 84(12): 1387-91.

[6] TAYLOR M E, STONE P. Transfer learning for reinforcement learning domains: A survey.[J]. Journal of Machine Learning Research, 2009, 10(7): 1633-1685.

[7] LASKIN M, LEE K, STOOKE A, et al. Reinforcement learning with augmented data[C]//Advances in Neural Information Processing Systems: vol. 33. Curran Associates, Inc., 2020: 19884-19895.

[8] ZHANG A, MCALLISTER R, CALANDRA R, et al. Learning invariant representations for reinforcement learning without reconstruction[J]. ArXiv preprint arXiv:2006.10742, 2020.

[9] ROSTAMI M, HE H, CHEN M, et al. Transfer learning via representation learning[G]//Federated and Transfer Learning. Springer, 2022: 233-257.

[10] LUO F M, JIANG S, YU Y, et al. Adapt to environment sudden changes by learning a context sensitive policy[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 36: 7. AAAI.org, 2022: 7637-7646.

[11] DUAN Y, SCHULMAN J, CHEN X, et al. RL^2: Fast reinforcement learning via slow reinforcement learning[J]. ArXiv preprint arXiv:1611.02779, 2016.

[12] YU T, QUILLEN D, HE Z, et al. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning[C]//Conference on Robot Learning. 2020: 1094-1100.

[13] BELLMAN R. On the theory of dynamic programming[J]. Proceedings of the National Academy of Sciences, 1952, 38(8): 716-719.

[14] ÅSTRÖM K J. Optimal control of Markov processes with incomplete state information I[J]. Journal of Mathematical Analysis and Applications, 1965, 10: 174-205.

[15] KAELBLING L P, LITTMAN M L, CASSANDRA A R. Planning and acting in partially observable stochastic domains[J]. Artificial Intelligence, 1998, 101(1-2): 99-134.

[16] LEVINE S, KUMAR A, TUCKER G, et al. Offline reinforcement learning: Tutorial, review, and perspectives on open problems[J]. ArXiv preprint arXiv:2005.01643, 2020.

[17] WATKINS C J C H, et al. Learning from delayed rewards[J]. Robotics & Autonomous Systems, 1989.

[18] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[19] FUJIMOTO S, HOOF H, MEGER D. Addressing function approximation error in actor-critic methods[C]//International Conference on Machine Learning. 2018: 1587-1596.

[20] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//International Conference on Machine Learning. 2018: 1861-1870.

[21] HAARNOJA T, ZHOU A, HARTIKAINEN K, et al. Soft actor-critic algorithms and applications[J]. ArXiv preprint arXiv:1812.05905, 2018.

[22] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[J]. ArXiv preprint arXiv:1707.06347, 2017.

[23] HOCHREITER S, YOUNGER A S, CONWELL P R. Learning to learn using gradient descent[C]//International Conference on Artificial Neural Networks. 2001: 87-94.

[24] ANDRYCHOWICZ M, DENIL M, GOMEZ S, et al. Learning to learn by gradient descent by gradient descent[C]//Advances in Neural Information Processing Systems: vol. 29. 2016.

[25] CHO K, VAN MERRIËNBOER B, BAHDANAU D, et al. On the properties of neural machine translation: Encoder-decoder approaches[J]. ArXiv preprint arXiv:1409.1259, 2014.

[26] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks[C]//International Conference on Machine Learning. 2017: 1126-1135.

[27] GUPTA A, MENDONCA R, LIU Y, et al. Meta-reinforcement learning of structured exploration strategies[C]//Advances in Neural Information Processing Systems: vol. 31. 2018.

[28] RAKELLY K, ZHOU A, FINN C, et al. Efficient off-policy meta-reinforcement learning via probabilistic context variables[C]//International Conference on Machine Learning. 2019: 5331-5340.

[29] SANTORO A, BARTUNOV S, BOTVINICK M, et al. Meta-learning with memory-augmented neural networks[C]//International Conference on Machine Learning. 2016: 1842-1850.

[30] GRAVES A, WAYNE G, DANIHELKA I. Neural turing machines[J]. ArXiv preprint arXiv:1410.5401, 2014.

[31] BLUNDELL C, URIA B, PRITZEL A, et al. Model-free episodic control[J]. ArXiv preprint arXiv:1606.04460, 2016.

[32] BADDELEY A. The concept of episodic memory[J]. Philosophical Transactions of the Royal Society of London. Series B: Biological Sciences, 2001, 356(1413): 1345-1350.

[33] YOUNG K J, SUTTON R S, YANG S. Integrating episodic memory into a reinforcement learning agent using reservoir sampling[J]. ArXiv preprint arXiv:1806.00540, 2018.

[34] PRITZEL A, URIA B, SRINIVASAN S, et al. Neural episodic control[C]//International Conference on Machine Learning. 2017: 2827-2836.

[35] LI Z, ZHU D, HU Y, et al. Neural episodic control with state abstraction[J]. ArXiv preprint arXiv:2301.11490, 2023.

[36] KUMAR A, IRSOY O, ONDRUSKA P, et al. Ask me anything: Dynamic memory networks for natural language processing[C]//International Conference on Machine Learning. 2016: 1378-1387.

[37] XIONG C, MERITY S, SOCHER R. Dynamic memory networks for visual and textual question answering[C]//International Conference on Machine Learning. 2016: 2397-2406.

[38] ZHOU W, PINTO L, GUPTA A. Environment probing interaction policies[J]. ArXiv preprint arXiv:1907.11740, 2019.

[39] LEE K, SEO Y, LEE S, et al. Context-aware dynamics model for generalization in model-based reinforcement learning[C]//International Conference on Machine Learning. 2020: 5757-5766.

[40] YU W, TAN J, LIU C K, et al. Preparing for the unknown: Learning a universal policy with online system identification[J]. ArXiv preprint arXiv:1702.02453, 2017.

[41] TODOROV E, EREZ T, TASSA Y. Mujoco: A physics engine for model-based control[C]//2012 IEEE/RSJ International Conference on Intelligent Robots and Systems. 2012: 5026-5033.

[42] SCHULMAN J, LEVINE S, ABBEEL P, et al. Trust region policy optimization[C]//International Conference on Machine Learning. 2015: 1889-1897.

[43] LILLICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning[J]. ArXiv preprint arXiv:1509.02971, 2015.

[44] LUO F M, TU Z, HUANG Z, et al. Efficient Recurrent Off-Policy RL Requires a Context-Encoder-Specific Learning Rate[J]. ArXiv preprint arXiv:2405.15384, 2024.

[45] KULESZA A. Determinantal Point Processes for Machine Learning[J]. Foundations and Trends® in Machine Learning, 2012, 5(2−3): 123-286.

[46] CHUNG J, GULCEHRE C, CHO K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. ArXiv preprint arXiv:1412.3555, 2014.

[47] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[48] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces[J]. ArXiv preprint arXiv:2312.00752, 2023.

[49] KINGMA D P, BA J. Adam: A Method for Stochastic Optimization[J]. CoRR, 2014, abs/1412.6980.

[50] WAWRZYŃSKI P. A cat-like robot real-time learning to run[C]//International Conference on Adaptive and Natural Computing Algorithms. 2009: 380-390.

[51] EREZ T, TASSA Y, TODOROV E. Infinite-horizon model predictive control for periodic tasks with contacts[J]. Robotics: Science and Systems VII, 2012, 73.

[52] SCHULMAN J, MORITZ P, LEVINE S, et al. High-dimensional continuous control using generalized advantage estimation[J]. ArXiv preprint arXiv:1506.02438, 2015.

致　　谢

行文至此，落笔为终。雪案萤窗，四载驹光。槐市芸编，一朝豹变。负笈之途将尽，裁书之礼宜申。谨以俪言，敬陈谢悃。

首先，感谢我的导师章宗长副教授。章老师矩范高标，自论文选题，至修改定稿，导我以洪纤之辨，示我以绳墨之严。绛帐春深，岂惟传经授业；讲席意重，更教砥节立心。此日雕虫之技，皆承匠石运斤；他年展骥之途，毋忘伯乐顾盼。

其次，感谢南京大学人工智能学院的全体老师。学院诸先生，绛帐谈玄，启龙文之奥义；朱衣点卷，剖骊渊之玄珠。杏坛春雨，非止润物无声；兰室德风，实乃树人正道。

随后，感谢罗凡明和张鑫钰两位学长。师兄二人，研席引航，术业提携。传薪解惑，启我以幽微之妙；指津授钥，导余出迷瘴之途。术业渐进，常怀感激之忱；拙作既成，永记襄助之义。

接着，感谢我的舍友和同学。同窗诸君，并辔文场，共济书舟。辩难穷理，每得灵犀一点；扶危纾困，常怀管鲍深衷。至若舍馆之谊，常忘日夜，泯晨昏而探玄微；或废寝食，思康健而问茶饭。

然后，感谢我的家人和朋友。终念椿萱之德，严慈倚闾，廿载劬劳。截发筵宾，岂止孟母三迁之志；囊萤照读，何惭欧母画荻之勤。今虽蟾宫折桂，未酬反哺之心；惟愿彩衣娱亲，稍慰倚门之望。

最后，特别感谢我的挚友林宇翔。结义自幼，肝胆至今；识于黄发，契若金兰。忆昔负笈他乡，共担风雨；迨今裁书槐市，同证枯荣。趔趄迷惘，分焚膏继晷之苦；豁然开朗，享文成业就之乐。或值文思蹇滞，赖有醴酒解颐；每逢歧路彷徨，幸得清言破雾。陈雷胶漆，岂止三生之幸；管鲍襟期，堪称九死无渝。总角之交，星霜与共；伯牙绝弦，白首可期。

山水一程，有幸三生；楮墨有限，感怀无极。四载槐市烟霞，尽化胸中块垒；廿年椿庭训诲，终成笔下风雷。愿以雕虫薄技，再赴星霜；敢凭展骥初心，重攀云岳。时维暮春，谨识于南京大学。