南京大学

本 科 毕 业 论 文

院　　系　人工智能学院

专　　业　人工智能

题　　目　**基于矩阵略图的对数几率老虎机计算加速**

年　　级　2021　学　　号　211300034

学生姓名　何临哲

指导教师　张利军　职　　称　教授

提交日期　2025 年 5 月 30 日

南京大学本科毕业论文（设计）
诚信承诺书

本人郑重承诺：所呈交的毕业论文（设计）（题目：基于矩阵略图的对数几率老虎机计算加速）是在指导教师的指导下严格按照学校和院系有关规定由本人独立完成的。本毕业论文（设计）中引用他人观点及参考资源的内容均已标注引用，如出现侵犯他人知识产权的行为，由本人承担相应法律责任。本人承诺不存在抄袭、伪造、篡改、代写、买卖毕业论文（设计）等违纪行为。

作者签名：何恰哲

学号：211300034

日期：2025年3月1日

目　　录

第一章 引言 7

1.1 研究背景 7

1.2 本文贡献 8

1.3 本文组织结构 9

第二章 相关工作 11

2.1 随机上下文老虎机 11

2.2 随机上下文（多项）对率老虎机 12

2.3 矩阵略图 14

第三章 OFUL-MLogB 略图算法 17

3.1 算法 18

3.2 计算复杂度分析 20

3.3 遗憾分析 23

3.4 定理简要证明 26

3.4.1 定理 3.1 的证明思路 26

3.4.2 定理 3.2 证明思路 29

第四章 实验验证 33

4.1 使用随机生成的数据进行实验 33

4.2 动作分布的实验 35

4.3 在真实数据集上的实验 36

第五章 结论 39

参考文献 41

致　　谢 45

附录 A FD 性质 47

附录 B 第三章定理的证明 51

符号表

$\overrightarrow{W}$	矩阵 $W \in \mathbb{R}^{K\times d}$ 的 Kd 维行拼接的向量化；
$\|\boldsymbol{x}\|_Z$	向量 $\boldsymbol{x}$ 关于 Z 的归一化范数：$\|\boldsymbol{x}\|_Z := \sqrt{\langle \boldsymbol{x}, Z\boldsymbol{x}\rangle}$；
$\|W\|_F$	矩阵弗罗贝尼乌斯范数（Frobenius norm）；
$\lambda_k(W)$	矩阵 W 的第 k 大特征值；
$\|W\|_{2,2}$	谱范数（算子范数），即最大奇异值，等价于 $\lambda_{\max}(W^\top W)^{1/2}$；
$A \preceq B$	$B - A$ 是半正定矩阵；
$A \otimes B$	克罗内克积（Kronecker product），$(A \otimes B)_{im+p,jn+q} = A_{i,j}B_{p,q}$；
δ_i^j	克罗内克函数（Kronecker delta function），当 $i = j$ 时为 1，否则为 0；
$\mathcal{F}_t$	算法表示前 t 轮生成的 σ-代数；
$\mathcal{O}(\cdot)$	表示渐进符号，主要关注 m, d, K, κ, T 等参数；
$\tilde{\mathcal{O}}(\cdot)$	进一步忽略对数因子的渐进符号；
$\ell_t(W)$	关于反馈 y_t、决策 $\boldsymbol{x}_t$ 和参数 W 的熵损失函数 $\ell_t(W) = -\boldsymbol{y}_t^\top \ln \boldsymbol{\sigma}(W\boldsymbol{x}_t)$
$\nabla \ell_t(\overrightarrow{W})$	损失函数 $\ell_t(W)$ 的梯度；
$\nabla^2 \ell_t(W)$	损失函数 $\ell_t(W)$ 的海森矩阵（Hessian Matrix）；

南京大学本科生毕业论文（设计、作品）中文摘要

题目：基于矩阵略图的对数几率老虎机计算加速

院系：人工智能学院

专业：人工智能

本科生姓名：何临哲

指导教师（姓名、职称）：张利军　教授

摘要：

多项对率老虎机（Multinomial Logistic Bandits，MLogB）是一种在在线学习中被广泛研究的老虎机模型．在该模型中，学习器需要从一系列动作集中选择动作，提交给环境，接收服从对率分布的反馈，并不断优化选择动作的策略．针对 MLogB 模型已提出多种算法，其中 OFUL-MLogB 算法拥有目前最先进的理论遗憾界 $\tilde{\mathcal{O}}(Kd\sqrt{T})$，其中 K 表示反馈数量，d 为特征向量维度，T 代表时间范围．但是，OFUL-MLogB 每次迭代需要三次方计算复杂度 $\mathcal{O}(|\mathcal{D}|K^3d^3)$，其中 $|\mathcal{D}|$ 表示决策集的规模，这限制了它在实际高维场景中的应用．

本文通过一种在线矩阵略图技术，加速 OFUL-MLogB 算法．具体而言，本文通过频繁方向（Frequent Direction，FD）方法维护历史费希尔信息矩阵（Fisher Information Matrix，FIM）的 m 阶近似矩阵，使算法的单轮计算复杂度降低至 $\mathcal{O}\left(|\mathcal{D}|(K^3+mK^2+dmK)+dK(m+K)^2\right)$．同时，计算加速对遗憾界的影响是可控的，遗憾界仅增长到 $\tilde{\mathcal{O}}\left((1+\rho_T/\lambda)Kd\sqrt{T}\right)$，其中 ρ_T 表示 m 阶截断矩阵的谱残差，λ 为正则化参数．最后，我们进行了实验，发现如果 m 的大小合适，算法能有效控制 ρ_T 的增长，从而其遗憾值仅略高于原算法．通过调整参数，我们的算法在计算效率与性能之间达到了良好平衡：计算时间减少了 64%，同时平均遗憾值增长最终控制在 10% 以内．

关键词：矩阵略图；频繁方向；对率老虎机；计算加速

南京大学本科生毕业论文（设计、作品）英文摘要

THESIS: Efficient Logit Bandits through Matrix Sketching

DEPARTMENT: School of Artificial Intelligence

SPECIALIZATION: Artificial Intelligence

UNDERGRADUATE: Lin-zhe He

MENTOR: Lijun Zhang,Professor

ABSTRACT:

Stochastic Logistic Bandits (MLogB) is a widely studied bandit model in online learning, where the learner sequentially selects actions from a set of actions, submits the action and receives feedback from the environment following a logistic distribution, and is required to continuously optimizes the action selection strategy. While the OFUL-MLogB algorithm establishes state-of-the-art regret bound $\tilde{\mathcal{O}}(Kd\sqrt{T})$ for online MLogB — K denotes the number of feedbacks, d the dimension of the context vector, and T the time horizon — its cubic computational complexity $\mathcal{O}(|\mathcal{D}|K^3d^3)$ per iteration limits practical deployment in high-dimensional settings.

In this paper, we accelerate OFUL-MLogB through strategic integration of Frequent Direction, a deterministic online matrix sketching algorithm. To be specific, our core innovation resides in maintaining an m-rank approximated matrix of the historical Fisher Information Matrix $\sum_{s=1}^{t} \nabla^2 \ell_t(W_{t+1})$ via Frequent Direction, thereby reduced complexity of the proposed algorithm to $\mathcal{O}\left(|\mathcal{D}|(K^3 + mK^2 + dmK) + dK(m+K)^2\right)$, where $|\mathcal{D}|$ is the size of the decision set. And the side effect to the regret bound is controllable, as the regret bound remains $\tilde{\mathcal{O}}\left((1+\rho_t/\lambda)Kd\sqrt{T}\right)$, where ρ_T quantifies the spectral residual from m-truncated matrix, and λ the regularization parameter. Lastly, the experiments demonstrates that appropriate chosen m results in slow growing of ρ_T, achieving slightly higher regret values than the original algorithm. Through parameter tuning, our algorithm achieves a good trade-off between computational efficiency and statistical performance: Computation time decreases by 64%, while the average regret degradation eventually remains below by 10%.

KEYWORDS: Matrix Sketching; Frequent Directions; Logistic Bandits; Efficient Computation

第一章　引言

1.1　研究背景

随机上下文老虎机问题[1] 是一个序列决策模型，其中，智能体需要与未知环境进行多轮互动. 在每一轮中，智能体需要从一个包含上下文信息（特征向量）的动作（决策）集合中，选择一个好的动作. 在选出动作（做出决策）后，环境会根据所选动作生成随机反馈. 而智能体的目标是利用反馈，不断优化其选择动作的策略，从而不断提升未来的决策质量. 随机上下文老虎机算法已在交互式机器学习中得到广泛应用，例如推荐系统[2]、数据路由优化[3] 以及移动健康平台[4].

本文主要关注随机多项对率老虎机（Multinomial Logistic Bandit，MLogB[5-6]），其中环境反馈 y_t 有 $K+1$ 种取值，且服从多项对率分布，具体分布参数由选定的动作决定：$P(y_t = k \mid \boldsymbol{x}_t) = [\boldsymbol{\sigma}(W_\star \boldsymbol{x}_t)]_k, k = 0, 1, \cdots, K$，其中 $\boldsymbol{x}_t \in \mathbb{R}^d$ 是智能体在第 t 轮的动作向量，而 $\boldsymbol{\sigma}(\cdot) : \mathbb{R}^K \mapsto \Delta^{K+1}$ 是对率函数，$W_\star \in \mathbb{R}^{K\times d}$ 是环境的未知参数. 而智能体的目标是在时间范围 T 内最小化（伪）遗憾值，该遗憾值定义为最佳决策的期望收益与智能体决策的期望收益之差. MLogB 模型具有实际应用价值，例如，在推荐系统中，系统会向用户推荐一项物品（决策），随后用户将提供离散反馈，如点击、购买或忽略. 能够适应此模型的算法将使系统能够持续提升用户的满意度或参与度.

在先前研究中，基于不同方法论的 MLogB 算法取得重要进展，例如基于汤普森采样（Thompson Sampling，TS）的 TS_2-Correlated 算法[7] 以及基于上置信界（Upper Confidence Bound，UCB）的 MNL-UCB 算法[5]. 其中，Zhang 等[6] 提出的 OFUL-MLogB 算法尤为突出，该算法通过改进的在线牛顿步（Online Newton Step，ONS），获得了优异的理论保证，算法的遗憾界达 $\tilde{\mathcal{O}}(Kd\sqrt{T})$. 尽管 OFUL-MLogB 具有在线优势，但在实际应用中，每轮计算成本往往过高 — 该算法每轮需消耗 $\mathcal{O}(|\mathcal{D}|K^3d^3)$ 计算量，其中 $|\mathcal{D}|$ 为动作集合的大小，d 为动作向量 $\boldsymbol{x}$ 的维

度. 在现代高维场景中，这种关于 d 的三次方依赖会带来愈发沉重的计算负担.

这一缺陷源于 OFUL-MLogB 需将所有历史信息存储于历史费希尔信息矩阵（Fisher Information Matrix，FIM）$\sum_{s=1}^{t} \nabla^2 \ell_s(W_{s+1})$，以指导策略更新和动作选择，其中 $\ell_s(W) = -\ln[\boldsymbol{\sigma}(W\boldsymbol{x}_s)]_{y_s}$ 为样本 $(\boldsymbol{x}_s, y_s)$ 关于参数 W 的信息熵损失函数. 历史数据中复杂而结构化程度低的细节张成了个高维空间，这使得矩阵运算（如乘法、求逆，尤其是奇异值分解）变得异常复杂. 为此，我们将频繁方向（Frequent Direction[8]，以下简称 FD）技术整合到 OFUL-MLogB 中，在同时试图保持其理论性能，提高 OFUL-MLogB 的计算效率. FD 能够在流式数据场景下，高效地用低秩矩阵近似协方差矩阵，且具有优异的理论保证 — 其近似误差有界.

1.2 本文贡献

在本研究中，我们展示了如何使用 FD 加速 OFUL-MLogB. 具体而言，我们将费希尔信息矩阵中的新项分解为外积形式，以实现 FD 更新，从而维持了历史费希尔信息矩阵的 m 阶近似. 然后基于问题的形式，针对几个耗时的奇异值分解（Singular Value Decomposition，SVD）操作进行优化. 通过 FD，计算复杂度从 $\mathcal{O}(|\mathcal{D}|K^3d^3)$ 降低至 $\mathcal{O}\left(|\mathcal{D}|(K^3 + mK^2 + dmK) + dK(m+K)^2\right)$，其中 $|\mathcal{D}|$ 表示决策集的规模. 与之对应地，FD 技术对遗憾界的副作用是有限的：遗憾界仅仅从 $\tilde{\mathcal{O}}(Kd\sqrt{T})$ 略微增长到 $\tilde{\mathcal{O}}\left(\Delta_T(m + Kd\ln\Delta_T)\sqrt{T}\right)$，其中 $\Delta_T = 1 + \rho_T/\lambda$，$\rho_T$ 不大于历史费希尔信息矩阵矩阵的 m 截断谱尾，λ 为正则化参数.

当所选动作张成的子空间秩为 $r \leqslant m$ 时，例如决策集固定且有限，谱尾项 Δ_T 可简化为 $\mathcal{O}(1)$. 在此情况下，遗憾界可降低至 $\tilde{\mathcal{O}}\left(m\sqrt{T}\right)$. 由于 $m \leqslant d$，该结果优于未采用 FD 技术的算法. 而大多数情况下，若 m 取值能恰当捕捉动作子空间的主成分信息，则 Δ_T 的增长速度极为缓慢. 略微的遗憾增长，换来了计算成本的大幅降低. 然而，若 m 过小以致无法保留主要的动作空间结构，或频谱存在重尾现象[9]，则过大的近似误差将削弱理论保证. 如 Wen 等[10] 所述，m 取值过小会导致 $\tilde{\mathcal{O}}(T)$ 的遗憾.

我们在球面上随机均匀采样的生成数据和 `MNIST` 数据集上进行了实验，实验结果表明，当 m 的取值适当时，不仅计算时间大幅减少，同时遗憾值增长率达到了与原算法相当的速率. 此外，当决策集固定且有限时，遗憾值与原算法几

乎一致，而计算时间则呈减少趋势.

1.3 本文组织结构

本文的组织结构如下：第一章简要相关工作的研究背景和意义、本文的主要贡献；第二章回顾了与随机上下文老虎机相关的研究，并着重介绍了与本文高度相关的 OFUL-MLogB 和 FD 技术；第三章详细介绍了本文提出的基于 FD 的 OFUL-MLogB 算法，具体而言，介绍了如何将海森矩阵（Hessian Matrix）转变为适合 FD 更新的形式，并着重几个费时的操作进行了优化，然后对 2 个主要的定理给出了简要的证明；第四章展示了算法在生成数据和 MNIST 数据集上的实验结果，验证了提出的算法的合理表现；最后在第五章总结了本文的工作和不足，并展望了未来的研究方向.

第二章　相关工作

本章简要回顾与 MLogB 及矩阵略图相关的研究工作，介绍随机上下文老虎机、多项对率老虎机和频繁方向算法的相关背景知识，并给出频繁方向算法的具体细节和计算复杂度.

2.1　随机上下文老虎机

随机上下文老虎机（Stochastic Contextual Bandit）是一种序贯决策框架，其中智能体与未知环境进行多轮交互，获取反馈. “随机性” 的含意是环境反馈服从某种概率分布，其分布参数由所选动作决定，而 “上下文” 指智能体可利用辅助信息（通常为特征向量）来预测动作对应的反馈[1]. 而智能体的目标是最小化时间范围 T 内的（伪）遗憾：

$$\mathrm{Regret}(T) = \sum_{t=1}^{T} \max_{\boldsymbol{x} \in \mathcal{D}_t} \mathbb{E}_{y_t}\left[r_t \mid \boldsymbol{x}\right] - \mathbb{E}_{y_t}\left[r_t \mid \boldsymbol{x}\right],$$

其中 r_t 表示与反馈 y_t 对应的奖励，$\boldsymbol{x}$ 为智能体选择的动作.

在各种老虎机模型中，多臂老虎机（Multi-Armed Bandit，MAB）是最基础的模型，智能体需从有限的集合 $[K]$ 中选择某一摇臂（动作），且不依赖上下文信息. 每个摇臂对应的反馈独立，且分别服从于 K 个未知分布. 该模型已被广泛研究，并衍生出多种算法，例如汤普森采样[11]、UCB[12]、ε-贪心算法和 EXP3.

随机线性老虎机（Stochastic Linear Bandit，SLB）通过引入上下文信息扩展了 MAB 模型，其反馈为关于动作向量的线性函数加上亚高斯随机噪声. 该模型由 Auer[13] 首次提出，其提出的算法 LinRel 的遗憾随摇臂数量增长. 随后 Abbasi-yadkori 等[14] 提出 OFUL 算法，通过自归一化定理改进遗憾界，实现了与动作数量无关的遗憾上界.

2.2 随机上下文（多项）对率老虎机

随机上下文（多项）对率老虎机（Multinomial Logistic Bandit，MLogB）假设反馈 $y_t \in \langle K+1 \rangle = \{0, 1, \cdots, K\}$ 服从（多项）对率分布：

$$\Pr\left[y_t = k \mid \boldsymbol{x}_t\right] = \sigma_k(W_\star \boldsymbol{x}_t) = \begin{cases} \frac{\exp(\left\langle \boldsymbol{w}_\star^k, \boldsymbol{x}_t \right\rangle)}{1+\sum_{i=1}^K \exp(\langle \boldsymbol{w}_\star^i, \boldsymbol{x}_t \rangle)}, & 若 1 \leqslant k \leqslant K, \\ \frac{1}{1+\sum_{i=1}^K \exp(\langle \boldsymbol{w}_\star^i, \boldsymbol{x}_t \rangle)}, & 若 k = 0, \end{cases}$$

其中环境参数 $W_\star = [\boldsymbol{w}_\star^1, \boldsymbol{w}_\star^2, \cdots, \boldsymbol{w}_\star^K]^\top \in \mathbb{R}^{K \times d}$ 对智能体未知，而 $\boldsymbol{x}_t \in \mathbb{R}^d$ 是智能体在第 t 轮从决策集 $\mathcal{D}_t$ 中选择的动作．给定奖励向量 $\boldsymbol{\rho} \in \mathbb{R}^{K+1}$，反馈 $y_t = k$ 的奖励为 ρ_k．而智能体的目标是最小化时间 T 内的遗憾，其定义为：

$$\begin{aligned} \mathrm{Regret}(T) &:= \sum_{t=1}^T \left(\max_{\boldsymbol{x} \in \mathcal{D}_t} \mathbb{E}_{y_t} \left[\sum_{k=0}^K \rho_k \mathbb{I}\left[y_t = k \mid \boldsymbol{x}\right] \right] - \mathbb{E}_{y_t} \left[\sum_{k=0}^K \rho_k \mathbb{I}\left[y_t = k \mid \boldsymbol{x}_t\right] \right] \right) \\ &= \sum_{t=1}^T \left(\max_{\boldsymbol{x} \in \mathcal{D}_t} \boldsymbol{\rho}^\top \boldsymbol{\sigma}(\boldsymbol{x}) - \boldsymbol{\rho}^\top \boldsymbol{\sigma}(\boldsymbol{x}_t) \right) \end{aligned}$$

为简化模型，一般令 $\rho_0 = 0$，即将 $k = 0$ 视为虚拟反馈．在 $K = 1$ 且奖励向量 $\boldsymbol{\rho} = [0, 1]^\top$（即偏好后一类反馈）的特殊情况下，遗憾可简化为[6,15]：

$$\mathrm{Regret}(T) = \sum_{t=1}^T \left(\max_{\boldsymbol{x} \in \mathcal{D}_t} \sigma_1(\boldsymbol{w}_\star^\top \boldsymbol{x}) - \sigma_1(\boldsymbol{w}_\star^\top \boldsymbol{x}_t) \right).$$

可将反馈重新定义为 $y_t \in \{\pm 1\}$ 并记 $\sigma(z) := \sigma_1(z)$ [1]．

在二元情况下，OL^{2}M[15] 是首个二元对率老虎机的在线算法，该算法每轮通过 ONS 的变体更新策略并选取动作，且仅需 $\mathcal{O}(1)$（与 t 无关）的计算成本．但其遗憾界与 $\kappa = \max_{\|\boldsymbol{x}\| \leqslant D, \|\boldsymbol{w}\| \leqslant S} 1/\sigma'(\boldsymbol{w}^\top \boldsymbol{x})$ 成正比，这是一个随参数域直径指数级增长的关键参数，它捕捉了对率奖励的非线性特性[6]．随后 Abeille 等[16] 提出的 OFULog-r 算法达到了 MinMax 最优的遗憾界 $\tilde{\mathcal{O}}(\sqrt{T/\kappa_*})$，其中 $\kappa_* = 1/\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_\star)$．然而，OFULog-r 需要存储全部历史数据，因此每轮计算成本为 $\mathcal{O}(t)$．而后续提出的 ada-OFU-ECOLog 算法[17] 在保持 MinMax 最优遗憾界的同时，将每轮计算

1 此处 $\sigma_1(z) = \frac{e^z}{1+e^z}$ 为标准对率函数，而二元反馈 $y \in \{-1, 1\}$ 的设定常见于二分类任务，因此概率分布可以简化为 $\Pr\left[y_t = y\right] = \sigma_1(yz)$，其与原始定义通过 $\tilde{y}_t = 2y_t - 1$ 可相互转换

Algorithm 1: OFU(L)-MLogB

Input: 正则化系数 λ，置信度 δ

1 初始化 $W_0 := 0 \in \mathbb{R}^{K\times d}, Z_0 := \lambda I_{Kd}$

2 **for** $t = 1, 2, \cdots$ **do**

3 根据公式 (2-1) 选择乐观最优决策 $\boldsymbol{x}_t := \operatorname{argmax}_{\boldsymbol{x}\in D_t} r_{t-1}(\boldsymbol{x}, \delta)$

4 提交决策 $\boldsymbol{x}_t$，并获取反馈 y_t

5 $\tilde{Z}_t := Z_{t-1} + \eta \nabla^2 \ell_t(W_{t-1})$

6 更新参数 $\overrightarrow{W_t} := \operatorname{argmin}_{\|W\|_F \leqslant S} \left\langle \ell_t(\overrightarrow{W_{t-1}}), \overrightarrow{W} \right\rangle + \frac{1}{2\eta} \left\| \overrightarrow{W} - \overrightarrow{W_{t-1}} \right\|_{\tilde{Z}_t}^2$

7 $Z_t := Z_{t-1} + \nabla^2 \ell_t(W_t)$

成本降至 $\mathcal{O}(\log t)$ 且降低存储需求至 $\mathcal{O}(1)$.

另一方面，Improved MNL-UCB 算法[5] 是针对多项对率老虎机问题的 UCB 算法，它虽然达到了 $\tilde{\mathcal{O}}(K^{3/2}\sqrt{T})$ 的遗憾界，但每轮需要消耗 $\mathcal{O}(t)$ 的计算资源. 此后，Zhang 等[6] 提出了首个针对 MLogB 问题的在线算法 OFUL-MLogB，该算法实现了 $\tilde{\mathcal{O}}(K\sqrt{T})$ 的遗憾界. 对于二元情况，该算法同样达到了 MinMax 最优的遗憾界 $\tilde{\mathcal{O}}(\sqrt{T/\kappa_*})$. 各算法的详细对比可参见 Zhang 等[6, 表 1].

本文主要改进多项对率老虎机的 OFUL-MLogB 算法. 具体而言，算法伪代码如算法 1 所示. 首先算法在第 3 行根据乐观奖励函数 $r_{t-1}(\boldsymbol{x}, \delta)$ 选择乐观最优动作 $\boldsymbol{x}_t$，其中

$$r_t(\boldsymbol{x}, \delta) = \begin{cases} \boldsymbol{\rho}^\top \boldsymbol{\sigma}(W_t \boldsymbol{x}) + \delta_t(\boldsymbol{x}, \delta), & \text{if } K \geqslant 2 \\ \max_{\boldsymbol{w}\in C_{t-1}} \langle \boldsymbol{w}, \boldsymbol{x} \rangle, & \text{if } K = 1 \end{cases} \tag{2-1}$$

$$\delta_t(\boldsymbol{x}, \delta) = \sqrt{\beta_t(\delta)} \left\| (\nabla \boldsymbol{\sigma}(W_t \boldsymbol{x}) \otimes \boldsymbol{x}) \boldsymbol{\rho} \right\|_{Z_t^{-1}} + \frac{\sqrt{K}}{2} R \beta_t(\delta) \left\| Z_t^{-1} (I_K \otimes \boldsymbol{x}\boldsymbol{x}^\top) \right\|_{2,2}$$

$$C_t = \left\{ \boldsymbol{w} \,\middle|\, \left\| \boldsymbol{w} - \boldsymbol{w}_t \right\|_{Z_t}^2 \leqslant \beta_t(\delta) \right\}$$

对应的置信域半径 $\beta_t(\delta)$ 则是

$$\begin{aligned} \beta_t(\delta) = {} & \alpha \frac{\lambda}{4\sqrt{6}Kd} Kd \ln(1 + \frac{D^2}{Kd\lambda} t) + \alpha(DS + S_{\frac{1}{t}}) \left(\frac{5}{4} + 4 \ln \frac{\sqrt{1+2t}}{\delta} \right) \\ & + 2\lambda S^2 + \alpha(2 + \ln(K+1)) \end{aligned} \tag{2-2}$$

其中 $\alpha = \ln(K+1) + 2(DS+1), S_{\frac{1}{t}} = \ln(K+1) + 2\ln((K+1)t + 2)$；在第 4 行提

交动作并获取反馈 y_t；最后在第 5 行至第 8 行更新参数 W_t, Z_t.

在 Zhang 等[6] 中，“OFUL-MLogB” 指代 $K \geqslant 2$ 的情况，其乐观奖励 $r_t(\boldsymbol{x}, \delta)$ 为

$$r_t(\boldsymbol{x}, \delta) = \boldsymbol{\rho}^\top \boldsymbol{\sigma}(W_t \boldsymbol{x}) + \delta_t(\boldsymbol{x}, \delta);$$

而 “OFU-MLogB” 表示 $K = 1$ 的情形，其乐观奖励通过 $1 - \delta$ 置信度下的乐观值计算：

$$r_t(\boldsymbol{x}, \delta) = \max_{\boldsymbol{w} \in C_{t-1}} \langle \boldsymbol{w}, \boldsymbol{x} \rangle .$$

可以看出，OFUL-MLogB 采用了一种改进的 ONS 框架，无需存储历史数据 $(\boldsymbol{x}_t, y_t)$，而是将所有信息储存在历史费希尔信息矩阵 $Z_t = \sum_{s=1}^{t} \nabla^2 \ell_t(W_t)$ 中. 这使得算法计算成本与时间 t 无关，特别适合长期部署的应用场景. 而每轮计算复杂度为 $\mathcal{O}(|\mathcal{D}| K^3 d^3)$，其中 $|\mathcal{D}|$ 表示决策集 $\mathcal{D}_t$ 的大小. 该复杂度主要源自三个关键矩阵运算：1) 维护 Z_t 及其逆矩阵；2) 对该矩阵进行 SVD；3) 对每个候选动作 $\boldsymbol{x} \in \mathcal{D}_t$ 计算矩阵 $(I_K \otimes \boldsymbol{x}\boldsymbol{x}^\top) Z_t$ 的最大特征值. 在高维场景下，这种关于维度 d 的三次方复杂度可能成为性能瓶颈.

2.3 矩阵略图

本文使用的矩阵略图技术是频繁方向算法（Frequent Direction, FD）[8,18]. 它是一种确定性矩阵略图（Matrix Sketching）算法，能有效解决数据流场景下的低秩逼近问题. 具体而言，给定略图大小 $m \ll d$ 和数据流 $\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_t \in \mathbb{R}^d$，该算法计算矩阵 $X_t = [\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_t]$ 的近似 $S_t \in \mathbb{R}^{d \times m}$ ，使得 $S_t \approx X_t$ 或 $S_t S_t^\top \approx X_t X_t^\top$ 成立. 虽然截断奇异值分解（truncated SVD）是最优的低秩矩阵逼近方法[8]，但对于大规模数据流而言，完整的奇异值分解计算可能面临不同挑战，例如数据无法一次性全部读取，而是逐个到达；此外，内存限制无法存储完整数据矩阵. FD 算法因其在线处理优势、最优误差界和其理论简洁性脱颖而出. 特别地，FD 的某些基本性质（如性质 3.1和 3.2）对本文的理论分析至关重要.

频繁方向算法的伪代码在算法 2 中给出. 在算法 2 的每一轮迭代中，算法第 3 行接收当前时刻 t 的新数据 $\boldsymbol{x}_t$，并在第 4 行将 $\boldsymbol{x}_t$ 追加到 S_{t-1} 的最后一列，得

Algorithm 2: 频繁方向算法（FD）

Input: 略图大小 m，在 t 时刻到达的数据 $x_t \in \mathbb{R}^d$，其中 $d \gg m$，正则化系数 λ

Output: 略图矩阵 S_t

1 初始化 $S_0 := 0^{d\times m}, \rho_0 := 0$

2 **for** $t = 1, 2, \cdots$ **do**

3 接受新数据 $\boldsymbol{x}_t \in \mathbb{R}^d$

4 将 $\boldsymbol{x}_t$ 追加到 S_{t-1} 的最后一列：$\hat{S}_t := \left[S_{t-1}, \boldsymbol{x}_t\right] \in \mathbb{R}^{d\times(m+1)}$

5 计算 SVD：$U_t \Sigma_t V_t^\top := \hat{S}_t$

6 $\rho_t := \rho_{t-1} + (\Sigma_t)_{m+1}^2$，其中 $(\Sigma_t)_{m+1}$ 表示 Σ_t 的第 $m+1$ 大奇异值

7 $S_t := U_t \sqrt{\Sigma^2 - (\Sigma_t)_{m+1}^2 I_{m+1}}$，并移出最后一列（零列）$S_t$.

8 $(H_t := (\lambda I_m + \Sigma_t - (\Sigma_t)_{m+1}^2 I_m)^{-1})$

9 **return** $S_t, \rho_t(, H_t, \Sigma_t - (\Sigma_t)_{m+1}^2 I_m, U_t)$

到 $\hat{S}_t$. 算法在第 5 行对矩阵进行奇异值分解（SVD）处理：

$$U_t \Sigma_t^2 U_t^\top = \hat{S}_t \hat{S}_t^\top = S_{t-1} S_{t-1}^\top + \boldsymbol{x}_t \boldsymbol{x}_t^\top$$

最终，算法第 7 行通过减去最小奇异值重构略图矩阵：

$$S_t = U_t \sqrt{\Sigma^2 - (\Sigma_t)_{m+1} I_{m+1}}$$

以确保 S_t 的秩不超过 m，并在第 8 行返回略图矩阵 S_t 及其他必要变量.

算法 2 的单轮最优时间复杂度为 $\mathcal{O}(dm)$. 在已知 $S_{t-1}S_{t-1}^\top$ 的奇异值分解（SVD）情况下通过采用 Gu-Eisenstat 方法[19]（如 Ghashami 等[8, 第 3 节] 所述）可在 $\mathcal{O}(dm)$ 时间内更新 $\hat{S}_t \hat{S}_t^\top$ 的 SVD. 具体而言，第 5 行 SVD 计算需要 $\mathcal{O}(dm)$，第 7 行构造 S_t 需要 $\mathcal{O}(dm)$，第 8 行计算 H_t 需要 $\mathcal{O}(m)$. 因此算法整体复杂度保持为 $\mathcal{O}(dm)$，该结果与 Kuzborskij 等[9, 第 3 节] 的结论一致.

FD 算法的近似误差具有最优界[8]定理 1.1 为

$$0 \preceq X_t X_t^\top - S_t S_t^\top \preceq \left(\min_{k<m} \frac{1}{m-k} \left\|X_t - (X_t)_k\right\|_F^2\right) I_d$$

其中 $X_t = [\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_t]$ 为原始数据矩阵，$(X_t)_k$ 表示 X_t 的最佳秩 k 近似. 该结

论可由 Ghashami 等[8, 性质 2] 推得：

$$X_t X_t^\top - S_t S_t^\top \preceq \rho_t I_d$$

结合 Ghashami 等[8, 性质 3] 的讨论可知，略图参数 ρ_t 满足上界：

$$\forall k < m.\ \rho_t \leqslant \frac{1}{m-k} \left\| X_t - (X_t)_k \right\|_F^2$$

批处理数据情况 当算法第 3 行输入的 $\boldsymbol{x}_t \in \mathbb{R}^{d\times k}$ 为 $k > 1$ 的批量数据矩阵时（这正是本文遇到的情况），可将 $\boldsymbol{x}_t$ 直接追加到 S_{t-1} 的最后一列，并直接应用奇异值分解，然后将第 7 行 S_t 的 $m+1$–$m+k$ 列全部移除．由此生成的略图矩阵 S_t 仍满足 A 章所述性质．此时算法时间复杂度变为 $\mathcal{O}(d(m+k)^2)$．如果应用 Gu-Eisenstat 方法更新奇异值分解，则算法复杂度为 $\mathcal{O}(dk(m+k))$.

第三章　OFUL-MLogB 略图算法

可以看出，在算法 1 中，第 3 行的乐观决策和第 6 行的参数更新都需要对 $Kd \times Kd$ 矩阵求逆、进行特征值分解，这是 OFUL-MLogB 算法的主要计算瓶颈. 在本章中，我们将 FD 算法应用于 OFUL-MLogB 算法，对矩阵 Z_t 进行略图化，以降低计算复杂度.

我们首先对问题假设进行说明，然后给出 OFUL-MLogB 算法的伪代码，最后对该算法的计算复杂度以及遗憾界进行分析.

假设

我们沿用 Amani 等[5], Zhang 等[6] 中的假设条件：

假设 3.1 (决策集有界性) 决策集合满足有界性约束：

$$\forall t > 0, \boldsymbol{x} \in \mathcal{D}_t.\ \|\boldsymbol{x}\|_2 \leqslant D$$

其中 D 为决策向量的最大欧几里得范数（*Euclidean norm*）.

假设 3.2 (参数有界性)（多项）对率回归模型参数 $W_\star$ 满足：

$$\|W_\star\|_F = \left\|\overrightarrow{W_\star}\right\|_2 \leqslant S$$

S 表示参数矩阵的弗罗贝尼乌斯范数上界.

假设 3.3 (奖励有界性) 奖励向量 $\boldsymbol{\rho} \in \mathbb{R}^{K+1}$ 满足：

$$\|\boldsymbol{\rho}\|_2 \leqslant R$$

其中第 *0* 个分量设为 0，表示第 *0* 类反馈为虚拟反馈.

Algorithm 3: OFU(L)-MLogB through Frequent Direction

Input: 正则化系数 λ，置信度 δ，略图大小 m

1 初始化 $W_0 := 0, Z_0 := \lambda I, S_0 := 0$

2 **for** $t = 1, 2, \cdots$ **do**

3 根据公式 (2-1) 选择后验最优决策 $\boldsymbol{x}_t := \mathrm{argmax}_{\boldsymbol{x}\in D_t} r_{t-1}(\boldsymbol{x}, \delta)$

4 提交决策 $\boldsymbol{x}_t$，并获取反馈 y_t

5 进行特征值分解：$P\Lambda P^\top := \mathrm{EIG}(\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t))$

6 $\tilde{Z}_t = [S_{t-1}, \sqrt{\eta}P\sqrt{\Lambda}\otimes\boldsymbol{x}_t][S_{t-1}, \sqrt{\eta}P\sqrt{\Lambda}\otimes\boldsymbol{x}_t]^\top + \lambda I$

7 更新参数 $\overrightarrow{W_t} := \mathrm{argmin}_{\|W\|_F\leqslant S}\left\langle\nabla\ell_t(\overrightarrow{W_{t-1}}), \overrightarrow{W}\right\rangle + \frac{1}{2\eta}\left\|\overrightarrow{W} - \overrightarrow{W_{t-1}}\right\|^2_{\tilde{Z}_t}$

8 进行特征值分解：$P\Lambda P^\top := \mathrm{EIG}(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t))$

9 $(S_t, H_t, \rho_t) := \mathrm{FD}(S_{t-1}, P\sqrt{\Lambda}\otimes\boldsymbol{x}_t)$,
$Z_t = \lambda I + S_tS_t^\top, Z_t^{-1} = \frac{1}{\lambda}I - \frac{1}{\lambda}S_tH_tS_t^\top$

假设 3.4 (对率函数利普希茨连续性)（多项）对率函数 $\boldsymbol{\sigma}(z)$ 的一阶导数满足：

$$\forall z \in [-SD, SD]^K.\ \frac{1}{\kappa}I \preceq \nabla\boldsymbol{\sigma}(z) \preceq LI$$

此处 κ 和 L 分别表示函数曲率的下界和利普希茨常数（*Lipschitz Constance*）.

3.1 算法

我们将 FD 应用于 OFUL-MLogB 算法. 改进后的算法伪代码如算法 3 所示. 在每轮迭代中，算法 3 首先根据第 3 行的决策规则 $\boldsymbol{x}_t := \mathrm{argmax}_{\boldsymbol{x}\in D_t} r_{t-1}(\boldsymbol{x}, \delta)$ 选择动作，其中乐观奖励函数 $r_{t-1}(\boldsymbol{x}, \delta)$ 则沿用原算法的定义 (2-1)，不同的是置信域半径则定义为

$$\begin{aligned}
\beta_t(\delta) = {} & \alpha\frac{\lambda}{4\sqrt{6}Kd}\Delta_t^\lambda\left(Kd\ln\Delta_t^{\lambda/2} + m\ln(1 + \frac{D^2}{m\lambda}t)\right) \\
& + \alpha(DS + S_{\frac{1}{t}})\left(\frac{5}{4} + 4\ln\frac{\sqrt{1+2t}}{\delta}\right) \\
& + 2\lambda S^2 + \alpha(2 + \ln(K+1)) \qquad (3\text{-}1) \\
\alpha = {} & \ln(K+1) + 2(DS+1) \\
S_{\frac{1}{t}} = {} & \ln(K+1) + 2\ln((K+1)t + 2) \\
\Delta_t^\lambda = {} & 1 + \frac{\rho_t}{\lambda}
\end{aligned}$$

可以看出，该置信域半径 $\beta_t(\delta)$ 与原算法 (2-2) 相比，增加了 m 阶截断谱尾 ρ_t 项. 随后在第 4 行将动作提交至环境，并接收反馈 y_t. 第 5 – 6 行构造了索引偏移海森矩阵的半略图矩阵 $\tilde{Z}_t$，其中 $\tilde{Z}_t = Z_{t-1} + \nabla^2 \ell_t(W_{t-1})$，我们采用 Chen 等[20, 方程 (4)] 中详述的方法来处理 $\tilde{Z}_t$ 的求逆与乘法运算. 第 7 行利用 $\tilde{Z}_t$ 和 ONS 变体更新参数 W_t；第 8–9 行使用 FD 对历史费希尔信息矩阵进行略图化：

$$S_t S_t^\top \approx \sum_{s=1}^{t} (P_s \sqrt{\Lambda_s} \otimes \boldsymbol{x}_s)(P_s \sqrt{\Lambda_s} \otimes \boldsymbol{x}_s)^\top = \sum_{s=1}^{t} \nabla^2 \ell_s(W_s) = \sum_{s=1}^{t} \nabla \boldsymbol{\sigma}(W_s \boldsymbol{x}_s) \otimes \boldsymbol{x}_s \boldsymbol{x}_s^\top.$$

以下我们将阐述一些不便于写入伪代码 3 的计算细节：

矩阵 $Z_t, \tilde{Z}_t$ 的乘法运算 给定矩阵 $Z_t = \lambda I + S_t S_t^\top$ 和 $\tilde{Z}_t = \lambda I + \tilde{S}_t \tilde{S}_t^\top$，其中 $\tilde{S}_t = [S_{t-1}, P\sqrt{\Lambda} \otimes \boldsymbol{x}_t]$，我们可在 $\mathcal{O}(Kdm)$ 和 $\mathcal{O}(Kd(m+K))$ 时间内计算矩阵-向量乘积 $Z_t \boldsymbol{v}$ 和 $\tilde{Z}_t \boldsymbol{v}$. 以 $Z_t \boldsymbol{v}$ 为例，先以 $\mathcal{O}(Kdm)$ 时间计算 $S_t^\top \boldsymbol{v}$，再以相同复杂度计算 $S_t(S_t^\top \boldsymbol{v})$，最后用 $\mathcal{O}(Kd)$ 时间计算 $\lambda \boldsymbol{v} + (S_t(S_t^\top \boldsymbol{v}))$.

正则化 (半) 略图矩阵 Z_t 和 $\tilde{Z}_t$ 的逆 在选择动作和参数更新过程中，需要计算 Z_t 及其半略图矩阵 $\tilde{Z}_t$ 的逆. 对于正则化略图矩阵 $Z_t = \lambda I + S_t S_t^\top$ 的逆，可采用 Kuzborskij 等[9, 第 3 节] 建议的公式：

$$\left(\lambda I_{Kd} + S_t S_t^\top\right)^{-1} = \frac{1}{\lambda} I_{Kd} - \frac{1}{\lambda} S_t (\lambda I_m + S_t^\top S_t)^{-1} S_t^\top. \tag{3-2}$$

由于 $S_t = U_t \Sigma_t$，其中 Σ_t 为 S_t 的奇异值，算法可通过 $(\lambda I_m + \Sigma_t^2)^{-1}$ 高效计算 $(\lambda I_m + S_t^\top S_t)^{-1}$，该矩阵在算法第 9 行记为 H_t. 类似地，矩阵-向量乘积 $Z_t^{-1} \boldsymbol{v}$ 可在 $\mathcal{O}(Kdm)$ 时间内完成.

对于半略图矩阵 $\tilde{Z}_t = \lambda I_{Kd} + \tilde{S}\tilde{S}^\top$ 的逆，可参考 Chen 等[20, 3.2 节] 的改进公式. 令 $\boldsymbol{z} = P\sqrt{\Lambda} \otimes \boldsymbol{x}_t$，有：

$$(\lambda I_{Kd} + \tilde{S}\tilde{S}^\top)^{-1} = \frac{1}{\lambda} I_{Kd} - \frac{1}{\lambda} \tilde{S} H \tilde{S}^\top \tag{3-3}$$

其中

$$H = \left(\lambda I_{m+K} + \tilde{S}^\top \tilde{S}\right)^{-1} = \begin{pmatrix} H_t + H_t B C^{-1} B^\top H_t & -H_t B C^{-1} \\ -C^{-1} B^\top H_t & C^{-1} \end{pmatrix},$$

$B = S_t^\top \boldsymbol{z}, C = \lambda I_K + \boldsymbol{z}^\top \boldsymbol{z} - B^\top H_t B$. 根据之前类似的论证，矩阵-向量乘积 $\tilde{Z}_t^{-1}\boldsymbol{v}$ 可在 $\mathcal{O}(dK(m+K) + (m+K)^2) = \mathcal{O}(Kd(m+K))$ 时间内完成.

注 3.1 我们不需要担心矩阵 C 的秩，因为

$$C - \lambda I_K = \boldsymbol{z}^\top \boldsymbol{z} - \boldsymbol{z}^\top S_t H_t S_t^\top \boldsymbol{z} = \boldsymbol{z}^\top U_t \left(I_K - \operatorname{diag}\left\{ \frac{(\Sigma_t)_1^2}{\lambda + (\Sigma_t)_1^2}, \frac{(\Sigma_t)_2^2}{\lambda + (\Sigma_t)_2^2}, \cdots, 0 \right\} \right) U_t^\top \boldsymbol{z}$$

是半正定的.

计算 $\left\| Z_t^{-1}(I_K \otimes \boldsymbol{x}\boldsymbol{x}^\top) \right\|_{2,2}$ 项 矩阵 $Z_t^{-1}(I_K \otimes \boldsymbol{x}\boldsymbol{x}^\top)$ 是一个 $Kd \times Kd$ 的矩阵，对其进行特征值分解需要 $\mathcal{O}(K^3 d^3)$ 的时间复杂度. 为高效计算该项，可利用以下公式简化运算：

$$\left\| Z_t^{-1}(I_K \otimes \boldsymbol{x}\boldsymbol{x}^\top) \right\|_{2,2} = \lambda_{\max}\left((I_K \otimes \boldsymbol{x})^\top Z_t^{-1} (I_K \otimes \boldsymbol{x}) \right).$$

令 $A = (I_K \otimes \boldsymbol{x})^\top Z_t^{-1}(I_K \otimes \boldsymbol{x})$，其元素 $(A_{ij})_{i,j=1}^K$ 可通过奇异值分解表示为：

$$A_{ij} = \frac{\boldsymbol{x}^\top \boldsymbol{x}}{\lambda} \delta_i^j + \sum_{k=1}^m \left(\frac{1}{\sigma_k + \lambda} - \frac{1}{\lambda} \right) \boldsymbol{x}^\top (\boldsymbol{u}_k)_i (\boldsymbol{u}_k)_j^\top \boldsymbol{x},$$

其中 δ_i^j 为克罗内克函数，$(\boldsymbol{u}_k)_i$ 表示 S_t 奇异向量 $\boldsymbol{u}_k$ 的第 i 个 K 长的分段. 具体推导详见下节 3.2.

3.2 计算复杂度分析

算法 3 的主要计算开销如下：

1. 构造对率函数梯度 $\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)$ 与 $\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)$；
2. 维护略图矩阵 S_t, Z_t 以及半略图矩阵 $\tilde{Z}_t$ 并求逆；

3. 根据决策规则 $r_t(\boldsymbol{x}, \delta)$ 选择最优动作 $\boldsymbol{x}_t$；
4. 更新参数矩阵 W_t；
5. 对矩阵 $\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)$ 和 $\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)$ 进行两次特征分解.

接下来，我们对每个步骤进行分析.

函数梯度 $\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)$ 与 $\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)$ 的计算复杂度 构造 $\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)$ 和 $\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)$，需要 $\mathcal{O}(dK)$ 时间，构造的结果为 $\nabla\boldsymbol{\sigma}(W\boldsymbol{x}) = \operatorname{diag}\{\boldsymbol{\sigma}(W\boldsymbol{x})\} - \boldsymbol{\sigma}(W\boldsymbol{x})\boldsymbol{\sigma}(W\boldsymbol{x})^\top$.

维护 $S_t, Z_t, \tilde{Z}_t$ 并求逆的计算复杂度 正如第 2.3 节所示，矩阵 S_t 和 Z_t 的更新和求逆可以在 $\mathcal{O}(dK(m+K)^2)$ 时间内完成.

借助公式 (3-3)，略图矩阵 $\tilde{Z}_t$ 的逆可以在 $\mathcal{O}(K^3 + dmK^2)$ 时间内计算完成：B 的计算时间复杂度为 $\mathcal{O}(K^2dm)$，C 为 $\mathcal{O}(mK^2 + d)$，C^{-1} 为 $\mathcal{O}(K^3)$，BC^{-1} 为 $\mathcal{O}(mK^2)$. H_1^1 的计算时间复杂度为 $\mathcal{O}(m^2K)$，H_1^2 和 H_2^1 为 $\mathcal{O}(mK)$，而 H_2^2 即为 C^{-1}. 综上所述，维护正则化半略图矩阵逆的整体时间复杂度为 $\mathcal{O}(K^3 + dmK^2)$，而原始方法[6] 的时间复杂度 $\mathcal{O}(d^3K^3)$.

选择最优动作 $\boldsymbol{x}_t$ 的计算复杂度 而当 $K \geqslant 2$ 时，期望奖励函数 $\boldsymbol{\rho}^\top\boldsymbol{\sigma}(z)$ 是非凹函数，因此难以高效计算其最大值. 当 $K = 1$ 时，需要求解双变量规划问题 $(\boldsymbol{x}_t, \hat{\boldsymbol{w}}_t) = \operatorname{argmax}_{\boldsymbol{x}\in\mathcal{D}_t, \boldsymbol{w}\in\mathcal{C}_t}\langle\boldsymbol{w}, \boldsymbol{x}\rangle$. 而在一般意义上而言，它是 NP 难问题[21]；有鉴于此，本文仅考虑 $\mathcal{D}_t$ 为有限集的情况.

为了从 $\mathcal{D}_t$ 选出乐观情况下最优的动作 $\boldsymbol{x}_t$，我们需要选出乐观奖励 $r_{t-1}(\boldsymbol{x}, \delta), \boldsymbol{x} \in \mathcal{D}_t$ 最大的动作 $\boldsymbol{x}_t$. 因此问题被归约为计算每个 $\boldsymbol{x} \in \mathcal{D}_t$ 的乐观奖励 $r_{t-1}(\boldsymbol{x}, \delta)$，并选出最大值.

当 $K \geqslant 2$ 时，给定 $\boldsymbol{x}$ 和 Z_t^{-1}，$\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x})$ 可在 $\mathcal{O}(dK)$ 时间内计算完成，$\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x})$ 的计算时间复杂度为 $\mathcal{O}(K)$，而 $\left\|(\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}) \otimes \boldsymbol{x})\boldsymbol{\rho}\right\|_{Z_t^{-1}}$ 的计算时间从原来的 $\mathcal{O}(d^2K^2)$ 降低至 $\mathcal{O}(dmK)$. 对于项 $\left\|Z_t^{-1}(I_K \otimes \boldsymbol{x}\boldsymbol{x}^\top)\right\|_{2,2} = \|A\|_{2,2}$，矩阵 $A =$

$(I_K \otimes \boldsymbol{x})^\top Z_t^{-1}(I_K \otimes \boldsymbol{x})$ 的计算可进一步优化：

$$A = \begin{bmatrix} (\boldsymbol{e}_1 \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_1 \otimes \boldsymbol{x}) & (\boldsymbol{e}_1 \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_2 \otimes \boldsymbol{x}) & \cdots & (\boldsymbol{e}_1 \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_K \otimes \boldsymbol{x})^\top \\ (\boldsymbol{e}_2 \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_1 \otimes \boldsymbol{x}) & (\boldsymbol{e}_2 \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_2 \otimes \boldsymbol{x}) & \cdots & (\boldsymbol{e}_2 \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_K \otimes \boldsymbol{x})^\top \\ \vdots & \vdots & \ddots & \vdots \\ (\boldsymbol{e}_K \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_1 \otimes \boldsymbol{x}) & (\boldsymbol{e}_K \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_2 \otimes \boldsymbol{x}) & \cdots & (\boldsymbol{e}_K \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_K \otimes \boldsymbol{x})^\top \end{bmatrix}.$$

该矩阵是的维度为 $K \times K$，因此其最大特征值可在 $\mathcal{O}(K^3)$ 时间内计算得到．令 $\Sigma_t = \operatorname{diag}\left\{\sigma_1, \cdots, \sigma_m\right\}$ 为 S_t 的奇异值矩阵，且令 $(\boldsymbol{u})_k$ 表示向量 $\boldsymbol{u}$ 中第 kK 至 $kK + K - 1$ 的分段．为简化表示，我们将 S_t 的奇异向量矩阵 $U_t = [\boldsymbol{u}_1, \cdots, \boldsymbol{u}_m]$ 的下标 t 省略．对于矩阵 A 的元素 A_{ij}，其表达式可进一步展开如下：

$$\begin{aligned} A_{ij} &= (\boldsymbol{e}_i \otimes \boldsymbol{x})^\top Z_t^{-1}(\boldsymbol{e}_j \otimes \boldsymbol{x}) \\ &= (\boldsymbol{e}_i \otimes \boldsymbol{x})^\top \sum_{k=1}^{Kd} \frac{1}{\sigma_k^2 + \lambda} \boldsymbol{u}_k \boldsymbol{u}_k^\top (\boldsymbol{e}_j \otimes \boldsymbol{x}) \\ &= (\boldsymbol{e}_i \otimes \boldsymbol{x})^\top \sum_{k=1}^{m} \frac{1}{\sigma_k^2 + \lambda} \boldsymbol{u}_k \boldsymbol{u}_k^\top (\boldsymbol{e}_j \otimes \boldsymbol{x}) + (\boldsymbol{e}_i \otimes \boldsymbol{x})^\top \sum_{k=m+1}^{Kd} \frac{1}{\lambda} \boldsymbol{u}_k \boldsymbol{u}_k^\top (\boldsymbol{e}_j \otimes \boldsymbol{x}) \\ &= \sum_{k=1}^{m} \frac{1}{\sigma_k^2 + \lambda} \boldsymbol{x}^\top (\boldsymbol{u}_k)_i (\boldsymbol{u}_k)_j^\top \boldsymbol{x} + \frac{1}{\lambda} (\boldsymbol{e}_i \otimes \boldsymbol{x})^\top \left(I_{Kd} - \sum_{k=1}^{m} \boldsymbol{u}_k \boldsymbol{u}_k^\top \right) (\boldsymbol{e}_j \otimes \boldsymbol{x}) \\ &= \frac{\boldsymbol{x}^\top \boldsymbol{x}}{\lambda} \delta_i^j + \sum_{k=1}^{m} \left(\frac{1}{\sigma_k^2 + \lambda} - \frac{1}{\lambda} \right) \boldsymbol{x}^\top (\boldsymbol{u}_k)_i (\boldsymbol{u}_k)_j^\top \boldsymbol{x} \end{aligned}$$

对于所有 $i \in [K]$ 和 $k \in [m]$，计算 $(\boldsymbol{u}_k)_i^\top \boldsymbol{x}$ 的时间复杂度为 $\mathcal{O}(dmK)$，构造矩阵 A 需要 $\mathcal{O}(mK^2)$ 时间，最终计算 A 的最大特征值需要 $\mathcal{O}(K^3)$ 时间．因此，对于集合 $\mathcal{D}_t$ 中每个元素的总计算时间为 $\mathcal{O}(|\mathcal{D}_t|(K^3 + mK^2 + dmK))$，较之原文[6]附录 C.3.4 中每个 $\boldsymbol{x} \in \mathcal{D}_t$ 所需的 $\mathcal{O}(d^3K^3)$ 时间复杂度有显著提升．

当 $K = 1$ 时，决策规则是 $\boldsymbol{x}_t = \operatorname{argmax}_{\boldsymbol{x} \in \mathcal{D}_t, \boldsymbol{w} \in \mathcal{C}_t} \langle \boldsymbol{w}, \boldsymbol{x} \rangle$．我们采用 Zhang 等[15, 第 3.3 节] 中的相同策略：当决策集 $\mathcal{D}_t$ 为有限集时，可通过以下公式枚举每个 $\boldsymbol{x} \in \mathcal{D}_t$：

$$\max_{\boldsymbol{x} \in \mathcal{D}_t, \boldsymbol{w} \in \mathcal{C}_t} \langle \boldsymbol{w}, \boldsymbol{x} \rangle = \max_{\boldsymbol{x} \in \mathcal{D}_t} \langle \boldsymbol{w}_{t-1}, \boldsymbol{x} \rangle + \sqrt{\beta_{t-1}(\delta)} \, \|\boldsymbol{x}\|_{Z_{t-1}^{-1}},$$

比起原来的 $\mathcal{O}(|\mathcal{D}_t|d^2)$，这只需要 $\mathcal{O}(|\mathcal{D}_t|dm)$ 的时间. 如果决策集 $\mathcal{D}_t$ 是单位球体，则问题可以简化为 QCQP 问题

$$\max_{\|\boldsymbol{x}\|_2\leqslant 1,\boldsymbol{w}\in\mathcal{C}_{t-1}} \langle \boldsymbol{w},\boldsymbol{x}\rangle = \min_{\|\boldsymbol{w}-\boldsymbol{w}_{t-1}\|^2_{Z^{-1}_{t-1}}\leqslant\beta_{t-1}(\delta)} -\|\boldsymbol{w}\|_2\,,$$

则略图技术可以将原来的 $\mathcal{O}(d^3)$ 复杂度降低至 $\mathcal{O}(dm)$.

更新估计参数 W_t 的复杂度 第四步可以分为两部分：

$$\overrightarrow{W}' = \overrightarrow{W}_{t-1} - \eta\tilde{Z}_t^{-1}\nabla\ell_t(\overrightarrow{W}_{t-1}) \text{ 和} \overrightarrow{W}_t = \operatorname*{argmin}_{\|W\|_F\leqslant S} \left\|\overrightarrow{W}-\overrightarrow{W}'\right\|_{\tilde{Z}_t}.$$

给定 $\tilde{Z}_t^{-1}$，第一部分可以在 $\mathcal{O}(K^2d+Kdm)$ 的时间内计算出来；而根据 Mhammedi 等[22, Section 4]，第二部分可以在 $\mathcal{O}(dK(m+K)^2)$ 时间内完成.

对 $\nabla\sigma(W_{t-1}\boldsymbol{x}_t), \nabla\sigma(W_t\boldsymbol{x}_t)$ 进行特征值分解的计算复杂度 最后一步是对 $K\times K$ 矩阵进行特征值分解，因此时间复杂度为 $\mathcal{O}(K^3)$.

综上所述，算法3的总体时间复杂度为

$$\mathcal{O}(|\mathcal{D}_t|(K^3+K^2m+dKm)+Kd(m+K)^2),$$

而原始 OFUL-MLogB 算法的时间复杂度为 $\mathcal{O}(|\mathcal{D}_t|K^3d^3)$[6]附录 C.3.4.

3.3 遗憾分析

通过利用费希尔信息矩阵的索引前向偏移，并采用二阶近似替代 ONS 算法中的线性近似，估计参数的置信半径 $\beta_t(\delta)$ 不再依赖于参数 κ. 该小节给出了估计参数 $\overrightarrow{W}_t$ 的**略图化**自归一化置信域，并分别讨论了 $K\geqslant 2$ 和 $K=1$ 两种情况下的遗憾界保证.

定理 3.1 如果 $\lambda\geqslant\max\left\{2LD^2,\alpha\max\left\{2\sqrt{6}D^2SL,24Kd\right\}\right\}$，则对任意 $\delta\in(0,1)$，

有至少 $1-\delta$ 的概率，以下不等式成立

$$\forall t > 0.\ \left\|\overrightarrow{W_t} - \overrightarrow{W_\star}\right\|_{Z_t}^2 \leqslant \beta_t(\delta),$$

其中

$$\begin{aligned}
\beta_t(\delta) &= 2\lambda R + \alpha(2 + \ln(K+1)) \\
&\quad + \alpha\left(DS + S_{\frac{1}{t}}\right)\left(\frac{5}{4} + 4\ln\frac{\sqrt{1+2t}}{\delta}\right) \\
&\quad + \alpha\frac{\sqrt{6}}{24Kd}\lambda\Delta_t^\lambda\left(Kd\ln\Delta_t^{\lambda/2} + m\ln(1 + 2\frac{D^2}{m\lambda}t)\right) \\
\Delta_t^\lambda &= 1 + \frac{\rho_t}{\lambda} \\
\alpha &= \ln(K+1) + 2(DS+1) \\
S_{\frac{1}{t}} &= \ln(K+1) + 2\ln((K+1)t + 2),
\end{aligned}$$

并且

$$\beta_t(\delta) = \mathcal{O}\left(\ln K(\ln K + \ln t)\left(\Delta_t^\lambda(Kd\ln\Delta_t^\lambda + m\ln t) + \ln\frac{1}{\delta}\right)\right).$$

定理 3.1 中的置信域与 κ 无关，这与 Zhang 等[6, 定理 3] 的结果类似. 而其主要区别在于置信域半径是通过费希尔信息矩阵的**略图**版本进行归一化的，而非原始矩阵 $\lambda I + \sum_{s=1}^t \nabla^2\ell_s(W_s)$. 这一差异导致置信半径 $\beta_t(\delta)$ 主导项的系数从 Kd 增大至 $\Delta_T^\lambda(Kd\ln\Delta_T^\lambda + m)$. 而核心的证明思想是在 Zhang 等[6, 定理 3] 的证明过程中利用 FD 的性质 3.1 和 A.3 填补略图矩阵和原矩阵之间的差异. 在接下来的证明中，定理 3.1 和 FD 性质 3.2 将弥补 Zhang 等[6, 命题 1，定理 4] 的证明中略图矩阵和原矩阵的不同.

定理 3.2 如果 $K \geqslant 2, \lambda \geqslant \max\left\{2LD^2, \alpha\max\left\{2\sqrt{6}D^2SL, 24Kd\right\}\right\}$，则对任意 $\delta \in (0,1)$，都有至少 $1-\delta$ 的概率，以下遗憾界成立

$$\begin{aligned}
\forall T > 0.\ \mathrm{Regret}(T) &= \mathcal{O}\Big(\Delta_T^\lambda(Kd\ln\Delta_T^{\lambda/2} + m\ln T)\ln K\sqrt{\ln T}\sqrt{T} \\
&\qquad + \kappa\sqrt{K}\ln^2 K\ln T(\Delta_T^\lambda(Kd\ln\Delta_T^{\lambda/2} + m\ln T))^2\Big) \\
&= \tilde{\mathcal{O}}\left(\Delta_T^\lambda(m + Kd\ln\Delta_T^\lambda)\sqrt{T}\right).
\end{aligned}$$

定理 3.3 如果 $K=1, \lambda \geqslant \max\left\{2LD^2, \alpha \max\left\{2\sqrt{6}D^2SL, 24d\right\}\right\}$，即算法 3 第 4 行的乐观决策规则变为

$$(\boldsymbol{x}_t, \hat{\boldsymbol{w}}_t) := \operatorname*{argmax}_{\boldsymbol{x}\in D_t, \boldsymbol{w}\in C_{t-1}} \boldsymbol{w}^\top \boldsymbol{x}, \tag{3-4}$$

则对任意 $\delta \in (0,1)$，有至少 $1-\delta$ 的概率，以下命题对任意 $T>0$ 成立

$$\begin{aligned}
&\mathrm{Regret}(T) \\
&= \mathcal{O}\left(\Delta_T^\lambda (d \ln \Delta_T^\lambda + m \ln T)\sqrt{\ln T}\sqrt{T/\kappa_*} + \kappa(\Delta_T^\lambda (d \ln \Delta_T^\lambda + m \ln T))^2 \ln^2 \ln T\right) \\
&= \tilde{\mathcal{O}}\left(\Delta_T^\lambda (m + d \ln \Delta_T^\lambda)\sqrt{T/\kappa_*}\right),
\end{aligned}$$

其中 $\kappa_* = 1/(\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_\star))$.

OFUL-MLogB 算法的原遗憾界为

$$\mathrm{Regret}(T) = \begin{cases} \tilde{\mathcal{O}}(Kd\sqrt{T}), & \text{if } 2 \leqslant K \\ \tilde{\mathcal{O}}(Kd\sqrt{T/\kappa_*}), & \text{if } K = 1 \end{cases}.$$

显然，略图 OFUL-MLogB 算法在多项情形下保持了与原始 OFUL-MLogB 算法相同的 κ 次优性，在二元情形下则保持了 κ 最优性. 定理 3.2 和 3.3 表明，除略图项 $\Delta_T^\lambda(d \ln \Delta_T^\lambda + m)$ 外，略图 FOUL-MLogB 的遗憾界关于时间范围 T 与 OFUL-MLogB 算法相似. 结合 FD 技术后，遗憾界上升了 $\Delta_T^\lambda(m + Kd \ln \Delta_T^\lambda)/(Kd)$ 倍，表明降维技术在计算效率与统计性能之间一贯的权衡关系.

SOFUL 算法[9] 是将 FD 技术应用于线性老虎机问题中的略图 OFUL 算法，而定理 3.2 和 3.3 与 SOFUL 的结果类似. 值得注意的是，SOFUL 通过 FD 技术，成功将计算复杂度从 $\Omega(d^2)$ 降低至 $\mathcal{O}(dm)$，但遗憾界却增长了 $\Delta_T^{\frac{3}{2}}(m + d \ln \Delta_T)/d$ 倍，而本文却增长了 $\Delta_T(m + Kd \ln \Delta_T)/(Kd)$ 倍. 这一差异可能源于在线学习到置信集转换方法（Online-to-confidence-set conversions[23]）和线性老虎机问题中最小二乘问题的解析特性的差异. 具体而言，MLogB 问题中的差分项

$$\left\|\boldsymbol{w}_t - \boldsymbol{w}_\star\right\|_{Z_t}^2 - \left\|\boldsymbol{w}_{t-1} - \boldsymbol{w}_\star\right\|_{Z_{t-1}}^2 \lesssim \ell_t(\boldsymbol{w}_t) - \ell_t(\boldsymbol{w}_\star)$$

替代了线性老虎机置信域半径中的第二项

$$\left\|\boldsymbol{w}_t - \boldsymbol{w}_\star\right\|_{Z_t} \leqslant \sqrt{\Delta_t} B_t(\delta) + \Delta_t \left\|\boldsymbol{w}_\star\right\|_{Z_t^{-1}},$$

从而消除了额外的 $\mathcal{O}(\Delta_t)$，其中 $B_t(\delta)$ 为 OFUL 中向量值鞅的自归一化上界（Self-Normalized Upper Bound for Vector-Valued Martingale）[14]定理 1.

在算法良好运行情况下，决策变量 $\boldsymbol{x}_t$ 和参数估计量 W_t 都将收敛至各自的最优解 $\boldsymbol{x}_\star$ 和真实参数 $W_\star$. 如果决策集 $\mathcal{D}_t$ 保持（部分）稳态时，海森矩阵 $\nabla^2 \ell_t(W_t)$ 在可能呈现显著相似性. 这种结构性规律导致费希尔信息矩阵 $\sum_{s=1}^{t} \nabla \boldsymbol{\sigma}(W_t \boldsymbol{x}_t) \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top$ 具有长尾谱特性，从而使有效的低秩近似成为可能. 如果精心设计的略图大小 m 能够捕捉该谱结构，则可将谱尾项 Δ_T 控制在较小量级 $\mathcal{O}(\log t)$ 甚至 $\mathcal{O}(\log\log t)$. 而如果 m 大于决策集 $\mathcal{D}_t$ 所张子空间的维度 d，则谱尾项 Δ_T 将被限制在 $\mathcal{O}(1)$. 因此，遗憾界可优化为：

$$\mathrm{Regret}(T) = \begin{cases} \tilde{\mathcal{O}}\left(m\sqrt{T}\right), & \text{if } 2 \leqslant K \\ \tilde{\mathcal{O}}\left(m\sqrt{T/\kappa_*}\right), & \text{if } K = 1 \end{cases},$$

由于 $m \leqslant d$，该结果较原始界 $\mathcal{O}(Kd\sqrt{T})$ 有显著提升. 然而，如果 $\mathcal{D}_t$ 随时间 t 变化剧烈，每次迭代所选的动作 $\boldsymbol{x}_t$ 都可能与之前的动作 $\boldsymbol{x}_{t-1}$ 有较大差异，导致海森矩阵 $\nabla^2 \ell_t(W_t)$ 的谱分布发生显著变化，从而使得略图矩阵 S_t 无法捕捉到明显的长尾特性，造成性能退化. 如果 m 选择过小，也可能无法有效捕捉到长尾特性，从而导致线性遗憾界[10].

3.4 定理简要证明

本节将概述上述定理的证明，首先给出定理的证明思路.

3.4.1 定理 3.1 的证明思路

为证明定理 Zhang 等[6, 定理 3] 的略图版本定理 3.1，FD 性质 3.1 与 3.2 至关重要：

性质 3.1

$$S_t S_t^\top \preceq S_{t-1} S_{t-1}^\top + \boldsymbol{x}_t \boldsymbol{x}_t^\top \preceq S_t S_t^\top + (\rho_t - \rho_{t-1}) I_d.$$

性质 3.2 (Kuzborskij 等[9] 引理 8) 对任意 $\lambda > 0, t > 0$,

$$\frac{\left|X_t X_t^\top + \lambda I_d\right|}{\left|\lambda I_d\right|} \leqslant \left(1 + \frac{\rho_t}{\lambda}\right)^d \left(1 + \frac{\operatorname{tr}(X_t X_t^\top)}{m(\rho_t + \lambda)}\right)^m.$$

接下来我们开始证明. 在算法 3 中，估计参数 W_t 的更新规则为

$$W_t := \operatorname*{argmin}_{W \in \mathcal{W}} \eta \tilde{\ell}_t(W) + \frac{1}{2} \left\| W - \overrightarrow{W}_{t-1} \right\|_{Z_{t-1}}^2.$$

与传统 OMD 不同的是，替代函数的近似部分是二次近似，而不是传统的线性近似. 即 $\tilde{\ell}_t(W)$ 是函数 $\ell_t(W)$ 在点 W_{t-1} 的二次近似

$$\tilde{\ell}_t(W) := \left\langle \nabla \ell_t(\overrightarrow{W}_{t-1}), \overrightarrow{W} - \overrightarrow{W}_{t-1} \right\rangle + \frac{1}{2} \left\| \overrightarrow{W} - \overrightarrow{W}_{t-1} \right\|_{\nabla^2 \ell_t(W_{t-1})}^2.$$

依此，根据 OMD 分析，可以得到以下不等式

$$\begin{aligned} \eta \left\langle \nabla \tilde{\ell}_t(\overrightarrow{W}_t), \overrightarrow{W}_t - \overrightarrow{W}_\star \right\rangle \leqslant & \frac{1}{2} \left\| \overrightarrow{W}_\star - \overrightarrow{W}_{t-1} \right\|_{Z_{t-1}}^2 - \frac{1}{2} \left\| \overrightarrow{W}_\star - \overrightarrow{W}_t \right\|_{Z_{t-1}}^2 \\ & - \frac{1}{2} \left\| \overrightarrow{W}_{t-1} - \overrightarrow{W}_t \right\|_{Z_{t-1}}^2. \end{aligned} \tag{3-5}$$

此外，根据 Jézéquel 等[24, 引理 4]，我们有

$$\ell_t(W_t) - \ell_t(W_\star) \leqslant \left\langle \nabla \ell_t(\overrightarrow{W}_t), \overrightarrow{W}_t - \overrightarrow{W}_\star \right\rangle - \frac{1}{2\eta} \left\| W_t - W_\star \right\|_{\nabla^2 \ell_t(W_t)}^2. \tag{3-6}$$

将不等式 (3-5) 和 (3-6) 相加起来，我们可以得到

$$\begin{aligned} & \frac{1}{2} \left\| \overrightarrow{W}_\star - \overrightarrow{W}_t \right\|_{Z_{t-1} + \nabla^2 \ell_t(W_t)}^2 - \frac{1}{2} \left\| \overrightarrow{W}_\star - \overrightarrow{W}_{t-1} \right\|_{Z_{t-1}}^2 + \frac{1}{2} \left\| \overrightarrow{W}_{t-1} - \overrightarrow{W}_t \right\|_{Z_{t-1}}^2 \\ \leqslant & \eta(\ell_t(W_\star) - \ell_t(W_t)) + \eta \left\langle \nabla \ell_t(\overrightarrow{W}_t) - \nabla \tilde{\ell}_t(\overrightarrow{W}_t), \overrightarrow{W}_t - \overrightarrow{W}_\star \right\rangle \end{aligned} \tag{3-7}$$

在不等式 (3-7) 中，根据 FD 性质 3.1，不等式左侧的第一项大于

$$\begin{aligned}\frac{1}{2}\left\|\overrightarrow{W_\star}-\overrightarrow{W_t}\right\|^2_{Z_{t-1}+\nabla^2\ell_t(W_t)} &= \frac{1}{2}\left\|\overrightarrow{W_\star}-\overrightarrow{W_t}\right\|^2_{\lambda I+S_{t-1}S_{t-1}^\top+\nabla^2\ell_t(W_t)}\\ &\geqslant \frac{1}{2}\left\|\overrightarrow{W_\star}-\overrightarrow{W_t}\right\|^2_{\lambda I+S_tS_t^\top}\\ &= \frac{1}{2}\left\|\overrightarrow{W_\star}-\overrightarrow{W_t}\right\|^2_{Z_t}\end{aligned} \tag{3-8}$$

而右侧第二项 $\left\langle\nabla\ell_t(\overrightarrow{W_t})-\nabla\tilde{\ell}_t(\overrightarrow{W_t}),\overrightarrow{W_t}-\overrightarrow{W_\star}\right\rangle$，根据 Zhang 等[6, 引理 12 公式 (34)]，$\tilde{\ell}_t(W)$ 是 $\ell_t(W)$ 的二阶近似，因此它是函数 $f(W)=\left\langle\nabla\ell_t(\overrightarrow{W}),\overrightarrow{W_t}-\overrightarrow{W_\star}\right\rangle$ 的泰勒展开二阶余项，那么可以利用 $\ell_t(W)$ 的 $\sqrt{6}$-自一致性求得上界：

$$\left\langle\nabla\ell_t(\overrightarrow{W_t})-\nabla\tilde{\ell}_t(\overrightarrow{W_t}),\overrightarrow{W_t}-\overrightarrow{W_\star}\right\rangle\leqslant\sqrt{6}LSD^2\left\|\overrightarrow{W_t}-\overrightarrow{W_{t-1}}\right\|_2^2. \tag{3-9}$$

最后不等式 (3-7) 的右侧的第一项 $\ell_t(W_\star)-\ell_t(W_t)$ 可以利用以下引理

引理 3.1 (Zhang 等[6] 引理 13，14) *如果 $\lambda\geqslant 2LD^2$，则对任意 $\delta\in(0,1)$，有至少 $1-\delta$ 的概率，以下不等式成立*

$$\begin{aligned}\forall t>0.\ \sum_{s=1}^t\ell_s(W_\star)-\ell_s(W_s)\leqslant\mathcal{O}\left((\ln K+\ln t)\ln\frac{t}{\delta}\right)+\frac{\sqrt{6}}{24Kd}\lambda\ln\frac{|\lambda/2I+X_tX_t^\top|}{|\lambda/2I|}\\ +\frac{12Kd}{\lambda}\sum_{s=1}^t\left\|\overrightarrow{W_{s-1}}-\overrightarrow{W_s}\right\|^2_{Z_{s-1}}.\end{aligned}$$

其中 $\ln\frac{|\lambda/2I+X_tX_t^\top|}{|\lambda/2I|}$ 项可以利用 FD 性质 3.2 求得上界．然后，我们调整参数 λ 使得以下三项相消

$$\frac{24\eta Kd}{\lambda}\sum_{s=1}^t\left\|\overrightarrow{W_{s-1}}-\overrightarrow{W_s}\right\|^2_{Z_{s-1}}+2\sqrt{6}\eta LSD^2\sum_{s=1}^t\left\|\overrightarrow{W_s}-\overrightarrow{W_{s-1}}\right\|_2^2-\sum_{s=1}^t\left\|\overrightarrow{W_s}-\overrightarrow{W_{s-1}}\right\|^2_{Z_{s-1}}\leqslant 0.$$

最后，将不等式 (3-8)、(3-9) 和引理 3.1 代入 (3-7)，并且将其从 $t=1,\cdots,T$ 求和，可以得到最终结果

$$\left\|\overrightarrow{W_t}-W_\star\right\|^2_{Z_t}\leqslant\left\|\overrightarrow{W_0}-W_\star\right\|^2_{Z_0}+\mathcal{O}\left(\ln K(\ln K+\ln t)\ln\frac{t}{\delta}\right)+\mathcal{O}(\Delta_t^\lambda(Kd\ln\Delta_t^\lambda+m\ln t))$$

$$= \mathcal{O}\left(\ln K(\ln K + \ln t)\left(\Delta_t^{\lambda}(Kd\ln\Delta_t^{\lambda} + m\ln t) + \ln\frac{1}{\delta}\right)\right).$$

3.4.2 定理 3.2 证明思路

首先，我们需要先对估计奖励 $\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_t\boldsymbol{x})$ 和真实奖励 $\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x})$ 之间的差异进行估计，不妨假设上界为 $\delta_t(\boldsymbol{x},\delta)$：

$$\Pr\left[\forall t>0.\ \left|\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}) - \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_t\boldsymbol{x})\right| \leqslant \delta_t(\boldsymbol{x},\delta)\right] \geqslant 1-\delta.$$

因此，我们对真实奖励有了乐观估计 $\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}) \leqslant \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_t\boldsymbol{x}) + \delta_t(\boldsymbol{x},\delta)$. 算法 3 利用乐观估计奖励 $\boldsymbol{x}_{t+1} := \operatorname{argmax}_{\boldsymbol{x}\in\mathcal{D}_t} r_t(\boldsymbol{x},\delta) = \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_t\boldsymbol{x}) + \delta_t(\boldsymbol{x},\delta)$ 进行决策. 而上述乐观估计上界 $\delta_t(\boldsymbol{x},\delta)$ 的存在性由下述引理保证

引理 3.2 对任意 $\delta\in(0,1)$，有至少 $1-\delta$ 的概率，以下不等式成立

$$\forall t>0.\ \left|\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}) - \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_t\boldsymbol{x})\right| \leqslant \delta_t(\boldsymbol{x},\delta) = \varepsilon_t^{\mathtt{fst}}(\boldsymbol{x},\delta) + \varepsilon_t^{\mathtt{snd}}(\boldsymbol{x},\delta),$$

其中

$$\varepsilon_t^{\mathtt{fst}}(\boldsymbol{x},\delta) = \sqrt{\beta_t(\delta)}\left\|(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x})\otimes\boldsymbol{x})\boldsymbol{\rho}\right\|_{Z_t^{-1}},$$

并且

$$\varepsilon_t^{\mathtt{snd}}(\boldsymbol{x},\delta) = \frac{\sqrt{K}}{2}R\beta_t(\delta)\left\|Z_t^{-1}(I\otimes\boldsymbol{x}\boldsymbol{x}^\top)\right\|_{2,2}.$$

推论 3.1 (Zhang 等[6] 命题 1) 对任意 $\delta\in(0,1)$，有至少 $1-\delta$ 的概率，以下不等式成立

$$\forall t>0.\ \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}) \leqslant r_t(\boldsymbol{x},\delta) = \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_t\boldsymbol{x}) + \delta_t(\boldsymbol{x},\delta).$$

那么算法的遗憾具有上界

$$\begin{aligned}
\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_\star) - \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_t) &\leqslant \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_\star) + \delta_{t-1}(\boldsymbol{x}_\star,\delta) - \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_t)\\
&\leqslant \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t) + \delta_{t-1}(\boldsymbol{x}_t,\delta) - \boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_t)\\
&\leqslant 2\delta_{t-1}(\boldsymbol{x}_t,\delta).
\end{aligned}$$

因此算法遗憾界的问题被归约为 $\sum_{t=1}^{T}\delta_{t-1}(\boldsymbol{x}_t,\delta)$ 的上界问题.

接下来的基本思路是利用泰勒定理（Taylor's Theorem），对估计奖励和真实奖励之差进行二阶展开

$$\begin{aligned}\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_t)-\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)=&\left(\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)\boldsymbol{\rho}\otimes\boldsymbol{x}_t\right)^\top(\overrightarrow{W_\star}-\overrightarrow{W_{t-1}})\\&+\frac{1}{2}(\overrightarrow{W_\star}-\overrightarrow{W_{t-1}})^\top(D^2\boldsymbol{\sigma}(\xi_1)[\boldsymbol{\rho}]\otimes\boldsymbol{x}_t\boldsymbol{x}_t^\top)(\overrightarrow{W_\star}-\overrightarrow{W_{t-1}})\end{aligned}$$

其中第一项可以继续对函数 $f(W)=\nabla\boldsymbol{\sigma}(W\boldsymbol{x}_t)$ 在点 W_t 应用泰勒定理

$$\begin{aligned}\left(\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)\boldsymbol{\rho}\otimes\boldsymbol{x}_t\right)^\top(\overrightarrow{W_\star}-\overrightarrow{W_{t-1}})=&(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\boldsymbol{\rho})^\top\left(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t\right)^\top(\overrightarrow{W_\star}-\overrightarrow{W_{t-1}})\\&+\frac{1}{2}(\overrightarrow{W_{t-1}}-\overrightarrow{W_t})^\top\left(D^2\boldsymbol{\sigma}(\xi_2)[\boldsymbol{\rho}]\otimes\boldsymbol{x}_t\boldsymbol{x}_t^\top\right)(\overrightarrow{W_\star}-\overrightarrow{W_{t-1}})\end{aligned}$$

对上述等式取绝对值,并利用绝对值不等式和柯西施瓦兹不等式(Chachy-Schwarzi Inequality)，我们可以得到

$$\begin{aligned}&\left|\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_t)-\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)\right|\\\leqslant&\left\|\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\boldsymbol{\rho}\right\|_2\left\|\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t\right\|_{2,Z_{t-1}^{-1}}\left\|\overrightarrow{W_\star}-\overrightarrow{W_{t-1}}\right\|_{Z_{t-1}}\\&+\frac{1}{2}\left\|\overrightarrow{W_{t-1}}-\overrightarrow{W_t}\right\|_{Z_{t-1}}\left\|Z_{t-1}^{-1}(D^2\boldsymbol{\sigma}(\xi_2)[\boldsymbol{\rho}]\otimes\boldsymbol{x}_t\boldsymbol{x}_t^\top)\right\|_{2,2}\left\|\overrightarrow{W_\star}-\overrightarrow{W_{t-1}}\right\|_{Z_{t-1}}\\&+\frac{1}{2}\left\|\overrightarrow{W_\star}-\overrightarrow{W_{t-1}}\right\|_{Z_{t-1}}\left\|Z_{t-1}^{-1}(D^2\boldsymbol{\sigma}(\xi_1)[\boldsymbol{\rho}]\otimes\boldsymbol{x}_t\boldsymbol{x}_t^\top)\right\|_{2,2}\left\|\overrightarrow{W_\star}-\overrightarrow{W_{t-1}}\right\|_{Z_{t-1}}\end{aligned}$$

其中,$\left\|\overrightarrow{W_\star}-\overrightarrow{W_{t-1}}\right\|_{Z_{t-1}}$ 可以根据定理 3.1 大概率具有上界 $\sqrt{\beta_{t-1}(\delta)}$,$\left\|\overrightarrow{W_{t-1}}-\overrightarrow{W_t}\right\|_{Z_{t-1}}$ 则根据 OMD 的 stability term 分析,具有上界 $\left\|\nabla\ell_t(W_{t-1})\right\|_{Z_{t-1}^{-1}}\leqslant 2\eta D/\lambda$(引理 B.1),而 $\|\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\boldsymbol{\rho}\|_2$ 则根据假设不大于 R.

将上述不等式从 $t=1,\cdots,T$ 求和

$$\begin{aligned}\mathrm{Regret}(T)=&\sum_{t=1}^{T}\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_\star)-\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_t)\\\leqslant&\,2\sum_{t=1}^{T}\delta_{t-1}(\boldsymbol{x}_t,\delta)\\\leqslant&\,2R\sqrt{\beta_T(\delta)}\sum_{t=1}^{T}\left\|\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t\right\|_{2,Z_{t-1}^{-1}}\end{aligned}$$

$$
\begin{aligned}
&+ \frac{4\eta D}{\lambda}\sqrt{\beta_T(\delta)}\sum_{t=1}^{T}\left\|Z_{t-1}^{-1}(D^2\boldsymbol{\sigma}(\xi_2)[\boldsymbol{\rho}]\otimes \boldsymbol{x}_t\boldsymbol{x}_t^\top)\right\|_{2,2}\\
&+ \beta_T(\delta)\sum_{t=1}^{T}\left\|Z_{t-1}^{-1}(D^2\boldsymbol{\sigma}(\xi_1)[\boldsymbol{\rho}]\otimes \boldsymbol{x}_t\boldsymbol{x}_t^\top)\right\|_{2,2}
\end{aligned}
$$

而第一项中的 $\sum_{t=1}^{T}\left\|\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes \boldsymbol{x}_t\right\|_{2,Z_{t-1}^{-1}}$ 可以利用算数-平方均值不等式（Arithmetic-Mean and Quadric-Mean Inequality，AM-QM）和引理 B.5 进行界定．而第二第三项中的 $\left\|Z_{t-1}^{-1}(D^2\boldsymbol{\sigma}(\xi)[\boldsymbol{\rho}]\otimes \boldsymbol{x}_t\boldsymbol{x}_t^\top)\right\|_{2,2}$ 可以利用 $-\|\boldsymbol{\rho}\|_1 I \preceq D^2\boldsymbol{\sigma}(\xi)[\boldsymbol{\rho}] \preceq \frac{1}{2}\|\boldsymbol{\rho}\|_1 I$ 和引理 B.6 进行界定

$$
\begin{aligned}
\sum_{t=1}^{T}\left\|\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes \boldsymbol{x}_t\right\|_{2,Z_{t-1}^{-1}} &\leqslant \sqrt{T}\sqrt{\sum_{t=1}^{T}\operatorname{tr}\left(Z_{t-1}^{-1}\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)\otimes \boldsymbol{x}_t\boldsymbol{x}_t^\top\right)}\\
&= \tilde{\mathcal{O}}\left(\sqrt{\Delta_T^{\lambda}(Kd\ln\Delta_T^{\lambda}+m)}\sqrt{T}\right)\\
\sum_{t=1}^{T}\left\|Z_{t-1}^{-1}(D^2\boldsymbol{\sigma}(\xi)[\boldsymbol{\rho}]\otimes \boldsymbol{x}_t\boldsymbol{x}_t^\top)\right\|_{2,2} &\leqslant \|\boldsymbol{\rho}\|_1\sum_{t=1}^{T}\operatorname{tr}\left(Z_{t-1}^{-1}(I_K\otimes \boldsymbol{x}_t\boldsymbol{x}_t^\top)\right)\\
&= \tilde{\mathcal{O}}\left(\kappa\Delta_T^{\lambda}(Kd\ln\Delta_T^{\lambda}+m)\right)
\end{aligned}
$$

因此，遗憾的上界得证

定理 3.3 的证明思路与定理 3.2 类似.

第四章　实验验证

在本章中，为了验证提出算法的有效性，本文将通过实验验证其计算效率和遗憾增长. 首先，本文将使用随机生成数据进行实验，并展示实验结果结果；然后本文将使用随机实验的数据，验证第 3.3 节提及的 $\{(W_t, \boldsymbol{x}_t) \mid t = 1, \cdots, T\}$ 分布规律；最后，本文将使用真实数据集进行实验，增加数据的多样性.

4.1　使用随机生成的数据进行实验

实验设置　首先遵照 Zhang 等[6] 的设置，我们将进行 10 次实验，每次实验的真实参数 $W_\star$ 均随机生成，每次实验进行 $T = 4000$ 轮迭代. 最后我们将汇报 10 次实验的综合结果. 具体设置如下：每次迭代中，环境将从半径 $D = 1$ 的球面上随机均匀采样 $|\mathcal{D}_t| = 20$ 个点作为决策集. 而在二元（$K = 1$）情况下，设置真实参数的模长设置为 $S = 5$；而在多元（$K = 4$）情况下，设置真实参数模长为 $S = 4$，而奖励向量被设置为 $\boldsymbol{\rho} = [0.25, 0.5, 0.75, 1]$. 与 Zhang 等[6] 的设置不同的是，我们将多元情况下我们设置上下文向量为 $d = 50$，二元情况下设置上下文向量为 $d = 200$，以模拟高维情况.

至于超参数，我们根据 Zhang 等[6] 推荐的参数设置 $\lambda_0 = \sqrt{K}\alpha S, \eta_0 = S/2 + \ln(K+1)/4$，并结合实际情况进行微调：在集合 $\{0.5\lambda_0, \lambda_0, 2\lambda_0, 4\lambda_0, 8\lambda_0, 16\lambda_0\} \times \{0.5\eta_0, \eta_0, 2\eta_0, 4\eta_0\}$ 中进行尝试，选择比较适合的参数组合 $(\lambda, \eta) = (16\lambda_0, 2\eta_0)$. 而置信度则设定为 $\delta = 0.1$. 而为了寻找合适的略图大小 m，我们先运行了一次上述相同设置的原算法，将选择的动作 $\{(W_t, \boldsymbol{x}_t) \mid t = 1, \cdots, T\}$ 全部收集，并进行 PCA 降维. 多次实验，选择合适的、能至少保持 90% 信息的 $m = 7$.

实验结果　最终实验结果如图 4-1 和图 4-2 所示.以图 4-1(a) 为例，标有 `sketch` 的曲线表示使用 FD 技术的算法，而标有 `non-sketch` 的曲线表示原算法. 10 次实验的平均遗憾值均在图中以实线展示，而标准差范围则以相应颜色的阴影展示. 图 4-1(b) 中柱形图上方的黑色误差线表示标准差的范围.

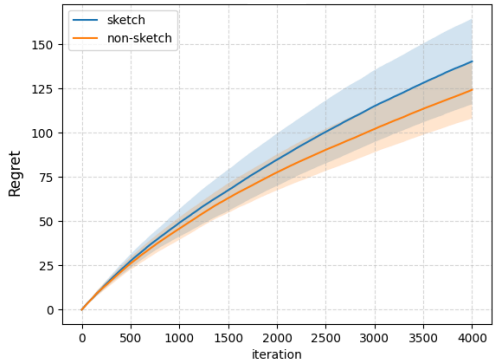

(a) 平均累计遗憾比较

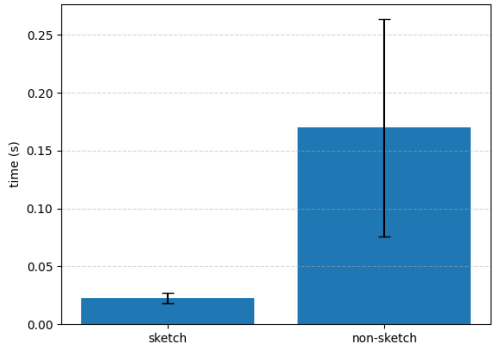

(b) 平均单轮计算时间比较

图 4-1　FD 技术在多项情况的比较

与原算法比较，应用 FD 技术的算法所消耗的时间减少了约 45% 以上，这是因为 FD 技术的引入让与费希尔信息矩阵相关的计算复杂度降低了．但为了适配 FD 技术，算法中需要增加一些额外的计算，加上由于设备限制，该次实验的维度没有设置得足够高，让 FD 技术节省时间的优势并没有完全体现．而另一方面，就实验而言，FD 技术引入并没有显著影响算法的性能，原算法的遗憾值并没有比应用 FD 技术的算法低很多．在这两个实验中，应用 FD 算法的平均遗憾值仅仅较原算法增长了不到 10% 左右．

相比二元情况，多项情况下 FD 的加速效果更加明显．这是因为，在多项情况，使用乐观奖励的二阶近似，因此会消耗三次方的计算复杂度；而在二元情况，使用原乐观奖励，因此会消耗平方的计算复杂度．这导致了在多项情况，原算法的计算复杂度远高于二元情况．应用 FD 技术后，算法单轮计算复杂度均为一次，因此 FD 技术的加速效果在多项情况中更为明显，

决策集固定不变的实验　在上述实验中，决策集 $\mathcal{D}_t$ 在每次迭代中都是随机生成的，因此 $\mathcal{D}_t$ 的具有随机性．而在实际应用中，决策集 $\mathcal{D}_t$ 可能是固定不变的．因此在这次实验中，我们进行如下特殊实验：每次实验开始，环境先从半径 $D = 1$ 的球面上随机均匀采样 $|\mathcal{D}| = 20$ 个点作为决策集 $\mathcal{D}$，然后在每次迭代中，$\mathcal{D}_t = \mathcal{D}$ 都保持不变，而反馈为二元的情况．剩余的实验设置与前述相同．

实验结果如图 4-3 所示．可以看出，FD 技术的引入并没有显著影响算法的性能，甚至在某些实验中，应用 FD 技术的算法的遗憾值低于原算法．而且算法的计算时间也相应减少．

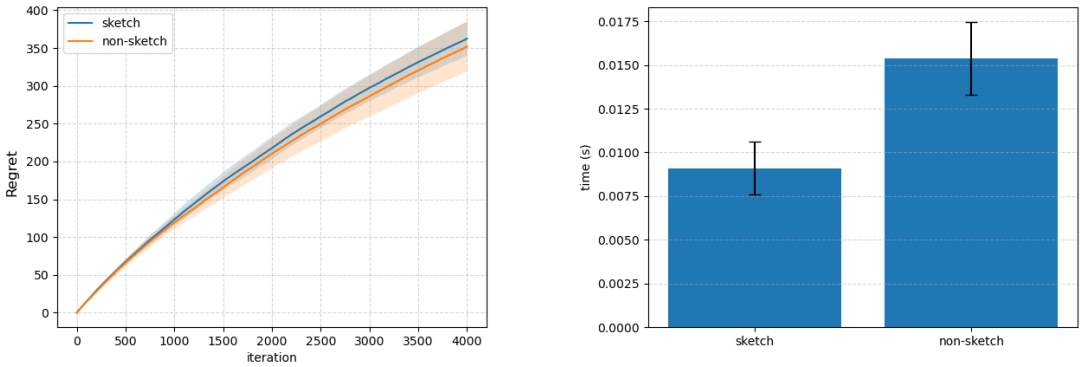

(a) 平均累计遗憾比较　　(b) 平均单轮计算时间比较

图 4-2　FD 技术在二元情况的比较

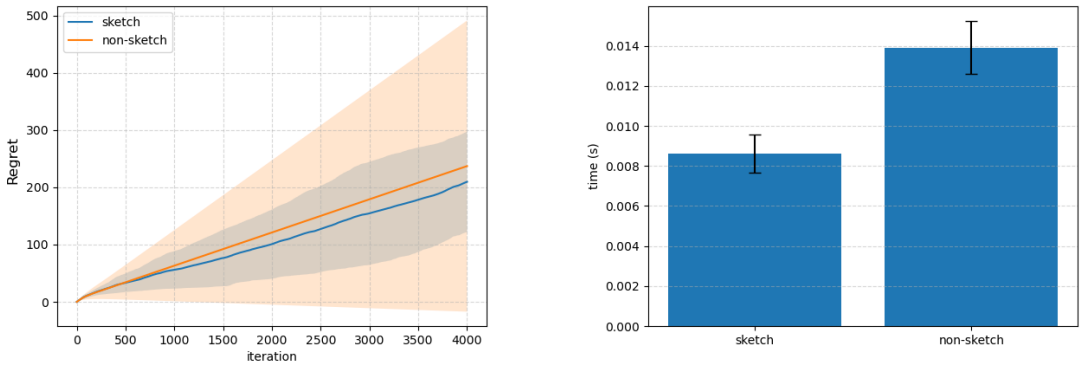

(a) 平均累计遗憾比较　　(b) 平均单轮计算时间比较

图 4-3　FD 技术在固定决策集上的比较

4.2　动作分布的实验

我们选取两次应用 FD 技术的实验，将所有的动作 $\{(W_t, \boldsymbol{x}_t) \mid t = 1, \cdots, T\}$ 收集，对每迭代 1000 轮的历史费希尔信息矩阵进行特征值分解，得到谱分布如图 4-1 所示．为了便于观察，图中横坐标进行了 $\log_{10}$ 对数变换．

可以看出，在实验开始阶段（$t = 20$），实验谱分布的较为均匀；而随着迭代的进行（$t = 1000 - 2000$），谱分布逐渐变得不均匀，大部分特征值都集中在某些特定的值上．实验后期（$t = 3000 - 4000$），谱分布呈现较为明显的长尾特征．两图 4-4 (a) 和 (b) 对比，可以看出，理想的谱分布（图 4-4 (a)）呈现了长尾分布的特征，而噪声较大的谱分布（图 4-4 (b)）虽然没有呈现明显的长尾分布，但大部分特征值仍然集中在某些特定的值上．

这是因为在实验开始阶段，算法对动作的选择是均匀的，因此所有动作的谱

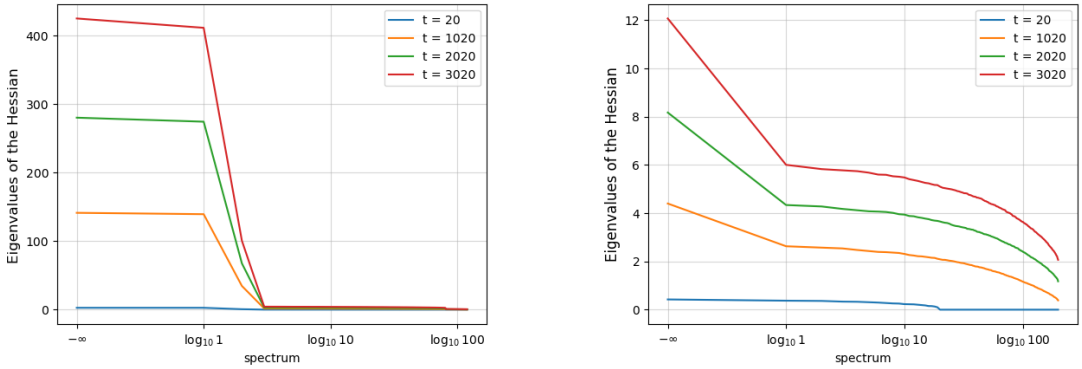

(a) 理想的谱分布　　(b) 噪声较大的谱分布

图 4-4　选择动作的谱分布分布：为了便于观察，图中横坐标进行了 $\log_{10}$ 对数变换

分布都较为均匀；而随着迭代的进行，算法对动作的选择逐渐变得不均匀：算法逐渐习得环境的真实参数，会更偏好选择某些动作，而对其他动作的选择则会逐渐减少．因此，算法对动作的选择逐渐变得不均匀，导致谱分布逐渐变得不均匀．而图 4-4 (b) 却没有完全呈现长尾分布的特征，这可能是因为模型的参数设置不够好，导致算法未能完全习得环境的真实参数，导致实验后期仍然在持续探索环境；或者可能是决策集 $\mathcal{D}_t$ 变动过大．

4.3　在真实数据集上的实验

我们模仿 Cesa-Bianchi 等[25] 的实验设置，将 K 分类任务改造成适合老虎机问题的设置．

实验设置　给定一个 K 分类的数据集 $\left\{(\boldsymbol{x}_i, y_i) \,\middle|\, \boldsymbol{x}_i \in \mathbb{R}^d, y_i \in [K], i = 1, \cdots, m\right\}$，我们设定一个二元老虎机问题：环境将数据集按照标记 y_i 划分为 K 个子集 $X_1, \cdots, X_K$，标记相同的数据点 $\boldsymbol{x}_i$ 被划分到同一个子集 X_{y_i} 中．在每次迭代中，环境从每个子集中随机选择一个样本，构成决策集合 $\mathcal{D}_t = \{\boldsymbol{x}_1, \cdots, \boldsymbol{x}_K\}$．给定一个目标类 $y_\star \in [K]$，算法需要根据内部的学习器，从决策集合 $\mathcal{D}_t$ 中选出标记为 $y_\star$ 的动作 $\boldsymbol{x}_t$．如果算法选择的动作 $\boldsymbol{x}_t$ 的标记 $y_t = y_\star$，获得反馈 $r(\boldsymbol{x}_t) = 1$；否则，反馈为 $r(\boldsymbol{x}_t) = 0$．算法的目标是尽可能从 $\mathcal{D}_t$ 中选择标记为 $y_\star$ 的动作．

我们使用 MNIST 手写数字识别数据集进行实验，特征向量是 28×28 的灰度图像，标记为 0 到 9 的数字．我们将图像展平为 $d = 784$ 维的向量，并归一化

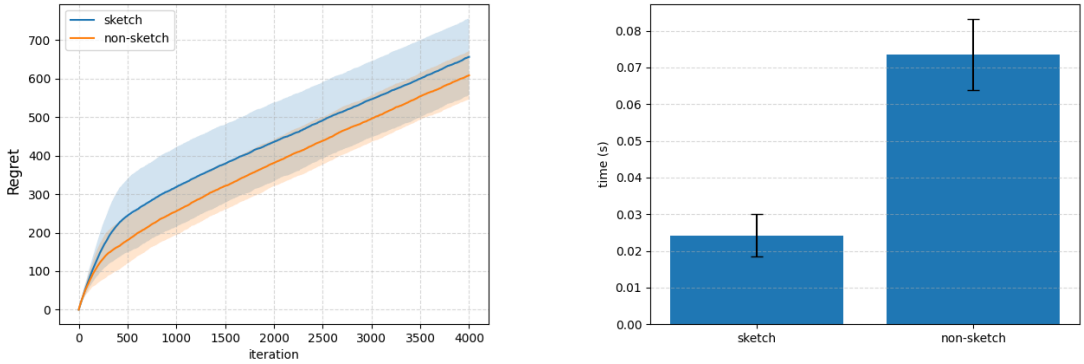

(a) 平均累计遗憾比较　　(b) 平均单轮计算时间比较

图 4-5　MNIST 数据集上的实验结果

到模长 $D = 0.5$，作为特征向量．我们选择 $y_\star = 2$ 作为目标类，并假设真实参数 $W_\star$ 是一个 $1 \times K$ 的矩阵，其范数 $\|W_\star\|_F = S = 10$．至于略图大小，我们对数据集进行 PCA 降维，据此选择 $m = 70$，这大约能保留 62% 的所有图像信息，和 87% 的数字 “2” 图像信息．最后，经过如前 4.1 节所述的超参数微调，我们选择 $(\lambda, \eta, \delta) = (31.7, 6.3, 0.1)$.

实验结果　如前 4.1 节，一共进行 10 次实验，每次实验进行 $T = 4000$ 轮迭代，最终综合结果如图 4-5 所示．可以发现，虽然 FD 算法导致了遗憾值的增长，但其收敛速度和增长幅度是可控的，而在本文的实验中，应用 FD 算法的平均遗憾值的增长不超过 9%．而由于 FD 技术的引入，算法的计算时间减少了约 50%．而相比 4.1 节的实验，FD 技术的加速效果更加明显，这得益于特征向量维度 d 的增加.

第五章　结论

本文的主要贡献在于将频繁方向技术应用到 OFUL-MLogB 算法中，在保证算法性能不受太大影响的前提下，计算效率得到了显著提升. 算法收敛时，选择动作 $(W_t, \boldsymbol{x}_t)$ 具有高度结构性. 本文利用了这个特点，使用频繁方向技术对历史费希尔信息矩阵进行压缩降维，达到了较高的压缩比率，使得在多项的情况下单轮更新复杂度从 $\mathcal{O}(|\mathcal{D}|K^3d^3)$ 降低到 $\mathcal{O}(|\mathcal{D}|dm^2K^2)$. 而在二元的情况下，由于使用的是乐观奖励的原函数，因此单轮更新复杂度从 $\mathcal{O}(|\mathcal{D}|d^2 + d^3)$ 降低到 $\mathcal{O}(|\mathcal{D}|dm^2)$. 在提高算法效率的同时，本文还保持了算法的亚优性. 在多项的情况下，算法的遗憾界为 $\tilde{\mathcal{O}}\left((1+\rho_T/\lambda)Kd\sqrt{T}\right)$，而在二元的情况下，算法的遗憾界为 $\tilde{\mathcal{O}}\left((1+\rho_T/\lambda)d\sqrt{T/\kappa_*}\right)$. 最后通过实验验证了本文提出的算法在实际应用中的有效性：一般情况下，如果决策集 $\mathcal{D}_t$ 变动不大，则 FD 算法能有效捕捉到主要信息，从而有效控制谱残差 ρ_T 的增长；在决策集 $\mathcal{D}_t$ 固定不变的情况下，如果 m 大于 $|\mathcal{D}|$，则可以达到最优的收敛速度.

尽管本文的研究取得了一定的进展，但仍然存在一些局限性. 首先，超参数 m 的选择对算法的性能和鲁棒性有较大影响，且依赖于对数据集的先验知识和算法特性的了解. 其次，本文的实验主要集中在随机生成的数据集上，实际数据的实验较少. 未来可以考虑研究超参数 m 对算法实际性能（如遗憾值、计算时间和鲁棒性）的影响，并研究如何在实际应用中自适应地选择合适的 m 值. 此外，对实际应用中的性能提升和存储提升的研究仍需更多实验验证，还需在更多实际应用场景中验证算法的有效性和鲁棒性.

参考文献

[1] Lattimore T, Szepesvári C. Bandit Algorithms[M]. 2020: 238-240.

[2] Li L, Chu W, Langford J, et al. A Contextual-bandit Approach to Personalized News Article Recommendation[C]//Proceedings of the 19th International Conference on World Wide Web. 2010: 661-670.

[3] Bubeck S, Cesa-Bianchi N. Regret Analysis of Stochastic and Nonstochastic Multi-armed Bandit Problems[J]. Foundations and Trends® in Machine Learning, 2012, 5(1): 1-122.

[4] Tewari A, Murphy S A. From Ads to Interventions: Contextual Bandits in Mobile Health[G]//Mobile Health: Sensors, Analytic Methods, and Applications. 2017: 495-517.

[5] Amani S, Thrampoulidis C. UCB-based Algorithms for Multinomial Logistic Regression Bandits[C]//Advances in Neural Information Processing Systems: vol. 34. 2021: 2913-2924.

[6] Zhang Y J, Sugiyama M. Online (Multinomial) Logistic Bandit: Improved Regret and Constant Computation Cost[C]//Advances in Neural Information Processing Systems: vol. 36. 2023: 29741-29782.

[7] Agrawal S, Avadhanula V, Goyal V, et al. Thompson Sampling for the MNL-Bandit[C]//Proceedings of the 30th Conference on Learning Theory. 2017: 76-78.

[8] Ghashami M, Liberty E, Phillips J M, et al. Frequent Directions: Simple and Deterministic Matrix Sketching[J]. SIAM Journal on Computing, 2016, 45(5): 1762-1792.

[9] Kuzborskij I, Cella L, Cesa-Bianchi N. Efficient Linear Bandits through Matrix

Sketching[C]//Proceedings of the 22nd International Conference on Artificial Intelligence and Statistics. 2019: 177-185.

[10] Wen D, Yin H, Zhang X, et al. Matrix Sketching in Bandits: Current Pitfalls and New Framework[Z/OL]. 2024. arXiv: 2410.10258.

[11] Thompson W R. On the Likelihood that One Unknown Probability Exceeds Another in View of the Evidence of Two Samples[J]. Biometrika, 1933, 25(3–4): 285-294.

[12] Auer P, Cesa-Bianchi N, Fischer P. Finite-time Analysis of the Multiarmed Bandit Problem[J]. Machine Learning, 2002, 47: 235-256.

[13] Auer P. Using Confidence Bounds for Exploitation-Exploration Trade-offs[J]. Journal of Machine Learning Research, 2003, 3: 397-422.

[14] Abbasi-yadkori Y, Pál D, Szepesvári C. Improved Algorithms for Linear Stochastic Bandits[C]//Advances in Neural Information Processing Systems: vol. 24. 2011: 2312-2320.

[15] Zhang L, Yang T, Jin R, et al. Online Stochastic Linear Optimization under One-bit Feedback[C]//Proceedings of the 33rd International Conference on Machine Learning. 2016: 392-401.

[16] Abeille M, Faury L, Calauzenes C. Instance-Wise Minimax-Optimal Algorithms for Logistic Bandits[C]//Proceedings of the 24th International Conference on Artificial Intelligence and Statistics. 2021: 3691-3699.

[17] Faury L, Abeille M, Jun K S, et al. Jointly Efficient and Optimal Algorithms for Logistic Bandits[C]//Proceedings of the 25th International Conference on Artificial Intelligence and Statistics. 2022: 546-580.

[18] Liberty E. Simple and Deterministic Matrix Sketching[C]//Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2013: 581-588.

[19] Gu M, Eisenstat S C. A Stable and Efficient Algorithm for the Rank-One Modification of the Symmetric Eigenproblem[J]. SIAM Journal on Matrix

Analysis and Applications, 1994, 15(4): 1266-1276.

[20] Chen C, Luo L, Zhang W, et al. Efficient and Robust High-Dimensional Linear Contextual Bandits[C]//Proceedings of the 29th International Joint Conference on Artificial Intelligence. 2020: 4259-4265.

[21] Dani V, Hayes T P, Kakade S M. Stochastic Linear Optimization under Bandit Feedback[C]//Proceedings of the 21st Annual Conference on Learning Theory. 2008: 355-366.

[22] Mhammedi Z, Koolen W M. Lipschitz and Comparator-Norm Adaptivity in Online Learning[C]//Proceedings of the 33rd Conference on Learning Theory. 2020: 2858-2887.

[23] Abbasi-Yadkori Y, Pal D, Szepesvari C. Online-to-Confidence-Set Conversions and Application to Sparse Stochastic Bandits[C]//Proceedings of the 15th International Conference on Artificial Intelligence and Statistics. 2012: 1-9.

[24] Jézéquel R, Gaillard P, Rudi A. Mixability Made Efficient: Fast Online Multiclass Logistic Regression[C]//Advances in Neural Information Processing Systems: vol. 34. 2021: 23692-23702.

[25] Cesa-Bianchi N, Gentile C, Zappella G. A Gang of Bandits[C]//Advances in Neural Information Processing Systems: vol. 26. 2013: 737-745.

[26] Tran-Dinh Q, Li Y H, Cevher V. Composite Convex Minimization Involving Self-concordant-Like Cost Functions[C]//Proceedings of the 3rd International Conference on Modelling, Computation and Optimization in Information Systems and Management Sciences. 2015: 155-168.

致　谢

在本论文完成之际，我谨向所有给予我帮助和支持的人表示衷心的感谢.

首先，我特别感谢我的导师**张利军**教授，从选题到写作，指导开题报告，教我基本的文献检索方法，他的严谨的治学态度和专业知识让我受益匪浅. 感谢他在整个研究过程中给予了我悉心指导和宝贵建议.

同时，我要感谢**邱梓豪**博士和**张宇杰**博士，邱博士在论文写作方面给予了无微不至的指导，帮助我打磨行文用词和篇幅结构；而张博士则指导我的阅读文献和进行实验，帮助我理解专业知识和相关方法的重点和难点，并指导我进行实验设计和结果分析. 非常感谢他们在研究过程中给予了我很多帮助和支持.

然后，感谢我的朋友，他在我写作遇到困难时，听我倾诉烦恼，给予了我很多安慰和鼓励. 感谢父母一直以来的理解与支持.

最后，感谢 LUG@NJU 提供的简便易用的 LaTeX 论文模板 `njuthesis`，使我的写作过程变得十分方便.

附录 A　FD 性质

本章中，我们提供了 FD 算法 2 的性质和一些必要的证明.

性质 A.1

$$S_t S_t^\top + (\rho_t - \rho_{t-1}) I_{\mathcal{U}} = S_{t-1} S_{t-1}^\top + \boldsymbol{x}_t \boldsymbol{x}_t^\top$$

对于某个维度小于 $m+1$ 的子空间 $\mathcal{U}$ 成立. 特别地，$I_{\mathcal{U}} = U_t U_t^\top$.

证明 根据算法 2 的第 4 行和 5–7 行，我们有如下关系

$$\hat{S}_t \hat{S}_t^\top = S_{t-1} S_{t-1}^\top + \boldsymbol{x}_t \boldsymbol{x}_t^\top,$$

并且

$$S_t S_t^\top = U_t \Sigma_t^2 U_t^\top - (\Sigma_t)_{m+1} U_t U_t^\top = \hat{S}_t \hat{S}_t^\top - (\rho_t - \rho_{t-1}) U_t U_t^\top.$$

将上述两个等式相加

$$S_t S_t^\top + (\rho_t - \rho_{t-1}) U_t U_t^\top = S_{t-1} S_{t-1}^\top + \boldsymbol{x}_t \boldsymbol{x}_t^\top.$$

因此，子空间 $\mathcal{U}_t := \operatorname{span}\left\{ U_{t1}, U_{t2}, \cdots, U_{t(m+1)} \right\}$,

$$U_t U_t^\top = I_{\mathcal{U}_t},$$

命题得证. □

FD 性质 3.1 的证明

证明 对任意 $\boldsymbol{x} \in \mathbb{R}^d$，我们有一下分解

$$\boldsymbol{x} = \boldsymbol{u} + \boldsymbol{u}_\perp, \boldsymbol{u} \in \mathcal{U}, \boldsymbol{u}_\perp \in \mathcal{U}^\perp.$$

因此

$$0 \leqslant \|\boldsymbol{u}\|_2^2 \leqslant \|\boldsymbol{u}\|_2^2 + \left\|\boldsymbol{u}_\perp\right\|_2^2.$$

即

$$0 \leqslant (\boldsymbol{u}+\boldsymbol{u}_\perp)^\top UU^\top(\boldsymbol{u}+\boldsymbol{u}_\perp) = (\boldsymbol{u}+\boldsymbol{u}_\perp)^\top I_{\mathcal{U}}(\boldsymbol{u}+\boldsymbol{u}_\perp) \leqslant (\boldsymbol{u}+\boldsymbol{u}_\perp)^\top I_d(\boldsymbol{u}+\boldsymbol{u}_\perp),$$

这意味着

$$0 \preceq I_{\mathcal{U}} \preceq I_d.$$

根据性质 *A.1* 和等式 $\rho_t - \rho_{t-1} = \Sigma_{m+1}$，我们有

$$S_tS_t^\top \preceq S_tS_t^\top + (\rho_t - \rho_{t-1})I_{\mathcal{U}} = S_{t-1}S_{t-1}^\top + \boldsymbol{x}_t\boldsymbol{x}_t^\top \preceq S_tS_t^\top + (\rho_t - \rho_{t-1})I_d. \qquad \square$$

性质 A.2 (Ghashami 等[8] 性质 1, 2)

$$X_tX_t^\top - \rho_t I_d \preceq S_tS_t^\top \preceq X_tX_t^\top$$

性质 A.3 对任意 $\lambda > 0$,

$$S_tS_t^\top + \lambda I_d \preceq X_tX_t^\top + \lambda I_d \preceq \left(1 + \frac{\rho_t}{\lambda}\right)\left(S_tS_t^\top + \lambda I_d\right)$$

证明 我们遵循 *Kuzborskij* 等[9] 中引理 *9* 的主要思路. 根据性质 *A.2*的第二个不等式，该命题的第一个不等式可以很容易地得到证明.

关于第二个不等式，令 $(\lambda_i, \boldsymbol{v}_i)$ 为矩阵 $S_tS_t^\top + \lambda I_d$ 第 i 个特征对，则我们有分解

$$S_tS_t^\top + \lambda I_d = \sum_{i=1}^{d}(\lambda_i + \lambda)\boldsymbol{v}_i\boldsymbol{v}_i^\top.$$

而根据性质 *A.2* 的第一个不等式

$$X_tX_t^\top \preceq S_tS_t^\top + \rho_t I_d = \sum_{i=1}^{d}(\lambda_i + \lambda + \rho_t)\boldsymbol{v}_i\boldsymbol{v}_i^\top.$$

因此

$$
\begin{aligned}
&(S_tS_t^\top+\lambda I_d)^{-\frac{1}{2}}(X_tX_t^\top+\lambda I_d)(S_tS_t^\top+\lambda I_d)^{-\frac{1}{2}}\\
\preceq&(S_tS_t^\top+\lambda I_d)^{-\frac{1}{2}}(S_tS_t^\top+(\rho_t+\lambda)I_d)(S_tS_t^\top+\lambda I_d)^{-\frac{1}{2}}\\
\preceq&\sum_{t=1}^{d}\frac{\lambda_i+\lambda+\rho_t}{\lambda_i+\lambda}\boldsymbol{v}_i\boldsymbol{v}_i^\top\\
\preceq&\sum_{t=1}^{d}\frac{\lambda+\rho_t}{\lambda}\boldsymbol{v}_i\boldsymbol{v}_i^\top=\frac{\lambda+\rho_t}{\lambda}\boldsymbol{I}
\end{aligned}
$$

左乘和右乘 $(S_tS_t^\top+\lambda I_d)^{\frac{1}{2}}$

$$
X_tX_t^\top+\lambda I_d\preceq\left(1+\frac{\rho_t}{\lambda}\right)(S_tS_t^\top+\lambda I_d)
$$

□

性质 A.4 (Kuzborskij 等[9] 引理 8) 对任意 $\lambda>0,t>0$,

$$
\frac{\left|X_tX_t^\top+\lambda I_d\right|}{\left|\lambda I_d\right|}\leqslant\left(1+\frac{\rho_t}{\lambda}\right)^d\left(1+\frac{\operatorname{tr}(X_tX_t^\top)}{m(\rho_t+\lambda)}\right)^m.
$$

性质 A.5 (Ghashami 等[8] 定理 1.1)

$$
\left\|X_tX_t^\top-S_tS_t^\top\right\|_{2,2}\leqslant\rho_t,
$$

并且

$$
\frac{1}{m}\left\|X_t-(X_t)_{(m)}\right\|_F^2\leqslant\rho_t\leqslant\min_{n<m}\frac{1}{m-n}\left\|X_t-(X_t)_{(n)}\right\|_F^2,
$$

其中 $(X_t)_{(n)}$ 是矩阵 X_t 的 n 秩最佳近似.

附录 B　第三章定理的证明

本章将详细证明定理 3.1、定理 3.2 和定理 3.3. 首先，我们先对本文所使用的对率函数 $\boldsymbol{\sigma}(z)$ 进行一些必要的说明.

为什么忽略了 $\boldsymbol{\sigma}(z)$ 的第零维

由于 $\boldsymbol{\sigma}(z) = \mathrm{softmax}(Gz)$，其中 $G = [0, I]^\top$，$\boldsymbol{\sigma}(z)$ 的一阶导数为

$$\nabla\boldsymbol{\sigma}(z) = \left(\mathrm{diag}\,\{\,\boldsymbol{\sigma}(z)\,\} - \boldsymbol{\sigma}(z)\boldsymbol{\sigma}(z)^\top\right) G.$$

但在第三节中,我们假设 $\boldsymbol{\rho}$ 的第 0 个分量为 0,因此 $\sum_{k=0}^{K} \rho_k \sigma_k(W\boldsymbol{x}) = \sum_{k=1}^{K} \rho_k \sigma_k(W\boldsymbol{x})$，那么 $\boldsymbol{\sigma}(z)$ 的第 0 个分量不会出现在遗憾分析中.

而且，在置信域的分析中，函数 $\boldsymbol{\sigma}(z)$ 只会出现在熵损失函数的梯度中

$$\begin{aligned}
\nabla\ell_t(W) &= (\boldsymbol{\sigma}(W\boldsymbol{x}_t) - \boldsymbol{y}_t)G \otimes \boldsymbol{x}_t \\
\nabla^2\ell_t(W) &= G^\top(\mathrm{diag}\left\{\,\boldsymbol{\sigma}(W\boldsymbol{x}_t)\,\right\} - \boldsymbol{\sigma}(W\boldsymbol{x}_t)\boldsymbol{\sigma}(W\boldsymbol{x}_t)^\top)G \otimes \boldsymbol{x}_t
\end{aligned}$$

可以发现，上述表达式都与 $\boldsymbol{\sigma}(z)$ 的第 0 个分量无关. 那么我们可以直接忽略 $\boldsymbol{\sigma}(z)$ 的第 0 个分量，仅考虑第 1 到第 K 个分量. 因此我们可以认为

$$\nabla\boldsymbol{\sigma}(z) = \mathrm{diag}\,\{\,\boldsymbol{\sigma}(z)\,\} - \boldsymbol{\sigma}(z)\boldsymbol{\sigma}(z)^\top.$$

但这也会导致 $\sum_{k=1}^{K} \sigma_k(z) < 1$.

关于上下界 L 和 κ 的一些讨论

一方面，$\lambda_{\max}(\nabla\boldsymbol{\sigma}(z))$ 有上界

$$\begin{aligned}\lambda_{\max}(\nabla\boldsymbol{\sigma}(z)) &\leqslant \sum_{k=1}^{K}\lambda_k(\nabla\boldsymbol{\sigma}(z)) = \operatorname{tr}(\nabla\boldsymbol{\sigma}(z)) = \sum_{k=1}^{K}\sigma_k(z)-\sigma_k(z)^2 \\ &\leqslant \sum_{k=1}^{K}\sigma_k(z) - \frac{\left(\sum_{k=1}^{K}\sigma_k(z)\right)^2}{K} \leqslant \begin{cases}\frac{K}{4}, & \text{如果}K\leqslant 2\\ \frac{K-1}{K}, & \text{否则}\end{cases}.\end{aligned}$$

因此，我们可以认为

$$L \leqslant \begin{cases}\frac{K-1}{K}, & \text{如果}2\leqslant K\\ \frac{1}{4}, & \text{否则}\end{cases}.$$

另一方面，当 $z = a\mathbf{1}, a\to\infty$，我们有

$$\nabla\boldsymbol{\sigma}(z) = \frac{1}{\mathrm{e}^{-a}+K}I_K - \frac{1}{(\mathrm{e}^{-a}+K)^2}\mathbf{1}\mathbf{1}^\top,$$

其中一个特征值 $\nabla\boldsymbol{\sigma}(0)$ 为

$$\frac{1}{\mathrm{e}^{-a}+K} - \frac{K}{(\mathrm{e}^{-a}+K)^2} = \frac{1}{\mathrm{e}^{-a}+\frac{K^2}{\mathrm{e}^{-a}}+2K} \to 0,\ \text{当}a\to\infty,$$

而其他 $K-1$ 个特征值为 $\frac{1}{\mathrm{e}^{-a}+K}$. 这意味着 κ 是关于域直径是指数大的

$$4K \leqslant \mathrm{e}^{SD} + \frac{K^2}{\mathrm{e}^{SD}} + 2K \leqslant \kappa.$$

更多的讨论可以参见 Amani 等[5, 第 3 节].

定理证明

定理 3.1 的证明

证明 我们遵循 *Zhang* 等[6, 定理 3] 的证明过程，并着重强调差异之处.

W_t 的更新规则为

$$W_t := \operatorname*{argmin}_{W\in\mathcal{W}} \overbrace{\left\langle \nabla \ell_t(\overrightarrow{W}_{t-1}), \overrightarrow{W} \right\rangle + \frac{1}{2}\left\| \overrightarrow{W} - \overrightarrow{W}_{t-1} \right\|^2_{\nabla^2 \ell_t(W_{t-1})}}^{\tilde{\ell}_t(W)} + \frac{1}{2\eta}\left\| \overrightarrow{W} - \overrightarrow{W}_{t-1} \right\|^2_{Z_{t-1}}.$$

令 $\tilde{\ell}_t(W)$ 表示 $\left\langle \nabla \ell_t(\overrightarrow{W}_{t-1}), \overrightarrow{W} \right\rangle + \frac{1}{2}\left\| \overrightarrow{W} - \overrightarrow{W}_{t-1} \right\|^2_{\nabla^2 \ell_t(W_{t-1})}$，并且根据引理 *B.4*

$$\left\langle \nabla \tilde{\ell}_t(\overrightarrow{W_t}), \overrightarrow{W_t} - \overrightarrow{W_\star} \right\rangle \leqslant \frac{1}{2\eta}\left\| \overrightarrow{W_\star} - \overrightarrow{W_{t-1}} \right\|^2_{Z_{t-1}} - \frac{1}{2\eta}\left\| \overrightarrow{W_\star} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}} - \frac{1}{2\eta}\left\| \overrightarrow{W_{t-1}} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}} \tag{B-1}$$

根据[6]引理 *1*，和 $\max_{W\in\mathcal{W}, x\in D} \|W\boldsymbol{x}\|_\infty = \max_{k\in\langle K\rangle} \boldsymbol{w}_k^\top \boldsymbol{x} \leqslant DS$

$$\ell_t(W_t) - \ell_t(W_\star) \leqslant \left\langle \nabla \ell_t(\overrightarrow{W_t}), \overrightarrow{W_t} - \overrightarrow{W_\star} \right\rangle - \frac{1}{\ln(K+1) + 2(DR+1)}\left\| \overrightarrow{W_t} - \overrightarrow{W_\star} \right\|^2_{\nabla^2 \ell_t(W_t)} \tag{B-2}$$

我们令 $2\eta = \ln(K+1) + 2(DS+1)$，并且将不等式 (B-1) 与 (B-2) 相加得

$$\begin{aligned}
&\left\| \overrightarrow{W_\star} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}+\nabla^2 \ell_t(W_t)} - \left\| \overrightarrow{W_\star} - \overrightarrow{W_{t-1}} \right\|^2_{Z_{t-1}} \\
\leqslant\ & 2\eta(\ell_t(W_\star) - \ell_t(W_t)) + 2\eta \left\langle \nabla \ell_t(\overrightarrow{W_t}) - \nabla \tilde{\ell}_t(\overrightarrow{W_t}), \overrightarrow{W_t} - \overrightarrow{W_\star} \right\rangle - \left\| \overrightarrow{W_{t-1}} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}}
\end{aligned}$$

对于左侧第一项 $\left\| \overrightarrow{W_\star} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}+\nabla^2 \ell_t(W_t)}$，根据 *FD* 性质 *3.1*，我们有

$$\left\| \overrightarrow{W_\star} - \overrightarrow{W_t} \right\|^2_{Z_t} \leqslant \left\| \overrightarrow{W_\star} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}+\nabla^2 \ell_t(W_t)}. \tag{B-3}$$

并且对于右侧第二项 $\left\langle \nabla \ell_t(\overrightarrow{W_t}) - \nabla \tilde{\ell}_t(\overrightarrow{W_t}), \overrightarrow{W_t} - \overrightarrow{W_\star} \right\rangle$，我们知道 $\tilde{\ell}_t(W)$ 是 $\ell_t(W)$ 在点 W_{t-1} 的二阶近似，因此 $\nabla \tilde{\ell}_t(W)$ 是函数 $\nabla \ell_t(W)$ 的一阶近似. 那么根据泰勒定理，我们有

$$\begin{aligned}
&\left\langle \nabla \ell_t(\overrightarrow{W_t}) - \nabla \tilde{\ell}_t(\overrightarrow{W_t}), \overrightarrow{W_t} - \overrightarrow{W_\star} \right\rangle \\
=\ & \left\langle \frac{1}{2!} D^3 \ell_t(\xi)[\overrightarrow{W_t} - \overrightarrow{W_{t-1}}, \overrightarrow{W_t} - \overrightarrow{W_{t-1}}], \overrightarrow{W_t} - \overrightarrow{W_\star} \right\rangle \\
=\ & \frac{1}{2} D^3 \ell_t(\xi)[\overrightarrow{W_t} - \overrightarrow{W_{t-1}}, \overrightarrow{W_t} - \overrightarrow{W_{t-1}}, \overrightarrow{W_t} - \overrightarrow{W_\star}]
\end{aligned}$$

$$
\begin{aligned}
&\text{(根据 } D^3\ell_t(\xi) \text{ 的连续性)} \\
&= \frac{1}{2} D^3\ell_t(\xi)[\overrightarrow{W_t} - \overrightarrow{W_\star}, \overrightarrow{W_t} - \overrightarrow{W_{t-1}}, \overrightarrow{W_t} - \overrightarrow{W_{t-1}}] \\
&\text{(根据 } \ell_t(W) \text{ 的 } \sqrt{6}\text{-自一致性)} \\
&\leqslant \frac{\sqrt{6}}{2} \left\| \overrightarrow{W_t} - \overrightarrow{W_\star} \right\|_2 \left\| \overrightarrow{W_t} - \overrightarrow{W_{t-1}} \right\|^2_{\nabla^2\ell_t(\xi)} \\
&\leqslant \sqrt{6} LSD^2 \left\| \overrightarrow{W_t} - \overrightarrow{W_{t-1}} \right\|_2^2
\end{aligned}
$$

因此

$$
\left\langle \nabla\ell_t(\overrightarrow{W_t}) - \nabla\tilde{\ell}_t(\overrightarrow{W_t}), \overrightarrow{W_t} - \overrightarrow{W_\star} \right\rangle \leqslant \sqrt{6} LSD^2 \left\| \overrightarrow{W_t} - \overrightarrow{W_{t-1}} \right\|_2^2. \tag{B-4}
$$

结合不等式 (B-3) 和 (B-4)，我们有

$$
\begin{aligned}
\left\| \overrightarrow{W_\star} - \overrightarrow{W_t} \right\|^2_{Z_t} - \left\| \overrightarrow{W_\star} - \overrightarrow{W_{t-1}} \right\|^2_{Z_{t-1}} &\leqslant 2\eta(\ell_t(W_\star) - \ell_t(W_t)) \\
&\quad + 2\sqrt{6}\eta LSD^2 \left\| \overrightarrow{W_t} - \overrightarrow{W_{t-1}} \right\|_2^2 - \left\| \overrightarrow{W_{t-1}} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}},
\end{aligned}
$$

将上述不等式进行 $t = 1, \cdots, T$ 求和

$$
\begin{aligned}
\left\| \overrightarrow{W_\star} - \overrightarrow{W_T} \right\|^2_{Z_T} &\leqslant 2\lambda R + 2\eta \sum_{t=1}^{T} \ell_t(W_\star) - \ell_t(W_t) \\
&\quad + \sum_{t=1}^{T} 2\sqrt{6}\eta LSD^2 \left\| \overrightarrow{W_t} - \overrightarrow{W_{t-1}} \right\|_2^2 - \sum_{t=1}^{T} \left\| \overrightarrow{W_{t-1}} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}}.
\end{aligned}
$$

根据引理 *3.1*，如果 $\lambda \geqslant 2LD^2$，项 $\sum_{t=1}^{T} \ell_t(W_\star) - \ell_t(W_t)$ 可以以至少 $1-\delta$ 的概率被界定：

$$
\begin{aligned}
\left\| \overrightarrow{W_\star} - \overrightarrow{W_T} \right\|^2_{Z_T} &\leqslant 2\lambda R + 2\eta\gamma_T(\delta) + 2\eta \frac{12Kd}{\lambda} \sum_{t=1}^{T} \left\| \overrightarrow{W_{t-1}} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}} \\
&\quad + \sum_{t=1}^{T} 2\sqrt{6}\eta LSD^2 \left\| \overrightarrow{W_t} - \overrightarrow{W_{t-1}} \right\|_2^2 - \sum_{t=1}^{T} \left\| \overrightarrow{W_{t-1}} - \overrightarrow{W_t} \right\|^2_{Z_{t-1}}.
\end{aligned}
$$

我们令 $\lambda \geqslant 2\eta \max\left\{2\sqrt{6}LSD^2, 24Kd\right\}$，可以将最后三项相消

$$
\begin{aligned}
2\eta\frac{12Kd}{\lambda}\left\|\overrightarrow{W_{t-1}}-\overrightarrow{W_t}\right\|_{Z_{t-1}}^2 &\leqslant \frac{1}{2}\left\|\overrightarrow{W_{t-1}}-\overrightarrow{W_t}\right\|_{Z_{t-1}}^2 \\
2\sqrt{6}\eta LSD^2\left\|\overrightarrow{W_t}-\overrightarrow{W_{t-1}}\right\|_2^2 \leqslant \frac{1}{2}\left\|\overrightarrow{W_{t-1}}-\overrightarrow{W_t}\right\|_{\lambda I}^2 &\leqslant \frac{1}{2}\left\|\overrightarrow{W_{t-1}}-\overrightarrow{W_t}\right\|_{Z_{t-1}}^2
\end{aligned}
$$

综上所述，如果 $\lambda \geqslant \max\left\{2LD^2, (\ln(K+1)+2(DS+1))\max\left\{2\sqrt{6}D^2SL, 24Kd\right\}\right\}$，我们有

$$
\left\|\overrightarrow{W_\star}-\overrightarrow{W_T}\right\|_{Z_T}^2 \leqslant 2\lambda R + (\ln(K+1)+2(DS+1))\gamma_T(\delta).
$$

□

定理 3.2 的证明

证明 遗憾定义为最优动作的期望奖励减去算法采取的动作的期望奖励：

$$
\begin{aligned}
\mathrm{Regret}(T) &= \sum_{t=1}^{T}\left(\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_\star)-\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_t)\right) \\
&= \sum_{t=1}^{T}\underbrace{\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_\star)-\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_\star)}_{\texttt{term a}}+\underbrace{\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_\star)-\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)}_{\texttt{term b}} \\
&\quad+\underbrace{\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)-\boldsymbol{\rho}^\top\boldsymbol{\sigma}(W_\star\boldsymbol{x}_t)}_{\texttt{term c}}
\end{aligned}
$$

其中 `term a` 和 `term c` 不大于

$$
\texttt{term a} \leqslant \delta_{t-1}(\boldsymbol{x}_\star,\delta), \texttt{term c} \leqslant \delta_{t-1}(\boldsymbol{x}_t,\delta),
$$

根据引理 *3.2*. 而根据算法选择准则 $\boldsymbol{x}_{t+1} := \mathrm{argmax}_{\boldsymbol{x}\in D_t} r_t(\boldsymbol{x},\delta)$，`term b` 不大于

$$
r_{t-1}(\boldsymbol{x}_\star,\delta) \leqslant r_{t-1}(\boldsymbol{x}_t,\delta) \implies \texttt{term b} \leqslant \delta_{t-1}(\boldsymbol{x}_t,\delta)-\delta_{t-1}(\boldsymbol{x}_\star,\delta).
$$

因此遗憾不大于 $2\sum_{t=1}^{T}\delta_{t-1}(\boldsymbol{x}_t,\delta)$：

$$
\mathrm{Regret}(T) \leqslant 2\sum_{t=1}^{T}\delta_{t-1}(\boldsymbol{x}_t,\delta) = 2\sum_{t=1}^{T}\varepsilon_{t-1}^{\texttt{fst}}(\boldsymbol{x}_t,\delta)+2\sum_{t=1}^{T}\varepsilon_{t-1}^{\texttt{snd}}(\boldsymbol{x}_t,\delta). \tag{B-5}
$$

对于项 $\sum_{t=1}^{T}\varepsilon_{t-1}^{\mathtt{fst}}(\boldsymbol{x}_t,\delta)$,

$$
\begin{aligned}
\sum_{t=1}^{T}\varepsilon_{t-1}^{\mathtt{fst}}(\boldsymbol{x}_t,\delta) &= \sum_{t=1}^{T}\sqrt{\beta_{t-1}(\delta)}\left\|(\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)\otimes\boldsymbol{x}_t)\boldsymbol{\rho}\right\|_{Z_{t-1}^{-1}} \\
&\leqslant \sqrt{\beta_{T-1}(\delta)}\sum_{t=1}^{T}\left\|(\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)\otimes\boldsymbol{x}_t)\boldsymbol{\rho}\right\|_{Z_{t-1}^{-1}} \\
&\leqslant \sqrt{\beta_{T-1}(\delta)}\sum_{t=1}^{T}\left\|(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)\otimes\boldsymbol{x}_t)\boldsymbol{\rho}\right\|_{Z_{t-1}^{-1}}+\left\|((\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)-\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t))\otimes\boldsymbol{x}_t)\boldsymbol{\rho}\right\|_{Z_{t-1}^{-1}}
\end{aligned}
$$

对于第一项

$$
\begin{aligned}
&\left\|(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)\otimes\boldsymbol{x}_t)\boldsymbol{\rho}\right\|_{Z_{t-1}^{-1}} \\
=&\left\|(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t)\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\boldsymbol{\rho}\right\|_2 \\
&\textit{(根据矩阵算子 }\|\cdot\|_{2,2}\textit{ 范数的定义)} \\
\leqslant&\left\|Z_{t-1}^{\frac{1}{2}}(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t)\right\|_{2,2}\left\|\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\boldsymbol{\rho}\right\|_2 \\
&\textit{(根据 }\nabla\boldsymbol{\sigma}(\cdot)\preceq I\textit{ 和假设 }\|\boldsymbol{\rho}\|_2\leqslant R\textit{)} \\
\leqslant&\left\|Z_{t-1}^{-\frac{1}{2}}(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t)\right\|_{2,2}R \\
=&R\left\|(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t)^{\top}Z_{t-1}^{-1}(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t)\right\|_{2,2}^{\frac{1}{2}} \\
=&R\left\|(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t)(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)^{\frac{1}{2}}\otimes\boldsymbol{x}_t)^{\top}Z_{t-1}^{-1}\right\|_{2,2}^{\frac{1}{2}} \\
=&R\left\|(\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)\otimes\boldsymbol{x}_t\boldsymbol{x}_t^{\top})Z_{t-1}^{-1}\right\|_{2,2}^{\frac{1}{2}} \\
\leqslant&R\sqrt{\mathrm{tr}((\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t)\otimes\boldsymbol{x}_t\boldsymbol{x}_t^{\top})Z_{t-1}^{-1})}=R\sqrt{\mathrm{tr}(\nabla^2\ell_t(W_t)Z_{t-1}^{-1})}
\end{aligned}
$$

第二和第三个等式是由于谱范数的性质 $\|A^{\top}A\|_{2,2}=\|A\|_{2,2}^2$ 和 $\|AB\|_{2,2}=\|BA\|_{2,2}$. 第四个等式是根据克罗内克乘积的性质 $(A\otimes B)(C\otimes D)=AC\otimes BD$，最后一个不等式是因为 $\|A\|_{2,2}=\lambda_{\max}(A)\leqslant\sum_i\lambda_i(A)=\mathrm{tr}(A)$.

对于第二项，我们先令 $\Xi_k:=\int_0^1\nabla^2\sigma_k((W_t+(W_{t-1}-W_t)\upsilon)\boldsymbol{x}_t)\,\mathrm{d}\upsilon$

$$
\left\|((\nabla\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t)-\nabla\boldsymbol{\sigma}(W_t\boldsymbol{x}_t))\otimes\boldsymbol{x}_t)\boldsymbol{\rho}\right\|_{Z_{t-1}^{-1}}
$$

$$
\begin{aligned}
&= \left\| \sum_{k=0}^{K} \rho_k((\nabla\sigma_k(W_{t-1}\boldsymbol{x}_t) - \nabla\sigma_k(W_t\boldsymbol{x}_t)) \otimes \boldsymbol{x}_t) \right\|_{Z_{t-1}^{-1}} \\
&\quad \textit{(根据均值定理)} \\
&= \left\| \sum_{k=0}^{K} \rho_k((\Xi_k(W_{t-1} - W_t)\boldsymbol{x}_t) \otimes \boldsymbol{x}_t) \right\|_{Z_{t-1}^{-1}} \\
&= \left\| Z_{t-1}^{-\frac{1}{2}} \left(\sum_{k=0}^{K} \rho_k \Xi_k \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top \right) \left(\overrightarrow{W}_{t-1} - \overrightarrow{W}_t \right) \right\|_2 \\
&\leqslant \left\| Z_{t-1}^{-\frac{1}{2}} \left(\sum_{k=0}^{K} \rho_k \Xi_k \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top \right) Z_{t-1}^{-\frac{1}{2}} \right\|_{2,2} \left\| \overrightarrow{W}_{t-1} - \overrightarrow{W}_t \right\|_{Z_{t-1}} \\
&\quad \textit{(根据引理 B.1 和 } -I \preceq \Xi_k \preceq \frac{1}{2}I\textit{)} \\
&\leqslant \left\| Z_{t-1}^{-1} \left(\sum_{k=0}^{K} \rho_k I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top \right) \right\|_{2,2} \frac{2\eta D}{\lambda} \\
&\quad \textit{(根据 } \|\boldsymbol{\rho}\|_1 \leqslant \sqrt{K}R\textit{)} \\
&\leqslant \frac{2\eta D}{\lambda} \left\| Z_{t-1}^{-1} \left(\sqrt{K} R I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top \right) \right\|_{2,2} \\
&= \frac{2\eta D R\sqrt{K}}{\lambda} \left\| Z_{t-1}^{-1} \left(I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top \right) \right\|_{2,2} \\
&\leqslant \frac{2\eta D R\sqrt{K}}{\lambda} \operatorname{tr}\left(Z_{t-1}^{-1} \left(I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top \right) \right)
\end{aligned}
$$

结合上述两项，我们有

$$
\begin{aligned}
\sum_{t=1}^{T} \varepsilon_{t-1}^{\texttt{fst}}(\boldsymbol{x}_t, \delta) \leqslant R\sqrt{\beta_{T-1}(\delta)} \sum_{t=1}^{T} \sqrt{\operatorname{tr}\left(Z_{t-1}^{-1} \nabla^2 \ell_t(W_t) \right)} \\
+ \frac{2\eta D R\sqrt{K}}{\lambda} \sqrt{\beta_{T-1}(\delta)} \sum_{t=1}^{T} \operatorname{tr}\left(Z_{t-1}^{-1} (I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top) \right).
\end{aligned} \tag{B-6}
$$

然后对于项 $\varepsilon_{t-1}^{\texttt{snd}}(\boldsymbol{x}_t, \delta)$

$$
\begin{aligned}
\sum_{t=1}^{T} \varepsilon_{t-1}^{\texttt{snd}}(\boldsymbol{x}_t, \delta) &= \sum_{t=1}^{T} \frac{\sqrt{K}}{2} R\beta_{t-1}(\delta) \left\| Z_{t-1}^{-1} (I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top) \right\|_{2,2} \\
&\leqslant \frac{\sqrt{K}}{2} R\beta_{T-1}(\delta) \sum_{t=1}^{T} \left\| Z_{t-1}^{-1} (I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top) \right\|_{2,2}
\end{aligned}
$$

$$\leqslant \frac{\sqrt{K}}{2} R\beta_{T-1}(\delta) \sum_{t=1}^{T} \operatorname{tr}\left(Z_{t-1}^{-1}(I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top)\right) \tag{B-7}$$

将不等式 (B-6) 和 (B-7) 代入遗憾界 (B-5)，

$$\begin{aligned}
\operatorname{Regret}(T) \leqslant\ & 2R\sqrt{\beta_{T-1}(\delta)} \sum_{t=1}^{T} \sqrt{\operatorname{tr}\left(Z_{t-1}^{-1} \nabla^2 \ell_t(W_t)\right)} \\
& + R\sqrt{K}\left(\frac{4\eta D}{\lambda}\sqrt{\beta_{T-1}(\delta)} + \beta_{T-1}(\delta)\right) \sum_{t=1}^{T} \operatorname{tr}\left(Z_{t-1}^{-1}(I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top)\right) \\
\leqslant\ & 2R\sqrt{\beta_{T-1}(\delta)}\sqrt{T}\sqrt{\sum_{t=1}^{T} \operatorname{tr}\left(Z_{t-1}^{-1} \nabla^2 \ell_t(W_t)\right)} \\
& + R\sqrt{K}\left(\frac{4\eta D}{\lambda}\sqrt{\beta_{T-1}(\delta)} + \beta_{T-1}(\delta)\right) \sum_{t=1}^{T} \operatorname{tr}\left(Z_{t-1}^{-1}(I \otimes \boldsymbol{x}_t \boldsymbol{x}_t^\top)\right)
\end{aligned}$$

根据引理 *B.5* 和 *B.6*，

$$\begin{aligned}
\operatorname{Regret}(T) \leqslant\ & 2R\sqrt{\beta_{T-1}(\delta)}\sqrt{T}\sqrt{\Delta_T^\lambda\left(Kd\ln\Delta_T^{\lambda/2} + m\ln(1 + 2\frac{D^2}{m\lambda}T)\right)} \\
& + R\sqrt{K}\left(\frac{4\eta D}{\lambda}\sqrt{\beta_{T-1}(\delta)} + \beta_{T-1}(\delta)\right)\kappa\Delta_T^\lambda\left(Kd\ln\Delta_T^{\lambda/2} + m\ln(1 + 2\frac{D^2}{m\lambda}T)\right) \\
=\ & \mathcal{O}\left(\Delta_T^\lambda(Kd\ln\Delta_T^{\lambda/2} + m\ln T)\ln K\sqrt{\ln T}\sqrt{T} + \kappa\sqrt{K}\ln^2 K\ln T(\Delta_T^\lambda(Kd\ln\Delta_T^{\lambda/2} + m\ln T))^2\right) \\
=\ & \tilde{\mathcal{O}}\left(\Delta_T^\lambda K\sqrt{T}\right) \qquad \square
\end{aligned}$$

定理 3.3 的证明

证明 根据第 *2.2* 的讨论中，遗憾可以被表示为

$$\operatorname{Regret}(T) = \sum_{t=1}^{T} \sigma(\boldsymbol{w}_\star^\top \boldsymbol{x}_\star) - \sigma(\boldsymbol{w}_\star^\top \boldsymbol{x}_t).$$

然后我们进行与 *Zhang* 等[6, Corollary 1] 的相似的分解：

$$\operatorname{Regret}(T)$$

$$= \sum_{t=1}^{T} \sigma(\boldsymbol{w}_\star^\top \boldsymbol{x}_\star) - \sigma(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)$$

(根据乐观决策准则 (2-1))

$$\leqslant \sum_{t=1}^{T} \sigma(\hat{\boldsymbol{w}}_t^\top \boldsymbol{x}_t) - \sigma(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)$$

(根据泰勒定理)

$$= \sum_{t=1}^{T} \sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)(\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t + \sigma''(\xi_t)((\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t)^2$$

(根据 $\sigma''(\cdot) \leqslant \frac{1}{4}$)

$$= \sum_{t=1}^{T} \sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)(\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t + \frac{1}{4}((\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t)^2$$

$$= \sum_{t=1}^{T} \sqrt{\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)}(\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \sqrt{\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)}\boldsymbol{x}_t + \frac{1}{4}((\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t)^2$$

(根据泰勒定理)

$$= \sum_{t=1}^{T} \sqrt{\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)}(\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \sqrt{\sigma'(\boldsymbol{w}_t^\top \boldsymbol{x}_t)}\boldsymbol{x}_t$$
$$+ \frac{\sigma''(\psi_t)}{2\sqrt{\sigma'(\psi_t)}} \sqrt{\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)}(\boldsymbol{w}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t(\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t + \frac{1}{4}((\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t)^2$$

(根据 $(\sigma''(\cdot))/(2\sqrt{\sigma'(\cdot)}) \leqslant \frac{1}{4}, \sigma'(\cdot) \leqslant \frac{1}{4}$)

$$= \sum_{t=1}^{T} \sqrt{\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)}(\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \sqrt{\sigma'(\boldsymbol{w}_t^\top \boldsymbol{x}_t)}\boldsymbol{x}_t + \frac{1}{8}(\boldsymbol{w}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t(\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t$$
$$+ \frac{1}{4}((\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star)^\top \boldsymbol{x}_t)^2$$

(根据柯西施瓦兹不等式)

$$= \sum_{t=1}^{T} \sqrt{\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)} \left\|\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star\right\|_{Z_{t-1}} \left\|\sqrt{\sigma'(\boldsymbol{w}_t^\top \boldsymbol{x}_t)}\boldsymbol{x}_t\right\|_{Z_{t-1}^{-1}}$$
$$+ \frac{1}{8} \left\|\boldsymbol{w}_t - \boldsymbol{w}_\star\right\|_{Z_t} \left\|\boldsymbol{x}_t\right\|_{Z_t^{-1}} \left\|\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star\right\|_{Z_{t-1}} \left\|\boldsymbol{x}_t\right\|_{Z_{t-1}^{-1}} + \frac{1}{4} \left\|\hat{\boldsymbol{w}}_t - \boldsymbol{w}_\star\right\|_{Z_{t-1}}^2 \left\|\boldsymbol{x}_t\right\|_{Z_{t-1}^{-1}}^2$$

(根据定理 3.1 和 $\beta_{t-1}(\delta) \leqslant \beta_t(\delta)$)

$$= \sqrt{\beta_T(\delta)} \sum_{t=1}^{T} \sqrt{\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_t)} \left\|\sqrt{\sigma'(\boldsymbol{w}_t^\top \boldsymbol{x}_t)}\boldsymbol{x}_t\right\|_{Z_{t-1}^{-1}}$$

$$+\frac{1}{8}\beta_T(\delta)\sum_{t=1}^{T}\|\boldsymbol{x}_t\|_{Z_t^{-1}}\|\boldsymbol{x}_t\|_{Z_{t-1}^{-1}}+\frac{1}{4}\beta_T(\delta)\sum_{t=1}^{T}\|\boldsymbol{x}_t\|_{Z_{t-1}^{-1}}^2$$

其中第六个等式是因为 $\frac{\sigma''(\cdot)}{2\sqrt{\sigma'(\cdot)}}=\frac{1}{2}(1-2\sigma(\cdot))\sqrt{\sigma(\cdot)(1-\sigma(\cdot))}\leqslant\frac{1}{4}$ 和 $\sigma'(\cdot)\leqslant\frac{1}{4}$.

至于第一项

$$\sum_{t=1}^{T}\sqrt{\sigma'(\boldsymbol{w}_\star^\top\boldsymbol{x}_t)}\left\|\sqrt{\sigma'(\boldsymbol{w}_t^\top\boldsymbol{x}_t)}\boldsymbol{x}_t\right\|_{Z_{t-1}^{-1}}$$

(根据柯西施瓦兹不等式)

$$\leqslant\sqrt{\sum_{t=1}^{T}\sigma'(\boldsymbol{w}_\star^\top\boldsymbol{x}_t)}\sqrt{\sum_{t=1}^{T}\left\|\sqrt{\sigma'(\boldsymbol{w}_t^\top\boldsymbol{x}_t)}\boldsymbol{x}_t\right\|_{Z_{t-1}^{-1}}^2}$$

$$=\sqrt{\sum_{t=1}^{T}\sigma'(\boldsymbol{w}_\star^\top\boldsymbol{x}_t)}\sqrt{\sum_{t=1}^{T}\operatorname{tr}\left(Z_{t-1}^{-1}\sigma'(\boldsymbol{w}_t^\top\boldsymbol{x}_t)\boldsymbol{x}_t\boldsymbol{x}_t^\top\right)}$$

(根据引理 B.5)

$$\leqslant\sqrt{\sum_{t=1}^{T}\sigma'(\boldsymbol{w}_\star^\top\boldsymbol{x}_t)}\sqrt{\Delta_T^\lambda\left(Kd\ln\Delta_T^{\lambda/2}+m\ln(1+2\frac{D^2}{m\lambda}T)\right)}$$

(根据 Faury 等[17, 定理 2])

$$\leqslant\sqrt{\mathrm{Regret}(T)+T\sigma'(\boldsymbol{w}_\star^\top\boldsymbol{x}_\star)}\sqrt{\Delta_T^\lambda\left(Kd\ln\Delta_T^{\lambda/2}+m\ln(1+2\frac{D^2}{m\lambda}T)\right)}$$

对于第二项

$$\sum_{t=1}^{T}\|\boldsymbol{x}_t\|_{Z_t^{-1}}\|\boldsymbol{x}_t\|_{Z_{t-1}^{-1}}$$

(根据柯西施瓦兹不等式)

$$\leqslant\sqrt{\sum_{t=1}^{T}\|\boldsymbol{x}_t\|_{Z_t^{-1}}}\sqrt{\sum_{t=1}^{T}\|\boldsymbol{x}_t\|_{Z_{t-1}^{-1}}}$$

(根据引理 B.7 和引理 B.6)

$$\leqslant\sqrt{\kappa\Delta_T^\lambda\left(Kd\ln\Delta_T^\lambda+m\ln(1+\frac{D^2}{m\lambda}T)\right)}\sqrt{\kappa\Delta_T^\lambda\left(Kd\ln\Delta_T^{\lambda/2}+m\ln(1+2\frac{D^2}{m\lambda}T)\right)}$$

$$\leqslant\kappa\Delta_T^\lambda\left(Kd\ln\Delta_T^{\lambda/2}+m\ln(1+2\frac{D^2}{m\lambda}T)\right)$$

然后根据引理 $B.6$，第三项不大于

$$\sum_{t=1}^{T} \|\boldsymbol{x}_t\|_{Z_{t-1}^{-1}}^2 \leqslant \kappa \Delta_T^{\lambda} \left(Kd \ln \Delta_T^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda}T) \right).$$

综上，我们有

$$\begin{aligned}\mathrm{Regret}(T) \leqslant & \sqrt{\beta_T(\delta)} \sqrt{\mathrm{Regret}(T) + T\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_\star)} \sqrt{\Delta_T^{\lambda} \left(Kd \ln \Delta_T^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda}T) \right)} \\ & + \frac{3}{8}\beta_T(\delta)\kappa \Delta_T^{\lambda} \left(Kd \ln \Delta_T^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda}T) \right).\end{aligned}$$

求解上述关于 $\mathrm{Regret}(T)$ 的不等式，我们得到了

$$\begin{aligned}\mathrm{Regret}(T) \leqslant & \sqrt{\beta_T(\delta)\Delta_T^{\lambda} \left(Kd \ln \Delta_T^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda}T) \right)} \sqrt{T\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_\star)} \\ & + (\frac{3}{8}\kappa + \sqrt{\frac{3}{8}\kappa} + 1)\beta_T(\delta)\Delta_T^{\lambda} \left(Kd \ln \Delta_T^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda}T) \right) \\ = & \mathcal{O}\left(\Delta_T^{\lambda}(Kd \ln \Delta_T^{\lambda} + m \ln T) \ln K \sqrt{\ln T} \sqrt{T\kappa_*} + \kappa(\Delta_T^{\lambda}(Kd \ln \Delta_T^{\lambda} + m \ln T))^2 \ln^2 K \ln T \right) \\ = & \tilde{\mathcal{O}}\left(\Delta_T^{\lambda} K \sqrt{T\kappa_*} \right),\end{aligned}$$

其中 κ_* 表示 $1/(\sigma'(\boldsymbol{w}_\star^\top \boldsymbol{x}_\star))$ □

必要的引理

引理 B.1 对于任意 $t > 0$，我们有

$$\left\| \overrightarrow{W_t} - \overrightarrow{W_{t-1}} \right\|_{Z_{t-1}}^2 \leqslant \frac{2\eta D}{\lambda}.$$

证明 根据 W_t 的定义，

$$W_t := \operatorname*{argmin}_{W \in \mathcal{W}} \left\langle \eta \nabla \ell_t(\overrightarrow{W_{t-1}}), \overrightarrow{W} \right\rangle + \frac{1}{2} \left\| \overrightarrow{W} - \overrightarrow{W_{t-1}} \right\|_{Z_{t-1} + \eta \nabla^2 \ell_t(W_{t-1})}^2,$$

W_t 满足一阶最优条件

$$\left\langle \eta\nabla\ell_t(\overrightarrow{W}_{t-1}) + (Z_{t-1} + \eta\nabla^2\ell_t(W_{t-1}))(\overrightarrow{W}_t - \overrightarrow{W}_{t-1}), \overrightarrow{W}_t - \overrightarrow{W}_{t-1} \right\rangle \leqslant 0.$$

对上述不等式进行变形，得到

$$\left\| \overrightarrow{W}_t - \overrightarrow{W}_{t-1} \right\|^2_{Z_{t-1}+\eta\nabla^2\ell_t(W_{t-1})} \leqslant \left\langle \eta\nabla\ell_t(\overrightarrow{W}_{t-1}), \overrightarrow{W}_t - \overrightarrow{W}_{t-1} \right\rangle.$$

根据 $\eta\nabla^2\ell_t(W_{t-1}) \succeq 0$ 和柯西施瓦兹不等式，

$$\begin{aligned}
\left\| \overrightarrow{W}_t - \overrightarrow{W}_{t-1} \right\|_{Z_{t-1}} &\leqslant \left\| \eta\nabla\ell_t(\overrightarrow{W}_{t-1}) \right\|_{Z_{t-1}^{-1}} \\
&\quad (\text{根据 } Z_{t-1} \succeq \lambda I) \\
&\leqslant \frac{\eta}{\lambda} \left\| \nabla\ell_t(\overrightarrow{W}_{t-1}) \right\|_2 \\
&= \frac{\eta}{\lambda} \left\| [0, I](\boldsymbol{\sigma}(W_{t-1}\boldsymbol{x}_t) - \boldsymbol{y}_t) \right\|_2 \left\| \boldsymbol{x}_t \right\|_2 \\
&\leqslant \frac{2\eta D}{\lambda}
\end{aligned}$$

□

引理 3.1 的证明

引理 B.2 如果 $\lambda \geqslant 2LD^2$，则对任意 $\delta \in (0,1)$，有至少 $1-\delta$ 的概率，我们有

$$\forall t > 0.\ \sum_{s=1}^{t} \ell_s(W_\star) - \ell_s(W_s) \leqslant \gamma_t(\delta) + \frac{12Kd}{\lambda} \sum_{s=1}^{t} \left\| \overrightarrow{W}_{s-1} - \overrightarrow{W}_s \right\|^2_{Z_{s-1}},$$

其中

$$\begin{aligned}
\gamma_t(\delta) = 2 + \ln(K+1) + \left(DS + S_{\frac{1}{t}} \right) \left(\frac{5}{4} + 4\ln\frac{\sqrt{1+2t}}{\delta} \right) \\
+ \frac{\sqrt{6}}{24Kd}\lambda\Delta_t^{\lambda} \left(Kd\ln\Delta_t^{\lambda/2} + m\ln(1 + 2\frac{D^2}{m\lambda}t) \right) \\
S_{\frac{1}{t}} = \ln(K+1) + 2\ln((K+1)t + 2)
\end{aligned}$$

证明 $\boldsymbol{\sigma}^+$ 记作函数 $\boldsymbol{\sigma}$ 的逆函数，

$$\boldsymbol{\sigma}^+(\boldsymbol{p}) = \left[\ln\frac{p_1}{p_0}, \ln\frac{p_2}{p_0}, \cdots, \ln\frac{p_K}{p_0}\right]^\top, \|\boldsymbol{p}\|_1 = 1, \boldsymbol{p} \in [0,1]^{K+1}.$$

然后我们定义关于 $\ell_t(\cdot)$ 的中间函数

$$\hat{\ell}_s(z) := -\boldsymbol{y}_t^\top \ln \boldsymbol{\sigma}(z), \hat{\ell}_s(W\boldsymbol{x}_s) = \ell_s(W).$$

令 z_s 为关于分布 $\mathcal{P}_s = \mathcal{N}(W_s, (cZ_s)^{-1})$ 的中间预测量

$$z_s = \boldsymbol{\sigma}^+(\mathbb{E}_{W\sim\mathcal{P}_s}[\boldsymbol{\sigma}(W\boldsymbol{x}_{s+1})]),$$

并且 z_s^μ 为 z_s 的平滑近似

$$z_s^\mu = \boldsymbol{\sigma}^+(\mathrm{smooth}_\mu(\boldsymbol{\sigma}(z_s))),$$

其中对于任意概率分布 $\|\boldsymbol{p}\|_1 = 1, \boldsymbol{p} \in [0,1]^{K+1}$, $\mathrm{smooth}_\mu(\boldsymbol{p}) = (1-\mu)\boldsymbol{p} + \mu/(K+1)$.
因此 z_s 和 z_s^μ 是 $\mathcal{F}_s$-可测的，

$$\left\|z_s^\mu\right\|_\infty = \max_{k\in\langle K\rangle}\left|\ln\frac{\boldsymbol{\sigma}_k(z_s^\mu)}{\boldsymbol{\sigma}_0(z_s^\mu)}\right| \leqslant \max\left\{\left|\ln\frac{1-\mu K/(K+1)}{\mu/(K+1)}\right|, \left|\ln\frac{\mu/(K+1)}{1-\mu K/(K+1)}\right|\right\} \leqslant \ln\left(\frac{K+1}{\mu} - K\right).$$

然后我们参照 *Zhang* 等[6, Theorem 3] 的证明．将 $\sum_{s=1}^t \ell_s(W_\star) - \ell_s(W_s)$ 分为三部分

$$\sum_{s=1}^t \ell_s(W_\star) - \ell_s(W_s) = \sum_{s=1}^t \ell_s(W_\star) - \hat{\ell}_s(z_{s-1}^\mu) + \sum_{s=1}^t \hat{\ell}_s(z_{s-1}^\mu) - \hat{\ell}_s(z_{s-1}) + \sum_{s=1}^t \hat{\ell}_s(z_{s-1}) - \ell_s(W_s).$$

对于第一项 $\sum_{s=1}^t \ell_s(W_\star) - \hat{\ell}_s(z_{s-1}^\mu)$，根据 *Zhang* 等[6, Lemma 13]，我们有

$$\sum_{s=1}^t \ell_s(W_\star) - \hat{\ell}_s(z_{s-1}^\mu) \leqslant \frac{5}{4}(DS + S_\mu) + 4(DS + S_\mu)\ln\frac{\sqrt{1+2t}}{\delta}, \tag{B-8}$$

其中 $S_\mu = \ln(K+1) + 2\ln(\frac{K+1}{\mu} + 2) \geqslant \ln(K+1) + 2(\left\|z_s^\mu\right\|_\infty + 1)$．而对于第二项

$\sum_{s=1}^{t} \hat{\ell}_s(z_{s-1}^{\mu}) - \hat{\ell}_s(z_{s-1})$，根据 *Zhang* 等[6, Lemma 17]，如果 $\mu \in [0, \frac{1}{2}]$

$$\begin{aligned}
\sum_{s=1}^{t} \hat{\ell}_s(z_{s-1}^{\mu}) - \hat{\ell}_s(z_{s-1}) &= \sum_{s=1}^{t} \ln \frac{\sigma_{y_s}(z_{s-1})}{(1-\mu)\sigma_{y_s}(z_{s-1}) + \mu 1/(K+1)} \\
&\leqslant \sum_{s=1}^{t} \ln \frac{1}{1-\mu K/(K+1)} \leqslant \sum_{s=1}^{t} \ln \exp(2\mu K/(K+1)) \\
&\leqslant \sum_{s=1}^{t} 2\mu = 2\mu t. \qquad \text{(B-9)}
\end{aligned}$$

第二个不等式是根据 $\forall x \in [0, \frac{1}{2}]$. $\frac{1}{1-x} \leqslant \exp(2x)$. 然后根据引理 *B.3*，第三项不大于

$$\sum_{s=1}^{t} \hat{\ell}_s(z_{s-1}) - \ell_s(W_s) \leqslant \alpha_t(\delta) + \frac{12Kd}{\lambda} \sum_{s=1}^{t} \left\| \overrightarrow{W}_{s-1} - \overrightarrow{W}_s \right\|_{Z_{s-1}}^2, \qquad \text{(B-10)}$$

其中，如果 $\lambda \geqslant 2LD^2$

$$\alpha_t(\delta) = \frac{\sqrt{6}}{24Kd} \lambda \Delta_t^{\lambda} \left(Kd \ln \Delta_t^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda} t) \right).$$

结合不等式 (B-8)，(B-9) 和 (B-10)，我们有

$$\begin{aligned}
\sum_{s=1}^{t} \ell_s(W_\star) - \ell_s(W_s) \leqslant \frac{5}{4}(DS + S_\mu) + 4(DS + S_\mu) \ln \frac{\sqrt{1+2t}}{\delta} + 2\mu t \\
+ \alpha_t(\delta) + \frac{12Kd}{\lambda} \sum_{s=1}^{t} \left\| \overrightarrow{W}_{s-1} - \overrightarrow{W}_s \right\|_{Z_{s-1}}^2
\end{aligned}$$

并且令 $\mu = \frac{1}{t}$，我们得到了

$$\begin{aligned}
\sum_{s=1}^{t} \ell_s(W_\star) - \ell_s(W_s) \leqslant \left(DS + S_{\frac{1}{t}} \right) \left(\frac{5}{4} + 4 \ln \frac{\sqrt{1+2t}}{\delta} \right) + 2 + \ln(K+1) \\
+ \alpha_t(\delta) + \frac{12Kd}{\lambda} \sum_{s=1}^{t} \left\| \overrightarrow{W}_{s-1} - \overrightarrow{W}_s \right\|_{Z_{s-1}}^2 \qquad \square
\end{aligned}$$

引理 B.3 如果 $\lambda \geqslant 2LD^2$，则对任意 $t > 0$

$$\sum_{s=1}^{t} \hat{\ell}_s(z_{s-1}) - \ell_s(W_s) \leqslant \alpha_t(\delta) + \frac{12Kd}{\lambda} \sum_{s=1}^{t} \left\| \overrightarrow{W}_{s-1} - \overrightarrow{W}_s \right\|_{Z_{s-1}}^2 ,$$

其中

$$\alpha_t(\delta) = \frac{\sqrt{6}}{24Kd} \lambda \Delta_t^{\lambda} \left(Kd \ln \Delta_t^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda} t) \right).$$

证明 根据 z_s 的定义，我们有

$$\exp(-\hat{\ell}_s(z_{s-1})) = \mathbb{E}_{W \sim \mathcal{P}_{s-1}} \left[\exp(-\ell_s(W)) \right].$$

因此

$$\begin{aligned}
\sum_{s=1}^{t} \hat{\ell}_s(z_{s-1}) - \ell_s(W_s) &= \sum_{s=1}^{t} -\ln \exp(-\hat{\ell}_s(z_{s-1})) - \ell_s(W_s) \\
&= \sum_{s=1}^{t} -\ln \mathbb{E}_{W \sim \mathcal{P}_{s-1}} \left[\exp(-\ell_s(W)) \right] - \ell_s(W_s) \\
&= \sum_{s=1}^{t} -\ln \mathbb{E}_{W \sim \mathcal{P}_{s-1}} \left[\exp(-(\ell_s(W) - \ell_s(W_s))) \right]
\end{aligned}$$

我们将分布 $\mathcal{P}_{s-1}$ 的均值从 W_{s-1} 移动到 W_s，得到新的分布 $\mathcal{Q}_{s-1} := \mathcal{N}(W_s, (cZ_{s-1})^{-1})$. 对于概率密度函数 $f_p(W), f_q(W)$，以下关系式成立

$$\frac{f_p(W)}{f_q(W)} = \exp\left(-\left\langle \nabla f_p(\overrightarrow{W}_s), \overrightarrow{W} - \overrightarrow{W}_s \right\rangle \right) \exp\left(-\frac{1}{2} \left\| \overrightarrow{W}_{s-1} - \overrightarrow{W}_s \right\|_{cZ_{s-1}}^2 \right).$$

因而

$$\begin{aligned}
&\sum_{s=1}^{t} -\ln \mathbb{E}_{W \sim \mathcal{P}_{s-1}} \left[\exp(-(\ell_s(W) - \ell_s(W_s))) \right] \\
= &\sum_{s=1}^{t} -\ln \mathbb{E}_{W \sim \mathcal{Q}_{s-1}} \left[\frac{f_p(W)}{f_q(W)} \exp\left(-\left(\ell_s(W) - \ell_s(W_s) \right) \right) \right]
\end{aligned}$$

$$
\begin{aligned}
&= \sum_{s=1}^{t} -\ln \mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\exp\left(-\left(\ell_s(W)-\ell_s(W_s)+\left\langle \nabla f_p(\overrightarrow{W_s}), \overrightarrow{W}-\overrightarrow{W_s}\right\rangle\right)\right)\right] \\
&\quad + \frac{1}{2}\left\|\overrightarrow{W_{s-1}}-\overrightarrow{W_s}\right\|^2_{cZ_{s-1}} \qquad \text{(B-11)}
\end{aligned}
$$

根据 *Tran-Dinh* 等[26, Theorem 4(d)]，并且 $\forall x>0.\ (\exp(x)-x-1)/x^2 \leqslant \exp(x^2)$，

$$
\ell_s(W)-\ell_s(W_s) \leqslant \left\langle \nabla \ell_s(\overrightarrow{W_s}), \overrightarrow{W}-\overrightarrow{W_s}\right\rangle + \mathrm{e}^{6\|W-W_s\|_F^2}\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|^2_{\nabla^2\ell_s(W_s)},
$$

如下，对等式 (B-11) 的对数期望项不大于

$$
\begin{aligned}
&-\ln \mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\exp\left(-\left(\ell_s(W)-\ell_s(W_s)+\left\langle \nabla f_p(\overrightarrow{W_s}), \overrightarrow{W}-\overrightarrow{W_s}\right\rangle\right)\right)\right] \\
\leqslant\ & -\ln \mathbb{E}\left[\exp\left(-\left(\left\langle \nabla \ell_s(\overrightarrow{W_s})+\nabla f_p(\overrightarrow{W_s}), \overrightarrow{W}-\overrightarrow{W_s}\right\rangle + \mathrm{e}^{6\|W-W_s\|_F^2}\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|^2_{\nabla^2\ell_s(W_s)}\right)\right)\right] \\
&\textit{(根据琴生不等式)} \\
=\ & -\ln\exp\left(-\mathbb{E}\left[\left\langle \nabla \ell_s(\overrightarrow{W_s})+\nabla f_p(\overrightarrow{W_s}), \overrightarrow{W}-\overrightarrow{W_s}\right\rangle + \mathrm{e}^{6\|W-W_s\|_F^2}\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|^2_{\nabla^2\ell_s(W_s)}\right]\right) \\
=\ & \mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\left\langle \nabla \ell_s(\overrightarrow{W_s})+\nabla f_p(\overrightarrow{W_s}), \overrightarrow{W}-\overrightarrow{W_s}\right\rangle + \mathrm{e}^{6\|W-W_s\|_F^2}\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|^2_{\nabla^2\ell_s(W_s)}\right] \\
=\ & \mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\mathrm{e}^{6\|W-W_s\|_F^2}\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|^2_{\nabla^2\ell_s(W_s)}\right] \\
&\textit{(根据柯西施瓦兹不等式)} \\
=\ & \sqrt{\mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\mathrm{e}^{12\|W-W_s\|_F^2}\right]}\sqrt{\mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|^4_{\nabla^2\ell_s(W_s)}\right]}
\end{aligned}
$$

对于第一项 $\sqrt{\mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\mathrm{e}^{12\|W-W_s\|_F^2}\right]}$，令 $Z_{s-1}=U\Sigma U^\top$ 为矩阵 Z_{s-1} 的特征值分解. 因而我们定义新的服从高斯分布 $\mathcal{N}(0,I)$ 的随机变量 $X:=\sqrt{c\Sigma}U^\top(\overrightarrow{W}-\overrightarrow{W_s})$，并且

$$
\begin{aligned}
\sqrt{\mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\mathrm{e}^{12\|W-W_s\|_F^2}\right]} &= \sqrt{\mathbb{E}_X\left[\exp\left(12\left\|U(c\Sigma)^{-\frac{1}{2}}X\right\|_2^2\right)\right]} \\
&= \sqrt{\mathbb{E}_X\left[\exp\left(12\sum_{i=1}^{Kd}\frac{1}{c\lambda_i}X_i^2\right)\right]}
\end{aligned}
$$

(根据 $Z_{s-1}\succeq\lambda I$)

$$
\begin{aligned}
&= \mathbb{E}_X\left[\exp\left(\frac{12}{c\lambda}X_i^2\right)\right]^{Kd/2} \\
&\text{(根据琴生不等式)} \\
&\leqslant \mathbb{E}_X\left[\exp\left(\frac{6Kd}{c\lambda}X_i^2\right)\right]
\end{aligned}
$$

通过设定 $\frac{6Kd}{c\lambda} \leqslant \frac{1}{4}$，和 $\mathbb{E}_{X\sim\mathcal{X}^2}\left[\exp(X/4)\right] \leqslant \sqrt{2}$，我们有

$$
\sqrt{\mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\mathrm{e}^{12\|W-W_s\|_F^2}\right]} \leqslant \sqrt{2}. \tag{B-12}
$$

并且对于第二项 $\sqrt{\mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|_{\nabla^2\ell_s(W_s)}^4\right]}$，我们进行如上相似的论述，除了需要对 $\nabla^2\ell_s(W_s)^{-\frac{1}{2}}Z_{s-1}\nabla^2\ell_s(W_s)^{-\frac{1}{2}}$ 进行特征值分解，而不是对矩阵 Z_{s-1}. 因此随机变量 $X := \sqrt{c\Sigma}U^\top\nabla^2\ell_s(W_s)^{\frac{1}{2}}(\overrightarrow{W}-\overrightarrow{W_s})$ 服从分布 $\mathcal{N}(0,I)$，然后

$$
\begin{aligned}
\sqrt{\mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|_{\nabla^2\ell_s(W_s)}^4\right]} &= \sqrt{\mathbb{E}_X\left[\left\|U(c\Sigma)^{-\frac{1}{2}}X\right\|_2^4\right]} \\
&= \sqrt{\mathbb{E}_X\left[\left(\sum_{i=1}^{Kd}\frac{1}{c\lambda_i}X_i^2\right)^2\right]} \\
&= \sqrt{\mathbb{E}_X\left[\sum_{i,j}\frac{1}{c^2\lambda_i\lambda_j}X_i^2X_j^2\right]} \\
&= \frac{1}{c}\sqrt{\sum_{i,j}\frac{1}{\lambda_i\lambda_j}\mathbb{E}_X\left[X_i^2X_j^2\right]}
\end{aligned}
$$

根据 $\forall i,j.\ \mathbb{E}_{X_i,X_j\sim\mathcal{N}(0,1)}\left[X_i^2X_j^2\right] \leqslant 3$

$$
\begin{aligned}
&\sqrt{\mathbb{E}_{W\sim\mathcal{Q}_{s-1}}\left[\left\|\overrightarrow{W}-\overrightarrow{W_s}\right\|_{\nabla^2\ell_s(W_s)}^4\right]} \\
&\leqslant \frac{1}{c}\sqrt{\sum_{i,j}\frac{1}{\lambda_i\lambda_j}3} = \frac{\sqrt{3}}{c}\sum_{i=1}^{Kd}\frac{1}{\lambda_i} \\
&= \frac{\sqrt{3}}{c}\operatorname{tr}(\nabla^2\ell_s(W_s)^{\frac{1}{2}}Z_{s-1}^{-1}\nabla^2\ell_s(W_s)^{\frac{1}{2}}) \\
&= \frac{\sqrt{3}}{c}\operatorname{tr}(\nabla^2\ell_s(W_s)Z_{s-1}^{-1})
\end{aligned} \tag{B-13}
$$

结合不等式 (B-12) 和 (B-13)，等式 (B-11) 如下不大于

$$\sum_{s=1}^{t}\hat{\ell}_s(z_{s-1})-\ell_s(W_s)\leqslant\frac{\sqrt{6}}{c}\sum_{s=1}^{t}\mathrm{tr}(\nabla^2\ell_s(W_s)Z_{s-1}^{-1})+\frac{1}{2}\sum_{s=1}^{t}\left\|\overrightarrow{W}_{s-1}-\overrightarrow{W}_s\right\|_{cZ_{s-1}}^2.$$

然后根据引理 *B.5*，我们设置 $\lambda\geqslant 2LD^2$，然后第一项不大于

$$\frac{\sqrt{6}}{c}\sum_{s=1}^{t}\mathrm{tr}(\nabla^2\ell_s(W_s)Z_{s-1}^{-1})\leqslant\frac{\sqrt{6}}{c}\Delta_t^{\lambda}\left(Kd\ln\Delta_t^{\lambda/2}+m\ln(1+2\frac{D^2}{m\lambda}t)\right).$$

综上所述，记得 $\frac{6Kd}{c\lambda}\leqslant\frac{1}{4}$ 和 $\lambda\geqslant 2LD^2$，因此我们令 $c:=\frac{24Kd}{\lambda}$

$$\sum_{s=1}^{t}\hat{\ell}_s(z_{s-1})-\ell_s(W_s)\leqslant\frac{\sqrt{6}}{24Kd}\lambda\Delta_t^{\lambda}\left(Kd\ln\Delta_t^{\lambda/2}+m\ln(1+2\frac{D^2}{m\lambda}t)\right)+\frac{12Kd}{\lambda}\sum_{s=1}^{t}\left\|\overrightarrow{W}_{s-1}-\overrightarrow{W}_s\right\|_{Z_{s-1}}^2.$$

□

引理 B.4 (OMD 分析中的 Range 项和 Negative 项) 对于任意 $t>0$，我们有

$$\left\langle\nabla\tilde{\ell}_t(),\overrightarrow{W}_t-\overrightarrow{W}_\star\right\rangle\leqslant\frac{1}{2\eta}\left\|\overrightarrow{W}_\star-\overrightarrow{W}_{t-1}\right\|_{Z_{t-1}}^2-\frac{1}{2\eta}\left\|\overrightarrow{W}_\star-\overrightarrow{W}_t\right\|_{Z_{t-1}}^2-\frac{1}{2\eta}\left\|\overrightarrow{W}_{t-1}-\overrightarrow{W}_t\right\|_{Z_{t-1}}^2.$$

证明 根据 W_t 的定义，

$$W_t:=\operatorname*{argmin}_{W\in\mathcal{W}}\tilde{\ell}(W)+\frac{1}{2\eta}\left\|\overrightarrow{W}-\overrightarrow{W}_{t-1}\right\|_{Z_{t-1}}^2,$$

$\tilde{\ell}(W)=\left\langle\nabla\ell_t(\overrightarrow{W}_{t-1}),\overrightarrow{W}\right\rangle+\frac{1}{2}\left\|\overrightarrow{W}-\overrightarrow{W}_{t-1}\right\|_{\nabla^2\ell_t(W_{t-1})}^2$，我们有一阶最优条件

$$\left\langle\eta\nabla\tilde{\ell}(\overrightarrow{W}_t)+Z_{t-1}\left(\overrightarrow{W}_t-\overrightarrow{W}_{t-1}\right),\overrightarrow{W}_\star-\overrightarrow{W}_t\right\rangle\geqslant 0.$$

对上述不等式变形，我们有

$$\begin{aligned}\left\langle\eta\nabla\tilde{\ell}(\overrightarrow{W}_t),\overrightarrow{W}_t-\overrightarrow{W}_\star\right\rangle&\leqslant\left\langle Z_{t-1}\left(\overrightarrow{W}_t-\overrightarrow{W}_{t-1}\right),\overrightarrow{W}_\star-\overrightarrow{W}_t\right\rangle\\&=\frac{1}{2}\left\|\overrightarrow{W}_\star-\overrightarrow{W}_{t-1}\right\|_{Z_{t-1}}^2-\frac{1}{2}\left\|\overrightarrow{W}_\star-\overrightarrow{W}_t\right\|_{Z_{t-1}}^2-\frac{1}{2}\left\|\overrightarrow{W}_{t-1}-\overrightarrow{W}_t\right\|_{Z_{t-1}}^2\end{aligned}$$

完成证明. □

引理 B.5 如果 $\lambda \geqslant 2LD^2$，则对任意 $t > 0$，我们有

$$\sum_{s=1}^{t} \operatorname{tr}(\nabla^2 \ell_s(W_s) Z_{s-1}^{-1}) \leqslant \Delta_t^{\lambda} \left(Kd \ln \Delta_t^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda} t) \right).$$

证明 令矩阵 $\tilde{Z}_t$ 为矩阵 Z_t 的原矩阵，

$$\tilde{Z}_t = \lambda I + \sum_{s=1}^{t} \nabla^2 \ell_s(W_s).$$

并且令新矩阵 $M_t := \frac{\lambda}{2} I + \sum_{s=1}^{t} \nabla^2 \ell_s(W_s)$，而且根据 $\nabla^2 \ell_t(W_t) \preceq \frac{\lambda}{2} I$，我们有

$$\tilde{Z}_t = \frac{\lambda}{2} I + \sum_{s=1}^{t} \nabla^2 \ell_s(W_s) + \frac{\lambda}{2} I \succeq \frac{\lambda}{2} I + \sum_{s=1}^{t} \nabla^2 \ell_s(W_s) + \nabla^2 \ell_{t+1}(W_{t+1}) = M_{t+1}.$$

因此

$$\begin{aligned}
&\sum_{s=1}^{t} \operatorname{tr}(\nabla^2 \ell_s(W_s) Z_{s-1}^{-1}) \\
&\textit{(根据 FD 性质 A.3)} \\
\leqslant\ & \sum_{s=1}^{t} \Delta_s^{\lambda} \operatorname{tr}(\nabla^2 \ell_s(W_s) \tilde{Z}_{s-1}^{-1}) \\
\leqslant\ & \sum_{s=1}^{t} \Delta_s^{\lambda} \operatorname{tr}(\nabla^2 \ell_s(W_s) M_s^{-1}) \\
=\ & \sum_{s=1}^{t} \Delta_s^{\lambda} \operatorname{tr}((M_s - M_{s-1}) M_s^{-1}) \\
&\textit{(根据函数 } \ln|X| \textit{ 的凹性)} \\
\leqslant\ & \sum_{s=1}^{t} \Delta_s^{\lambda} \ln \frac{|M_s|}{|M_{s-1}|} \\
\leqslant\ & \Delta_t^{\lambda} \sum_{s=1}^{t} \ln \frac{|M_s|}{|M_{s-1}|}
\end{aligned}$$

$$= \Delta_t^\lambda \ln \frac{\left|M_t\right|}{\left|\frac{\lambda}{2} I\right|}$$

根据 *FD* 性质 *3.2*，我们有

$$\sum_{s=1}^{t} \operatorname{tr}(\nabla^2 \ell_s(W_s) Z_{s-1}^{-1}) \leqslant \Delta_t^\lambda \left(K d \ln \Delta_t^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda} t) \right).$$

□

引理 B.6 如果 $\lambda \geqslant 2LD^2$，则对任意 $t > 0$，我们有

$$\sum_{s=1}^{t} \operatorname{tr}((I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^\top) Z_{s-1}^{-1}) \leqslant \kappa \Delta_t^\lambda \left(K d \ln \Delta_t^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda} t) \right).$$

证明 令矩阵 $\tilde{Z}_t$ 为矩阵 Z_t 的原矩阵，

$$\tilde{Z}_t = \lambda I + \sum_{s=1}^{t} \nabla^2 \ell_s(W_s).$$

并且令新矩阵 $M_t := \frac{\lambda}{2} I + \frac{1}{\kappa} \sum_{s=1}^{t} I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^\top$，而根据 $\frac{1}{\kappa}(I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^\top) \preceq LD^2 I \preceq \frac{\lambda}{2} I$，我们有

$$\tilde{Z}_t = \frac{\lambda}{2} I + \sum_{s=1}^{t} \nabla^2 \ell_s(W_s) + \frac{\lambda}{2} I \succeq \frac{\lambda}{2} I + \sum_{s=1}^{t} \frac{1}{\kappa}(I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^\top) + \frac{1}{\kappa}(I \otimes \boldsymbol{x}_{t+1} \boldsymbol{x}_{t+1}^\top) = M_{t+1}.$$

因此

$$\begin{aligned}
&\sum_{s=1}^{t} \operatorname{tr}((I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^\top) Z_{s-1}^{-1}) \\
&\textit{(根据 FD 性质 A.3)} \\
\leqslant\ & \sum_{s=1}^{t} \Delta_s^\lambda \operatorname{tr}((I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^\top) \tilde{Z}_{s-1}^{-1}) \\
\leqslant\ & \sum_{s=1}^{t} \Delta_s^\lambda \kappa \operatorname{tr}(\frac{1}{\kappa}(I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^\top) M_s^{-1})
\end{aligned}$$

$$
\begin{aligned}
&= \kappa \sum_{s=1}^{t} \Delta_s^{\lambda} \operatorname{tr}((M_s - M_{s-1}) M_s^{-1}) \\
&\quad \textit{(根据函数 } \ln|X| \textit{ 的凹性)} \\
&\leqslant \kappa \sum_{s=1}^{t} \Delta_s^{\lambda} \ln \frac{|M_s|}{|M_{s-1}|} \\
&\leqslant \kappa \Delta_t^{\lambda} \sum_{s=1}^{t} \ln \frac{|M_s|}{|M_{s-1}|} \\
&= \kappa \Delta_t^{\lambda} \ln \frac{|M_t|}{\left|\frac{\lambda}{2} I\right|}
\end{aligned}
$$

最后根据 *FD* 性质 *3.2*，我们有

$$
\sum_{s=1}^{t} \operatorname{tr}(\nabla^2 \ell_s(W_s) Z_{s-1}^{-1}) \leqslant \kappa \Delta_t^{\lambda} \left(K d \ln \Delta_t^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda} t) \right).
$$

□

引理 B.7 如果 $\lambda \geqslant 2LD^2$，则对于任意 $t > 0$，我们有

$$
\sum_{s=1}^{t} \operatorname{tr}((I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^{\top}) Z_s^{-1}) \leqslant \kappa \Delta_t^{\lambda} \left(K d \ln \Delta_t^{\lambda/2} + m \ln(1 + 2\frac{D^2}{m\lambda} t) \right).
$$

证明 令矩阵 $\tilde{Z}_t$ 为矩阵 Z_t 的原矩阵，

$$
\tilde{Z}_t = \lambda I + \sum_{s=1}^{t} \nabla^2 \ell_s(W_s).
$$

因此

$$
\begin{aligned}
&\sum_{s=1}^{t} \operatorname{tr}((I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^{\top}) Z_s^{-1}) \\
&\quad \textit{(根据 FD 性质 A.3)} \\
&\leqslant \sum_{s=1}^{t} \Delta_s^{\lambda} \operatorname{tr}((I \otimes \boldsymbol{x}_s \boldsymbol{x}_s^{\top}) \tilde{Z}_s^{-1})
\end{aligned}
$$

$$
\begin{aligned}
&\leqslant \kappa \sum_{s=1}^{t} \Delta_s^{\lambda} \operatorname{tr}((\tilde{Z}_s - \tilde{Z}_{s-1})\tilde{Z}_s^{-1}) \\
&\quad \textit{(根据函数 } \ln|X| \textit{ 的凹性)} \\
&\leqslant \kappa \sum_{s=1}^{t} \Delta_s^{\lambda} \ln \frac{\left|\tilde{Z}_s\right|}{\left|\tilde{Z}_{s-1}\right|} \\
&\leqslant \kappa \Delta_t^{\lambda} \sum_{s=1}^{t} \ln \frac{\left|\tilde{Z}_s\right|}{\left|\tilde{Z}_{s-1}\right|} \\
&= \kappa \Delta_t^{\lambda} \ln \frac{\left|\tilde{Z}_t\right|}{|\lambda I|}
\end{aligned}
$$

最后根据 *FD* 性质 *3.2*，我们有

$$
\sum_{s=1}^{t} \operatorname{tr}(\nabla^2 \ell_s(W_s) Z_{s-1}^{-1}) \leqslant \kappa \Delta_t^{\lambda} \left(K d \ln \Delta_t^{\lambda} + m \ln(1 + \frac{D^2}{m\lambda} t) \right). \qquad \square
$$